

**UNIVERSIDAD NACIONAL AGRARIA  
LA MOLINA**

**ESCUELA DE POSGRADO  
DOCTORADO EN CIENCIA ANIMAL**



**“COMUNIDADES VEGETALES Y ESTIMACIÓN DE BIOMASA CON  
SENSORES MULTIESPECTRALES Y SISTEMAS AÉREOS NO  
TRIPULADOS EN PASTIZALES DE PUNA SECA”**

**Presentada por:**

**ANDRÉS CORSINO ESTRADA ZÚÑIGA**

**TESIS PARA OPTAR EL GRADO DE DOCTOR  
*DOCTORIS PHILOSOPHIAE* EN CIENCIA ANIMAL**

**Lima – Perú**

**2021**

**UNIVERSIDAD NACIONAL AGRARIA  
LA MOLINA**

**ESCUELA DE POSGRADO  
DOCTORADO EN CIENCIA ANIMAL**

**“COMUNIDADES VEGETALES Y ESTIMACIÓN DE BIOMASA CON  
SENSORES MULTIESPECTRALES Y SISTEMAS AÉREOS NO  
TRIPULADOS EN PASTIZALES DE PUNA SECA”**

**TESIS PARA OPTAR EL GRADO DE DOCTOR**

*Doctoris Philosophiae*

**Presentada por:**

**ANDRÉS CORSINO ESTRADA ZÚÑIGA**

**Sustentada y aprobada ante el siguiente jurado:**

Ph.D. María Helena Souza de Abreu  
**PRESIDENTE**

Ph.D. Javier Ñaupari Vásquez  
**ASESOR**

Ph.D. Enrique Flores Mariazza  
**CO-ASESOR**

Ph.D. Lucrecia Aguirre Terrazas  
**MIEMBRO**

Ph.D. Néstor Montalvo Arquiñigo  
**MIEMBRO**

Ph.D. Narcisa Gabriela Prícope  
**MIEMBRO EXTERNO**

**Dedicado a:**  
A mi familia

Por su amor, compañía, cariño y apoyo permanente

## **Agradecimiento**

Si tuviera que mencionar en detalle a todos los que me apoyaron en el logro de este objetivo, serían necesarias varias páginas. Sin embargo, quiero dejar constancia de mi agradecimiento a las siguientes instituciones y personas:

Al equipo docente del Programa de Doctorado en Ciencia Animal de la Universidad Agraria La Molina (UNALM).

Al laboratorio de evaluación y utilización de pastizales (LEUP) de la UNALM y al laboratorio de cambio climático de la UNSAAC.

Mi especial agradecimiento a mis asesores, Javier Ñaupari Vásquez Ph.D. y Enrique Flores Mariazza Ph.D., así como a los integrantes de mi jurado.

Agradecer también a mis compañeros del doctorado, en particular a Samuel Pizarro.

Finalmente, agradecer a los comuneros Juan Mamani, de Chalhuanca, y a Celso Ramos, de Quena, por permitirme acceder a sus tolares y bofedales durante los tres años que duró el estudio.

# ÍNDICE GENERAL

I.	INTRODUCCIÓN.....	1
II.	REVISIÓN DE LITERATURA.....	3
2.1	RADIACIÓN ELECTROMAGNÉTICA Y RESPUESTA DE LOS PASTIZALES .....	3
2.1.1	<i>Respuesta espectral de los diferentes objetos del pastizal.....</i>	5
2.1.1.1	Respuesta espectral de los pastos.....	5
2.1.1.2	Respuesta espectral del agua.....	7
2.1.1.3	Respuesta espectral del suelo.....	9
2.2	ÍNDICES DE VEGETACIÓN UTILIZADOS CON PERCEPCIÓN REMOTA.....	10
2.3	RELACIÓN DE LOS ÍNDICES DE VEGETACIÓN Y PRODUCCIÓN DE BIOMASA EN COMUNIDADES VEGETALES.....	14
2.3.1	<i>Comunidades vegetales de puna seca.....</i>	14
2.3.2	<i>Índices de vegetación y producción de biomasa.....</i>	15
2.4	PLATAFORMAS Y SENSORES REMOTOS .....	18
2.4.1	<i>Sensores remotos para el estudio de vegetación .....</i>	18
2.4.1.1	Resolución de un sistema sensor.....	19
2.4.1.2	Tipos de sensores .....	20
2.4.2	<i>Plataformas para el estudio de pastizales .....</i>	21
2.4.2.1	Plataformas fuera de la atmósfera.....	22
2.4.2.2	Plataformas dentro de la atmósfera: Sistemas de vehículos aéreos no tripulados .....	27
2.4.2.3	Componente de los sistemas de vehículos aéreos no tripulados (UAS) .....	28
2.4.2.4	Clasificación de los UAS y UAV .....	28
2.4.2.5	Utilización de la plataforma UAS en el estudio de recursos naturales y pastizales .....	34
2.5	ALTURA DE VUELO Y CALIDAD DE IMAGEN ADQUIRIDA CON SENSORES REMOTOS 35	
2.6	ESCALAMIENTO DE ORTOMOSAICOS OBTENIDOS CON IMÁGENES ADQUIRIDAS POR UAV A UNA IMAGEN SATELITAL .....	39
III.	MATERIALES Y MÉTODOS.....	42
3.1	UBICACIÓN DEL ÁMBITO DE ESTUDIO.....	42
3.2	PROCESO METODOLÓGICO DE LA INVESTIGACIÓN .....	44
3.2.1	<i>Proceso metodológico para determinar la altura de vuelo del UAV para la detección e identificación de comunidades vegetales tolar y bofedal .....</i>	44
3.2.1.1	Fase de preparación y campo .....	45
3.2.1.2	Fase de gabinete .....	50
3.2.2	<i>Proceso metodológico para estimar la producción de biomasa de comunidades vegetales tolar y bofedal a partir de signos espectrales e índices de vegetación .....</i>	54

3.2.2.1	Fase de campo.....	54
3.2.2.2	Fase de gabinete.....	59
3.2.3	<i>Proceso metodológico para validar el escalamiento de ortomosaicos obtenidos con el UAS hacia una imagen satelital Rapideye .....</i>	65
<b>IV.</b>	<b>RESULTADOS Y DISCUSIÓN .....</b>	<b>69</b>
4.1	ALTURA DE VUELO DE SISTEMAS AÉREOS NO TRIPULADOS (UAS) PARA IDENTIFICACIÓN DE COMUNIDADES VEGETALES TOLARES Y BOFEDALES .....	69
4.1.1	<i>Identificación de la mejor altura de vuelo para la comunidad vegetal bofedal.....</i>	69
4.1.1.1	Altura de vuelo para identificar la comunidad vegetal bofedal utilizando ortografías RGB.....	69
4.1.1.2	Altura de vuelo para identificar la comunidad vegetal bofedal utilizando ortografías NDVI.....	71
4.1.2	<i>Determinación de la mejor altura de vuelo para la comunidad vegetal tolar de puna seca .....</i>	75
4.1.2.1	Altura de vuelo para identificar la comunidad vegetal tolar, utilizando ortofotografías RGB.....	75
4.1.2.1	Altura de vuelo para identificar la comunidad vegetal tolar, utilizando ortofotografías NDVI .....	77
4.2.	ESTIMACIÓN DE BIOMASA A PARTIR DE SIGNOS ESPECTRALES EN ORTOFOTOGRAFÍAS MULTIESPECTRALES .....	82
4.2.1	<i>Estimación de biomasa en la comunidad vegetal bofedal a partir de signos espectrales e índices de vegetación.....</i>	82
4.2.1.1	Índices de vegetación de la comunidad vegetal bofedal a partir de imágenes multiespectrales.....	82
4.2.1.2	Predicción de biomasa aérea de la comunidad vegetal bofedal de puna seca en base a índices de vegetación (evaluación de modelos, asociación de variables y predicción) .....	83
4.2.1.3	Elaboración de mapas de producción de biomasa de la comunidad vegetal bofedal del fundo San Vicente de Palcca, Chalhuanca.....	91
4.2.2	<i>Estimación de biomasa en la comunidad vegetal tolar de puna seca .....</i>	98
4.2.2.1	Índices de vegetación estimados para la comunidad vegetal tolar de puna seca .....	98
4.2.2.2	Predicción de biomasa aérea de la comunidad vegetal tolar de puna seca en base a índices de vegetación (evaluación de modelos, asociación de variables y predicción) .....	100
4.2.2.3	Elaboración de mapas de producción de biomasa de la comunidad vegetal tolar del fundo Quena Callalli .....	109
4.3.	ESCALAMIENTO DE ORTOMOSAICOS OBTENIDOS CON PLATAFORMA UAS, HACIA UNA IMAGEN SATELITAL RAPIDEYE .....	118
4.3.1	<i>Índices de vegetación de las comunidades vegetales de puna seca en imágenes Rapideye.....</i>	118
4.3.2	<i>Variables para la predicción de biomasa aérea de las comunidades de puna seca en base índices de vegetación .....</i>	121
4.3.3	<i>Predicción de biomasa de las comunidades vegetales bofedal y tolar con imágenes Rapideye + ortofotografías UAS .....</i>	124
4.3.4	<i>Elaboración de mapas de producción de biomasa de las comunidades vegetales tolar y bofedal de puna seca .....</i>	126
<b>V.</b>	<b>CONCLUSIONES.....</b>	<b>136</b>

<b>VI. RECOMENDACIONES .....</b>	<b>137</b>
<b>VII. REFERENCIAS BIBLIOGRÁFICAS.....</b>	<b>138</b>
<b>VIII. ANEXOS.....</b>	<b>151</b>
8.1 ANEXOS DEL PROCESO METODOLÓGICO .....	151
8.2 ANEXOS DEL OBJETIVO ALTURA DE VUELO DE SISTEMAS AÉREOS NO TRIPULADOS (UAS) .....	162
8.3 ANEXOS DEL OBJETIVO ESTIMACIÓN DE BIOMASA A PARTIR DE SIGNOS ESPECTRALES EN ORTOFOTOGRAFÍAS MULTIESPECTRALES .....	167
8.4 ANEXOS ESCALAMIENTO DE ORTOMOSAICOS OBTENIDOS CON PLATAFORMA UAS HACIA UNA IMAGEN SATELITAL RAPIDEYE .....	173

## ÍNDICE DE TABLAS

Tabla 1: Longitud de onda y zona de espectro.....	5
Tabla 2: Índices de vegetación.....	11
Tabla 3: Plataformas, satélites y sensores fuera de la atmósfera terrestre utilizados para estudios de vegetación .....	26
Tabla 4: Clasificación de los UAV por sus características .....	31
Tabla 5: Clasificación de los UAV por sus capacidades de vuelo.....	32
Tabla 6: Clasificación por tamaño y peso del UAV .....	33
Tabla 7: Composición florística del bofedal de Chalhuanca .....	47
Tabla 8: Composición florística de la comunidad vegetal bofedal -fundo Quena- .....	47
Tabla 9: Vuelos realizados por el DRONE .....	58
Tabla 10: Identificación de especie segmentada (arbusto de tola) a diferentes alturas de vuelo, imagen RGB.....	70
Tabla 11: Identificación de especie segmentada (arbusto de tola) a diferentes alturas de vuelo, imagen RGB.....	75
Tabla 12: Índices de vegetación comunidad vegetal bofedal .....	83
Tabla 13: Evaluación de modelos para predicción de biomasa .....	85
Tabla 14: Evaluación de los modelos para predicción de biomasa.....	90
Tabla 15: Estimación de cobertura vegetal por clase.....	91
Tabla 16: Estimación de biomasa modelo Random Forest datos de campo de la comunidad vegetal bofedal.....	94
Tabla 17: Índices de vegetación.....	98
Tabla 18: Evaluación de modelos para predicción de biomasa .....	100
Tabla 19: Evaluación de los modelos para predicción de biomasa.....	107
Tabla 20: Estimación de biomasa con Randon Forest y datos de campo .....	112
Tabla 21: Precisión y concordancia de los modelos validados con imágenes escaladas UAS + <i>Rapideye</i> .....	121
Tabla 22: Comparación de estimación de biomasa UAS - <i>Rapideye</i> de la comunidad vegetal bofedal de puna seca .....	130
Tabla 23: Comparación de estimación de biomasa plataforma UAS e imágenes <i>Rapideye</i> , comunidad vegetal tolar de puna seca.....	133

## ÍNDICE DE FIGURAS

Figura 1: Espectro electromagnético.....	4
Figura 2: Firmas espectrales .....	6
Figura 3: Reflectancia espectral en diferentes tipos de vegetación verde, comparada con hojas senescentes (verde – amarillo) .....	6
Figura 4: Respuesta espectral del agua y la nieve.....	8
Figura 5: Respuesta espectral del suelo .....	9
Figura 6: Plataformas y sensores remotos.....	22
Figura 7: Componentes de la UAS _ vuelo y tierra .....	28
Figura 8: UAV de ala fija y rotativa .....	30
Figura 9: Zona de estudio.....	43
Figura 10: Proceso metodológico para determinar la altura de vuelo.....	44
Figura 11: Plataformas UAS DJI utilizado para determinar altura de vuelo .....	45
Figura 12: Planes de vuelo 2D y 3D .....	49
Figura 13: Puntos de control en tierra.....	49
Figura 14: Proceso metodológico para estimar biomasa a partir de signos espectrales .....	54
Figura 15: Plataformas UAS utilizados en el estudio .....	56
Figura 16: Puntos de control en tierra y transectas para muestreo de biomasa .....	57
Figura 17: Secuencia para procesar imágenes .....	61
Figura 18: Diseño metodológico para escalar ortofotografías multiespectrales a imágenes satelitales .....	65
Figura 19: Imágenes Rapideye.....	66
Figura 20: Ortofotografías multiespectrales .....	67
Figura 21: Comunidad vegetal bofedal adquiridas a diferentes alturas de vuelo con sensor RGB ...	69
Figura 22: Altura de vuelo para identificación de comunidad vegetal bofedal .....	71
Figura 23: identificación de cojines de <i>Distichia</i> a través de rangos NDVI.....	72
Figura 24: Rango de índices NDVI para evaluación de comunidad vegetal bofedal .....	73
Figura 25: Imágenes NDVI y lecturas con algoritmo .....	73
Figura 26: Mejor altura de vuelo NDVI.....	74
Figura 27: Fotografías de comunidad vegetal tolar .....	76
Figura 28: Determinación de mejor altura de vuelo en imágenes RGB .....	77
Figura 29: Determinación del mejor rango de NDVI para identificación de la tola.....	78

Figura 30: Determinación del mejor rango para identificar la especie segmentada de la comunidad vegetal tolar.....	79
Figura 31: Conteo del arbusto tola en imagen NDVI, rango 0.20-0.45 a diferentes alturas de vuelo	79
Figura 32: Mejor altura de vuelo NDVI _ Rango 0.2 a 0.45 _ 25 m de altura .....	80
Figura 33: Índices de vegetación de la comunidad vegetal bofedal .....	84
Figura 34: Priorización de variables para estimar biomasa en bofedales (MDG) .....	86
Figura 35: Grados de asociación entre biomasa con datos de campo e índices de vegetación.....	87
Figura 36: Predicción de biomasa para final de época de lluvia (g/pixel). RF .....	88
Figura 37: Predicción de biomasa para final de época seca (g/pixel). RF .....	89
Figura 38: Comparación y predicción de biomasa en RF y observado en campo .....	90
Figura 39: Coberturas de la comunidad vegetal bofedal.....	92
Figura 40: Estimación de producción biomasa (MV) del bofedal en campo, con el modelo Random Forest.....	93
Figura 41: Estimación de producción biomasa bofedal (MS) en campo y con el modelo Random Forest.....	95
Figura 42: Índices de vegetación en época seca y época de lluvia .....	99
Figura 43: Priorización de variables por importancia - índice decreciente de Gini.....	102
Figura 44: Asociación de variables para predicción de biomasa .....	103
Figura 45: Estimación de biomasa con modelo RF para cobertura césped de puna .....	105
Figura 46: Estimación de biomasa con modelo RF para cobertura tolar .....	106
Figura 47: Comparación entre predicción RF y observado en campo .....	108
Figura 48: Estimación de cobertura vegetal.....	109
Figura 49: Clasificación de coberturas comunidad vegetal tolar de puna seca .....	110
Figura 50: Estimación de producción de biomasa para la comunidad vegetal tolar materia verde .	111
Figura 51: Estimación de producción de biomasa para la comunidad vegetal tolar con materia seca .....	113
Figura 52: Índices de vegetación de imagen <i>Rapideye</i> (2018) final de la época de estiaje, mes de octubre.....	119
Figura 53: Índices de vegetación (UAV + <i>Rapideye</i> ) .....	120
Figura 54: Priorización de variables por importancia - índice decreciente de Gini.....	122
Figura 55: Asociación de variables entre ortofotografías (UAS) e imágenes <i>Rapideye</i> .....	123
Figura 56: Predicción de biomasa comunidad vegetal bofedal _ imagen <i>Rapideye</i> + ortofotografía UAS.....	124
Figura 57: Predicción de biomasa componente césped _ imagen <i>Rapideye</i> + ortofotografía UAS	125

Figura 58: Predicción de biomasa componente tola - imagen <i>Rapideye</i> + ortofotografías UAS ....	125
Figura 59: Mapa de coberturas, imágenes <i>Rapideye</i> + ortofotografías UAS .....	127
Figura 60: Mapa de coberturas imágenes <i>Rapideye</i> + UAS escaladas .....	128
Figura 61: Cobertura vegetal de la comunidad vegetal bofedal con imágenes <i>Rapideye</i> + UAS....	129
Figura 62: Coberturas comunidad vegetal tolar -imágenes <i>Rapideye</i> escalada.....	132

## ÍNDICE DE ANEXOS

Anexo 1: Proceso de generación ortofotografías (PIX 4D y Agisoft) .....	151
Anexo 2: Algoritmo para contabilizar especie segmentada.....	153
Anexo 3: Algoritmo para estimar biomasa a partir de signos espectrales de ortofotografías multiespectrales.....	156
Anexo 4: Imágenes para escalamiento.....	160
Anexo 5: Comunidad vegetal Bofedal _ Evaluación de rangos NDVI para identificación de los cojines de DIMU época seca (2017).....	162
Anexo 6: Comunidad vegetal BOFEDAL _ Evaluación de altura de vuelo con imágenes NDVI para identificación de los cojines de DIMU época seca (2017).....	162
Anexo 7: Comunidad vegetal Bofedal_ evaluación de rangos NDVI para identificación de los cojines de DIMU época lluvia (2017).....	163
Anexo 8: Comunidad vegetal Bofedal _ Evaluación de altura de vuelo con imágenes RGB identificación de los cojines de DIMU época de lluvia .....	163
Anexo 9: Comunidad vegetal Bofedal _ Evaluación de altura de vuelo con imágenes RGB identificación de los cojines de DIMU época seca .....	164
Anexo 10: Comunidad vegetal Tolar _ Evaluación de altura de vuelo con imágenes RGB para identificación del arbusto Tola época lluvia (2017).....	164
Anexo 11: Comunidad vegetal Tolar _ Evaluación de altura de vuelo con imágenes RGB para identificación del arbusto Tola época seca (2017).....	165
Anexo 12: Comunidad vegetal Tolar _ Evaluación de rangos NDVI para identificación del arbusto Tola época lluvia (2017) .....	165
Anexo 13: Comunidad vegetal Tolar _ Evaluación de rangos NDVI para identificación del arbusto Tola época seca (2017) .....	166
Anexo 14: Comunidad vegetal Tolar _ Evaluación de altura de vuelo con imágenes NDVI para identificación del arbusto Tola.....	166
Anexo 15: Priorización de variables por importancia _ índice decreciente de Gini Comunidad vegetal Bofedal .....	167
Anexo 16: Estimación de rendimiento de biomasa Kg/ha. datos de campo Comunidad vegetal Bofedal.....	168
Anexo 17: Comparación de rendimiento de biomasa Kg/ha. Entre modelo RF y datos de campo comunidad vegetal Bofedal.....	168

Anexo 18: Diferencias en la estimación de biomasa entre RF y datos de campo comunidad vegetal Bofedal.....	168
Anexo 19: Priorización de variables por importancia _ índice decreciente de Gini Césped de puna .....	169
Anexo 20: Priorización de variables por importancia _ índice decreciente de Gini Tola .....	170
Anexo 21: Clasificación de coberturas _ ortofotografías UAS. Comunidad vegetal Tolar.....	170
Anexo 22: Estimación biomasa comunidad vegetal Tolar_ modelo Randon Forest Comunidad Vegetal Tolar.....	171
Anexo 23: Estimación de biomasa con datos de campo Comunidad vegetal Tolar .....	171
Anexo 24: Comparación de producción biomasa predicho Randon Forest &. observación en campo Comunidad vegetal Tolar.....	171
Anexo 25: Diferencias de la producción de biomasa Randon Forest & observación en campo comunidad vegetal Tolar.....	172
Anexo 26: Valores NDVI en imagen Rapideye.....	173
Anexo 27: Clasificación de área ocupada por clase _imagen Rapideye.....	174

## RESUMEN

La teledetección y los sistemas de información geográfica son herramientas que, en la última década, se utilizan para la gestión de recursos naturales. Sin embargo, las imágenes satelitales como *Landsat* han presentado limitaciones en la resolución espacial, espectral y temporal para el campo de la agricultura y la ganadería de precisión. Frente a ello, aparecen como alternativa los microsensores adheridos a sistemas aéreos no tripulados (UAS). Así, el objetivo del estudio fue identificar y estimar la biomasa de las comunidades vegetales de tolar y bofedales de puna seca a través de sensores multiespectrales incorporados en los UAS. Para determinar la altura de vuelo, se recopilaron imágenes de las comunidades vegetales con sensores multiespectrales a 25, 50, 75 y 100 m de altura. Paralelamente, se recolectaron muestras de vegetación en las transectas fijas que formaban parte de los puntos de control en tierra. Las imágenes adquiridas fueron procesadas en *Pix 4D* y *Agisoft*, logrando ortofotografías RGB y NDVI de alta resolución. Para la etapa de escalamiento hacia la imagen satelital, se adquirieron imágenes *Rapideye*. El estudio determinó que la mejor altura de vuelo para identificar la comunidad vegetal tolar de puna seca y la especie segmentada, el arbusto de tola, es de 25 metros, mientras que para los cojines de DIMU de los bofedales es de 25 a 50 metros, precisando que la observación de las especies segmentadas de tola y DIMU a 75 y 100 metros de altura es difusa. Por otra parte, el modelo *Random Forest*, con una precisión de entrenamiento y prueba de 0.94, un coeficiente Kappa de 0.9071 y  $R^2 = 0.482$ , predijo en promedio 3 g/pixel y 2 g/pixel de MV de césped para las épocas de lluvia y seca. La biomasa predicha para el componente tola fue de 15 g/pixel de MV para ambas épocas del año. Este mismo modelo, con precisión de entrenamiento y prueba de 0.8206, un coeficiente Kappa de 0.833 y  $R^2 = 0.479$ , predijo un promedio de 2.5 g/pixel y 2 g/pixel de MV del componente DIMU para las épocas de lluvia y seca. El proceso de escalamiento se realizó con un nivel de asociación ( $p=0.61$  y  $p=0.96$ ) entre ortofotografía e imágenes *Rapideye*, con un nivel de precisión de 0.8253 de entrenamiento y 0.8306 de prueba, un índice Kappa de 0.8091 y  $R^2 = 46.20$ . La predicción de biomasa con las imágenes escaladas comparadas con la predicción realizada para ortofotografías, presentó una diferencia que va desde 49% a 115.57%, por ello, es necesario seguir investigando algoritmos y ecuaciones que disminuyan la diferencia encontrada.

**Palabras Clave:** Biomasa, índice de vegetación, Drone, comunidad vegetal, Tolar, Bofedal.

## ABSTRACT

Remote sensing and geographic information systems are tools that have been used in the management of natural resources in the last decade. However, long-standing satellite images such as Landsat have presented limitations in spatial, spectral and temporal resolutions to develop precision agriculture and livestock. Faced with this, microsensors attached to unmanned aerial systems (UAS) appear as an alternative. The objective of the study was to identify plant communities and biomass estimation with multispectral sensors in UAS in plant communities of tolar and bofedal of Puna Seca. To determine the flight height and the study, images were collected with multispectral sensors at 25, 50.75 and 100 m flight height, at the same time that vegetation samples were collected in the fixed transects that were part of the control points. on land. The acquired images were processed in Pix 4D and Agisoft achieving high resolution RGB, NDVI orthophotos, which were used by the algorithms prepared for processing. Rapideye images Platform for the scaling to satellite image stage. The study has determined that the best flight height to identify the dry puna Tolar plant community and the segmented Tola shrub species is 25 meters, while for DIMU cushions it is 25 to 50 meters, observing the Tola and DIMU segmented species at 75 and 100 meters is diffuse. The Random Forest model with a training and test precision of 0.94, Kappa coefficient of 0.9071 and R<sup>2</sup> = 0.482 predicted on average 3 g / pixel and 2 g / pixel of MV. of Lawn for rainy and dry season, the predicted biomass for the Tola component was 15 g / pixel of MV for both seasons. This same model with training and test precision of 0.8206, Kappa coefficient of 0.833 and R<sup>2</sup> = 0.479 predicted an average of 2.5 g / pixel and 2 to g / pixel MV. DIMU for rainy and dry season. The scaling process was performed with an association level ( $p = 0.61$  and  $p = 0.96$ ) between orthophotography and Rapideye images, precision level 0.8253 training and 0.8306 test, Kappa index of 0.8091 and R<sup>2</sup> = 46.20, the prediction of biomass with the Scaled images compared to the enhanced prediction for orthophotographs presented a difference that goes from 49% to 115.57%, therefore it is necessary to continue investigating algorithms and equations that decrease the difference found.

**Keyword:** Biomass, vegetation Index, Drone Plant Community, Tolar, Bofedal.

## I. INTRODUCCIÓN

El Perú, por la presencia de la cordillera de los Andes, presenta una diversidad de zonas de vida con características ecoclimáticas muy particulares (Pulgar 1996 y Holdridge 1987). En los Andes del sur del Perú, nace la franja de la puna seca, que se extiende desde los 15° latitud sur y comprende desde las tierras altas del departamento de Arequipa hasta Tucumán en Argentina, a 30° latitud sur (Troll 1968, Tapia y Flores 1984).

En esta zona de producción homogénea se encuentran comunidades vegetales de tola (*Parastrephia quadrangulare*), bofedales, pajonales y césped de puna (Berrio y Estrada 1994), que representan el 42% de los aproximadamente 22 millones de hectáreas de pastos naturales reportados para la sierra peruana (Flores *et al.* 2014).

En la actualidad, los estudios de productividad primaria y de producción de biomasa en pastizales utilizan métodos destructivos, que consisten en cortes sucesivos de la parte aérea de la planta. Este sistema presenta algunas desventajas, como alta demanda de tiempo y personal, altos costos de logística y la dificultad para estimar la variabilidad espacial y temporal de las especies vegetales. Frente a ello, el uso de imágenes satelitales y los sistemas de información geográfica (SIG) aparecen como una alternativa práctica y viable (Byrne 2010).

La teledetección y los SIG son utilizados cada vez más para la gestión de los recursos naturales y la agricultura, sin embargo, las imágenes satelitales disponibles tienen limitaciones de resolución espacial, espectral y temporal. Por ello, la incorporación de los sistemas aéreos no tripulados (UAS = *Unmanned Aerial System*) y los microsensores, han posibilitado una nueva posibilidad de teledetección de alta resolución, superando algunas limitaciones presentadas por las imágenes satelitales (D’Oleira *et al.* 2012).

Los sensores multiespectrales transportados por UAS pueden estimar la radiación fotosintéticamente activa y el grado de verdor de la vegetación. Sin embargo, la capacidad de estimar la productividad neta y la producción de biomasa aún es limitada por falta de modelos adecuados (Ceroni *et al.* 2015). A pesar de este potencial demostrado en el estudio de las

comunidades vegetales y la agricultura, aún no se convierten en una alternativa metodológica para clasificar y evaluar los pastizales, especialmente en el territorio andino (Segura *et al.* 2008 y D’Oleira *et al.* 2012).

El objetivo general de la investigación es diseñar una metodología de identificación y estimación de biomasa para comunidades vegetales de puna seca, mediante sensores multiespectrales transportados por sistemas aéreos no tripulados (UAS). Los objetivos específicos son: (i) Determinar la altura de vuelo del UAS para la detección e identificación de comunidades vegetales de tola y de bofedal; (ii) Estimar la producción de biomasa de comunidades vegetales de tola y bofedal a partir de signos espectrales e índices de vegetación y (iii) Validar el escalamiento de ortomosaicos obtenidos con el UAS hacia una imagen satelital.

## II. REVISIÓN DE LITERATURA

### 2.1 RADIACIÓN ELECTROMAGNÉTICA Y RESPUESTA DE LOS PASTIZALES

La teledetección, aplicada a los estudios de comunidades vegetales, identifica objetos (pastizal) situados sobre la superficie terrestre. Para que la observación sea posible, es necesario que exista interacción entre el objeto (pastizal, arbustos, suelo y agua) y el sensor, siendo esta interacción un flujo de radiación que parte de los objetos y es captado por un sensor. Hay tres tipos de radiación (Chuvieco 2008, Jones y Vaughan 2010):

- ❖ Radiación solar reflejada por los objetos (Luz visible e infrarrojo reflejado).
- ❖ Radiación terrestre emitida por los objetos (Infrarrojo térmico).
- ❖ Radiación emitida por el sensor y reflejada por los objetos (Radar).

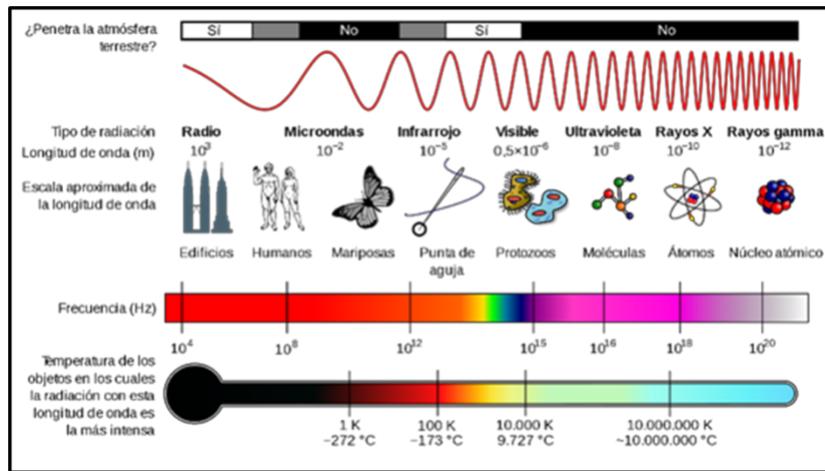
De acuerdo al tipo de radiación utilizada, la teledetección se clasifica en dos: *Teledetección pasiva*, que tiene como base el uso de la radiación solar, que es reflejada por los pastos, el agua de la superficie de la Tierra (luz visible, infrarrojo cercano e infrarrojo térmico) que utilizaremos en el presente estudio. Y la *teledetección activa*, que utiliza la radiación emitida por un radar (Iglesias 2003, Horning *et al.* 2010 y Raymond 2015).

La radiación electromagnética se propaga mediante ondas que viajan por el espacio a una velocidad de la luz (299,792 Km/s), la energía es transportada en cantidades discretas de energía denominadas *cuantos* (Jones y Vaughan 2010).

Las ondas presentan longitudes muy diferentes, desde los rayos gama y X, con longitudes de onda menores de 100 angstrom, hasta las ondas de radio y televisión con longitudes de onda mayores de un metro (Soria y Matar 2016).

El conjunto de todas las longitudes de onda se denomina espectro electromagnético, diferenciándose las regiones en función de la longitud de onda. Las regiones más utilizadas en

la teledetección son: la luz visible, el infrarrojo reflejado, el infrarrojo térmico y el radar (Esser 2010) (Figura 1).



**Figura 1: Espectro electromagnético**

(Incluye longitud de onda, frecuencia y temperatura)

Fuente: Soria y Matar (2016)

La distribución de longitudes de onda tiene una forma acampanada, con pendiente mayor en las longitudes de onda bajas que en las de onda altas, y un pico máximo en una longitud de onda que puede calcularse en grados Kelvin (°K) (Chuvieco 2008 y Rueda *et al.* 2015). Considerando que la temperatura del Sol es de aproximadamente 6000 °K y de la Tierra es de 300 °K, entonces la radiación solar va a ser la mayor para una longitud de onda de 0.48 μm (región visible) y la temperatura terrestre va a ser la más alta una longitud de onda de 9.66 μm (infrarrojo térmico) (Figura 1).

La radiación infrarroja es un tipo de radiación electromagnética y térmica, de mayor longitud de onda, en consecuencia, tiene menor frecuencia que la luz visible y mayor que las microondas. El rango de longitud de onda va desde unos 0.70 μm hasta 10.00 μm. La radiación infrarroja es emitida por cualquier cuerpo cuya temperatura sea mayor que 0 °K, es decir -273 °C o cero absolutos (Elisalde 2002).

Los estudios de pastizales basados en los índices de vegetación utilizan espectros de luz que se encuentran en la región longitudinal de la onda de espectros visibles compuestos por las

regiones azul, verde y roja. Además de las regiones del infrarrojo cercano y medio (Tucker 1979) (Tabla 1).

**Tabla 1: Longitud de onda y zona de espectro**

LONGITUD DE ONDA	ZONA DE ESPECTRO
0.45 – 0.52 $\mu\text{m}$	Azul Luz visible
0.52 – 0.60 $\mu\text{m}$	Verde Luz visible
0.63 – 0.69 $\mu\text{m}$	Rojo Luz visible
0.76 – 1.25 $\mu\text{m}$	Infrarrojo cercano
1.55 – 1.75 $\mu\text{m}$	Infrarrojo medio
2.08 – 2,35 $\mu\text{m}$	Infrarrojo medio
10.4 – 12.5 $\mu\text{m}$	Infrarrojo térmico

FUENTE: Elaboración propia

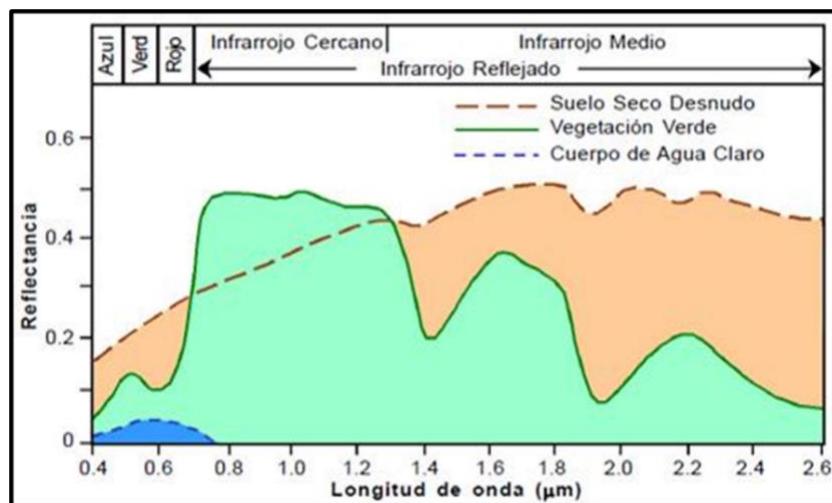
### **2.1.1 Respuesta espectral de los diferentes objetos del pastizal**

Para la identificación de objetos y procesos en la superficie del pastizal para el estudio comunidades vegetales tolal y bofedal, se debe conocer la reflectividad del suelo, vegetación y agua, respecto a las diferentes longitudes de onda (Escobar 2015).

Cada longitud de onda que da la reflectividad en porcentaje, se conoce como “firma espectral” y constituye una marca de filiación de los objetos. Ello facilita y hace posible distinguir entre suelo, agua y vegetación, e incluso entre diferentes tipos de suelo y vegetación (Watanave 2012) (Figura 2).

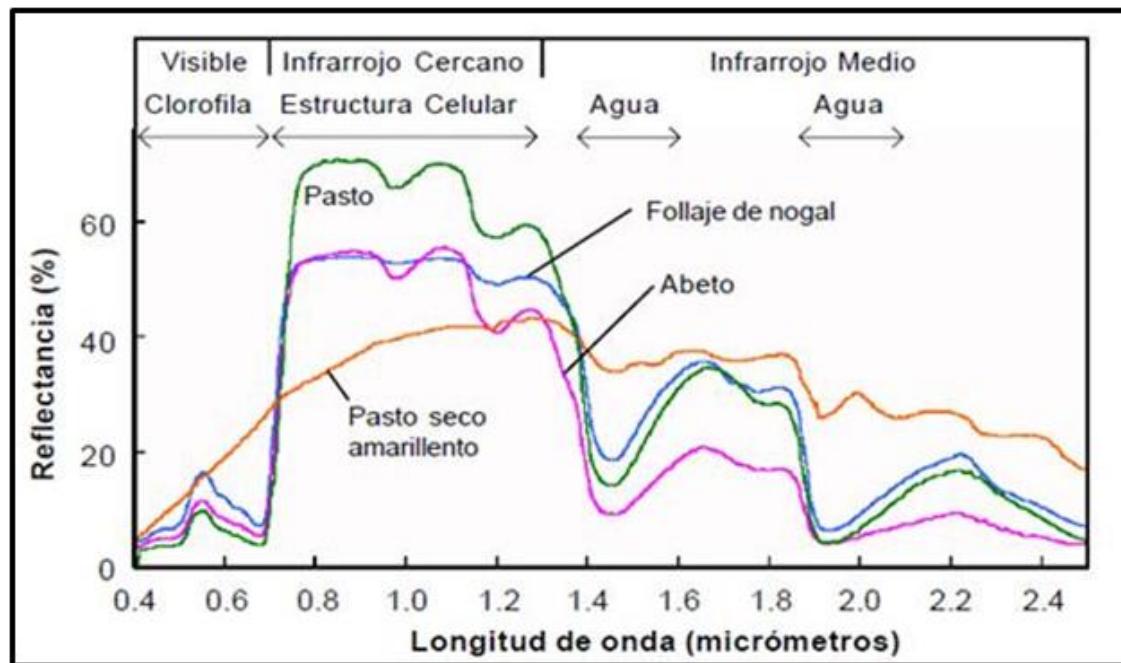
#### **2.1.1.1 Respuesta espectral de los pastos**

Los pastizales sanos tienen una reflectividad baja en el espectro visible, aunque con un incremento de pico en el color verde debido a los pigmentos de clorofila. La clorofila aparece en concentraciones entre 5 y 10 veces mayores que otros pigmentos como el caroteno (Massa y Duarte 2016).



**Figura 2: Firmas espectrales**

Fuente: Watanave (2012)



**Figura 3: Reflectancia espectral en diferentes tipos de vegetación verde, comparada con hojas senescentes (verde – amarillo)**

Fuente: Watanave (2012)

La reflectividad es muy alta en el infrarrojo cercano, debido a la escasa absorción de este espectro por las plantas. En el infrarrojo medio hay una disminución en la absorción en las longitudes de onda donde el agua de la planta absorbe la energía (Espinosa *et al.* 2016 y Segura *et al.* 2008) (Figura 3).

En la época de estiaje, las hojas de los pastizales de la comunidad vegetal tololar y bofedal pierden los cloroplastos (órganos que contienen la clorofila) porque dejan de ser necesarios, por tanto, Estas plantas presentan un color pardo-amarillento debido a la mayor importancia del caroteno y otros pigmentos (Vila *et al.* 2007) (Figura 3).

La curva se debilita en la vegetación enferma disminuyendo el infrarrojo y aumentando la reflectividad en el rojo y azul. La reflectividad del pasto va a depender de su contenido en agua. Cuando el contenido de agua aumenta se incrementa la absorción de la radiación por parte de la planta y disminuye la reflectividad.

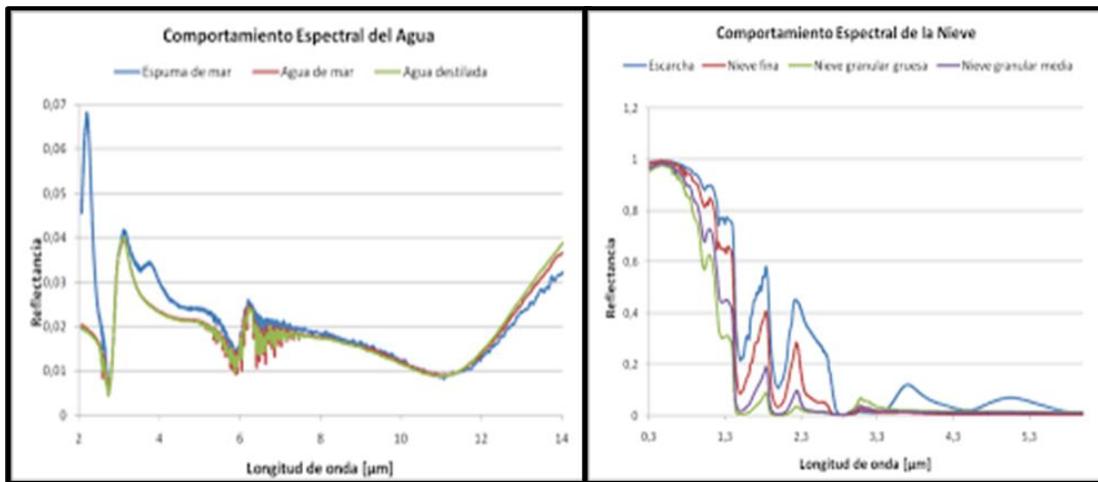
La cantidad de energía de los fotones de ondas mayores (infrarrojo cercano) es muy baja para ser utilizada por la vegetación, por lo que apenas se absorbe el 5 % y el resto se transmite o refleja. Este proceso reiterado en capas diferentes, aumenta el porcentaje de energía reflejada por una comunidad vegetal (Zerda y Tiedemann 2010).

El envejecimiento de las plantas que componen el pastizal muestra una reducción en la reflectividad en el infrarrojo, generado por las variaciones en la estructura interna de las hojas son los que generan los patrones de respuesta espectral diferentes para cada una de las especies. El agua presente en los tejidos vegetales contribuye a la absorción del infrarrojo medio en las diferentes longitudes de onda, cuanto menor sea el contenido de agua en el pasto, mayor será su reflectividad en el infrarrojo medio (Elisalde 2002).

### **2.1.1.2 Respuesta espectral del agua**

El agua es el único elemento capaz de difundir la radiación hacia abajo por tener reflectividad muy baja, aunque que ésta sea dependiente de la longitud de onda. El agua absorbe la mayoría de la radiación en las bandas del infrarrojo próximo medio (Corrales 2016). La reflectividad

aumenta en el espectro visible, en particular en las bandas azul y verde, ello se observa con mayor nitidez en los bofedales. La turbidez del agua incrementa la reflectividad en el verde y en el infrarrojo, observándose que el proceso de eutrofización aumenta su reflectividad en el verde (Figura 4).



**Figura 4: Respuesta espectral del agua y la nieve**

Fuente: Watanave (2012)

El agua clara tiene buenas propiedades de traslado de la radiación electromagnética en el espectro visible y de asimilación en el infrarrojo. La reflectividad, aparece en el verde que va reduciéndose hasta el infrarrojo. La ausencia de reflectividad en el infrarrojo es la clave para diferenciar áreas de tierra y agua en costas, lagos y ríos (Horning *et al.* 2010).

La profundidad a la que la luz puede acceder, está relacionada a la longitud de onda. Es así que en el agua clara la luz penetra hasta 10 m de profundidad con una longitud de onda de 0,5  $\mu\text{m}$  y 0,6  $\mu\text{m}$ . Al incrementarse la profundidad del lago o río, la reflectividad en cualquier longitud de onda desciende. La respuesta espectral dependerá del patrón de turbidez. Si es fitoplancton, aparecen alteraciones notorias en el verde (aumenta) y en el azul (disminuye) (Reeves 2015, Corrales y Ochoa 2016).

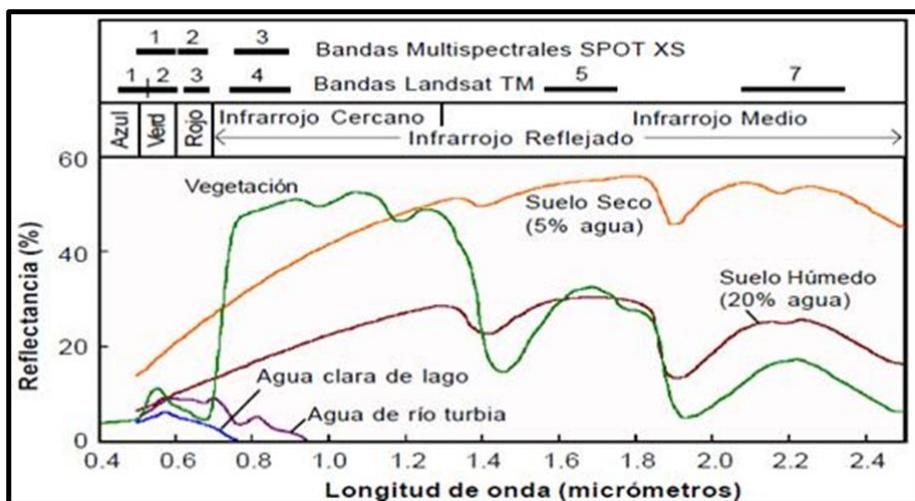
La reflectividad de la nieve es muy diferente a la del agua. Es alta en todas las longitudes de onda, sobre todo cuando hay presencia de nieve fresca, llegando a saturar los sensores en

algunos casos. Existe la posibilidad de confundir nubes altas con la nieve, teniendo en cuenta que la reflectividad de la nieve cae hasta cero para longitudes de onda  $>1,4 \mu\text{m}$ , mientras el de las nubes siempre será alta (Herrera y Chuvieco 2014).

### 2.1.1.3 Respuesta espectral del suelo

Las propiedades espectrales del suelo son taxativamente simples, siendo la transmisión nula, generando que toda la energía se absorbe o refleja, la reflectividad es baja en todas las bandas, incrementándose en camino al infrarrojo por la interdependencia entre reflectividad y contenido en agua del suelo (Zafra 2017). Este incremento se ve paralizado en aquellas regiones donde el agua absorbe energía, por consiguiente, a mayor cantidad de agua en el suelo, hay menor reflectividad.

La textura es un factor que afecta la respuesta espectral del suelo, el aumento medio del tamaño de partícula del suelo incrementa la reflectividad, siendo los suelos arenosos los que presentan mayor reflectividad que los suelos fracos o arcillosos (Verstraete y Pinty 1996) (Figura 5).



**Figura 5: Respuesta espectral del suelo**

Fuente: Watanave (2012)

Los suelos arcillosos presentan baja reflectividad en el infrarrojo, ya que corresponden a las longitudes de onda máxima generada por la absorción del agua. En los suelos arenosos como

el de los tolares, las zonas de baja reflectividad aumentan cuando el contenido de agua disminuye (Tucker *et al.* 1985).

## 2.2 ÍNDICES DE VEGETACIÓN UTILIZADOS CON PERCEPCIÓN REMOTA

Los índices de vegetación son datos cuantitativos que miden la biomasa o vigor vegetal en los pastizales con valores digitales (García y Cervijón 2015). Estos valores se obtienen a partir de las combinaciones de longitudes de onda electromagnética que son captadas por los sensores remotos llamados *bandas espectrales*, las que fueron diseñadas para establecer un valor numérico que muestre la cantidad o vigor de vegetación en el píxel (Tucker 1979, Campbell 1987 y Salgado 2015). De esta forma, se puede evaluar el estado de conservación y salud la vegetación en base a la estimación de la radiación que las plantas reflejan o emiten. Los píxeles cubiertos por proporciones substanciales de vegetación saludable muestran altos valores de índices de vegetación.

La ciencia ha desarrollado una variedad de índices de vegetación que se utilizan para ayudar en el monitoreo de la vegetación, estos índices están basados en interacciones diferentes entre especies vegetales que componen los pastizales y la energía electromagnética de bandas del espectro rojo e infrarrojo (Rueda *et al.* 2015 y Vila *et al.* 2007) (Tabla 2).

Los índices de vegetación han sido utilizados para identificar los atributos funcionales y biofísicos de coberturas vegetales (Zerda y Tiedemann 2010). Esto se debe a su elevada correlación con variables, entre ellas la producción de biomasa, el índice de área foliar y la tasa de fotosíntesis, constituyéndose así en una herramienta para la discriminación de la vegetación (Tucker *et al.* 1985).

Los estudios de pastizales basados en los índices de vegetación utilizan espectros de luz que se encuentran en la región de espectros visibles compuestos por las regiones azul, verde y roja. Además de las regiones del infrarrojo cercano y medio (Tucker 1979).

En el monitoreo de las comunidades vegetales se han utilizado una gran variedad de índices de vegetación. La mayoría de estos índices se basan en las interacciones diferenciadas entre la

energía electromagnética de las bandas del espectro rojo e infrarrojo y la vegetación. A ello se suman los diferentes arreglos que se realizan considerando los efectos atmosféricos y del suelo (Campbell 1987).

**Tabla 2: Índices de vegetación**

INDICE	FÓRMULA	AUTORES
Índice de vegetación de diferencia normalizada (NDVI).	$NDVI = \frac{(NIR - RED)}{(NIR + RED)}$	Rouse <i>et al.</i> 1973.
Vegetación de diferencia normalizada verde (GNDVI).	$GNDVI = \frac{(NIR - GREEN)}{(NIR + GREEN)}$	Gitelson <i>et al.</i> 1996.
a) Índice de ratio de vegetación (RVI). <i>Ratio Vegetation Index.</i>	$RVI = \frac{NIR}{RED}$	Jordan 1969
Índice de vegetación mejorada (EVI).	$EVI = \frac{G * (NIR - RED)}{NIR + C_{1RED} - C_{2BLUE} + L}$ $EVI = 2.5 \frac{(NIR - RED)}{(NIR + RED + 1)}$ <b>Constante: C=2.5 L=1; C=2.4, L=0.5.</b>	Jiang <i>et al.</i> 2008
Índice de vegetación ajustado al suelo (SAVI).	$SAVI = (1 + L) * \frac{NIR - RED}{NIR + RED + L} * (1 * L)$	Huete 1988
Índice de vegetación borde rojo de diferencia normalizada (NDRE).	$NDRE = \frac{NIR - Red\ edge}{Red\ edge + NIR}$	McFeeters 1996
Índice de la ratio de absorción de clorofila modificado (MCARI).	$MCARI = [(R_{700} - R_{670}) - 0.2 \times (R_{700} - R_{550})] \times \frac{R_{700}}{R_{670}}$	Daughtry <i>et al.</i> 2000
Diferencial de agua normalizado (NDWI).	$NDWI = \frac{NIR - SWIR}{NIR + SWIR}$ $NDWI = \frac{VERDE - NIR}{VERDE + NIR}$	Clevers 1988 McFeeters 1996

**Fuente:** Elaboración propia

Los índices de vegetación más utilizados son:

- **Índice de vegetación de diferencia normalizada (NDVI).** Es el más conocido y usado, y viene a ser la combinación aritmética que permite mostrar los contrastes en la respuesta de los patrones espectrales de la vegetación rojo ( $\Lambda$ RED = 0,58 a 0.68  $\mu\text{m}$ ) e infrarrojo cercano ( $\Lambda$ NIR = 0,725 a 1.1  $\mu\text{m}$ ). El NDVI se basa en el particular comportamiento radiométrico de la vegetación (Kharuf *et al.* 2018 y Manrique 1999), que tiene relación directa con la actividad fotosintética y la estructura foliar de las plantas. Esto permite determinar la vigorosidad de la planta (Rouse *et al.* 1974). Este índice fue introducido para facilitar la separación del brillo que produce el suelo de la reflectancia de la vegetación.
- **Vegetación de diferencia normalizada verde (GNDVI).** Es el índice de verdor de la planta relacionada a la actividad fotosintética. Es considerado una variante del NDVI (Kumar *et al.* 2007) que utiliza la banda infrarrojo cercano (NIR), la banda verde (GREEN) del espectro electromagnético (Muñoz 2013 y Martínez 2016). Los valores oscilan -1 a 1. Los valores entre -1 a 0 (Rouse *et al.* 1974) por que están asociados a la presencia de agua o suelo desnudo. Este índice está recomendado para ser usado en la fase intermedia y final del ciclo de un cultivo (Gitelson *et al.* 1996).
- **Índice de ratio de vegetación (RVI).** considerado el pionero de los índices para el estudio de la vegetación (Jordán 1969), se basa en el principio de las hojas, que absorben relativamente la luz roja (RED), tomando en cuenta la diferencia espectral en la vegetación en las longitudes de onda del rojo (RED) y el infrarrojo cercano (NIR). Según las características espectrales de la vegetación, los arbustos tienen baja reflectancia sobre el rojo y han mostrado una alta correlación con el índice de área foliar (LAI), con la biomasa de las hojas en materia seca y con el contenido de clorofila en las hojas. El RVI es muy utilizado para estimar y monitorear biomasa verde de alta densidad de vegetación. Además, tiene buena correlación con la biomasa de la planta.
- **Índice de vegetación mejorada (EVI).** Es uno de los índices de vegetación mejorados, que a diferencia del NDVI incorporan la banda azul en adición a la banda roja e infrarroja del espectro (Farel y Rivas 2011). El EVI obtiene respuesta de las variaciones estructurales de la planta, incluyendo el índice de área foliar (LAI) (Verstraete y Pinty 1996 y Martínez 2016). El índice de vegetación mejorada (EVI) se desarrolló con el fin de optimizar la señal

de vegetación a través de una sensibilidad mejorada en biomasa alta y un mejor monitoreo de la vegetación, ello mediante un desacoplamiento de la señal de fondo con la canopia y la reducción por las influencias atmosféricas (Huete *et al.* 2002).

- **Índice de vegetación ajustado al suelo (SAVI).** Este índice utiliza las bandas del infrarrojo (NIR) cercano y la longitud de onda roja (RED), y agrega un factor de ajuste del suelo o “coeficiente L” a la ecuación. Este coeficiente se incluye para dar cuenta de la no transferencia radioactiva del infrarrojo cercano (NIR) y rojo (RED). El factor L elegido, depende de la densidad de la vegetación que uno desea analizar. Huete *et al.* (1994), sugirieron los siguientes valores: para un nivel de densidad muy pobre el valor de L=1, para una densidad de nivel intermedio L=0.5, y para un alto nivel de densidad L=0.25.
- **Índice de vegetación borde rojo de diferencia normalizada (NDRE).** Utiliza una combinación de la banda luz NIR y una banda de frecuencia que se encuentra en la región de transición entre la luz roja y NIR, por ello el nombre de “Red Edge” (Bessone *et al.* 2016). el NDRE es menos propenso a la saturación en presencia de vegetación densa, la que podría encontrarse en las mediciones de estimación de biomasa de pastos. Por lo tanto, NDRE a veces puede proporcionar una mejor medición de la variabilidad en un área donde NDVI simplemente medirá como un +1 uniforme. Para estudios de vegetación, pastos, cultivos, se recomienda utilizar NDRE (Bessone *et al.* 2016).
- **Índice de ratio de absorción de clorofila modificado (MCARI).** Este índice se calcula a partir de datos de reflectancia en el verde. Está influenciado por parámetros como el índice de área foliar, clorofila y la interacción entre la clorofila y el índice de área foliar y. Este índice es sensible a elementos no fotosintéticos como el suelo y la luminosidad (Daughtry *et al.* 2000 y Escobar 2015).
- **Diferencial de agua normalizado (NDWI).** Fue utilizado por primera vez en 1996. Refleja el contenido de humedad en plantas y suelos y se determina en correlación con el NDVI. Los valores que se obtienen oscilan entre -1 y 1 para las zonas menos húmedas.

## **2.3 RELACIÓN DE LOS ÍNDICES DE VEGETACIÓN Y PRODUCCIÓN DE BIOMASA EN COMUNIDADES VEGETALES**

### **2.3.1 Comunidades vegetales de puna seca**

El concepto de comunidad vegetal es muy general y puede aplicarse a: (i) tipos de vegetación de cualquier tamaño y longevidad, (ii) a un estrato de plantas en un área local, como las hierbas, plántulas leñosas y musgo del bosque; (iii) a un tipo de vegetación muy extendida (regional); (iv) a una parcela de vegetación que experimenta cambios rápidos en las especies que la componen; (v) a una vegetación muy estable, si esta no ha sido expuesta a cambios significativos durante cientos de años (Sotomayor 1990, Flórez y Malpartida 1987).

La puna seca se identifica como zona xerofítica de suelos arenosos, donde se desarrollan las comunidades vegetales de tolar, bofedal, pajonal, césped de puna. La comunidad vegetal tolar es la más importante de la región y está compuesto por *Parastrepbia quadrangulare*, *Parastrepbia lepidophila* y *Baccharis sp* (Tapia y Flores 1984, Nina 2015). Los tolares están asociados con *Muhlenberia fastigiata* y la anual *Muhlenbergia Peruviana*, *Calamagrostis vicunarum*, *Geranium sessiliflorum*, *Scirpus rigidus*, *Lachemilla pinnata*, y *Azorella dispensoides* (Tapia y Flores 1984, Berrio y Estrada 1994, Matteucci *et al.* 2015). Esta comunidad presenta invasión de especies espinosas y lignificadas, como el *Margiricarpus pinnatus*, *Margiricarpus cristatus* y algunas veces *Opuntia pentlandi*.

La comunidad vegetal tolar, junto a sus componentes, el césped y la tola, ocupan aproximadamente el 47% de la cobertura de pastizales altoandinos de la sierra sur (Puno, Moquegua, Tacna y Arequipa) (Sotomayor 1990 y Ramos 2018). Así también, los tolares muestran niveles de producción de biomasa que van desde 15,745 a 22,325.86 Kg/ha para la época seca y de lluvias (Zorogastúa *et al.* 2012). Con una capacidad de carga de 3 a 4 unidades alpaca. los tolares se utiliza como fuente de energía en los hornos artesanales, y el césped, que durante la época de lluvia sirve como alimento de alpacas y llamas (Zorogastúa *et al.* 2012 y Ramos 2018).

La comunidad vegetal bofedal se encuentra en lugares donde hay afloramiento de agua, presentan plantas de crecimiento almohadillado, como la *Distichia muscoides*, asociada con *Plantago rigida* y *Hypsella reniformis* (Flores *et al.* 2005, Sotomayor 1991 y Siguayo 2008). Según la variación del grado de humedad presentan inclusiones de *Lachemilla pinnata*, *Hipochoeris taraxacoides* y *Paspalum pigmaeum*, *Festuca dollicophilla*.

La producción de biomasa en bofedales de puna seca está directamente relacionada a las condiciones climáticas, a la extracción de la tola como combustible y a las malas prácticas de pastoreo (Sotomayor 1990 y Matteucci *et al.* 2015). Los estudios de cobertura vegetal, producción de biomasa y capacidad de carga, realizados entre los años 1990 – 2017 en la puna seca de la sierra sur del Perú, registran los siguientes datos: en la época de lluvias la producción de biomasa va desde 4,325 Kg/ha hasta 15,288.13 Kg/ha en materia verde, mientras que en la época seca la producción de biomasa va desde 1,534.14 hasta 7,325.56 Kg/ha (Mango 2017, Siguayro 2008, Berrio y Estrada 1994, Florez 1993).

Los bofedales de la región tienen capacidad de carga de 6 a 8 unidades de alpaca por hectárea por año (Siguayro 2008 y Nina 2015). Sin embargo, la capacidad de carga real que soportan los bofedales es de 25 y 30 unidades alpaca/ha/año, los reportes de investigación realizados para la zona en el periodo 2001 – 2016, señalan pérdidas de cobertura de los bofedales hasta del 5% anual (Ramos 2018 y Zorogastúa *et al.* 2012). Los estudios también reportan disminución progresiva en la producción de biomasa, llegando a estimar descensos de 2,435.48 a 4,625 Kg/ha en la época de lluvia. Estas pérdidas son generadas por cambios en las condiciones climáticas e incremento de la actividad antrópica (Matteucci *et al.* 2015 y Mango 2017).

### 2.3.2 Índices de vegetación y producción de biomasa

La técnica de percepción remota y el uso de índices de vegetación es una herramienta valiosa para la cuantificación de la existencia de biomasa aérea y de los cambios asociados (Buzzi *et al.* 2017). Los datos obtenidos con percepción remota y el uso de los diferentes índices de vegetación permiten la estimación indirecta del valor de la biomasa y condición de los pastizales y bosques. Información que debe ser complementada con datos de biomasa tomados en campo.

El empleo de datos por percepción remota e índices de vegetación tiene ventajas, ya que cubren áreas extensas y facilitan formas de observación ordenada. Chávez *et al.* (2017) indican que, con la realización de los análisis multitemporales adecuados, es posible realizar predicciones, determinar futuros escenarios, realizar monitoreo de vegetación y estimar el cambio producido en las diferentes formas de uso y ocupación de la tierra.

Los bosques naturales y matorrales son un importante reservorio de biomasa utilizables para la producción animal, Perea (2018) con imágenes LANDSAT 8 OLI de la época seca y lluviosa del año 2016, utilizando tres índices de vegetación (NDVI, SAVI y EVI) para la estimación de biomasa aérea reportó que el índice de vegetación NDVI para la época seca obtuvo un  $R^2 = 0,82$  y un RMSE de 17 t/ha, de biomasa aérea.

Con mapas del índice de vegetación de diferencia normalizada (NDVI) derivados del SPOT 4-Vegetation, analizaron la dinámica mensual y anual de bosque nativo y pastizal de la provincia de Santiago del Estero. El modelo de análisis en la dinámica y del pastizal y del bosque, encontró valores altos de NDVI, durante la estación húmeda (octubre- mayo) y valores disminuidos de NDVI en la estación seca (junio-septiembre) (Zerda y Tiedeman 2010).

Los estudios de vegetación reportan que el potencial de producción de biomasa del bosque es superior a la del pastizal (Zerda y Tiedeman 2010). Utilizando índices de vegetación determinaron que el pastizal decrece a una tasa de  $-0,5$  NDVI/ día, mientras que el bosque decrece a una tasa de  $-0,3$  NDVI/día Nicholson *et al.* (1990) en el mismo periodo de tiempo y bajo las mismas condiciones de falta de precipitaciones y bajas temperaturas. Se estima que este comportamiento está asociado con la diversidad de especies que conforman el bosque.

La degradación de las tierras y los pastizales son la mayoría de los problemas ambientales, que son estudiados a través de los índices de vegetación de imágenes satelitales, siendo el NDVI el índice más utilizado, para ello (Gaitan *et al.* 2015) analizó la tendencia del NDVI del sensor MODIS en el periodo 2000 – 2014. La metodología de uso de índices de vegetación junto con los indicadores de campo y datos climáticos, puede integrar un sistema de monitoreo de tierras a escala nacional. Los estudios muestran que en base a imágenes de sensores MODIS TERRA

encontró un coeficiente de determinación de 0.31 ( $n = 46$ ,  $p < 0.01$ ) y 0.22 ( $n = 46$ ,  $p < 0.0$ ) para la relación entre biomasa aérea y los índices de vegetación NDVI y EVI respectivamente. La baja correlación y variabilidad encontrada se atribuyó a las características particulares de la vegetación de las evaluadas, así como a la heterogeneidad de la vegetación contenida en un pixel de MODIS (6.25 Ha) (Paredes 2018).

La estimación de biomasa aérea utilizando índices de vegetación para cultivares de trigo, maíz y caña de azúcar se consideran como pioneros en el análisis de los índices de vegetación para estimar biomasa. Bessone *et al.* (2016). La determinación de zonas con mayor rendimiento y calidad de trigo a partir de imágenes multiespectrales, muestra variación en la asociación entre NDVI y NDRE. El índice NDVI explicó en un 66% la variación del rendimiento de biomasa, mientras que el índice NDRE la explicó en un 79%. El mejor desempeño del NDRE para determinar rendimiento, se produjo en la diferenciación de las condiciones de riego.

Isla y Lozano (2005), en el estudio de comparación de índices de vegetación para detectar deficiencias de nitrógeno en maíz, usando datos radiométricos obtenidos en campo, calcularon índices de vegetación que guardan relación con el contenido de clorofila de la hoja. Los índices de vegetación RVI, NADVI y NIR fueron utilizados para obtener una alta sensibilidad a la concentración de clorofila y minimizar la influencia de la biomasa. Se usaron también los índices GNDVI y SIPI, ya que tienen correlación con los carotenoides/clorofila, de esta forma, el índice se verá afectado por el estrés hídrico existente.

El estudio de Kharuf *et al.* (2018), realizado en cultivos de caña de azúcar, encontró que la relación directa entre la variación de vigor vegetal y los niveles de clorofila y con ello caracterizó su distribución espacial, y su evolución a lo largo del periodo de vida del cultivar. El mapa de NDVI que obtuvieron, posibilitó clasificar las parcelas en el campo de acuerdo a la respuesta espectral alta, baja o nula. Con la información, trazaron planes de manejo de los cultivos, pero además determinaron que la correlación entre el estado de salud de las plantas y los valores de NDVI, encontrándose en las parcelas más saludables mayores valores de índice NDVI (superior 0.49). Los valores bajos que van de 0.21 a 0.39 presentan las parcelas que han sufrido estrés nutricional o pobre fertilización nutricional. Los NDVI por debajo de 0.21 casi nulos, están en los sectores de vegetación con suelos muy pobres.

## 2.4 PLATAFORMAS Y SENSORES REMOTOS

### 2.4.1 Sensores remotos para el estudio de vegetación

Un sensor remoto es el instrumento tecnológico útil para captar imágenes a distancia. Puede captar información en diferentes regiones espectrales las que se le denomina banda o canal. Las diferentes bandas pueden caracterizarse en función de las siguientes variables: **Amplitud espectral** (región donde se capta datos espectrales), **Resolución radiométrica** (intensidad que puede captar a partir del número de intervalos), **Resolución espacial** (tamaño de pixel) y **Resolución temporal** (muestra tomada cuando el satélite pasó dos veces por el mismo sitio medido en tiempo) (Justice *et al.* 1985, Jones y Vaughan 2010).

Los sensores remotos son fundamentales en la realización de investigaciones sobre cobertura de pastizales, cultivos y bosques a diferentes escalas, haciendo posible reconocer la estacionalidad de la vegetación y planificar los procesos de monitoreo del comportamiento de los pastizales. Esto es posible cuando se dispone de datos derivados de información adquirida con sensores remotos con bases de datos temporalmente regulares (Zerda y Tiedemann 2010, Horning *et al.* 2010).

Los sensores remotos se clasifican por su capacidad de recepción de la energía procedente del suelo y de la cubierta existente, vegetación, infraestructura, agua. Los sensores remotos se dividen en sensores activos y pasivos. Los sensores remotos pasivos son fotográficos, óptico-electrónicos y de antena, mientras que los sensores remotos activos miden el tiempo de retorno de la onda emitida desde el sensor. Los más conocidos son *Lídar* y *Radar* (Jones y Vaughan 2010).

#### **2.4.1.1 Resolución de un sistema sensor**

La resolución de un sensor es la capacidad para diferenciar información a detalle. Esta resolución depende del funcionamiento adecuado del sensor y la combinación de sus componentes internos (Rueda *et al.* 2015 y Horning *et al.* 2010).

**Resolución espacial:** Designa al objeto más pequeño que puede ser distinguido sobre una imagen. El pixel es el tamaño de la unidad mínima de información en la imagen. La resolución de estos sensores depende de la altura orbital, velocidad de exploración y el número de detectores. Sin embargo; en los sensores de antena la resolución depende del radio de apertura, la altura de la plataforma y de la longitud de onda a la que trabajen (Reeves *et al.* 2015 y Horning *et al.* 2010).

La resolución espacial juega un papel fundamental en el análisis e interpretación de la ortofotografía e imagen satelital, porque muestra cada detalle que se ofrece la imagen, y está relacionada a la escala en la que se va a trabajar y el grado de confiabilidad de la interpretación (Buzzi *et al.* 2017).

**Resolución espectral:** Muestra la capacidad del sensor para discriminar las bandas espectrales en número y anchura de las bandas espectrales. Su utilidad está relacionada al número de bandas que proporcione la ortofotografía y la imagen. La recolección de bandas muy estrechas se realiza con sensores de alta resolución espectral (Buitrón y Calizaya 2012, Jones y Vaughan 2010, Delgado 2009).

**Resolución radiométrica:** Detecta las variaciones de radiancia espectral que el sensor recibe, la que se observa en los niveles de gris recogidos. La interpretación es muy dependiente a la precisión radiométrica (Campbell 1987, Corrales y Ochoa 2016, Jones y Vaughan 2010).

La resolución radiométrica está directamente relacionada al número de bits que el sensor puede almacenar. En el caso de *Landsat*, son ocho bits y, por lo tanto, 256 niveles de gris. La cantidad de energía que llega al sensor se transforma en números, de 0 a 255, que son los niveles digitales

(ND). Este paso implica establecer el promedio de la cuantía de radiación que llega al sensor dentro del rango de amplitud espectral y del tamaño del pixel (Corrales y Ochoa 2016).

**Resolución temporal:** Es la frecuencia de cobertura que proporciona el sensor. Por ejemplo, la resolución temporal METEOSAT proporciona una imagen cada 30 minutos, NOAA cada seis horas, LANDSAT cada 15 – 16 días y SPOT, como los de más baja resolución, hay que contratarlos previamente (Delgado 2009).

#### 2.4.1.2 Tipos de sensores

**Sensores pasivos:** Los sensores pasivos recogen la energía electromagnética que procede de las cubiertas terrestres (Comisión Colombiana del Espacio 2007).

**Sensores fotográficos:** En la teledetección las cámaras fotográficas son los instrumentos más utilizados para recopilar imágenes. La pancromático (blanco y negro) es película fotográfica más utilizada. Las películas de color mezclan capas fotoquímicas diferenciadas. También se utilizan películas en infrarrojo, blanco y negro y el infrarrojo color. El número de objetivos de la cámara puede variar entre una cámara monobanda o una cámara multiespectral (Maini y Agrawal 2007).

**Exploradores de barrido:** Es un espejo móvil que oscila perpendicularmente a la dirección de la trayectoria del recorrido. Lo que permite observar una franja de terreno a ambos lados del satélite y ampliar la banda detectada a longitudes de onda mayores del visible. Este sistema facilita la calibración y corrección radiométrica, realizando coberturas sistemáticas de grandes espacios por su capacidad obtener información a tiempo real (Comisión Colombiana del Espacio 2007).

**Exploradores de empuje:** Facilitan el aumento de la resolución espacial respecto a los sistemas de barrido convencionales y disminuyen problemas geométricos. Destacan dos sistemas pasivos que son utilizados con frecuencia, las cámaras de vídeo y los sensores radiómetros de microondas.

### **Sensores activos:**

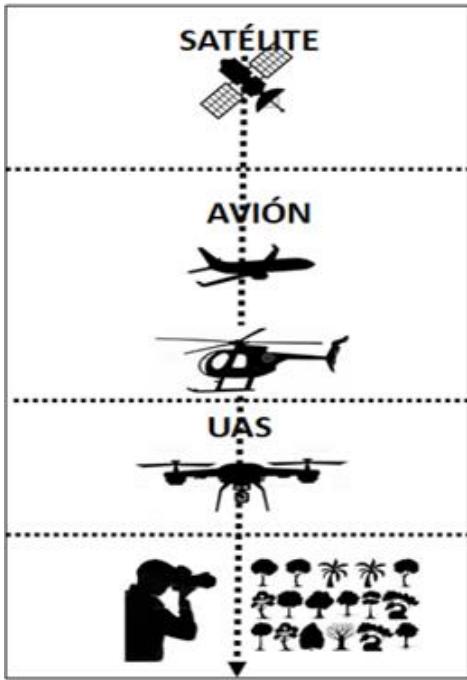
**Radar:** Su característica es la gran capacidad de emisión de un haz energético que luego de su reflexión sobre la superficie terrestre se vuelve a recoger. El radar está diseñado para trabajar en cualquier condición atmosférica. A estos sistemas de radar de imágenes de los satélites, se han incorporado equipos adicionales para la medición de distancias (Sánchez 2008).

**Lídar:** *Light Detection And Ranging* (LIDAR), es un sensor activo que emite hacia la superficie pulsos de luz que van desde el ultravioleta hasta el infrarrojo cercano. Creando información sobre el tipo de componentes de la zona de estudio. Esta tecnología es la fusión de la tecnología *Radio Detection And Ranging* (RADAR) con la tecnología del láser junto la unión de estas dos tecnologías permite mejorar la precisión de los sistemas de detección.

El fundamento de los equipos que tienen como base la tecnología LIDAR es el cálculo del tiempo de vuelo (TOF - *Time Of Flight*) de los pulsos láser, conociendo la velocidad del y las características angulares con las que la información fue emitido, y la diferencia de tiempos entre el rayo emitido por el sensor y el reflejado por la superficie terrestre, determinando de manera sencilla la distancia a la que se encuentra el objetivo respecto al Lídar (Sánchez 2008).

#### **2.4.2 Plataformas para el estudio de pastizales**

Las plataformas son sistemas que transportan los equipos (sensores) necesarios para captar, almacenar y transmitir imágenes a distancia. Las plataformas que se utilizan para el estudio del medio ambiente, recursos naturales y pastizales están ubicadas dentro y fuera de la atmósfera (Figura 6).



**Figura 6: Plataformas y sensores remotos**

Fuente: Adaptado de Esser y Ortega (2010)

#### 2.4.2.1 Plataformas fuera de la atmósfera

El uso de plataformas de percepción remota que se encuentran fuera de la atmósfera y son utilizados para estudios ambientales y de vegetación monitorean el área total de la superficie de la tierra, cubriendo una sección suficientemente grande comparada con las imágenes adquiridas desde aviones. Los satélites diseñados para percepción remota son generalmente no tripulados.

La utilización de los sensores remotos ubicados fuera de la atmósfera para evaluación de recursos naturales y pastizales empiezan a operar en 1975 siendo uno de los pioneros el satélite Landsat. Los estudios que utilizaron imágenes adquiridas con el satélite Landsat estuvieron orientados a analizar grandes ecosistemas. Inicialmente la interpretación de las imágenes del satélite Landsat se realizaban en base a la apreciación de las diferentes tonalidades que registraban los objetos de la superficie terrestre (Tapia y Flores 1984).

Utilizando satélites y sensores remotos ubicados fuera de la atmósfera (Chen y Wang 2005) estudiaron la salud de la vegetación utilizando como indicadores el vigor, presión de pastoreo y resiliencia de los pastizales, mientras que (Suo *et al.* 2008) estudió la diversidad del paisaje incorporando como indicadores la riqueza del paisaje, la erosión y la escorrentía y finalmente (Chen *et al.* 2010) utilizando imágenes satelitales y el índice de vegetación NDVI analizó la cobertura vegetal de ecosistemas de pastizales.

Los estudios de producción de biomasa área de plantas C-3 y C-4 a partir de imágenes derivados de las plataformas NOAA y sensor AVHRR muestra una correlación moderada ( $R= 0.58$ ) y un  $R^2= 0.54$  con mediciones en campo (Shoko *et al.* 2016).

Utilizando imágenes del satélite SPOT se realizaron estudios de relación entre cobertura vegetal con productividad forrajera, incorporando el índice de calidad de preferencia del ganado, se logró establecer un rango de preferencia de las pasturas por el ganado según su calidad nutricional de las plantas que pueden ser utilizadas como forraje. Y en la sierra central del Perú utilizando el satélite TERRA con el sensor MODIS (Paredes 2018) realizó estudios de evaluación de biomasa aérea.

Utilizando imágenes *Landsat* para pastizales de puna de las regiones de Ancash, Junín y Pasco se identificaron los factores más importantes que determinan el proceso de degradación de los pastizales (grado de degradación y vulnerabilidad) en territorios afectados por el cambio climático. El estudio encontró que existe una correlación espacial positiva (Pearson = 0.67 y Spearman = 0.61) entre degradación y vulnerabilidad al cambio climático (Pizarro 2017).

Las plataformas y sensores remotos (Tabla 3), muestran que su utilización está directamente relacionada a la magnitud del estudio. Aquellos que tienen resoluciones espaciales más grandes (grano más fino) serán utilizados para estudios de vegetación que requieren mayor detalle y precisión, y aquellos que muestran resoluciones espaciales más pequeños (grano muy grueso) podrán ser utilizados para estudios de exploración (Shoko *et al.* 2016).

**Tabla 3: Plataformas, satélites y sensores fuera de la atmósfera terrestre utilizados para estudios de vegetación**

SATÉLITE	SENSOR	AÑO	RESOLUCIÓN ESPACIAL		RESOLUCIÓN ESPECTRAL (Nº de bandas)	RESOLUCIÓN RADIOMÉTRICA (Bits)	RESOLUCIÓN TEMPORAL (Días)
			TAMAÑO PIXEL (m)	ANCHO DE FRANJA EN TIERRA (Km)			
NOAA 10	AVHRR	1992	1100	2900	5	11	1
LANDSAT (2 -3)	MSS	1972	80	185	5	6	16
LANDSAT (4.5)	TM	1986	30	185	7	8	16
LANDSAT 8	OLI	2013	30	170	9	12	16
TERRA EOS – AM	MODIS	2000	500 a 1000	2330	7	8	1
TERRA EOS – AMI	ASTER	1999	60	15	14	8	1
SPOT 5	SOPT 5 MSS	2002	10 a 20	120	4	8	26
SENTINEL N 2	SENTINEL 2 MSI	2014	10,20,60	290	15	8 – 16	5
RapidEye	Rapideye	2009	5	77	5	8	5.5

#### **2.4.2.2 Plataformas dentro de la atmósfera: Sistemas de vehículos aéreos no tripulados**

Los sistemas de vehículos aéreos no tripulados UAS (*Unmanned Aerial Systems*), conocidos popularmente como DRONES (*nombre heredado de los vehículos militares a control remoto usados como blancos de tiro, también llamados “zángano”*; UAV (*Unamanned Aerial Veicles*) y RPAS (*Remotely Piloted Aircraft Systems*), son nombres que distinguen la el sistema completo y la aeronave que se requiere para su funcionamiento (Iglesias 2003 y Cuerno *et al.* 2016).

El UAS se considera un sistema completo, compuesto por la aeronave (UAV, RPA) e incluye: sistemas de control y comunicación, sistemas de telecomunicación de mandos de vuelo y datos con sistema de telemetría, piloto automático, las cámaras con microsensores, y el equipo adicional requerido para el vuelo: El equipo de tierra, equipo de comunicaciones, el equipo de comando, el equipo de lanzamiento y de recuperación (OACI 2011, Cuerno *et al.* 2016).

El desarrollo tecnológico de los UAS, RPAS o DRONE, estuvo impulsado por la industria militar. Fue utilizado para operaciones de espionaje, bombardeo o blancos de tiro. El origen de los drones se remonta a mediados del siglo XIX (García y Quintano 2017).

El 2015 la industria de los drones comerciales de uso civil introdujo al mercado el DRONE “Phantom” y “Parrot Sequoia” que introdujo la visión inteligente de una computadora y la tecnología de aprendizaje automático, que le permitió durante el cumplimiento de su misión evitar obstáculos, adquirir fotografías y rastrear de forma inteligente animales, personas, arbustos, pastizales y otros objetos presentes en las comunidades vegetales. Fue un hito importante para la fotografía con drones y su utilización para diversas actividades humanas (EASA 2015).

#### **2.4.2.3 Componente de los sistemas de vehículos aéreos no tripulados (UAS)**

Un sistema UAS completo incluye, a la aeronave, los sistemas de telecomunicación de comandos de vuelo y un conjunto datos y un sistema de telemetría, adicionalmente un piloto automático. Son también componentes las cámaras/sensores y/o equipo adicional de abordo y de recuperación (Iglesias 2003, OACI 2011, PAE 2015). El equipo de tierra está compuesto por un sistema de comunicaciones y de comando y de lanzamiento/recuperación (Figura 7).

El **componente de vuelo** está formado por el vehículo aéreo, el sistema de adquisición de imágenes con sensores, el sistema GPS para ejecución de vuelos y recuperación del UAV, el sistema de aterrizaje, los sensores remotos incorporados y un sistema de comunicación (Santamarina *et al.* 2017, OACI 2011).

El **componente en tierra** está formado por la estación de control en tierra. Este da las órdenes y monitorea el vuelo de los UAV y a su vez recibe información enviada por el UAV y sus sensores respectivos (OACI 2011, PAE 2015).



**Figura 7: Componentes de la UAS \_ vuelo y tierra**

#### **2.4.2.4 Clasificación de los UAS y UAV**

Los UAS se pueden clasificar desde diferentes puntos de vista, siendo las siguientes:

### **a. Por su uso y tipo de usuario**

En función al uso, se pueden clasificar como UAV civiles y militares: Los **UAV militares**, son un tipo de drones desarrollados exclusivamente para operaciones militares y van equipados con armamento. En la actualidad existen más de 60 países que reconocen utilizar UAV militares. Su éxito radica en la gran precisión, en no llevar piloto abordo, en no llevar más carga y no generar pedidas humanas. Los **UAV de uso civil** son utilizados para desarrollar múltiples aplicaciones tecnológicas, deportivas, turísticas y de investigación de vegetación. Estos representan menos del 15% del total del mercado de drones (OACI 2011, MDE 2009).

### **b. Por los métodos de control del UAV**

Los UAS tienen diferentes métodos de control:

**Autónomo:** No requiere control desde tierra por un piloto humano, guiándose por sus propios sensores integrados y sistemas.

**Monitorizado:** Este sistema requiere de una persona que proporcione información al UAV y supervise el vuelo. El UAV sigue su propio plan de vuelo, el piloto en tierra puede decidir qué acción realizará, puede cancelar la operación o utilizar los mandos para retorno a casa en caso de incidentes inesperados.

**Supervisado.** El piloto en tierra pilota el UAV. La nave realiza tareas de manera autónoma controladas remotamente. El UAV es pilotado directamente mediante un equipo de comando control (EASA 2015, OACI 2015, MDE 2009).

### **c. Por el tipo de sustentación en aire**

Para entender mejor su potencial de uso civil, la clasificación de los UAS se basa en el tipo de aeronave. Esto ofrece una idea de su facilidad y versatilidad de operación. Están las naves

de despegue vertical, que incluyen **ala rotativa** o hélices (helicópteros, quadrocópteros, hexacópteros) y los de **ala fija** (aeroplanos) (Figura 8). Actualmente, existen modelos híbridos que combinan las capacidades de ambos tipos (D’Oliera *et al.* 2012, Ishida *et al.* 2017 y Santamarina *et al.* 2017).



**Figura 8: UAV de ala fija y rotativa**

Cerca del 90% de los UAS de uso civil son multirrotores, especialmente adecuados para la captura de imágenes y videos. Las ventajas que presentan los UAV multirrotor son el despegue y aterrizaje vertical, en comparación de los de ala fija, que requieren espacios amplios para su aterrizaje. Los multirrotores tienen la capacidad de volver a un punto fijo y mantenerse en una posición en el aire sin moverse. Resulta muy adecuado para aplicaciones de inspección, monitoreo o toma de imágenes y videos (Ishida *et al.* 2018, Banco Mundial 2017).

Respecto a la maniobrabilidad y precisión del vuelo, los vehículos multirrotores están capacitados para rotar sobre su eje y maniobrar acercándose lo más cercano posible a un objeto, en cambio los de ala fija siguen trayectorias curvilíneas previamente establecidas con radios de giro amplios y con velocidades de ascenso y descenso bastante reguladas y estrictas (EASA 2015, OACI 2015).

Sin embargo, los UAV de ala fija son mucho más eficientes que los multirrotores. Por ejemplo, si ambos tienen el mismo tamaño, los de ala fija ofrecen mayor autonomía. Además,

la sustentación de las alas permite menor gasto energético, por tanto, mayor duración del tiempo de vuelo. Así también, adquieren mayor velocidad que, combinada con la mayor eficiencia, cubren mayores áreas de trabajo. Finalmente, muestran mayor resistencia al cambio de temperatura, a la lluvia y al viento (Ishida *et al.* 2018).

#### **d. Por sus características de los UAV**

La capacidad de vuelo de un UAS está definida por el alcance de altitud y autonomía. La AUVSI (*Association for Unmanned Vehicle Systems International*), ha establecido una clasificación donde la mayoría de los UAV se encuentran en la categoría de *mini*, destacando los helicópteros, multirrotores helicópteros y naves de ala fija de alcance medio (Tabla 4) (OACI 2011, Banco Mundial 2017, PAE 2015 y MDE 2009).

**Tabla 4: Clasificación de los UAV por sus características**

Categoría	Acrónimo	Alcance (Km)	Altitud de vuelo(m)	Autonomía (horas)	Carga máxima en despegue (Kg)	Tipo de aeronave
<b>Micro</b>	$\mu$ (Micro)	<10	250	1	<5	H,A, otros
<b>Mini</b>	Mini	<10	150 a 300	<2	<30	H,a, p, Otros
<b>Alcance cercano</b>	CR	10 a 30	3.000	2 a 4	150	H,A,P, Otros
<b>Alcance corto</b>	SR	30 a 70	3.000	3 a 6	200	A, otros
<b>Alcance medio</b>	MR	70 a 200	5.000	6 a 10	1.25	A, otros
<b>Altitud baja/penetración profunda</b>	LADP	>250	50 a 9.000	0,5 a 1	350	A
<b>Autonomía media</b>	MRE	>500	8.000	10 a 18	1.25	A,H
<b>Autonomía alta/altitud baja</b>	LALE	>500	3.000	>24	<30	A
<b>Autonomía alta/altitud media</b>	MALE	>500	14.000	24 a 48	1.5	A,H
<b>Autonomía alta/altitud alta</b>	HALE	>2000	20.000	24 a 48	12	A
<b>Combate</b>	UCAV	aprox.1500	10.000	aprox. 2	10	H,A
<b>Ofensiva</b>	LETH	300	4.000	3 a 4	250	A
<b>Señuelo</b>	DEC	0 a 500	5.000	<4	250	A,H
<b>Estratosférico</b>	STRATO	>2000	Entre 20.000 y 30.000	>48	ND (no disponible)	A
<b>Exo-estratosférico</b>	EXO	ND	>30.000	ND	ND	A

### e. Por su capacidad de vuelo

Esta clasificación está articulada con las regulaciones para la operación de UAS y UAV en el espacio aéreo civil. Tiene que ver además con su nivel de autonomía (Tabla 5).

**Tabla 5: Clasificación de los UAV por sus capacidades de vuelo**

	Blanco móvil (Drone)	Nivel 1 No autónoma	Nivel 2 Maniobra autónoma	Nivel 3 Piloto inteligente limitado	Nivel 4 Piloto Inteligente completo
<b>Trayectoria de vuelo en dimensiones</b>	Preprogramada	Preplanificada preprogramada	Preplanificada, preprogramada	Parcialmente autónomo Posibilidad de cálculo de ruta	Posibilidad de cálculo de ruta
<b>Presencia de piloto</b>	Por seguridad	Guiado y control continuo	Como Nivel 1	Supervisión continua, guiado y controlado ocasional	Solo como respaldo
<b>Posibilidad de actuación de piloto</b>	Solo en despegue y aterrizaje	Manipulación	Como Nivel 1	Posible	Solo como respaldo
<b>Necesidad de actuación del piloto</b>	Solo en FTS	En todos los casos	Cuando no haya maniobra automática	Ocasional	Solo como respaldo
<b>Piloto automático</b>	No	No	No	Limitado	completo
<b>Presencia de ATC</b>	Supervisión	Contacto continuo con el operador	Contacto continuo con el operador	Contacto continuo con el operador y con el piloto automáticos	Contacto continuo con el piloto automático (con el operador como respaldo)
<b>Intervención de ATC</b>	Petición o activación del FTS	Por petición del operador	Por petición del operador	Por petición del operador o del piloto automáticos	Por petición del piloto automático (del operador por respaldo)

Fuente: Curso aviación civil - OACI (2011)

### f. Por la regulación para la operación de UAS y UAV

Según el Banco Mundial (2017) y PAE (2015), los UAS son considerados aeronaves, por ello en el ámbito internacional se está tratando de normalizar la emisión de licencias para

operadores, en concordancia con la política de asignación de licencias para aeronaves tripuladas y la normativa que cada país tiene sobre su espacio aéreo (Tabla 6).

**Tabla 6: Clasificación por tamaño y peso del UAV**

Clase	Categoría	Empleo normal	Altitud de funcionamiento normal	Radio de misión normal	Comandante principal apoyado	Plataforma de ejemplo
clase I (menos de 150gr)	Menor >20kg	Unidad táctica (emplea sistema de lanzamiento)	Hasta 5k ft AGL	50km (LOS)	BN / Regt, BG	Hermes 90 luna
	Mini 2-20 kg	Subunidad táctica (manual lauch)	Hasta 3k ft AGL	25km (LOS)	Coy / Sqn	Aladin DH3 DRAC Eagle Raven Scan Skylark Satrix T-Hawk
	Micro <2kg	Tactical PI, Sect, individual (operador sigle)	Hasta 200 pies AGL	5 km (LOS)	PI, secta	Blanck window
Clase II(150 kg a 600 kg)	Táctil	Formación Táctica	Hasta 10,000 pies AGL	200 km (LOS)	Bde Comd	Aerostar hermes 450 iview 250 guardabosques sperwer
Clase III(Mas de 600 Kg)	Combate	Estratégico / Nacional	Hasta 65,000 pies	Ilimitado (BLOS)	Teatro COM	
	Sano	Estratégico / Nacional	Hasta 65,000 pies	Ilimitado (BLOS)	Teatro COM	Halcón global
	Masculino	Operacional / teatro	Hasta 45,000 pies MSL	Ilimitado (BLOS)	JTF COM	Depredador B Depredador A, Harfang,TP Hermes 900

**Fuente: Curso aviación civil - OACI (2011)**

En base a la clasificación de Blyenburgh, y no siendo tan exhaustivos, estos autores presentan una guía para la clasificación de los UAS, principalmente de licencias, que son utilizadas por la Dirección General de Aeronáutica Civil (DGAC) del Ministerio de Transportes y Comunicaciones del Perú (DGAC – MTC 2015).

La normativa española y peruana clasifican los UAV por su peso. De acuerdo a ello, se asignan las tareas que pueden hacer legalmente. Los **UAV menores de 2 Kg** pueden realizar vuelos tipo BVLOS (fuera del alcance visual), condicionado a la emisión de un NOTAM. Los **UAV menores de 10 Kg** podrán operar en zonas urbanas y en espacios donde hay

concentración de personas al aire libre. Los **UAV de hasta de 25 Kg** son considerados drones de uso comercial y requieren de permisos para volar (PAE 2015, MDE 2009, OACI 2015) (Tabla 6).

#### **2.4.2.5 Utilización de la plataforma UAS en el estudio de recursos naturales y pastizales**

El uso los UAS como plataformas de detección remota ofrece la posibilidad de adquirir ortofotografías de alta resolución espectral, espacial y temporal, imágenes utilizadas para la clasificación de pastizales (La liberte 2011). En los últimos años el uso de las UAS ha crecido considerablemente, empleándose con éxito para cartografiar los bosques, los pastizales (Dunford 2009), las malas hierbas, los suelos y los cultivos (Rango *et al.* 2009).

El monitoreo en los cambios de la cobertura del pastizal, cultivar y de uso del suelo resulta siendo un tema de gran interés en el campo de la conservación y la producción de biomasa aérea, permitiendo estudiar el estado de coberturas de alta importancia como el bosque, los matorrales, los bofedales, pastos cultivados y cultivares en general. Para esté fin las ortografías adquiridas con plataformas UAS cuentan con alta resolución espacial, temporal (a tiempo real) y radiométrica (Pricope *et al.* 2019, Easdale *et al.* 2019, Ulrike *et al.* 2020).

Los sistemas de monitoreo de biomasa de los pastizales, la estructura de la pradera y la variabilidad espacio temporal es de importancia clave en las decisiones de gestión sostenible de los sitios de pastizal. Ulrike *et al.* (2020) para la predicción de la biomasa de pastizales encuentra coeficientes de determinación de  $R^2$  0.57 a 0.73 para biomasa seca y  $R^2$  0.43 a 0.79 para biomasa fresca.

Marabel (2016) con ortofotografías multiespectrales (R, G, B, NIR) adquiridas con sistemas aerotransportados y con el modelo de análisis máquina de soporte de vectores (SVM, *Super Vector Machine*) y con modelos de regresión lineal por mínimos cuadrados parciales (PLS, *Partial Least Squares*) y la regresión por mínimos cuadrados realizó estimaciones de

biomasa, obteniendo rectas exactas durante el proceso de calibración ( $R^2= 0,99$  en las 4 bandas: R, G, B, NIR y un RMSE por inferior a 0,020%).

## 2.5 ALTURA DE VUELO Y CALIDAD DE IMAGEN ADQUIRIDA CON SENSORES REMOTOS

La resolución espectral de las imágenes adquiridas con sensores en vehículos aéreos no tripulados (UAS), además de la calidad del sensor remoto, dependen de la altura de vuelo, la hora de vuelo y las condiciones ambientales (Kharuf *et al.* 2018).

Ulrike *et al.* (2019) para el monitoreo de biomasa en pastizales, utilizando plataformas UAS compuesto por un vehículo Phantom 4 Advanced DJI, recopilaron fotografías multiespectrales a 25 metros de altura de vuelo. Los pixeles de las ortofotografías obtenidas fueron de 2.6 a 3.6 cm y de alta resolución radiométrica. Imágenes que permitieron estimar biomasa con un  $R^2 = 0,87$  con (RMSE 0.274) y  $R^2 = 0,78$  (RMSE 0.278).

Easdale *et al.* (2019) para evaluar pastizales utilizando un UAV de ala fija de 2 kg que transportaba una cámara con resolución de 16 megapíxeles, desarrollaron vuelos a 200 m de altura capturando fotografías con resolución espacial de 7 cm (pixel: 7cm x 7 cm): El autor explica que por la altura de vuelo con la que se adquirió las imágenes, fue necesario realizar correcciones radiométricas y geométricas, para luego generar un ortomosaicos multiespectrales de cuatro bandas (rojo, verde, azul e infrarrojo cercano). A partir de estas imágenes se logró identificar tres zonas: Zona con dominancia de estepa graminosa y su referencia a la parte alta de la cuenca, zona de estepa, y su referencia a una cuenca media y la zona asociada a los cursos principales de agua y relacionada a la cuenca baja.

Grüner *et al.* (2019) con la finalidad de predecir biomasa en pastos cultivados de clima templado con un UAV Phantom Advanced 3 DJI, implementaron vuelos a 20 metros de altura, obteniendo imágenes con resolución espacial de 7 y 8 cm por pixel. A esta altura de vuelo logró diferenciar mezclas de gramíneas y leguminosas en pasturas de trébol rojo, alfalfa y Rye gras italiano.

Vinícius *et al.* (2019) tomaron imágenes de cultivo de maíz híbrido (AG1051) con sensores transportados por UAV a 30 y 60 m de altura de vuelo, encontrando que los valores estimados fueron más precisos utilizando la lente ojo de pez a 30 m de altitud, correspondiente a 2,97 kg m<sup>2</sup>, que está muy cerca de los valores medidos en campo (2,92 kg m<sup>2</sup>).

En un estudio de identificación de variedades de caña de azúcar utilizando una cámara Parrot Sequoia, se aplicaron vuelos a tres diferentes alturas: 40 m (vuelo I), 80 m (Vuelo II) y 120 m (vuelo III), a una velocidad de 6 m/s (Kharuf *et al.* 2018). El análisis mostró que el tamaño de los pixeles de las ortofotos fue de 3 cm, 7 cm y 11 cm para el sensor multiespectral, y de 2 cm, 3 cm y 5 cm para el sensor RGB en función de las respectivas alturas de vuelo. El estudio llegó a la conclusión de que la información del vuelo III, a 120 m de altura, presentó imágenes de buena resolución espectral, al mismo tiempo que permitió mapear un área mucho mayor.

La calidad de la imagen adquirida por los sensores remotos está relacionada al número y tamaño de los pixeles (Ishida *et al.* 2017). Bajo esta hipótesis, usando sensores remotos en UAS y con el objetivo de identificar árboles de mango con mayor precisión que las imágenes satelitales, se adquirieron 200 imágenes de plantaciones de mangos a 25 y 50 m de altura, con resolución de 656 x 494 pixeles. La distancia de muestreo de tierra esperada (GSD) fue aproximadamente de 57 mm, a una altura de 25 m y 115 mm. Pero los resultados no mostraron diferencias en la calidad de la imagen para identificar los árboles de mango a una altura de 50 m.

Kharuf *et al.* (2018), encontraron que las imágenes del vuelo a 40 m, no generan buenos resultados en la reconstrucción de las imágenes RGB, mostrando espacios vacíos en la zona central de la ortofotografía, debido a que no se logra el traslape necesario entre imágenes. Los mosaicos obtenidos a 80 y 120 m fueron procesados para obtener el índice NDVI, que fue contrastado con puntos de respuesta espectral específica en el cultivo de caña, confirmándose la relación entre sectores con altos valores de NDVI y bloques de alto vigor vegetal del cultivar de caña de azúcar.

En la actualidad, diversas investigaciones están explorando variables o criterios que faciliten la evaluación de la calidad de la imagen adquirida en relación a la altura de vuelo, de modo que puedan ser aplicados en estudios de vegetación.

Azcoiti (2016) y Zafra (2017), proponen tres grandes variables: nube de punto, modelo digital de elevación (MDE) y ortofoto, cada una con sus respectivos indicadores.

Para la variable nube de puntos se utilizaron dos indicadores: número de puntos generados en el procesamiento de imágenes a diferentes alturas de vuelo y distribución de la nube midiendo el número de celdas hasta el noveno nivel. Con estos dos indicadores, Azcoiti (2016) determinó que analizar imágenes de vuelos a diferentes alturas con el respectivo aumento de imágenes no mejora la nube de puntos generados en el análisis. Utilizando el test de Chi<sup>2</sup>, comparó la nube de puntos con la realidad del terreno, obteniendo la desviación estándar y la distancia media de la nube de referencia al objeto de estudio. Los resultados de este análisis muestran que la distancia media aumenta con la introducción de vuelos de diferentes alturas.

Azcoiti (2016), respecto a la variable Modelos Digitales de Elevación (MDE), midió los valores correspondientes a las localizaciones de los puntos de control, calculando el Error Cuadrático Medio (RSME). Los resultados muestran que los vuelos a diferentes alturas no generan modelos más precisos. Los vuelos de menor altura muestran menor error. Un indicador no evaluado que se puede incorporar, es el análisis de altimetría respecto al punto de control (Boix 2015).

Para la evaluación de la calidad de la ortofoto, se debe considerar la variable *calidad de la imagen*, usando el indicador *número de pixeles creados por altura de vuelo*. Se debe tomar en cuenta que los pixeles obtenidos de vuelos más bajos contienen mayor cantidad de datos que los pixeles de vuelos a mayor altura. El segundo indicador de apoyo es la *calidad de la georreferencia*, que se utiliza para comparar la calidad de las ortofotos con la realidad. Así también, se debe tomar en cuenta la herramienta del *error cuadrático medio* (RMSE), cuya

aplicación permite disminuir el error conforme aumenta la introducción de vuelos a diferentes alturas (Azcoiti 2016 y Quispe 2016).

Para analizar la distancia de muestreo en tierra (GSD) en la generación de cartografía, utilizando tecnología UAS con cámara de 5 MP de resolución en fotogrametría, Quispe (2015 y 2016), implementó vuelos y adquirió imágenes de 50 m, 75 m, 100 m, y 125 m de altura con respecto a la posición de despegue. Esto le permitió realizar un adecuado análisis entre el nivel de resolución espacial y los elementos detectables para generar cartografía digital y/o analógica. Los resultados muestran que, de acuerdo al GSD de las ortofotos obtenidas con el UAV y el sensor utilizado, se pueden elaborar productos cartográficos a escalas de 1:1000, 1:750, 1:500 y 1:250 (Quispe 2015 y Quispe 2016).

La calidad de una imagen puede determinarse a partir de la observación y conteo de los árboles, arbustos u otras características que marquen la diferencia entre individuos u objetos (Falk 2014). Es así que, en una imagen aérea tomada desde un ángulo cenital, los árboles y arbustos pueden ser reconocidos por la forma de la copa o canopia, similar a un círculo, y por la sombra que proyectan sobre el suelo (Perrin 2004).

Dadas las características de las copas de los árboles, estos presentan altos valores en la banda del infrarrojo cercano, mientras que las zonas cubiertas por sombras presentan valores bajos en todas las bandas. En lugares donde los árboles son pequeños, estos se diferenciaron no solo por sus parámetros radiales, sino también porque presentaron menor intensidad infrarroja por tener poca vegetación. De esta manera, sus valores de intensidad no pudieron superar el umbral y no fueron detectados. Sin embargo, se puede vincular los tamaños de las copas y las sombras con los parámetros morfométricos de los árboles a fin de brindar estimaciones de la producción (Falk 2014).

## **2.6 ESCALAMIENTO DE ORTOMOSAICOS OBTENIDOS CON IMÁGENES ADQUIRIDAS POR UAV A UNA IMAGEN SATELITAL**

La evaluación de pastizales en regiones andinas es una herramienta clave para realizar diagnósticos ambientales y planificar el manejo ganadero. Si bien hay un consenso entre los investigadores sobre la utilidad de esta herramienta en los andes peruanos, resulta ser de alto costo, evaluar pastizales que (tengan grano fino) o mucho detalle en campo y a la vez, cubrir paisajes (extensión) con zonas muy amplias. Siendo necesario compatibilizar la resolución espectral, la calidad de la información obtenida, con la extensión espacial del área de estudio donde se requiere para tomar decisiones y en los ecosistemas de pastizales este aspecto todavía es un desafío (Elisalde 2002 y Gomes 2005).

Easdale *et al.* (2018) clasificaron ecosistemas de pastizal mediante el uso de imágenes satelitales y ortofotografías adquiridas con UAV y comparó sus respectivas contribuciones para evaluar pastizales. Comparó la resolución espacial de una clasificación realizada con imágenes satelitales SPOT 7 y ortografías capturadas por un sensor óptico transportado por un UAV. Concluyendo:

- Que las características diferentes de los datos capturados por sensores del satélite SPOT 7 y de los sensores transportados en UAV ofrecen una complementariedad alta debido al tipo de información que pueden brindar.
- Las imágenes obtenidas con UAV se podrían usar para diferenciar la estructura de la vegetación de un píxel, en los lugares clave identificados para dar un seguimiento continuo o temporal y muy detallado de ciertos ecosistemas, que sirva como soporte de decisiones para el manejo de pastoreo en pastizales heterogéneos.
- La precisión de producción de biomasa y calidad forrajera de las comunidades vegetales estimadas con ortofotografías de las UAV, no pueden ser estimadas con la misma precisión con imágenes satelitales, aún estas sean de alta resolución.

Bradshaw (2019), analizó la viabilidad de clasificar en sincronía y acceder a información de vegetación a nivel comunitario, utilizando dos plataformas de teledetección, UAS y *Planet Scope*. Se utilizaron tres diferentes métodos de clasificación: árbol de decisiones de productividad, árbol de decisión basado en estructura y una clasificación supervisada. Los resultados muestran que ningún método de clasificación arrojó la precisión esperada, aún con imágenes de alta resolución. Se concluyó que las dos plataformas no tienen una relación sólida para informar el análisis de pixeles aplicado en extensiones grandes o en diferentes escalas temporales, esto principalmente por las discrepancias entre los sensores tanto en resolución espectral y espacial.

La utilización de productos tele detectados (fotografías áreas e imágenes satelitales) ha sido central para el análisis de los espacios urbanos (Bradshaw 2019). Por ejemplo, a partir de las imágenes adquiridas con Sentinel 2 MSI y el Landsat 8 OLI, se comparó los resultados de diversos índices NDVI, SAVI, NDWI y MNDWI en estos dos satélites. Las imágenes utilizadas fueron corregidas a reflectancia de superficie y recortadas por el área de interés. Luego se calcularon todos los índices y a partir de las herramientas de análisis local se realizaron las comparaciones. A partir de los resultados obtenidos, se puede concluir que ambos sensores son comparables con un nivel de correlación de 0,90. El satélite Sentinel 2A permite un mayor nivel de detalle con su resolución espacial, mejorando el análisis de las zonas estudiadas.

Las imágenes adquiridas de plataformas satelitales son calibradas mediante correcciones geométricas y atmosféricas para su utilización. Las correcciones pueden generar distorsiones entre imágenes obtenidas en diferentes estaciones o tiempos, debido a la concentración de aerosoles y nubes presentes en la atmósfera. Estos sensores disponen de un alto número de bandas o resolución espectral, aunque el tamaño de los pixeles o resolución espacial es demasiado grande, ocasionando que la reflexión del suelo o de las hierbas generar alteraciones en la precisión de la imagen (Ceroni *et al.* 2015).

La calibración radiométrica de la imagen adquirida con UAV es más sencilla, estas no necesitan la calibración atmosférica. Esta característica le permite una elevada precisión, y

facilita una perfecta comparación temporal de imágenes. Los sensores transportados por drones disponen de menos tres bandas (resolución espectral), pero su elevada resolución espacial permite obtener información para un análisis más preciso de la vegetación (Bradshaw 2019 y HEMAV 2018).

Una vez establecidos los criterios y parámetros que condicionan el uso de una plataforma y el análisis que se desea realizar sobre los cultivos se determina el uso de la plataforma, para ello es importante destacar que su combinación de sistemas supone tener información de calidad y útil de la vegetación. La calidad de un píxel para estudiar vegetación está definida por la resolución, si esta imagen contiene información del cultivo únicamente o existe la presencia de otros materiales que cambien la calidad de la radiometría (Bradshaw 2019, HEMAV 2018 y Santa *et al.* 2013).

### **III. MATERIALES Y MÉTODOS**

#### **3.1 UBICACIÓN DEL ÁMBITO DE ESTUDIO**

El estudio se realizó en dos sectores, el fundo San Vicente de Palcca de la comunidad de Chalhuanca del distrito de Yanque (zona de bofedales), y en el fundo Quena de la comunidad Hanansaya I del distrito de Callalli (zona de tolares).

La zona de estudio corresponde a una franja altiplánica de la provincia de Caylloma, región Arequipa. Se encuentra ubicada entre las coordenadas 71° 15` a 71° 20` longitud oeste, y de 15° 15` a 16° 20` latitud sur. La altitud va desde los 3800 a 5000 msnm (Figura 9).

La zona es considerada como semiárida y clasificada como zona homogénea de producción de puna seca. Tiene una precipitación pluvial media de 415.1 mm/año. Presenta una temperatura máxima de 13.8 °C y media mínima de -4.08 °C (Tapia y Flores 1984).

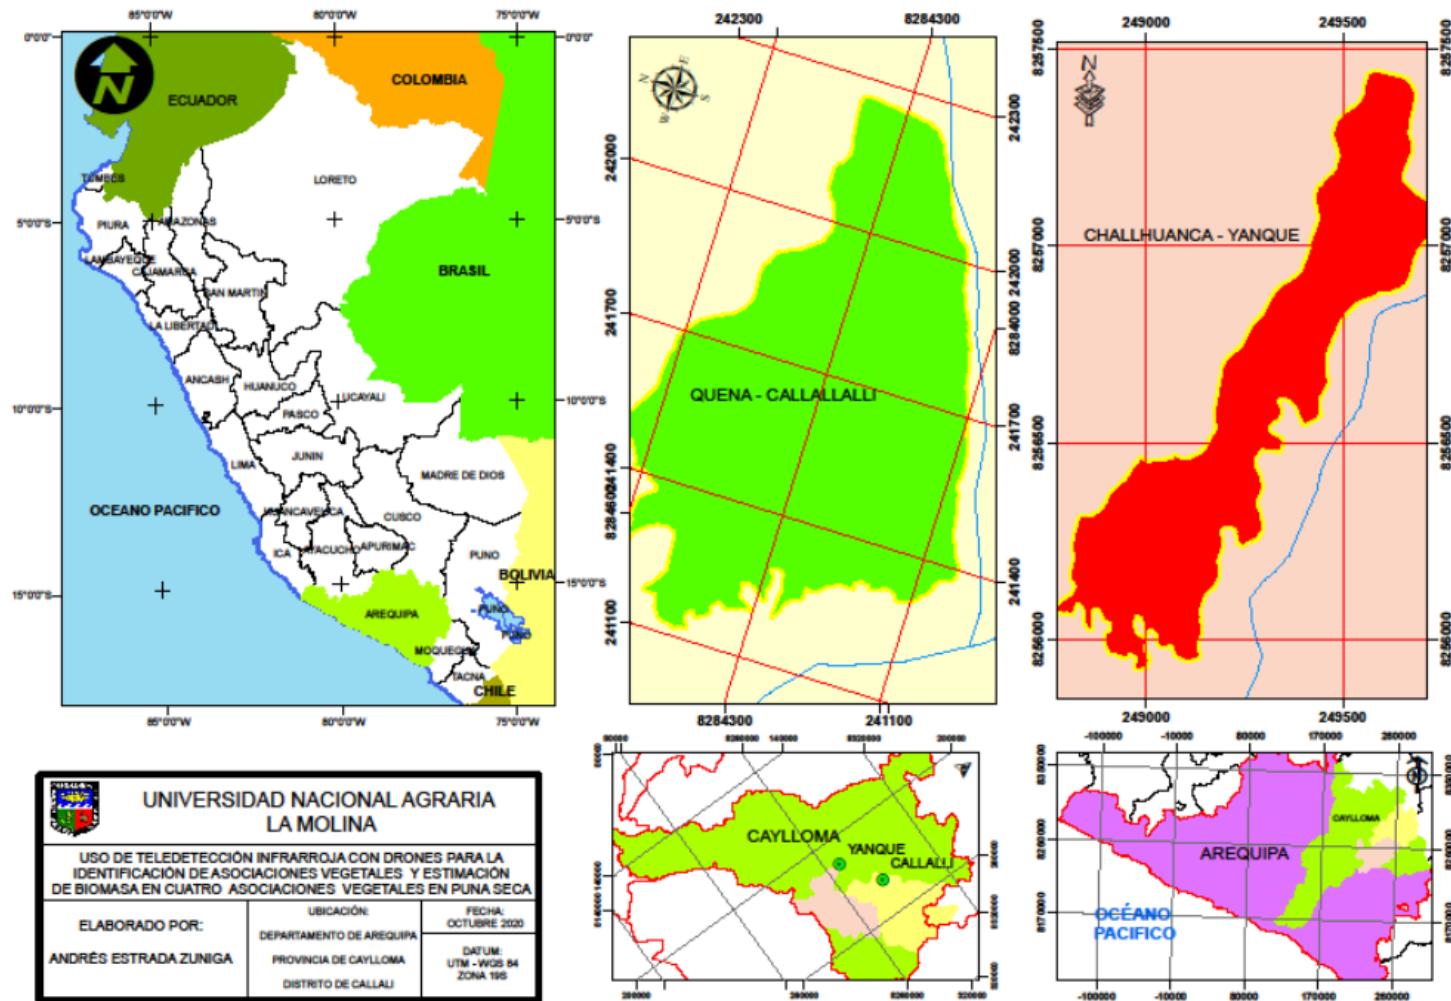


Figura 9: Zona de estudio

### 3.2 PROCESO METODOLÓGICO DE LA INVESTIGACIÓN

El objetivo general de la investigación es diseñar una metodología de identificación y estimación de biomasa para comunidades vegetales de puna seca, mediante sensores multiespectrales transportados por sistemas aéreos no tripulados (UAS) y validar el escalamiento de ortomosaicos obtenidos con el sistema UAS hacia una imagen satelital. Por ello la metodología para la investigación se planteó un proceso por objetivo.

#### 3.2.1 Proceso metodológico para determinar la altura de vuelo del UAV para la detección e identificación de comunidades vegetales tolar y bofedal

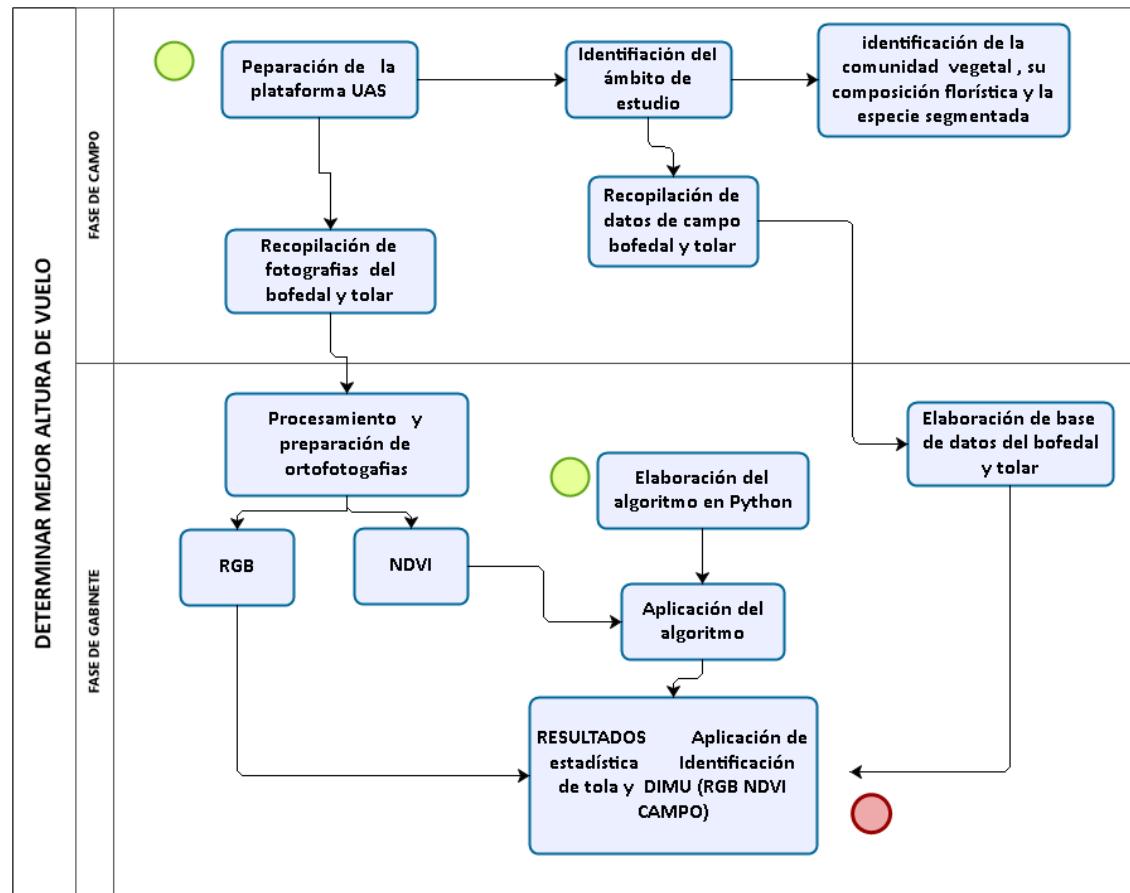


Figura 10: Proceso metodológico para determinar la altura de vuelo

### 3.2.1.1 Fase de preparación y campo

#### 3.2.1.1.1 Plataforma UAS para la recopilación de fotografías y generación de ortofotografías RGB y NDVI

La adquisición de fotografías para determinar la mejor altura de vuelo para identificar comunidades vegetales tolal y bofedal, se realizó con una plataforma UAS equipada con accesorios de las siguientes características.

- ❖ **UAV multirrotor Matrice 100 DJI:** Equipado con cámaras DJI Zenmuse X3 RGB y NDVI de 12.4 Mpx, con una resolución de 10 cm/pixel a 100 m de altura. El UAV desarrolló una autonomía de vuelo de 20 minutos, a una altura de 4500 msnm. Durante el estudio esta plataforma se utilizó para la adquisición de imágenes RGB y NDVI en alturas de vuelo de: 25, 50, 75 y 100 m (Figura 11).
- ❖ **GPS Diferencial SPECTRA:** Nivel profesional, con sistema GPS GALILEO y GLONASS, con RKT y precisión de 2 cm, con antena interna de 25 canales. Este equipo se utilizó para la ubicación de puntos de control en tierra.
- ❖ **Sistema computación:** se utilizó para la generación de ortofotografías y desarrollo de los modelos.

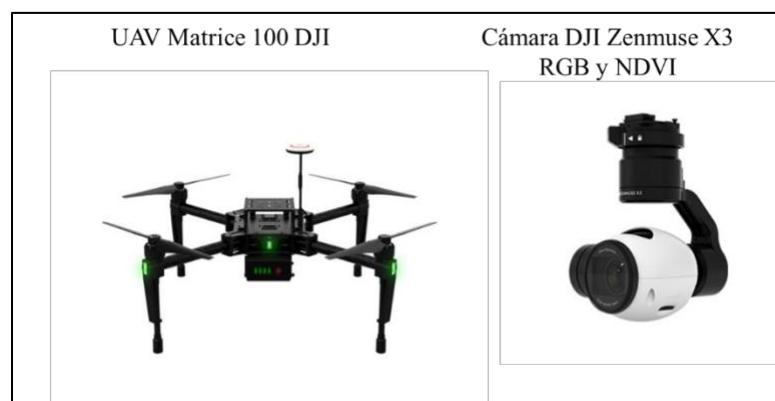


Figura 11: Plataformas UAS DJI utilizado para determinar altura de vuelo

### **3.2.1.1.2 Identificación de comunidades, composición florística e identificación de la especie sobresaliente para la segmentación**

La etapa preparatoria consistió en la identificación de los lugares de estudio e identificación de la composición florística, selección de la especie sobresaliente. Para la elaboración del algoritmo la especie sobresaliente se denomina especie segmentada.

#### **a. Identificación y selección de los lugares de estudio y especie sobresaliente**

Para realizar la identificación y selección de los lugares de estudio se realizaron las siguientes actividades:

- Revisión de literatura e informes sobre las principales comunidades vegetales presentes en el ámbito de estudio y su importancia para el desarrollo de la actividad pecuaria de camélidos sudamericanos.
- Identificación de propietarios de las unidades productivas y establecer un compromiso para no extraer el arbusto tola durante los tres años que duró el estudio. Se estableció un acuerdo, que permitió al equipo investigador acceder a realizar mediciones, tomar muestras y realizar vuelos con los UAV en dos épocas del año, en marzo y octubre.
- Con los acuerdos establecidos se eligió como lugares de muestreo para la comunidad vegetal tolar el fundo Quena ubicado en el distrito de Callalli y para la comunidad vegetal bofedal el fundo San Vicente de Palca ubicado en la Comunidad del Chalhuanca del distrito de Yanque, ambas en la provincia de Caylloma, región Arequipa.
- En esta etapa se realizó una primera evaluación de las comunidades vegetales, donde se identificó la especie sobresaliente para la elaboración del algoritmo. Siendo la especie segmentada la ***Distichia muscoides*** (DIMU) para la comunidad

vegetal bofedal y la *Parastrepia lepidophylla* (tola) para la comunidad vegetal tolara ambas de puna seca. Finalmente se determinó la composición florística de cada una de las comunidades vegetales (Tabla 7 y Tabla 8).

**Tabla 7: Composición florística del bofedal de Chalhuanca**

CLASE	FAMILIA	ESPECIE
Bofedal de Distichia (Bofedal de Kunkuna)	Juncaceae	<i>Distichia muscoides.</i>
		<i>Oxicloe andicola.</i>
	Plantaginaceae	<i>Plantago tubulosa</i>
Bofedal (Oqo Pilli; Pacupacu y <i>Plantagos</i> <i>sp</i> )	Rosaceae	<i>Lachemilla pinnata.</i>
	Asteracea	<i>Hipochoeris sessiflora</i>
		<i>Hypochoeris taraxacoides.</i>
		<i>Werneria picnaea</i>
	Poaceae	<i>Acciane Pulvinata</i>
Inclusiones de césped de puna.	Cyperaceae	<i>Carex sp.</i>
	Poaceae	<i>Calamagrostis rigescens.</i>
	Rasaceae	<i>Lachemilla pinnata</i>
Inclusiones de <i>chilliwar</i> (zona de transición)	Fabaceae	<i>Trifolium amabili</i>
	Poacea	<i>Festuca dollicophilla.</i>
	Rasaceae	<i>Lachemilla pinnata</i>
Inclusiones de agua más especies acuáticas	Fabaceae	<i>Trifolium amabili</i>
	Rosaceae	<i>Lachemilla diplophilla.</i>
	Haloragecea	<i>Miripyllum elantoides (Llacho)</i>
	Nostocaceae	<i>Nostoc sphaericum (Llullucha)</i>
	Ranunculaceae	<i>Ranunculus flagelliformis.</i>

**Tabla 8: Composición florística de la comunidad vegetal bofedal -fundo Quena-**

CLASE	FAMILIA	
Tolar	Asteracea	<i>Parastrepia lepidophylla.</i> <i>Parastrepia quadrangulare.</i> <i>Parastrrepia philicaeformis.</i> <i>Baccharis tricuneata.</i> <i>Baccharis buxifolia.</i>
Inclusión de césped de puna	Poaceae	<i>Muhlenbergia peruviana.</i> <i>Muhlenbergia fastigiata.</i> <i>Paspalum pygmaeum.</i> <i>Calamagrostis Vicugnarum.</i> <i>Poa candamoana.</i>
	Rasaceae	<i>Lachemilla Pinnata.</i>
	Fabaceae	<i>Trifolium amabili.</i>
Inclusiones de gramíneas altas	Poaceae	<i>Festuca ortophylla.</i> <i>Stipa Ichu.</i> <i>Stipa obtusa.</i>
Inclusiones de kanllereres asociada a otras especies	Rosacea	<i>Margiricarpus strictum.</i> <i>Margiricarpus pinantum.</i>
	Efeiraceae	<i>Ephedra americana.</i>
	Cactacea	<i>Opuntia Floccosa.</i>

### **3.2.1.1.3 Recopilación de información en las comunidades vegetales tolar y bofedal**

#### **a. Recopilación de información y muestras en campo**

Para la recolección de datos en campo se utilizó el método del cuadrante georreferenciado, siendo este de 100 m<sup>2</sup> (10 m x 10 m). En los 100 cuadrantes seleccionados se realizó el conteo de la especie segmentada que para el estudio fueron el arbusto de tola (*Parastrepia lepidophilla*) y los cojines de DIMU (*Distichia muscoides*)

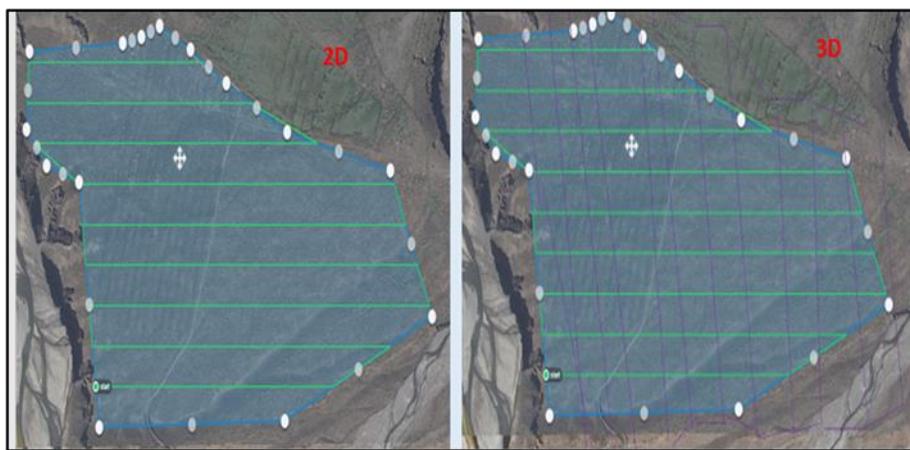
En la comunidad vegetal tolar, en cada cuadrante se identificó al azar 100 plantas de tola para medir altura de planta, la base menor (pegado al suelo) y la base mayor o canopia y luego estas plantas fueron extraídas para determinar la biomasa en materia verde (MV) y materia seca (MS).

Para la comunidad vegetal bofedal, se tomaron 100 muestras de cojines/almohadillas de *Distichia muscoides*, donde se midió la altura o elevación del cojín y su diámetro. Para la estimación de biomasa se tomó muestras en cuadrantes de (10 cm x 10 cm), dimensión que se aproxima al tamaño de un pixel.

#### **b. Recopilación de fotografías con la plataforma UAS**

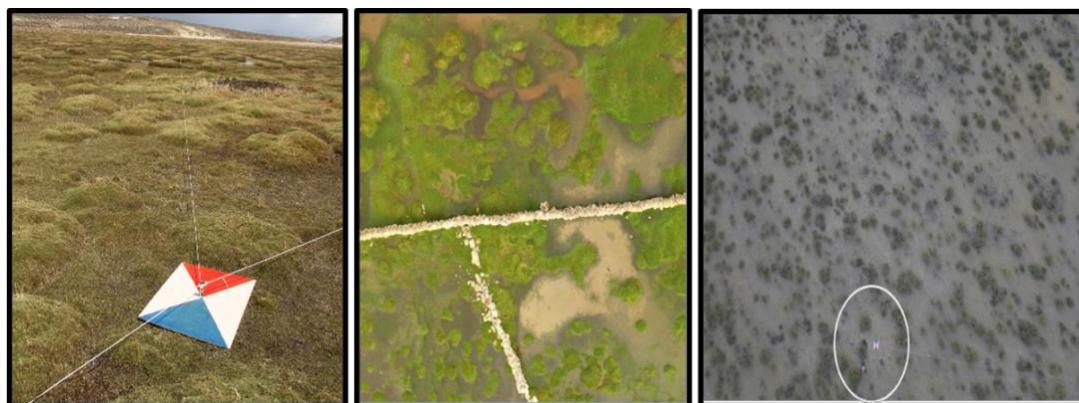
La adquisición de fotografías con la plataforma UAS se realizó dos veces al año: al final de la época de lluvia (marzo) y al final de la época seca o de estiaje (octubre). Para este fin se siguieron los siguientes pasos.

- **La planificación de vuelos** se realizó con el software Drone de Ploy (D’Oleira 2012). Los planes de vuelo fueron diseñados con una sola grilla o con líneas de vuelo paralelas, con el fin de lograr una superposición o traslape de imágenes del 70%. (Figura 12).



**Figura 12: Planes de vuelo 2D y 3D**

- **Los puntos de control en tierra** son referentes para realizar las correcciones geométricas en el proceso de elaboración de las ortofotografías (D’Oleira 2012). En cada zona de vuelo se colocaron tres puntos de control en tierra (cada una con un punto central y tres puntos extremos al final de una transecta fija de 100 m). Estos puntos eran cuadrantes de triplay de 80 x 60 cm, pintados de color azul, rojo y blanco, fácilmente identificados por el sensor y reconocidos durante el tratamiento de las fotografías (Figura 13). Cada uno de los puntos de control tienen datos georreferenciados de alta precisión y fueron tomados con GPS diferencial.



**Figura 13: Puntos de control en tierra**

- **Misión del UAV para la adquisición de fotografías.** Las misiones de vuelo para la adquisición de fotografías se realizaron a 25, 50, 75 y 100 m de altura. Se utilizaron sensores RGB, NDVI y multiespectrales. Considerando el rendimiento de los UAV.
- **La hora de vuelo** en todos los casos fue desde las 9:00 hasta las 13:00 horas, tiempo que se determinó en función de las condiciones climatológicas, como presencia de lluvia y vientos con alta velocidad que ponían en riesgo la seguridad de los UAV (Tabla 9).

### **3.2.1.2 Fase de gabinete**

#### **3.2.1.2.1 Preparación de la base de datos y ortofotografías multiespectrales**

La base de datos se elaboró con información de campo y laboratorio. La base de datos contiene información sobre altura de planta y diámetro, materia verde y materia seca, ortofotografías RGB y NDVI procesadas de acuerdo al ámbito de estudio. La base de datos fue creada dando los siguientes pasos.

##### **a. Ordenamiento y preparación de datos de campo**

Los datos obtenidos en campo fueron ordenados en una tabla de excel contando con la información siguiente:

**Arbusto Tola: La información almacenada en la base de datos fue:** Altura de la planta, diámetro de base menor (ras del suelo), diámetro de base mayor (canopia) y peso de las plantas de tola (muestra).

**Cojines de DIMU: La información almacenada en la base de datos fue;** Altura del cojín, diámetro del cojín, peso de la muestra tomada en un cuadrante de 10 cm x 10 cm.

### **b. Generación de ortofotografías RGB y NDVI en la plataforma DJI**

Las fotografías RGB y NDV adquiridas con el sensor Zenmuse X3 RGB y NDVI, fueron procesadas en la plataforma DJI. Logrando contar con ortofotografías RGB y NDVI de las dos comunidades en estudio para 25, 50, 75, 100 m de altura (Anexo 1).

### **c. Preparación de ortofotografías en cuadrantes para ser leído por el algoritmo creado**

Las ortofotografías RGB y NDVI adquiridas a 25, 50, 75 y 100 m de altura fueron de las comunidades vegetales tolar y bofedal fueron recortados en cuadrantes de 10 m x10 m (100 m<sup>2</sup>) utilizando el software Arc Gis. Para realizar el recorte de las muestras se utilizó los puntos de GPS tomados en los cuadrantes durante el trabajo de campo. En esta etapa se preparó 100 muestras de imágenes RGB y NDVI a diferentes alturas de vuelo que fueron utilizados para alimentar al algoritmo creado (Anexo 2a).

### **d. Creación del algoritmo en Python**

Se elaboró un algoritmo en el lenguaje de programación *Python* con la capacidad de contabilizar objetos segmentados mediante la lectura de umbrales NDVI encontrados en las ortofotografías (Anexo 2b).

Las especies segmentadas para el estudio fueron: el arbusto de *Parastrephia lepidophylla* o “tolá” para la comunidad vegetal tolar y, los cojines de *Distichia muscoides* o “DIMU” para la comunidad vegetal bofedal de puna seca.

El algoritmo estuvo diseñado para utilizar como insumos de entrada: muestras de 10 m x 10 m de las imágenes NDVI adquiridas a diferentes alturas de vuelo (25, 50, 75 y 100 m), valor estimado de los umbrales inferior y superior de NDVI. Como producto de salida se tiene una nueva imagen con individuos o especies segmentadas contadas (Anexo 2a).

### **3.2.1.2.2 Procesamiento de información**

#### **a. Conteo de plantas de Tola y cojines de DIMU en ortofotografías RGB**

En las muestras de 10 m x 10 m de ortofotografías RGB adquiridas a 25, 50, 75 y 100 m de altura de vuelo se identificó y contó el número de especies sobresalientes. Para el caso de asociación vegetal tolar se identificó y contabilizó las plantas de *Parastrephia lepidophylla* (tola), mientras que para la comunidad vegetal comunidad bofedal se contabilizó los cojines de *Distichia muscoides* (DIMU).

#### **b. Aplicación del algoritmo creado sobre ortofotografías NDVI**

Para contabilizar el número de plantas de la especie segmentadas, plantas de arbusto de tola y cojines de DIMU se realizó los siguientes pasos (Anexo 2b, Anexo 2c):

- En las ortofotografías NDVI se realizó la valoración de los umbrales inferior y superior para las especies segmentada. Presentando un rango de valor de 0.20 a 0.45 para los arbustos de tola y un rango de valor de 0.68 a 0.95 de NDVI para los cojines de DIMU.
- En el algoritmo se incorporó el rango con umbrales superior e inferior para el conteo de la especie segmentada. Para identificar el mejor rango de identificación del arbusto tola se utilizó las muestras de ortofotografías NDVI adquiridas a 25 metros de altura y los rangos de: 0.20 a 0.45, 0.26 a 0.45, 0.31 a 0.45, 0.36 a 0.45, y 0.41 a 0.45; y para la identificación de cojines de DIMU utilizando muestras de ortofotografías NDVI adquiridas a 25 metros de altura se validó los rangos de NDVI (0.68- 0.95, 0.76 – 0.95, 0.81 – 0.95, 0.86 - 0.95 y 0.91 - 0.95).
- Para el conteo del arbusto de tola y cojines de DIMU, se alimentó el algoritmo con muestras de 10 m x 10 m para diferentes alturas de vuelo 25, 50, 25 y 100 m

para cada rango de valores del índice de vegetación NDVI validados en el paso anterior.

### c. Análisis estadístico con la técnica de mínimos cuadrados

Mínimos cuadrados es una técnica de análisis numérica de la optimización matemática, que busca encontrar una función continua que permita mejor aproximación a los datos observados en campo, de acuerdo con el criterio de mínimo error cuadrático. Esta técnica minimiza la suma de los cuadrados de las diferencias entre los puntos generados de la función elegida y los valores de datos.

En esta técnica los parámetros  $\beta_0$  y  $\beta_1$  son usualmente llamados coeficientes de regresión, los cuales tienen una interpretación, la pendiente  $\beta_1$  es el cambio en el promedio de la distribución de “Y” producida por el cambio en una unidad de “X”.

Los parámetros  $\beta_0$  y  $\beta_1$  son desconocidos y pueden ser estimados usando datos de muestras, los cuales pueden ser de un experimento, estudio observacional o de la existencia de datos históricos.

El método de mínimos cuadrados es utilizado para estimar  $\beta_0$  y  $\beta_1$  es decir, estimamos  $\beta_0$  y  $\beta_1$  de modo que la suma de los cuadrados de la diferencia entre las observaciones “Y” y la línea recta sea un mínimo. Por lo que  $\hat{\beta}_0$  y  $\hat{\beta}_1$  del intercepto y la pendiente son los estimadores de los mínimos cuadrados del intercepto y la pendiente respectivamente. De este modo el modelo de regresión simple será:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Esta ecuación muestra un punto de estimación del promedio de “Y” para un “X” en particular. La diferencia entre los valores observados de “Y” y los correspondientes valores ajustados de  $\hat{Y}$  es el valor residual, este valor residual juega un rol importante en la investigación de la adecuación del modelo y en detectar desviaciones de los supuestos subyacentes.

### 3.2.2 Proceso metodológico para estimar la producción de biomasa de comunidades vegetales tolar y bofedal a partir de signos espectrales e índices de vegetación

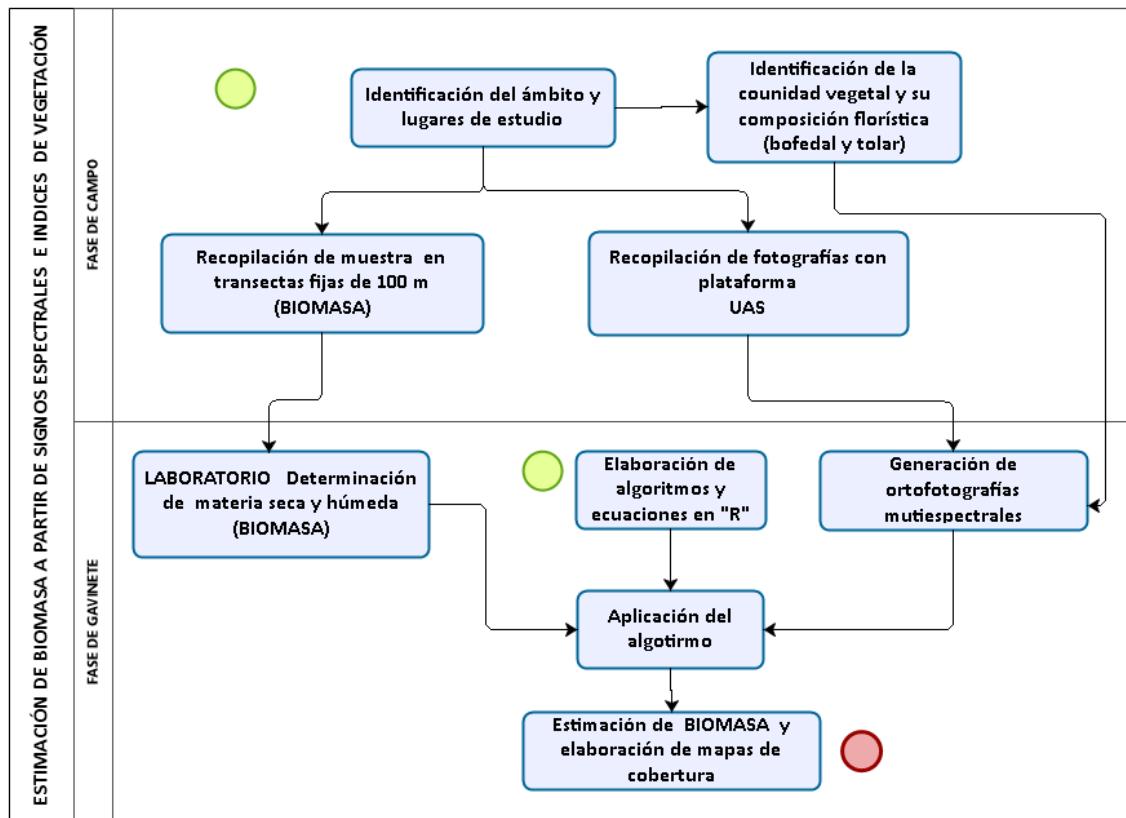


Figura 14: Proceso metodológico para estimar biomasa a partir de signos espectrales

#### 3.2.2.1 Fase de campo

##### 3.2.2.1.1 Preparación de la plataforma UAS para recopilación de fotografías

Para este objetivo la adquisición de fotografías para estimar la producción de biomasa en las comunidades vegetales tolar y bofedal de puna seca, se realizó con dos plataformas UAS equipada con accesorios de las siguientes características (Figura 14).

- ❖ **UAV Multirrotor Spyder DJI:** Equipado con una cámara Micasense de 12 Mpx, con sensor multiespectral de cinco bandas, azul, verde, rojo, borde rojo e infrarrojo cercano

(NIR). Presentaba una resolución de 6.35 cm/pixel a 100 m de altura. El UAV desarrolla autonomía de vuelo de 20 minutos, a una altura de 4500 msnm. Durante el trabajo de campo, esta plataforma se utilizó para adquirir fotografías multiespectrales a una altura de vuelo de 100 m (Figura 15).

- ❖ **UAV de ala fija eBee:** Equipado con una cámara Parrot Sequoia de 16 Mpx, con un sensor multiespectral de cuatro bandas espectrales, verde, rojo, borde rojo y NIR. Presenta una resolución de 13 cm/pixel a 120 m de altura de vuelo, y una velocidad de disparo de un segundo para todas las bandas.

El UAV con una autonomía de vuelo de 30 minutos a una altura de 4500 msnm. El UAV eBee se utilizó para recopilar imágenes multiespectrales a una altura de vuelo de 100 m. Esta UAV no puede utilizarse a menor altura por las condiciones geográficas de la zona de estudio y el requerimiento de un espacio amplio para la realización de su misión (Figura 15).

- ❖ **GPS Diferencial SPECTRA:** Nivel profesional, con sistema GPS GALILEO y GLONASS, con RKT y precisión de 2 cm, con antena interna de 25 canales. Este equipo se utilizó la ubicación de puntos de control en tierra.
- ❖ **Sistema de cómputo:** Se utilizó para la generación de ortofotografías y desarrollo de los modelos.



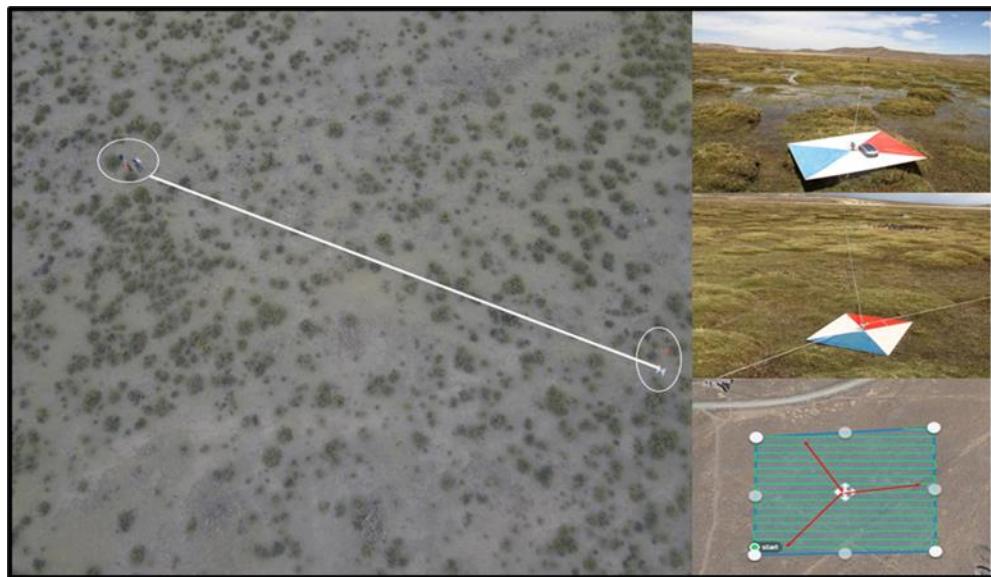
**Figura 15: Plataformas UAS utilizados en el estudio**

### 3.2.2.1.2 Recopilación de información en las comunidades vegetales tolar y bofedal

#### a. Recopilación de información y muestras en campo

Para la determinación de biomasa en la comunidad tolar, se tomaron 100 muestras de tola a lo largo de las transectas fijas. En el mismo acto se midió el diámetro de la menor (ras del suelo), diámetro de la canopia y la altura de la planta.

Adyacente a la muestra de tola, se tomaron 100 muestras de césped con un cuadrante de 0.25 x 0.25 cm. En lo posible se trató de mantener un metro de distancia entre cada muestra. Las muestras fueron inmediatamente pesadas en una balanza de 0.01 g de precisión (Figura 16).



**Figura 16: Puntos de control en tierra y transectas para muestreo de biomasa**

#### b. Recopilación de fotografías con la plataforma UAS

La adquisición de imágenes con la plataforma UAS se realizó dos veces al año: al final de la época de lluvia (marzo) y al final de la época seca o de estiaje (octubre).

Para este fin se siguieron los siguientes pasos:

- **La planificación de la misión**

La planificación de vuelos se realizó con el software PIX 4D, para dos y tres dimensiones (D’Oleira 2012). Los planes de vuelo para 2D fueron diseñados con una sola grilla o con líneas de vuelo paralelas, con el fin de lograr una superposición o traslape de imágenes del 70%. Los vuelos 3D se diseñaron con doble grilla o dos capas superpuestas de líneas paraleladas.

- **Los puntos de control en tierra**

Los puntos de control en tierra son referentes para realizar las correcciones geométricas en el proceso de elaboración de las ortofotografías (D’Oleira 2012).

En cada zona de vuelo se colocaron tres puntos de control en tierra (cada una con un punto central y tres puntos extremos al final de una transecta fija de 100 m). Estos puntos eran cuadrantes de triplay de 80 x 60 cm, pintados de color azul, rojo y blanco, fácilmente identificados por el sensor y reconocidos durante el tratamiento de las imágenes (Figura 16). Cada uno de los puntos de control tienen datos georreferenciados de alta precisión y fueron tomados con GPS diferencial.

**Tabla 9: Vuelos realizados por el DRONE**

UAV	FECHA DE VUELO		HORA DE VUELO	ALTURA DE VUELO (m)	TIEMPO DE VUELO POR BATER (min).	
	BOFEDAL	TOLAR			4500 msnm	3800 msnm
MATRICE 100 DJI	15/03/2017	15/03/2017	9:00 - 13:00	25 50 75 100	18	20
	12/10/2017	13/10/2017	9:00 - 13:00	25 50 75 100	18	20
	15/03/2018	16/03/2018	9:00 - 13:00	25 50 75 100	18	20
	12/10/2018	11/10/2018	9:00 - 13:00	25 50 75 100	18	20
	12/03/2019	11/03/2020	9:00 - 13:00	25 50 75 100	18	20
ebee	12/10/2018	11/03/2020	9:00 - 16:00	100	35	35
Spyder DJI	12/03/2019	11/03/2020	9:00 - 13:00	25 50 75 100	18	20

- **Misión del UAV para la adquisición de fotografías**

Las misiones de vuelo para la adquisición de fotografías se realizaron a 100 m de altura. Se utilizaron cámaras con sensores y multiespectrales Parrot Sequoia y Micasense (Tabla 9).

- **La hora de vuelo**

La hora de vuelo en todos los casos fue entre las 9:00 y las 13:00 horas, tiempo que se determinó en función de las condiciones climatológicas, como presencia de lluvia y vientos con alta velocidad que ponían en riesgo la seguridad de los UAV (Tabla 9).

### **3.2.2.2 Fase de gabinete**

#### **3.2.2.2.1 Preparación de la base de datos**

La base de datos estuvo compuesta valores de materia verde (MV), materia seca (MS), puntos GPS de cada punto de muestreo en un libro Excel, fotografías sin procesar en JPG y ortofotografías en formato TIF y JPG. Para crear la base de datos se realizaron los pasos que a continuación se detallan:

- a. Determinación de humedad y materia seca de la muestra tomadas en bofedales y tolares en laboratorio**

La materia seca (MS) representa el peso total de la muestra de pasto, menos su contenido de agua. El método más utilizado consiste el uso de calor para la eliminación del agua libre, que permite determinar el peso residual. Para es necesario someter las muestras a temperaturas adecuadas que permitan un secado rápido para disminuir pérdidas generadas por respiración celular y acciones enzimáticas (De la Rosa 2002).

Para determinar la materia seca de las muestras adquiridas en los bofedales y tolares, se utilizó una estufa de aire forzado a una temperatura de 105 °C, por un periodo de 24 horas (Chávez y Bolaños 2017). El principio de este método se basa fundamentalmente en la calefacción e ingreso de aire mediante resistencias eléctricas por circulación forzada mediante un sistema de ventilación termodinámica. Este sistema asegura la distribución uniforme de la temperatura a partir de la generación de un flujo homogéneo de aire caliente.

La fórmula utilizada para el cálculo de materia seca fue:

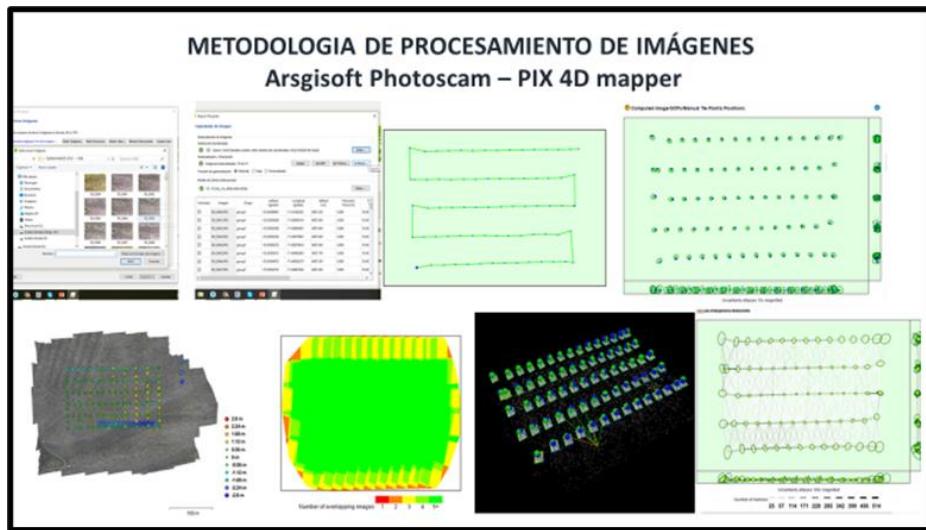
$$\% \text{ HUMEDAD} = \frac{\text{PESO DE LA MATERIA HUMEDA} - \text{PESO DE LA MATERIA SECA}}{\text{PESO DE LA MUESTRA HUMEDA}} \times 100$$

$$\% \text{ de MS} = 100 - \% \text{ Humedad}$$

### b. Generación de ortofotografías multiespectrales

Para el procesamiento de imágenes adquiridas por el sensor transportado por el UAV, se utilizaron los softwares de fotogrametría *Agisoft metashape* y *Pix-4D*, cuyo procesamiento tiene los siguientes pasos (Figura 17). Se amplia y detalla cada paso en el (Anexo 1).

- ❖ Añadir la carpeta o fotografías adquiridas por el UAV a la plataforma fotogramétrica *Agisoft metashape* y *Pix-4D*.
- ❖ Orientar las fotografías.
- ❖ Crear una nube de puntos densa.
- ❖ Crear malla.
- ❖ Crear textura.
- ❖ Crear el modelo de telsas.
- ❖ Crear modelo digital de elevación y crear ortomosaico.
- ❖ Creación de ortomosaicos RGB o con índice NDVI.



**Figura 17: Secuencia para procesar imágenes**

**c. Creación del algoritmo en R para determinar la biomasa a partir de signos espectrales**

Para la estimación de biomasa a partir de imágenes espectrales e índices de vegetación se formuló algoritmos en el lenguaje de programación *R*. Utilizando las librerías “Caret”, “Performance Analytics”, “Corrplot”, “RandomForest”, “Rgdal”, “Raster”, “Sp”, que tuvieron como insumo principal las ortofotografías multiespectrales obtenidas con la plataforma UAS (Anexo 3).

El algoritmo utilizando ortofotografías multiespectrales tiene el atributo de calcular diferentes índices espectrales (NDVI, SAVI, EVI, etc.) y generar mapas de cobertura, utilizando combinaciones de bandas espectrales e índices de vegetación a través del sistema de aprendizaje *Random Forest* (Anexo 3b).

Con el lenguaje de programación *R*, se elaboró algoritmos para clasificar coberturas, predecir la producción de biomasa e identificar y seleccionar variables en estudio (espectros e índices) (Anexo 3b).

Los algoritmos utilizaron como insumos: datos de muestras de campo, como materia verde y materia seca de las muestras vegetales; ortofotografías multiespectrales. Los productos resultantes del algoritmo son coberturas vegetales de la zona estudiada, predicción de producción de biomasa por pixel y estimación de la producción de biomasa por hectárea (Anexo 3c).

#### **d. Procesamiento de información utilizando el algoritmo elaborado**

El proceso se inició implementando los algoritmos elaborados en el lenguaje de programación *R*. Después del entrenamiento, se priorizaron las variables más importantes (las variables estuvieron compuestas por índices espectrales e índices de vegetación), a través la media decreciente de *Gini*.

Cada modelo se evaluó individualmente a través de un set de prueba, tomando en cuenta los parámetros de regresión  $R^2$ , RMSE y MAE.

Los pasos seguidos para la estimación de la biomasa a partir de signos espectrales fueron:

##### **❖ Índice de media decreciente de Gini (MDG)**

La disminución media de *Gini* es el promedio de la disminución total de una variable en la impureza del nodo, ponderada por la proporción de muestras que alcanzan ese nodo en cada árbol de decisión individual en el bosque aleatorio. Una media aleatoria más alta en *Gini* indica una mayor importancia de la variable.

##### **❖ Coeficiente de correlación de Pearson**

La prueba para la medición de la relación estadística entre dos variables continuas fue el coeficiente de correlación de Pearson. Este coeficiente de correlación presenta un rango de valores de +1 a -1. Un valor de 0 indica que no hay asociación entre las dos variables comparadas, mientras que un valor mayor que 0 indica una asociación positiva, es decir, que en la medida que aumenta el valor de una variable, también

aumenta el valor de la otra variable, y un valor menor a 0 indica una asociación negativa. Significa que a medida que aumenta el valor de una variable, el valor de la otra variable disminuye.

$$r_{xy} = \frac{S_{xy}}{S_x S_y}$$

Las variables priorizadas del estudio fueron sometidas a una correlación de Pearson (rango de -1 a 1), con la finalidad de establecer los grados de asociación entre los datos de biomasa obtenidos en campo y los valores de los índices de vegetación seleccionados. En este mismo proceso se buscó también la correlación entre los diferentes índices de vegetación seleccionados y la producción de biomasa. Se dio énfasis al NDVI.

#### ❖ Modelos de predicción de biomasa

Para la predicción de biomasa se utilizaron los siguientes modelos: Regresión Lineal, *Support Vector Machines* (SVM) o máquina de soporte vectorial y el modelo *Random Forest random* o árbol de decisiones.

#### ❖ Modelo de Regresión Lineal Múltiple

La regresión lineal múltiple facilita la generación de modelos donde el valor de la variable de respuesta (Y) se determina a partir de un conjunto de variables independientes llamadas predictores ( $X_{1i}, X_{2i}, X_{3i}$ ).

Los modelos de regresión múltiple se emplean para predecir el valor de una variable dependiente o para evaluar la influencia que tienen las variables llamadas predictores sobre ella (Amat 2016 y Montgomery *et al.* 2012). La ecuación es la siguiente.

$$Y_i = (\beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_n X_{ni}) + e_i$$

**Donde:**

**Y**= Valor pronosticado de la variable respuesta, para un valor seleccionado de la variable **X**.

**Xi .... Xn** = Son los espectros (Green, Red, Blue, NIR) e índices de vegetación (NDVI, EVI, SAVI, NDRE, NDWI, GNDVI, SIPI, RVI)

**$\beta_0$**  = Es el término independiente. - Valor esperado de la variable dependiente cuando los predictores ( $X_{1i}.....X_{ni}$ ) son cero.

**$\beta_1, \beta_2, \beta_n$**  = Coeficientes de regresión parciales.- Es el efecto que tiene el incremento de una unidad de la variable  $X_i$  sobre la variable dependiente  $Y$ , manteniéndose constantes el resto de variables.

**$e_i$** : Es el residuo o error, la diferencia entre valor observado y estimado por el modelo.

#### ❖ Model Support Vector Machines (SVM)

El modelo SVM, o máquinas de soporte vectorial, son un conjunto de algoritmos de aprendizaje relacionados con problemas de clasificación y regresión.

Si hay un conjunto de muestras, el modelo puede etiquetarlas y, previa configuración, puede construir intuitivamente un modelo que represente la clase de una nueva muestra. El SVM identifica las muestras en un determinado espacio. Cuando las muestras nuevas se ponen en correspondencia con el modelo elegido, pueden ser clasificadas en función a los espacios que pertenezcan (Gregory 2016 y Gil 2018).

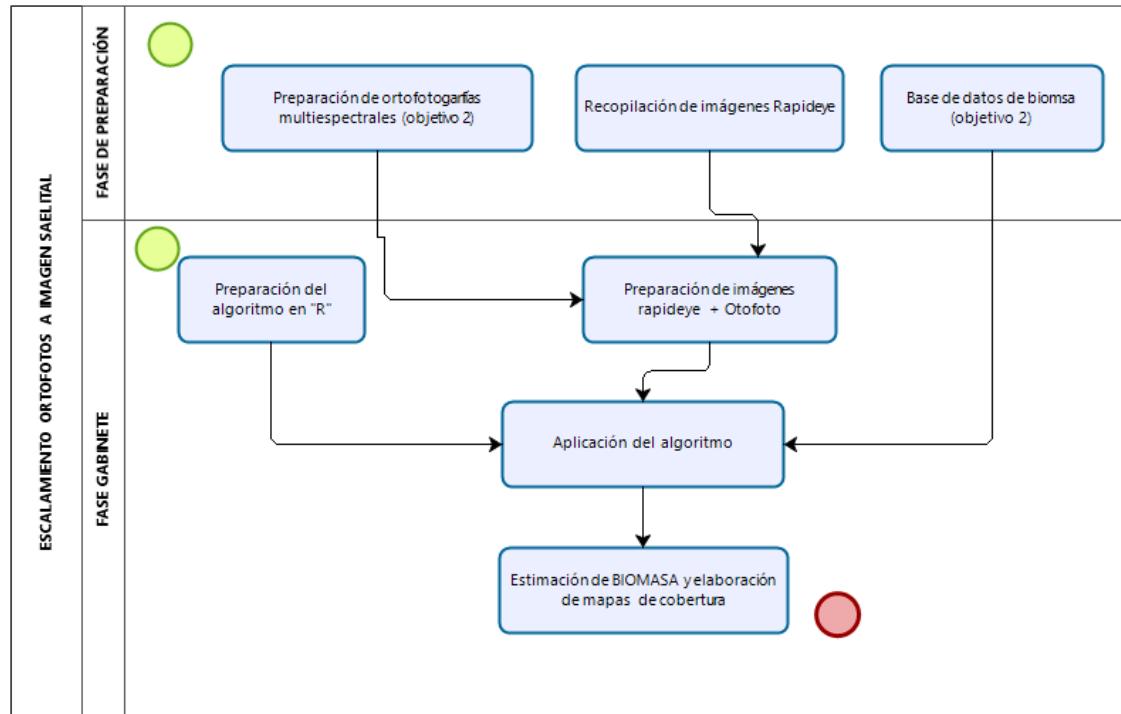
#### ❖ Modelo Random Forest – RF (Bosques aleatorios) para predicción de biomasa, estimación de biomasa y generación de mapas de cobertura

Es un modelo predictivo que utiliza criterios establecidos por el usuario para tomar decisiones en cada nodo. Los árboles de clasificación predicen la clase a la que pertenecen los datos. Este modelo es considerado una combinación de árboles predictores, de modo que cada árbol depende de los valores de un vector aleatorio valorado y con la misma distribución para cada un (Gregory 2016).

RF es un modelo de alta precisión comparado con los algoritmos actuales. Funciona de manera eficiente con una gran base de datos, manejando miles de variables de entrada. RF aporta estimaciones de qué variables son importantes en la clasificación, generando una estimación objetiva interna del error a medida que avanza la construcción del bosque (Gil 2018).

### **3.2.3 Proceso metodológico para validar el escalamiento de ortomosaicos obtenidos con el UAS hacia una imagen satelital Rapideye**

Para realizar el escalamiento de las ortofotografías multiespectrales a imágenes satelitales se consideran los siguientes pasos:



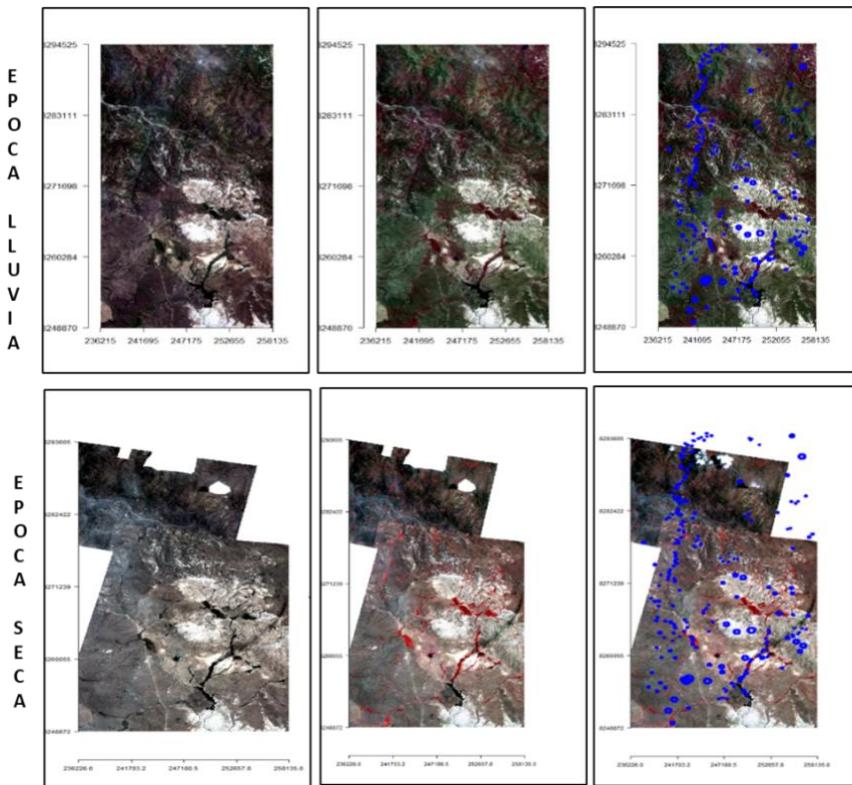
**Figura 18: Diseño metodológico para escalar ortofotografías multiespectrales a imágenes satelitales**

#### **a. Recopilación de imágenes satelitales Rapideye**

Se adquirieron imágenes multiespectrales *Rapideye* de cinco metros (Figura 19).

Los criterios utilizados para escoger las imágenes fueron:

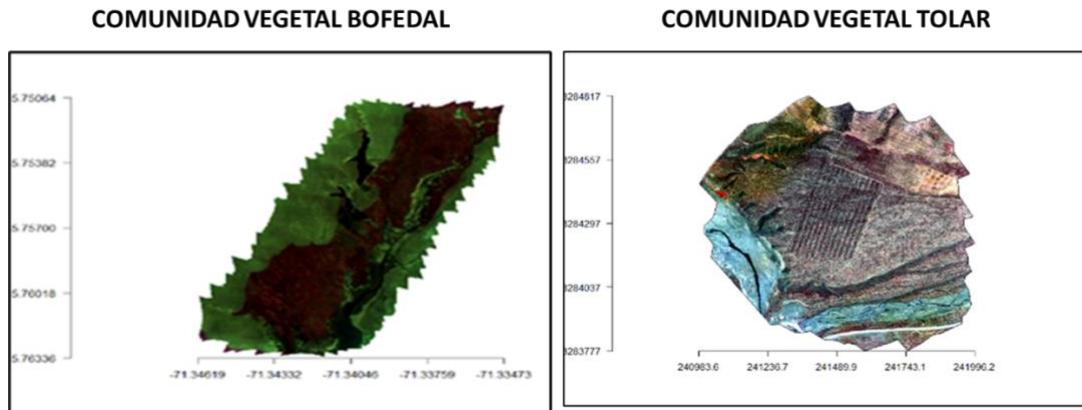
- La fecha de adquisición coincide o esté muy cercana al día de la adquisición de las fotografías con la plataforma UAS (19 de marzo del 2019 para el final de la época de lluvias y del 14 de octubre para la época de final de la época seca).
- Imagen con buena resolución radiométrica, que no presente ruido y que la presencia de nubes sea inferior al 10%.



**Figura 19: Imágenes Rapideye**

#### b. Recopilación de ortofotografías multiespectrales

Para el proceso de escalamiento se utilizaron ortofotografías multiespectrales, las mismas que fueron utilizadas para la estimación de biomasa a partir de signos espectrales e índices vegetación (Figura 20).



**Figura 20: Ortofotografías multiespectrales**

#### c. Recopilación de información de producción de biomasa

Para realizar el escalamiento es necesario contar con información de producción de biomasa en materia verde (MV) y materia seca (MS) obtenidos a partir del muestreo de campo. Esta información es parte de la base de datos generada para el objetivo dos, estimaciones de biomasa a partir de signos espectrales.

#### d. Preparación de las imágenes Rapideye

Las imágenes Rapideye adquiridas para el estudio ya tienen las correcciones atmosféricas y radiométricas, la preparación de las imágenes se realizó siguiendo las siguientes acciones.

- La primera acción consistió en unir las imágenes adquiridas en función del ámbito de estudio (Fundo Quena ubicado en la comunidad Hanansaya I del distrito de Callalli y el fundo San Vicente de Palcca ubicado en la comunidad de Chalhuanca del distrito de Yanque), área al que se proyectó el escalamiento.
- La segunda acción fue recortar las imágenes *Rapideye* a la dimensión de la ortofotografía para fines de escalamiento y predicción de biomasa.

#### e. Escalamiento de ortofotografías a imágenes Rapideye

Los ortomosaicos obtenidos a partir de las ortofotografías adquiridas con las UAV, constituyen áreas específicas de identidad conocida (tolar y bofedal). Por ello, en el proceso de extrapolación se validó su utilidad como áreas de entrenamiento, esto para realizar predicciones en imágenes satelitales con mayor tamaño de pixeles. Para el proceso de escalamiento se utilizó el modelo *Randon Forest* (Bradshaw y Pricope 2019). Los pasos del proceso metodológico fueron:

- Determinación de los signos espectrales e índices de vegetación de las comunidades vegetales en las imágenes Rapideye (Anexo 4b).
- Evaluación de modelos y variables para predicción de biomasa: *Elastic net*, *Machine Learning para clasificación (SMV)* y *Random Forest*.
- Priorización de variables a través del índice de media decreciente de Gini. Las variables estuvieron compuestas por signos espectrales e índices de vegetación.
- Valoración de los niveles de asociación a través del Coeficiente de Correlación de Pearson, en imágenes escaladas.
- Predicción de biomasa (g/pixel) por comunidad vegetal: (Comunidad vegetal tolar y comunidad vegetal bofedal) en imágenes escaladas.
- Elaboración del mapa de coberturas y estimación de biomasa en imágenes escaladas se realizó con *Random Forest*.

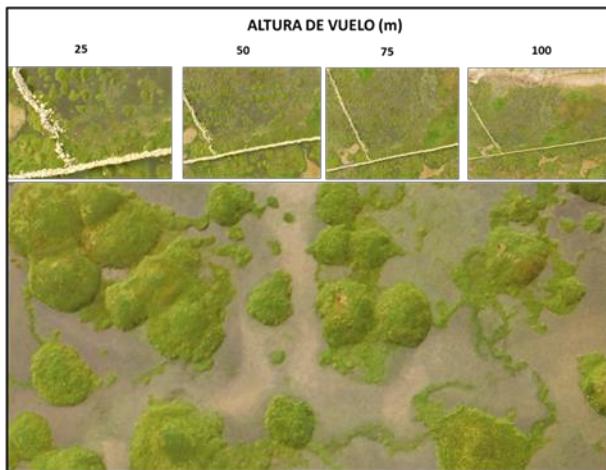
## IV. RESULTADOS Y DISCUSIÓN

### 4.1 ALTURA DE VUELO DE SISTEMAS AÉREOS NO TRIPULADOS (UAS) PARA IDENTIFICACIÓN DE COMUNIDADES VEGETALES TOLARES Y BOFEDALES

#### 4.1.1 Identificación de la mejor altura de vuelo para la comunidad vegetal bofedal

##### 4.1.1.1 Altura de vuelo para identificar la comunidad vegetal bofedal utilizando ortografías RGB

Para la identificación de la comunidad vegetal bofedal se determinó como el objeto segmentado los cojines o almohadillas de DIMU. Como objetos secundarios de observación los parches de bofedal multiflora, inclusiones de gramíneas altas FEDO, suelo desnudo y agua (Figura 21).



**Figura 21: Comunidad vegetal bofedal adquiridas a diferentes alturas de vuelo con sensor RGB**

Los resultados muestran que a 25 m de altura se puede identificar con nitidez los cojines o almohadillas de DIMU, llegando a contabilizar en promedio 9.77 cojines al final de la época de lluvia (marzo) y 11.04 al final de la época de estiaje (octubre). Estos valores se aproximan

al conteo realizado en campo, que en promedio asciende a 10.65 cojines de DIMU para ambas épocas del año (Tabla 10).

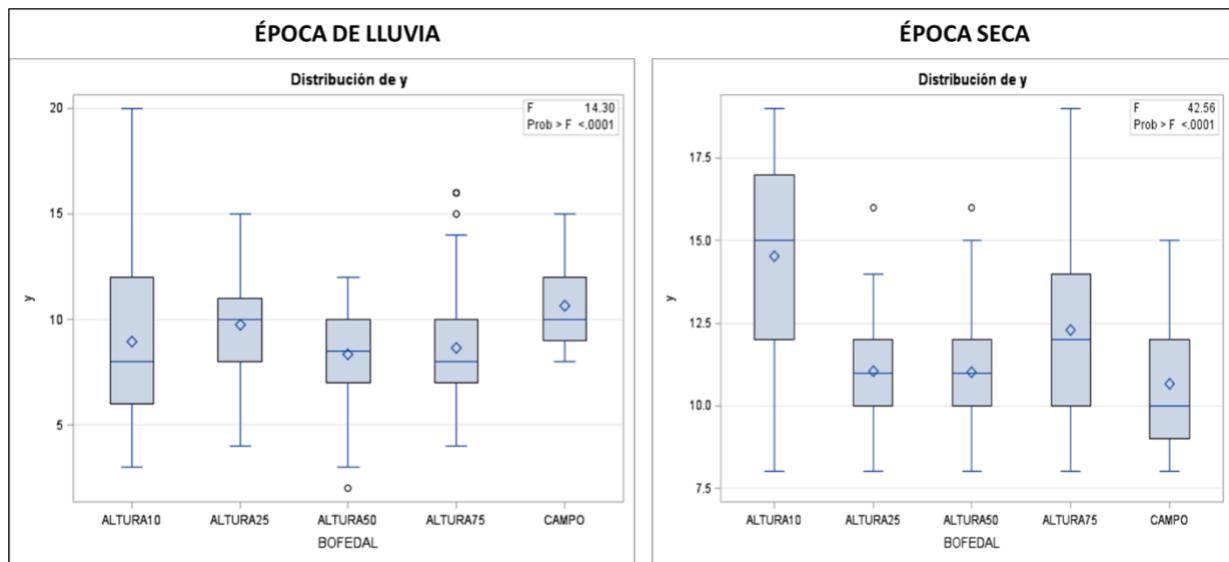
**Tabla 10: Identificación de especie segmentada (arbusto de tola) a diferentes alturas de vuelo, imagen RGB**

ALTURA DE VUELO (m)	NÚMERO DE COJINES DE DIMU	
	ÉPOCA DE LLUVIA	ÉPOCA DE ESTIAJE
25	9.77	10.04
50	8.46	11.01
75	8.11	12.28
100	8.82	14.52
Conteo en Campo	10.65	10.65

Para las alturas de vuelo de 50, 75 y 100 m, en ortofotografías adquiridas al finalizar la época seca, se identificaron 11.01, 12.28 y 14.52 cojines de DIMU respectivamente, mientras que hacia el final de la época de lluvia, para las mismas alturas, se identificaron 8.46, 8.11, 8.82 cojines de DIMU. Cabe indicar que a 75 y 100 m de altura se pueden identificar los parches de DIMU, los parches de bofedal multiflora, los parches de gramíneas altas de FEDO y el agua (Tabla 10).

La evaluación estadística determinó que para la época de lluvia existen diferencias significativas entre las diferentes alturas de vuelo ( $p<0.001$ ). Mientras que en los valores observados en campo y las lecturas efectuadas para la época seca a 25 y 50 m de altura son similares ( $p=0.2123$  y  $p=0.2561$ ), los valores observados en las imágenes adquiridas a alturas de vuelo de 75 y 100 m son diferentes.

Esto implicaría que la mejor altura de vuelo para la identificación de la comunidad vegetal bofedal para la época de lluvia, sería de 25 m, y para la época de estiaje sería de 25 y 50 m, ya que por encima de los 75 m de altura las lecturas de identificación de DIMU se hacen imprecisas (Figura 22).



**Figura 22: Altura de vuelo para identificación de comunidad vegetal bofedal**

Imágenes adquiridas con sensor Zenmuse X3 DJI. Final de la época de lluvia y final de la época seca

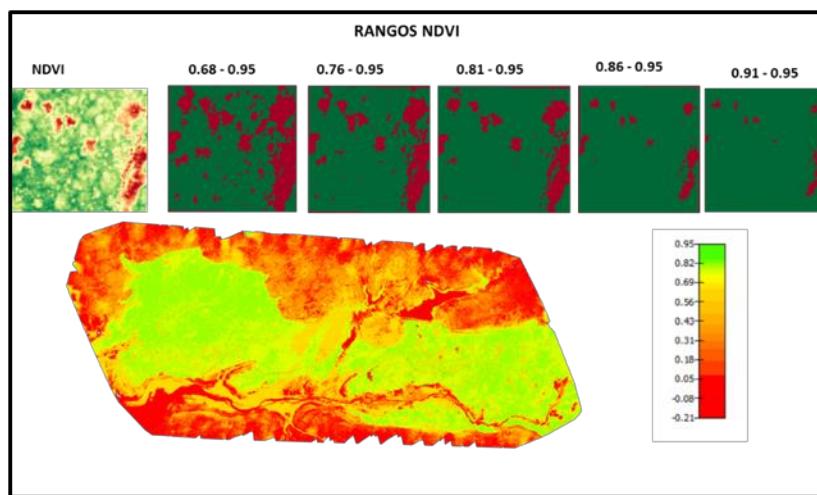
La mejor época para identificación de bofedales sería al final del periodo seco. La identificación de parches se puede realizar sin dificultad en las cuatro alturas estudiadas (25, 50, 75 y 100 m); sin embargo, es importante dejar establecido que, a alturas de vuelo de 25 y 50 m, la lectura de parches tiene mayor precisión y se facilita su delimitación (Figura 22, Anexo 5, Anexo 6).

#### 4.1.1.2 Altura de vuelo para identificar la comunidad vegetal bofedal utilizando ortografías NDVI

Durante el procesamiento de las fotografías con el software *Pix 4D* se determinó que los umbrales para identificar la especie segmentada DIMU en ortofotografías NDVI, es de 0.68 para el umbral inferior y 0.95 para el umbral superior en ambas épocas del año.

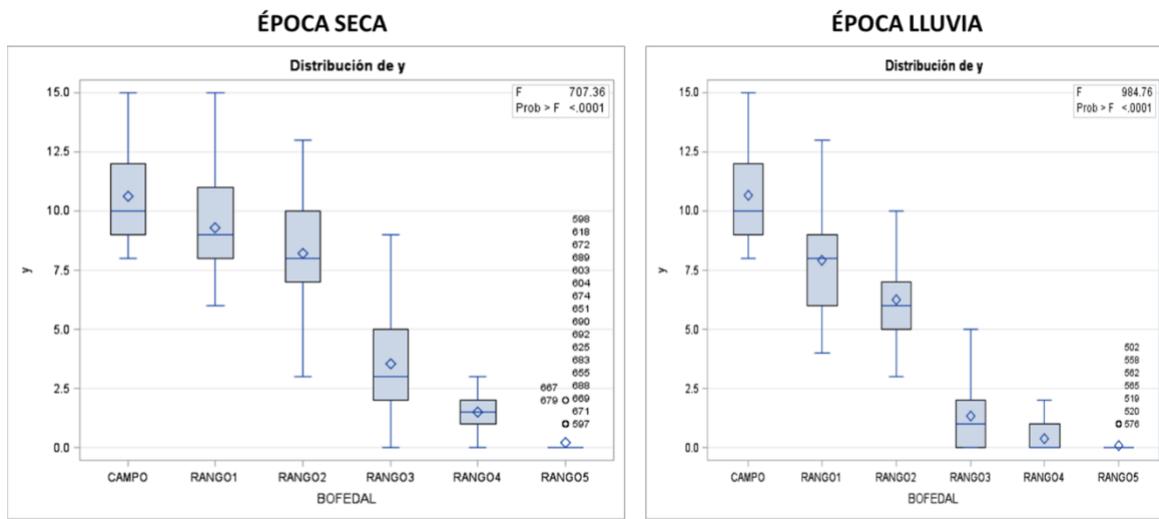
Evaluados los rangos de NDVI (0.68- 0.95, 0.76 – 0.95, 0.81 – 0.95, 0.86 - 0.95 y 0.91 - 0.95) para la época de lluvia se encontró 9.28 cojines de DIMU en el rango 0.68 – 0.95, y en este mismo rango para la época seca se identificó 7.91 cojines de DIMU.

En el rango 0.76-0.95 se identificaron 8.22 y 6.42 cojines de DIMU, mientras que, en los rangos de amplitud menor, 0.81, 0.86 y 0.91 a 0.95, disminuyó la precisión en la identificación de DIMU, llegando en algunos casos a identificar solo un cojín (Figura 23, Anexo 7, Anexo 8).



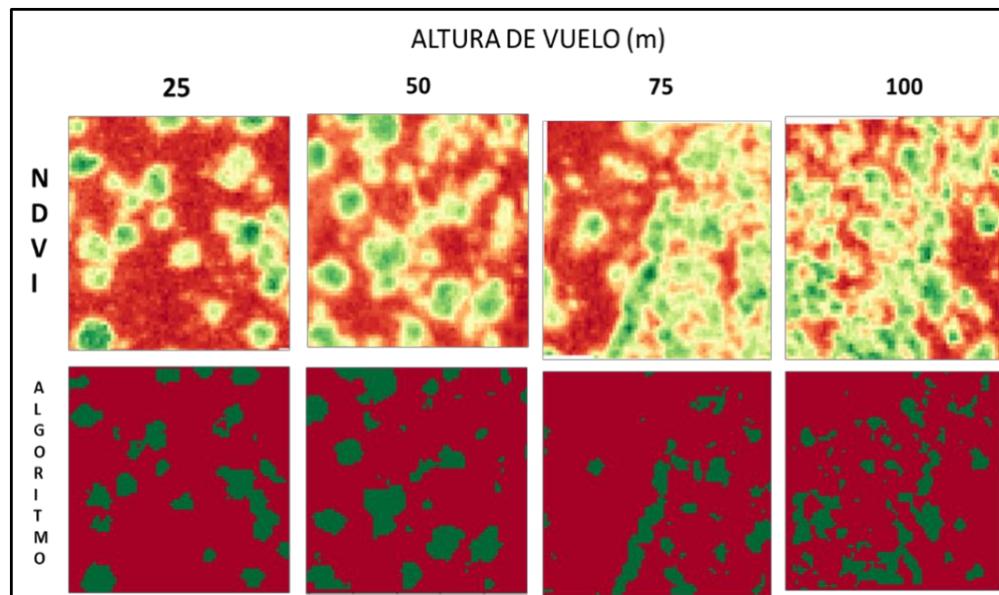
**Figura 23: identificación de cojines de *Distichia* a través de rangos NDVI**

La evaluación estadística determinó que existen diferencias significativas entre los rangos de NDVI ( $p<0.001$ ) y los valores registrados en campo durante las dos épocas de muestreo. Esto implica que en el rango más amplio se identifica mejor los cojines de DIMU y, conforme disminuye el rango NDVI a 0.76, 0.81, 0.86, 091 a 0.95, las lecturas de identificación se hacen imprecisas. Esto indica que las mediciones para identificar DIMU para ambas épocas del año se deben realizar en el rango de 0.68 - 0.95, y con restricciones en el rango 0.76 – 0.95 (Figura 24).



**Figura 24: Rango de índices NDVI para evaluación de comunidad vegetal bofedal**

El análisis realizado con un rango de NDVI de 0.68 - 0.9, identificó 9.38 cojines de DIMU a 25 m de altura, siendo este el valor más próximo al encontrado en campo (10.65). A 50 m de altura la lectura empieza a ser imprecisa, llegando a contabilizar 7.25 cojines de DIMU. Finalmente, a 75 y 100 m de altura el algoritmo encuentra menor separabilidad de cojines de DIMU, identificando los cojines muy cercanos como un solo objeto (Figura 25).



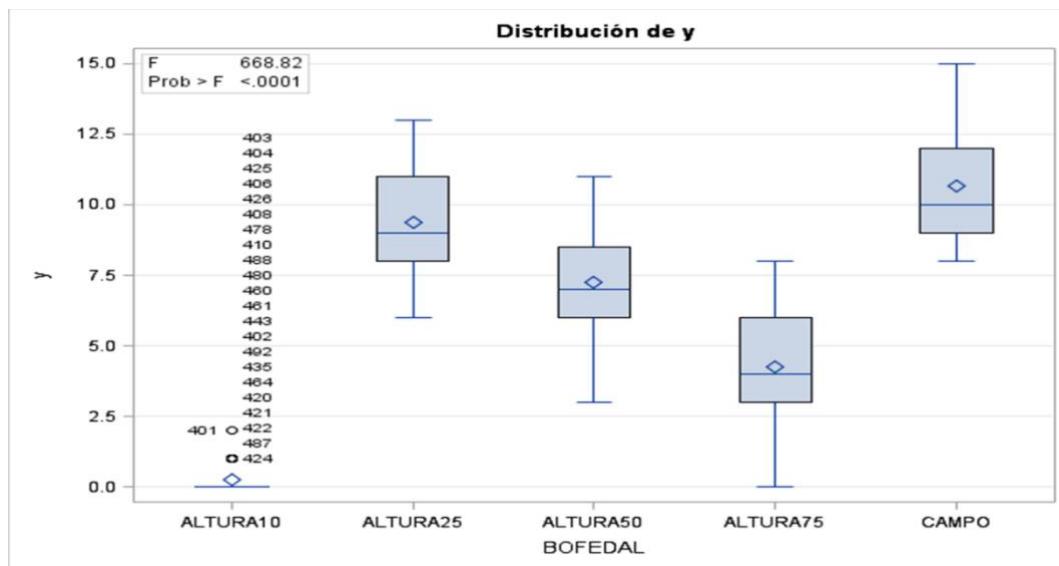
**Figura 25: Imágenes NDVI y lecturas con algoritmo**

La evaluación de los resultados con mínimos cuadrados determina que existen diferencias estadísticas significativas ( $p < 0.0001$ ) entre las diferentes alturas de vuelo. De ello se desprende que, la mejor altura para identificar la comunidad vegetal bofedal es de 25 m, aunque se puede utilizar vuelos de 50 m, pero con restricciones (Figura 26).

A partir de la evaluación estadística y de fotogrametría, utilizando imágenes RGB y NDVI adquiridas con la plataforma UAS y con cámara Zenmuse X3 DJI, se considera que el mejor rango de NDVI para la identificación de cojines de DIMU es de 0.68 a 0.95, mientras que los rangos de 0.71 a 0.95 y más próximos al umbral superior muestran alta imprecisión en la lectura de las muestras.

Para el estudio se estableció que la mejor altura de vuelo para identificar la comunidad vegetal bofedal de puna seca es de 25 m, pudiendo utilizarse también ortofotografía de 50 m con restricciones (Figura 26) (Anexo 9).

Los resultados no muestran diferencias entre las épocas de estudio, por consiguiente, utilizando el parámetro NDVI, se puede realizar estudios en cualquier época del año (Anexo 9).



**Figura 26: Mejor altura de vuelo NDVI**

#### **4.1.2 Determinación de la mejor altura de vuelo para la comunidad vegetal tolar de puna seca**

##### **4.1.2.1 Altura de vuelo para identificar la comunidad vegetal tolar, utilizando ortofotografías RGB**

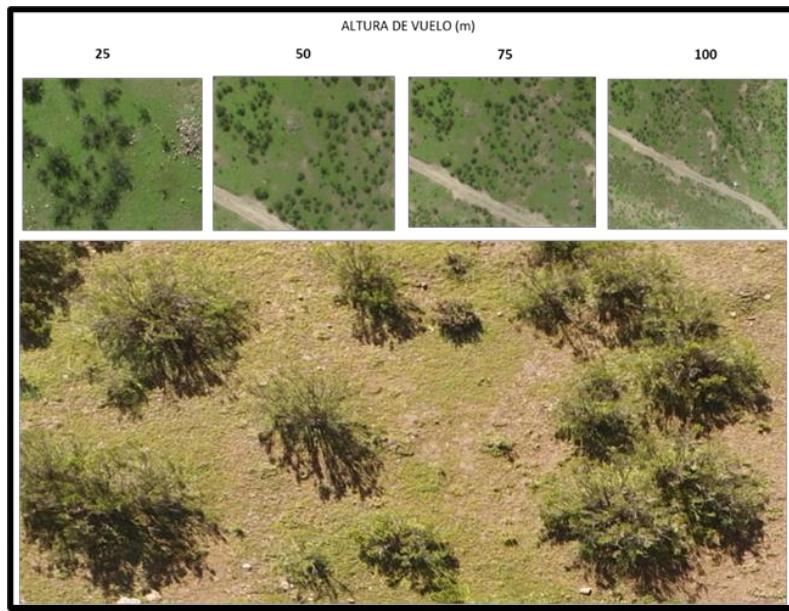
Utilizando ortofotografías RGB obtenidas a 25 m de altura de vuelo, se identifica y contabiliza con nitidez la especie segmentada *Parastrepia lepidophylla* (tolá), así como de las inclusiones de *Bracharis sp.*, gramíneas altas como la *Stipa sp.*, *Festuca ortophylla*, *Margiricarpus sp* (Tabla 11).

**Tabla 11: Identificación de especie segmentada (arbusto de tolá) a diferentes alturas de vuelo, imagen RGB**

ALTURA DE VUELO (m)	NÚMERO DE PLANTAS TOLA	
	ÉPOCA DE LLUVIA	ÉPOCA DE ESTIAJE
25	27.55	27.24
50	33.06	29.61
75	38.08	36.36
100	39.40	38.76
Conteo en campo	28.97	28.97

A 50 m de altura, la especie segmentada (arbustos de tolá), aparece como pequeños parches irregulares de color verde intenso en comparación a los demás componentes de la imagen. Un conocedor de la comunidad vegetal puede identificar y contabilizar las plantas de tolá con limitaciones de precisión, porque ésta se mimetiza con otras especies de crecimiento alto (*Braccharis sp* y *Margiricarpus sp*).

En imágenes adquiridas a 75 y 100 m de altura, la tolá se observa como puntos difusos de color verde oscuro, imposibilitando la identificación y conteo de especies (Figura 27).

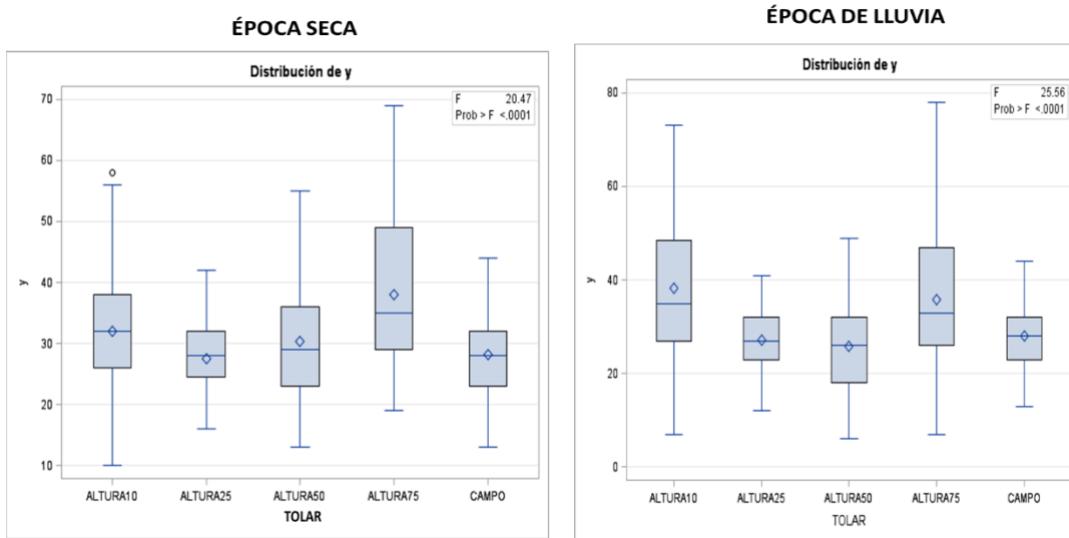


**Figura 27: Fotografías de comunidad vegetal tolار  
Imágenes adquiridas con cámara Zenmuse X3 DJI RGB**

En las imágenes RGB de 25 y 50 metros de altura se pueden identificar y delimitar con mayor precisión los parches de tola, césped y suelo desnudo, mientras que en las imágenes de 75 y 100 m de altura se observa menor separabilidad de estas tres coberturas (Figura 27).

Considerando que las imágenes adquiridas con la plataforma UAS tienen mejor resolución que las imágenes satelitales, para un estudio de mayor alcance territorial se puede utilizar las ortofotografías adquiridas a 75 y 100 m de altura de vuelo.

La evaluación estadística muestra diferencias significativas entre las alturas de vuelo ( $p<0.001$ ). Los valores observados en campo y las lecturas efectuadas a 25 m de altura son similares entre sí: ( $p=0.4408$ ) para las muestras adquiridas al final de la época de lluvias y ( $p=0.3394$ ) para las muestras adquiridas al finalizar la época seca (Figura 28). Estos valores son diferentes con los encontrados en las imágenes adquiridas de 50, 75 y 100 m de altura de vuelo (Anexo 10 y Anexo 11).



**Figura 28: Determinación de mejor altura de vuelo en imágenes RGB**

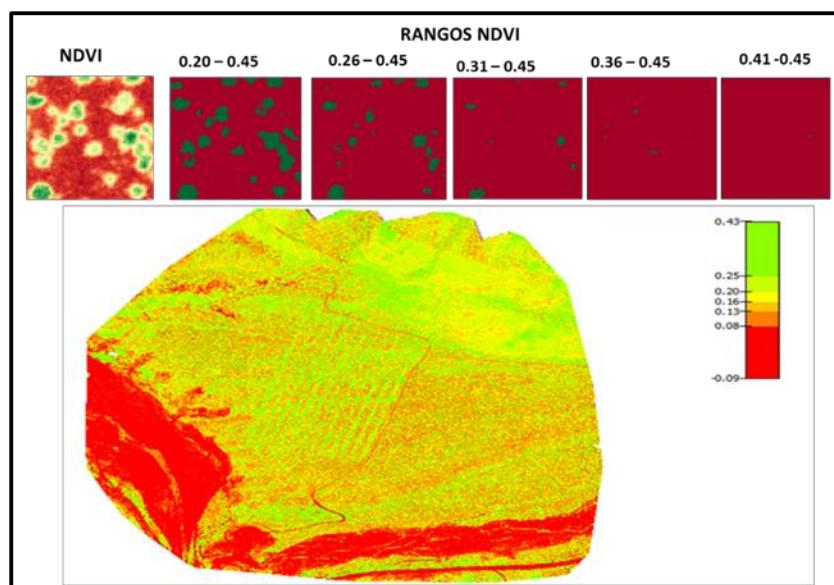
#### 4.1.2.1 Altura de vuelo para identificar la comunidad vegetal tolar, utilizando ortofotografías NDVI

En el procesamiento de las ortofotografías NDVI el “arbusto de tola” presentó un valor de 0.20 en el umbral inferior y de 0.45 en el umbral superior en ambas épocas de muestreo (seca y lluvias).

Durante el análisis del algoritmo de las imágenes NDVI adquiridas a 25 metros de altura y los diferentes rangos de: 0.20 a 0.45, 0.26 a 0.45, 0.31 a 0.45, 0.36 a 0.45, y 0.41 a 0.45 de NDVI, se encontró para el rango amplio 0.20 a 0.45 una media de 29.42 plantas de tola identificadas al final de la época de lluvia, y 21.42 plantas identificadas para el final de la época seca. Estos valores son los que más se aproximan al muestreo realizado en campo, que tuvo una media de 28.11 para los mismos cuadrantes en ambas épocas del año.

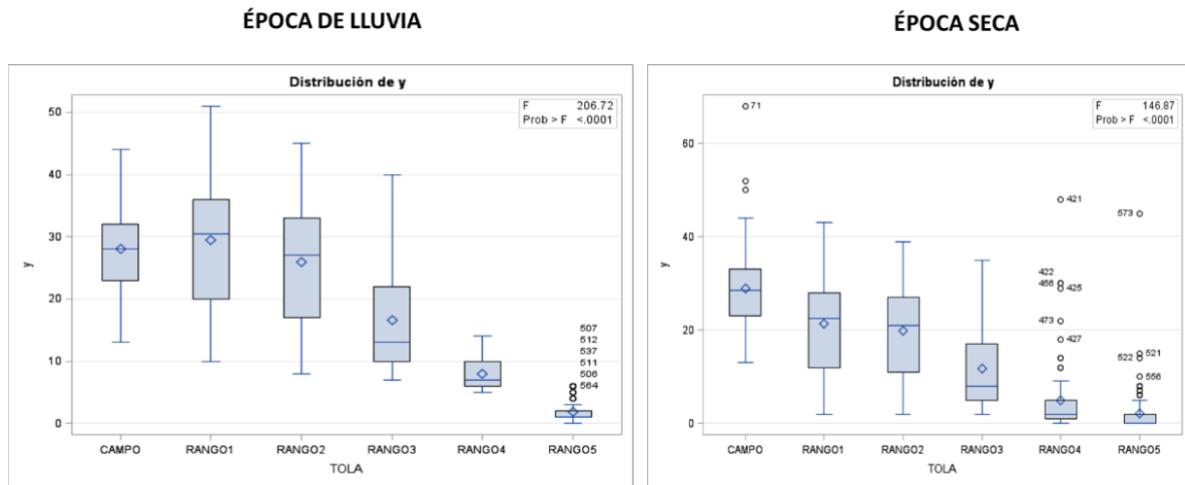
A medida que la amplitud del rango disminuía, el número de plantas de tola identificadas también decreció, es así que para el rango de 0.26 a 0.45 de NDVI, el algoritmo identificó 25.89 y 19.89 plantas de tola respectivamente, mientras para los rangos de menor amplitud, como 0.31 a 0.45, 0.36 a 0.45, el número de plantas disminuyó significativamente, llegando

en la mayoría de los casos a cero individuos identificados en el rango más estrecho de 0.41 a 0.45 de NDVI (Figura 29).



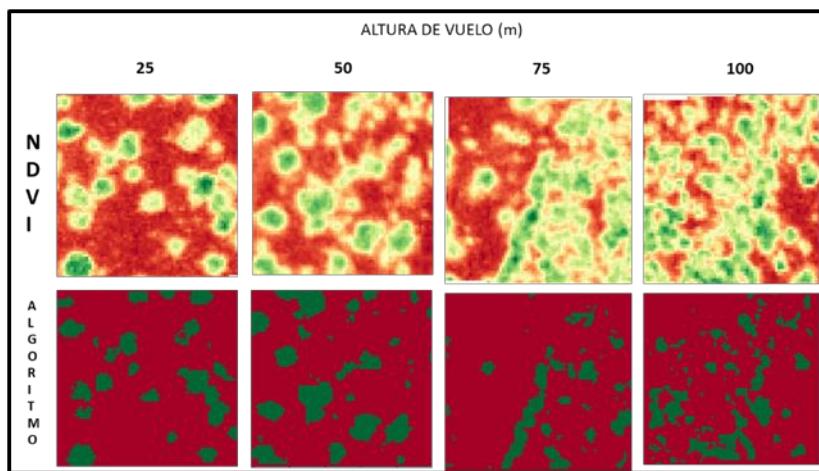
**Figura 29: Determinación del mejor rango de NDVI para identificación de la tola**

La evaluación estadística de los resultados con mínimos cuadrados determinó que existen diferencias significativas entre los diferentes rangos de NDVI ( $p<0.001$ ). Los valores registrados en campo en las dos épocas de muestreo y los valores observados en las lecturas efectuadas en los rangos de 0.26 a 0.45 y 0.31 a 0.45 de NDVI, son similares ( $p=0.1593$ ) para las muestras adquiridas al final de la época seca. Esto implica que en el rango más amplio se identifica mejor el arbusto de tola, y conforme disminuye el rango NDVI, las lecturas de identificación de la tola se hacen imprecisas. Es decir, que las mediciones se pueden realizar en los rangos de 0.20 a 0.45 y 0.26 a 0.45; sin embargo, para lograr una mejor identificación de especies es conveniente utilizar el rango más amplio (0.20 – 0.45) (Figura 30, Anexo 12, Anexo 13).



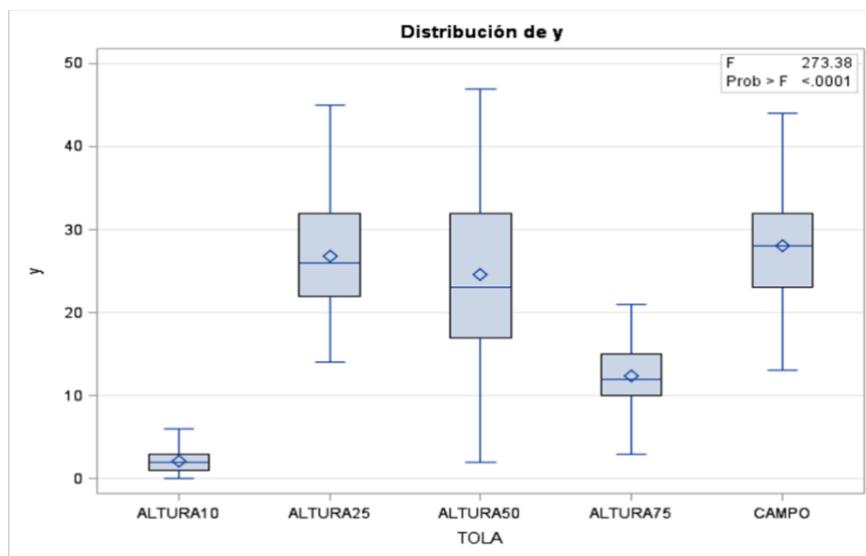
**Figura 30: Determinación del mejor rango para identificar la especie segmentada de la comunidad vegetal tolara**

El algoritmo elaborado para la identificación del arbusto de tola, utilizando el mejor rango de NDVI establecido (0.20 a 0.45) y las ortofotografías NDVI adquiridas a 25 y 50 metros de altura de vuelo, identificó en promedio 26.81 y 24.54 arbustos de tola, datos que se aproximan al promedio de plantas identificadas durante el trabajo de campo (28.11). Por su parte, la identificación y contabilización de la especie segmentada en ortofotografías NDVI obtenidas a 75 y 100 m de altura vuelo, fueron imprecisas (Figura 31).



**Figura 31: Conteo del arbusto tola en imagen NDVI, rango 0.20-0.45 a diferentes alturas de vuelo**

Los resultados del análisis de datos muestran diferencias estadísticas significativas ( $p<0.0001$ ) entre las diferentes alturas de vuelo para identificar plantas de tola. Los valores observados en campo y la identificación de especies a 25 metros de altura son similares ( $p=0.1793$ ), aunque diferentes con los valores de las demás alturas evaluadas. Ello significa que la mejor altura de vuelo para la identificación de la comunidad vegetal tolar desde el análisis de fotografías NDVI es de 25 metros (Figura 32 y Anexo 14).



**Figura 32: Mejor altura de vuelo NDVI \_ Rango 0.2 a 0.45 \_ 25 m de altura**

La calidad de una imagen puede determinarse a partir de la observación y conteo de árboles, arbustos u otras características que marquen la diferencia entre objetos (Falk 2014), es así que en una imagen aérea tomada desde un ángulo cenital los árboles y arbustos pueden ser reconocidos por la forma de la copa o canopia. Considerando estos criterios, se identificó el arbusto de tola por el diámetro, la altura de la planta y el grado de verdor de su canopia. Los cojines de DIMU se identificaron por el diámetro, el verdor y la altura que estos muestran respecto a las demás especies de la comunidad vegetal.

En la actualidad se vienen validando diferentes alturas de vuelo de las plataformas UAS para adquirir imágenes que permitan identificar pasturas y clasificar coberturas de comunidades vegetales en pastizales y arbustos. Bethany *et al.* (2019) y Berrio *et al.* (2015), utilizando imágenes adquiridas a 100 de altura de vuelo identificaron cuatro clases de pastizales:

pradera, pradera de poa, coberturas acacia, y praderas de pastizales. Easdale *et al.* (2019) utilizando imágenes adquiridas a 200 metros de altura de vuelo, identificaron coberturas de pastizal de estepa graminosa y graminosa-arbustiva, un ambiente ecotonal entre el humedal y la estepa y ambientes de alta humedad asociados a cursos de agua. El estudio de identificación de comunidades vegetales con muestras de ortofotografías RGB y NDVI adquiridas a 100 metros de altura, identificó coberturas de las comunidades tolar, bofedal, agua y suelo desnudo, pero no logró identificar especies segmentadas (arbusto de tola y cojines de DIMU).

Botello *et al.* (2019), utilizando imágenes adquiridas a 30 metros de altura de vuelo, clasificaron cultivares de avena y alfalfa. Las coberturas mostradas fueron mejores para avena, porque las plantas de alfalfa no cubrían completamente el suelo, mientras que Grüner *et al.* (2018), con imágenes adquiridas con vuelos realizados a 20 m de altura, diferenciaron mezclas de gramíneas y leguminosas en pasturas de trébol rojo, alfalfa y rye grass italiano. Estos resultados son concordantes con los resultados encontrados en la investigación realizada. Las ortofotografías RGB y NDVI adquiridas a 25 metros de altura de vuelo lograron identificar el arbusto tola y los cojines de DIMU. Estos resultados están sustentados por la alta resolución espectral de las ortofotografías adquiridas a alturas de vuelo que van de 20 a 50 m.

El rango del NDVI varía de -1 a +1. En este rango se genera gran cantidad de datos que pueden utilizarse para realizar clasificaciones detalladas de la vegetación. Pero se debe considerar que el rango de valores de NDVI puede variar según las clases de vegetación, ya que valores iguales en este índice pueden tener un significado muy distinto en el campo (Buitrón y Calisaya 2012). Ambos autores indican que a partir de los valores 0.4 se tiene vegetación con mayor cobertura, los valores de 0.6 indican áreas boscosas, mientras que los valores por encima de 0.7 hasta 1 podrían indicar campos de cultivos de gran vigor.

Gross (2005) sugiere que valores de NDVI inferiores a 0.1 corresponden a áreas estériles. Los valores de 0.2 a 0.3 indican presencia de pastizales y arbustos, mientras que 0.6 a 0.8 corresponden a vegetación selvática o tropical (Escuer 2007, Buitrón y Calisaya 2012).

La clasificación e identificación de especies segmentadas en comunidades vegetales con especies similares, utilizando sensores de alta resolución en plataformas UAS, tienen éxito cuando: el rango espectral del sensor utilizado cubre la banda roja y el infrarrojo cercano del espectro de 600 a 875 nm (Bethany *et al.* 2019). Los resultados del presente estudio de identificación de comunidades vegetales de puna seca utilizaron sensores NDVI con longitudes de onda de 575 a 850 nm, lo cual permitió identificar rangos de NDVI para la comunidad vegetal tolar (0.20 a 0.45) y su especie segmentada, así como la comunidad de vegetal bofedal (0.68 a 0.95) y su especie segmentada.

Los valores presentados en los diferentes estudios muestran que no es posible generalizar un valor del índice NDVI, mucho menos para todas las especies o coberturas vegetales. Los resultados sugieren que previamente se realice estudios prospectivos que permitan conocer: la altura de la zona de estudio, la época de estudio y el tipo de cobertura que tiene la comunidad a estudiar. Es común a todos los estudios, que el valor del NDVI será mayor cuando el territorio estudiado muestre mayor verdor.

## **4.2. ESTIMACIÓN DE BIOMASA A PARTIR DE SIGNOS ESPECTRALES EN ORTOFOTOGRAFÍAS MULTIESPECTRALES**

### **4.2.1 Estimación de biomasa en la comunidad vegetal bofedal a partir de signos espectrales e índices de vegetación**

#### **4.2.1.1 Índices de vegetación de la comunidad vegetal bofedal a partir de imágenes multiespectrales**

Los valores del índice NDVI encontrados para el bofedal, tienen alta variación, desde -0.4 a 0.9 para la época de lluvia y de -0.5 a 0.5 para la época seca. Los índices de vegetación mejorados y los que usan la banda verde, no presentan variación significativa entre épocas de muestreo. El índice de vegetación EVI para ambas épocas presenta valores que varían

entre 0.0 a 1.0, y el índice GNDVI presenta valores de -0.5 a 0.6 (Tabla 12). Los valores encontrados incluyen la cobertura de agua y suelo desnudo de la comunidad vegetal.

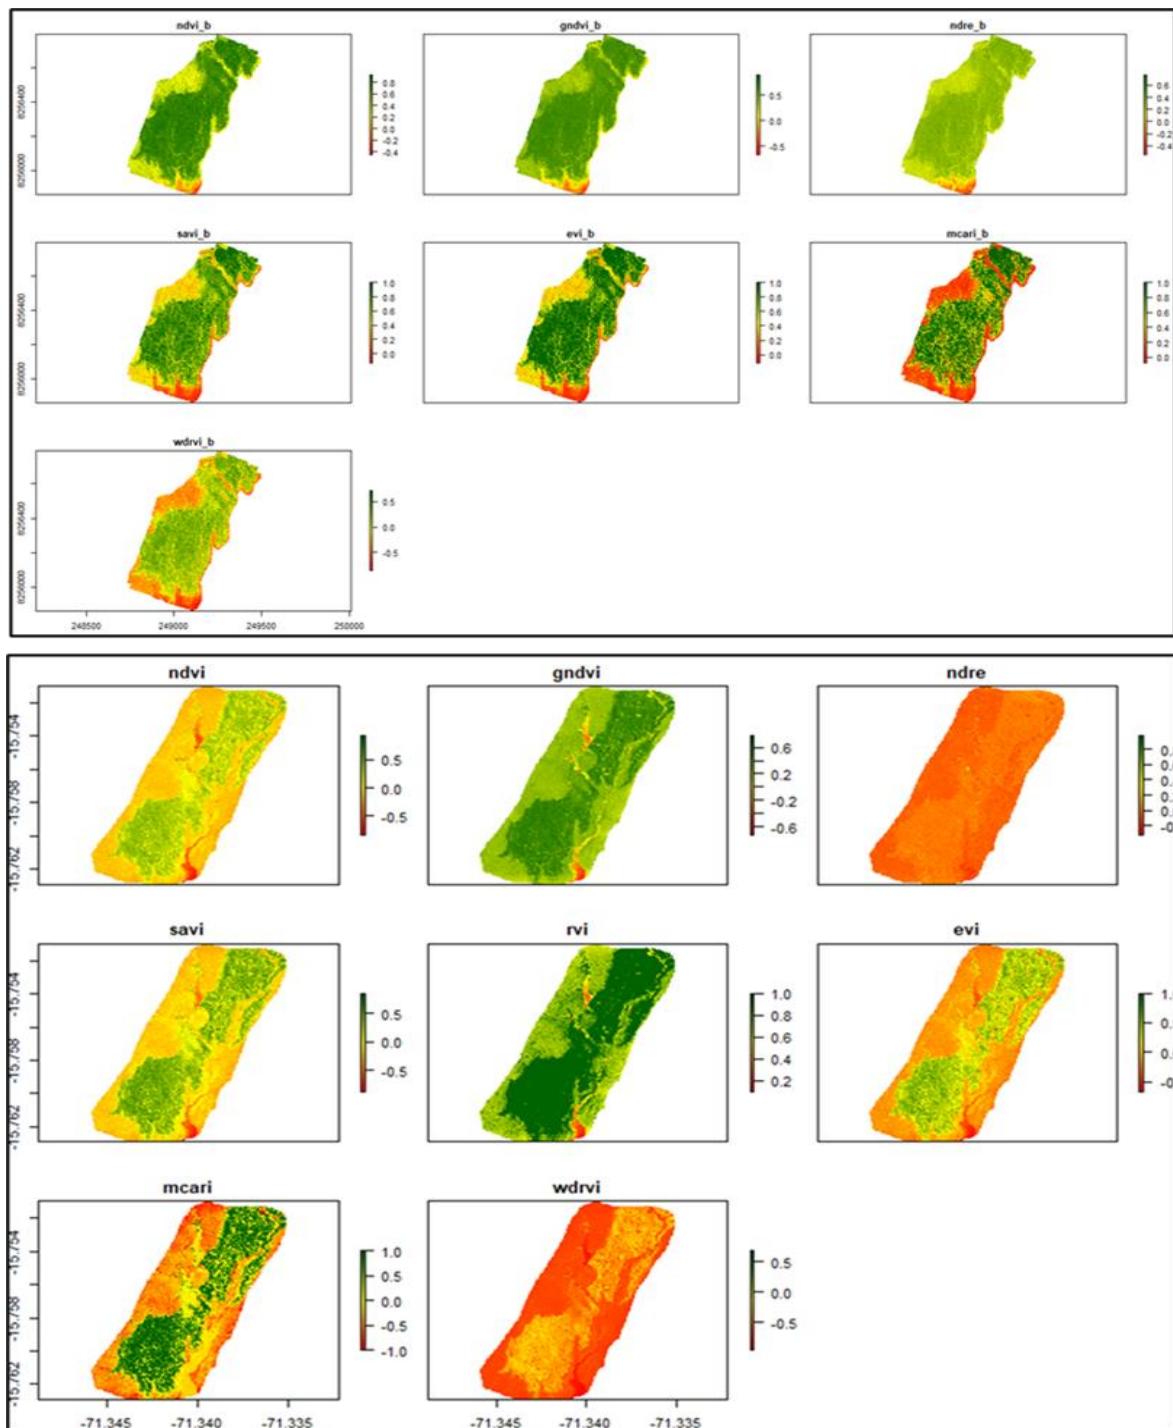
**Tabla 12: Índices de vegetación comunidad vegetal bofedal**

ÍNDICES	ÉPOCA LLUVIA		ÉPOCA SECA	
	MÍNIMO	MÁXIMO	MÍNIMO	MÁXIMO
NDVI	-0.4	0.9	-0.5	0.5
GNDVI	-0.5	0.5	-0.6	0.6
NDRE	-0.4	0.6	-0.8	0.8
SAVI	0.0	1.0	-0.5	0.5
EVI	0.0	1.0	0.0	1.0
MCARI	0.0	1.0	-1.0	1.0
WDRVI	-0.5	0.5	-0.5	0.5

El índice de vegetación SAVI, corregido por efecto del suelo, muestra una variación muy importante entre la época de lluvia y la época seca, siendo significativamente menor el valor de la época seca. El índice de vegetación MCARI, influenciado por la interacción del índice del área foliar y la clorofila (Daughtry *et al.* 2000), muestra un rango amplio para la época seca, que va desde -1 a 1, y para la época de lluvia de 0.00 a 1.0. Finalmente, el índice de vegetación WDRVI o de rango amplio de vegetación, alcanzó valores que van de -0.5 a 0.5 (Tabla 12 y Figura 33).

#### **4.2.1.2 Predicción de biomasa aérea de la comunidad vegetal bofedal de puna seca en base a índices de vegetación (evaluación de modelos, asociación de variables y predicción)**

El modelo *Random Forest*, en muestras de bofedal recopiladas en la época de lluvia, encuentra una precisión de entrenamiento de 0.9293, una precisión de prueba de 0.9354 y un índice de Kappa (concordancia) de 0.9153. Siendo *Random Forest* ligeramente superior a los modelos *Elastic Net* y *SVM* (Tabla 13).



**Figura 33: Índices de vegetación de la comunidad vegetal bofedal**

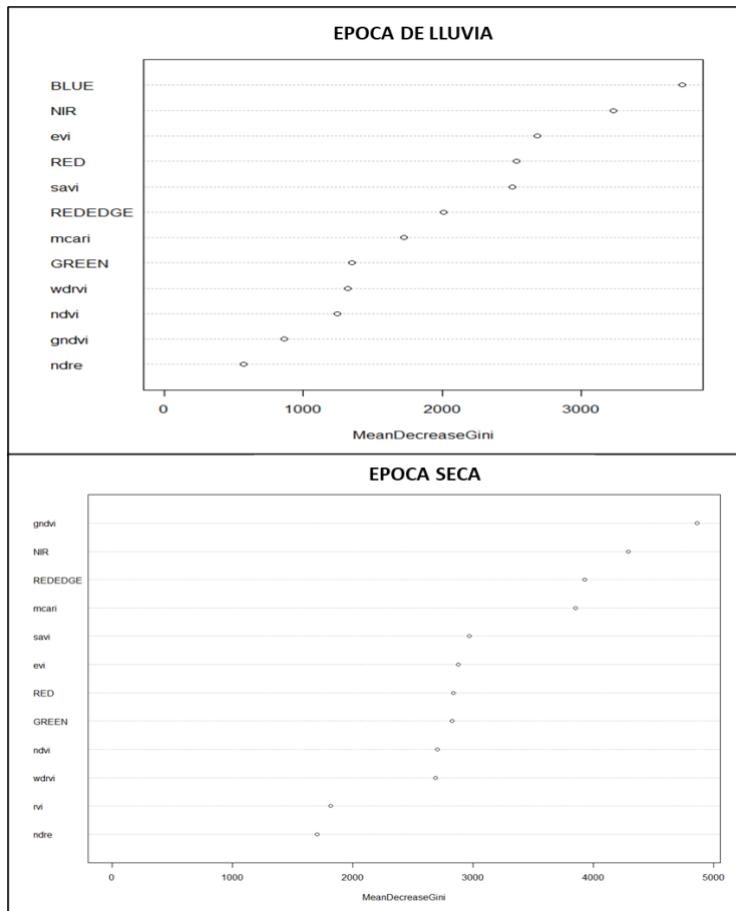
Para la época seca, el modelo *Random Forest* muestra un valor de precisión de entrenamiento de 0.8206, un valor de precisión de prueba de 0.8333 y el índice Kappa de 0.7910. A partir de estos resultados, se establece que *Random Forest* permite una predicción más cercana a la realidad para la comunidad vegetal bofedal de puna seca.

**Tabla 13: Evaluación de modelos para predicción de biomasa**

MODELO	ÉPOCA DE LLUVIA			ÉPOCA SECA		
	PRECISIÓN		KAPPA TEST	PRECISIÓN		KAPPA TEST
	ENTRENA MIENTO	PRUEBA		ENTRENA MIENTO	PRUEBA	
Elastic Net	0.9111	0.9196	0.8946	0.7942	0.8067	0.7680
Machine Learning para clasificación (SVM)	0.9001	0.9093	0.8809	0.7797	0.7888	0.7465
Random Forest.	0.9293	0.9354	0.9153	0.8206	0.8333	0.7910

La media decreciente de Gini (MDG), en muestras recopiladas al final de la época de lluvia, identificó el espectro azul (BLUE) e infrarrojo cercano (NIR) como variables de mayor importancia para la clasificación de coberturas y predicción de biomasa en bofedales: estas variables (espectros BLUE y NIR), se encuentran en más de 3000 nodos de árboles de decisión aleatoria, seguido por los índices de vegetación EVI y SAVI, que se encuentran entre 2000 y 3000 nodos de árboles de decisión. Los índices de vegetación MCARI, WRDVI, NDVI, GNDVI y NDRE tienen menor importancia como variables para ser usados por Random Forest en la predicción de biomasa (Figura 34, Anexo 15).

Para el final de la época seca, la MDG establece que los índices de vegetación GNDVI y MCARI, y los espectros NIR y Red Edge, son los de mayor importancia. Se encuentran en más de 4000 nodos de árboles de decisión, seguidos por los índices de vegetación SAVI, EVI y NDVI, presentes en más de 3000 nodos de árboles de decisión (Figura 34).



**Figura 34: Priorización de variables para estimar biomasa en bofedales (MDG)**

El coeficiente de correlación de Pearson, determinó asociaciones negativas entre el valor de biomasa de las muestras adquiridas en campo en base a materia verde y los índices de vegetación seleccionados para el estudio. Destacan los valores de asociación encontrados para NDVI de ( $p= -0.43$ ) para época de lluvia y ( $p= -0,22$ ) para la época seca (Figura 35). Este mismo coeficiente estableció asociaciones fuertes entre los diferentes índices de vegetación, con valores que van de ( $p=0.70$  y  $P=1.0$ ). El análisis de la imagen incluye los valores de suelo y agua.

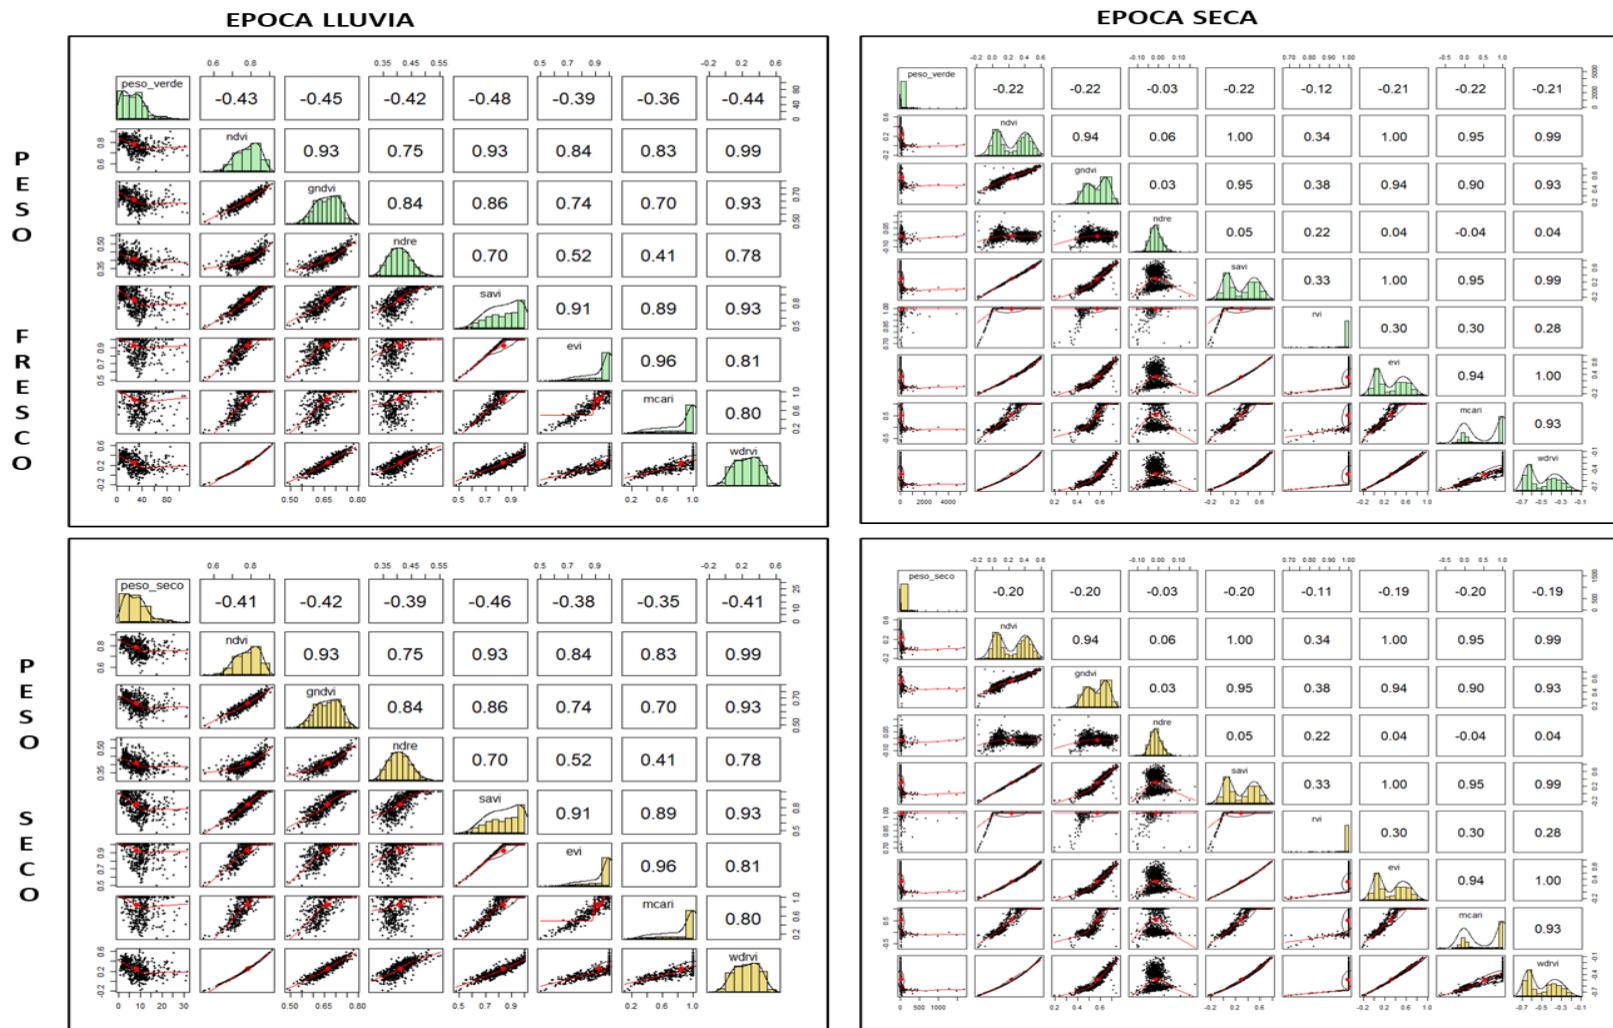
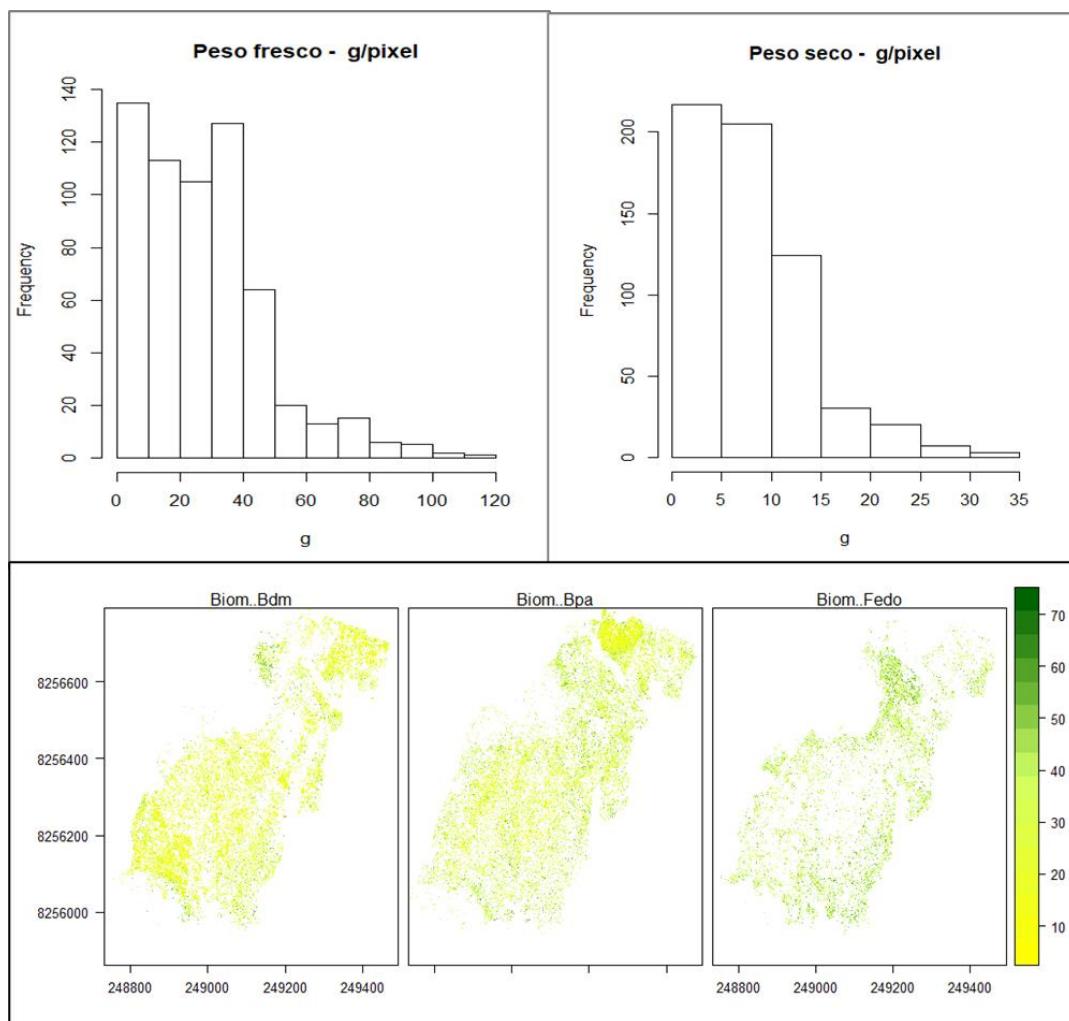
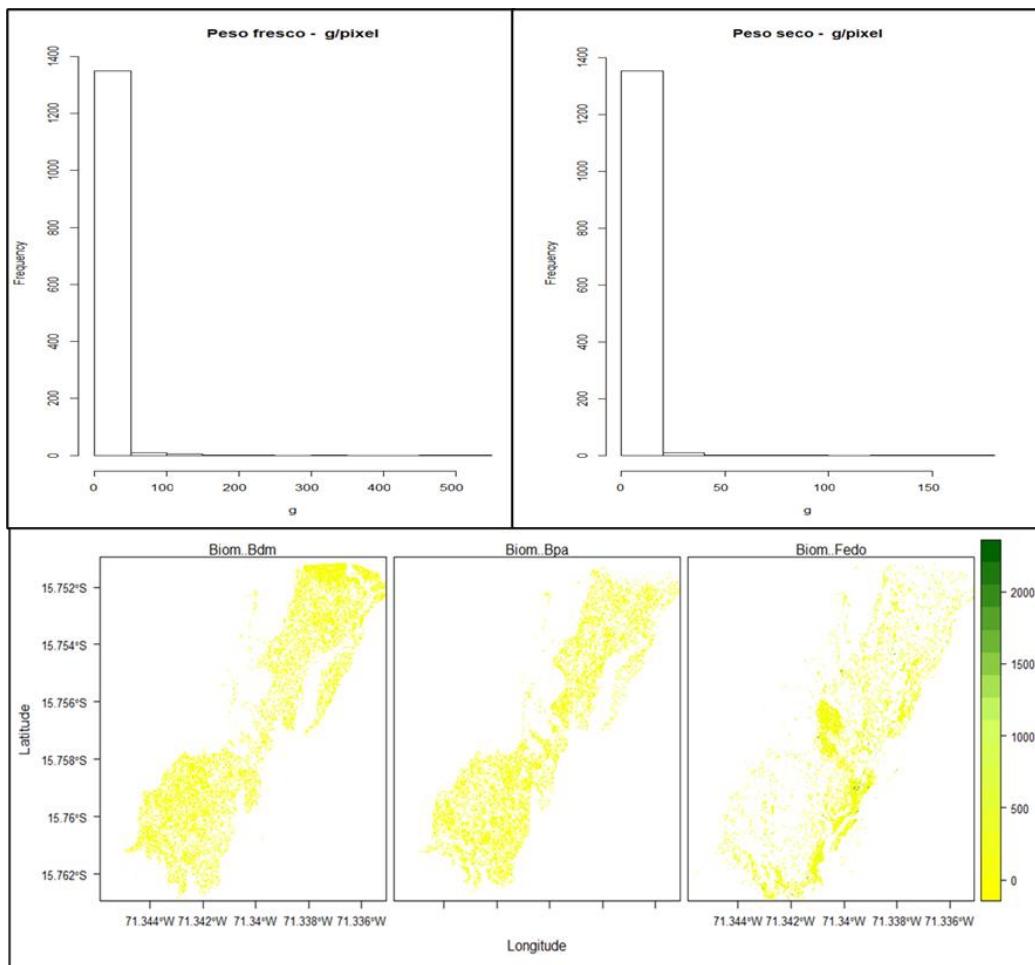


Figura 35: Grados de asociación entre biomasa con datos de campo e índices de vegetación

El modelo *Random Forest* predijo la producción de biomasa para la época de lluvia en un rango de 2 a 120 g/pixel utilizando la materia verde, encontrándose el mayor número de muestras entre 2 a 10 g/pixel, y un segundo grupo de 11 a 40 g/pixel. Para la misma época, con materia seca, las muestras estuvieron distribuidas entre 2 a 35 g/pixel, y la mayor frecuencia se presenta entre 2 a 10 g/pixel. Para el final de la época seca, el modelo predijo producciones de biomasa de 2 a 100 g/pixel en materia verde y de 5 a 50 g/pixel en materia seca (Figura 36 y Figura 37).



**Figura 36: Predicción de biomasa para final de época de lluvia (g/pixel). RF**



**Figura 37: Predicción de biomasa para final de época seca (g/pixel). RF**

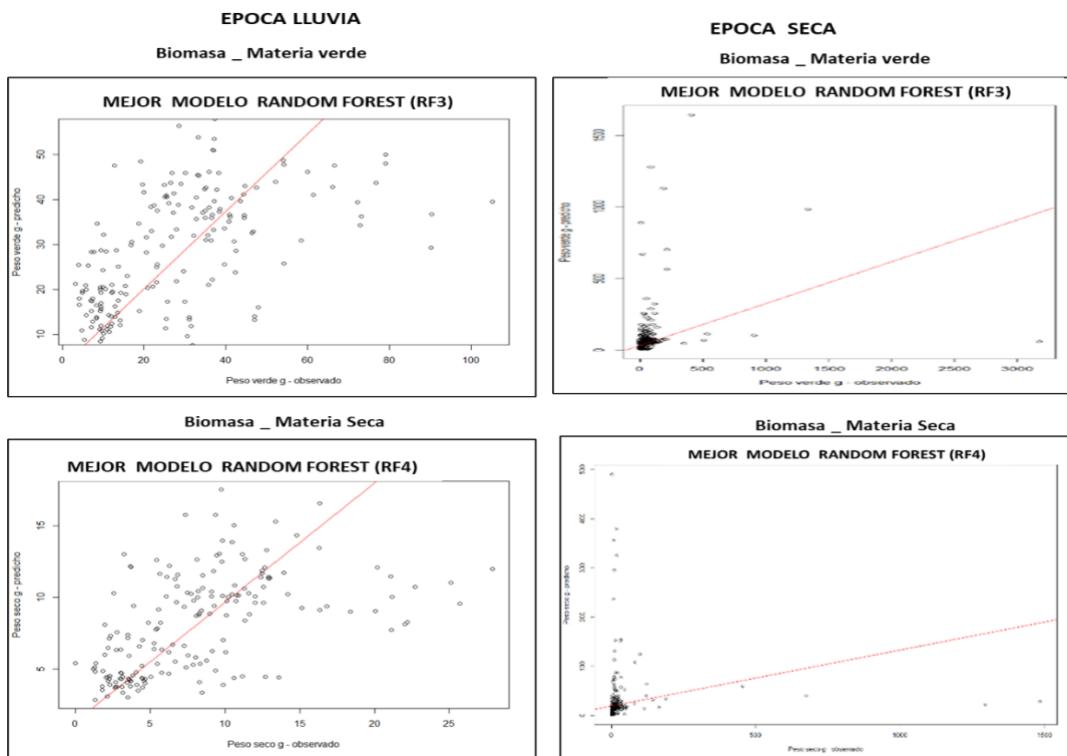
La evaluación de la predicción de biomasa en bofedales de puna seca, a partir de índices de vegetación para las dos épocas de muestreo, establece que, el modelo de Regresión Lineal ( $R^2= 0.26$  y  $R^2= 0.24$ ) y el modelo SVM ( $R^2= 0.23$  y  $R^2=0.21$ ) presentan los más bajos coeficientes de determinación entre los modelos seleccionados, siendo su posibilidad de estimación de biomasa muy imprecisa para las dos épocas de muestreo. El modelo *Random Forest*, realiza la predicción de biomasa de la comunidad vegetal bofederal de puna seca con un coeficiente de determinación ( $R^2= 0.479$ ) para el final de la época de lluvia y ( $R^2= 0.465$ ) para el final de la época de seca (Tabla 14).

**Tabla 14: Evaluación de los modelos para predicción de biomasa**

MODELO	ÉPOCA LLUVIA			ÉPOCA SECA		
	RMSE	RSq	MAE	RMSE	RSq	MAE
Linear Regression	20.792	0.263	52.210	105.000	0.238	56.210
Support Vector Machine (SVM)	21.430	0.230	53.370	106.240	0.211	57.370
Random Forest	24.312	0.479	48.379	95.081	0.465	53.379

Los coeficientes de determinación en su conjunto son bajos, por lo tanto, su posibilidad para predecir biomasa en los bofedales es imprecisa. El modelo *Random Forest* realiza predicciones de producción de biomasa más cercanas a lo observado en campo, en ambas épocas de estudio.

En la figura de dispersión (Figura 38), se observa una mejor distribución en materia verde para la época de lluvia comparado con materia seca. Para la época seca en MV y no presentan buena distribución de datos.



**Figura 38: Comparación y predicción de biomasa en RF y observado en campo**

#### **4.2.1.3 Elaboración de mapas de producción de biomasa de la comunidad vegetal bofedal del fundo San Vicente de Palcca, Chalhuanca**

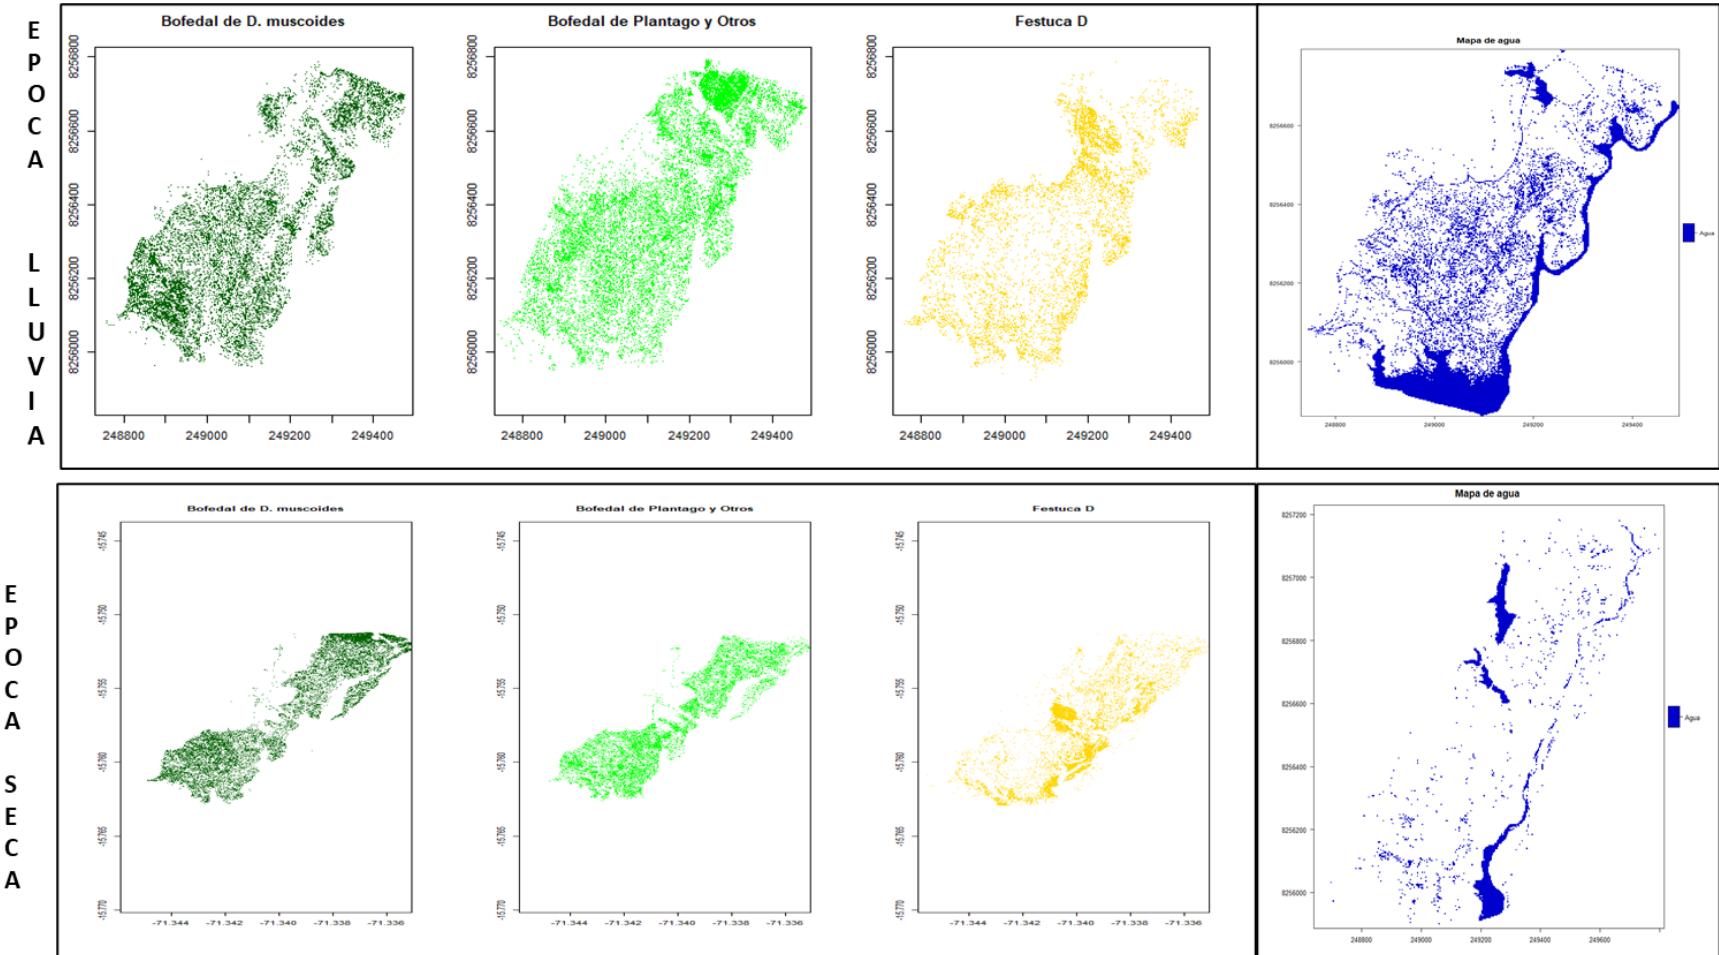
La clasificación supervisada sobre la ortofotografía multiespectral de la comunidad vegetal bofedal de puna seca, identificó cinco coberturas: bofedal DIMU, bofedal multiflora, inclusiones de FEDO, suelo desnudo y agua.

Los resultados de la estimación del área entre coberturas muestran diferencias entre las imágenes adquiridas al final de la época de lluvia y las imágenes adquiridas al final de la época seca. Para la época de lluvia, las cifras son: bofedal DIMU (1.66 ha), bofedal multiflora (0.75 ha) e inclusiones de FEDO (0.89 ha). Para la época seca se estimaron áreas ligeramente mayores (Tabla 15)

**Tabla 15: Estimación de cobertura vegetal por clase**

CLASE -COBERTURA	ÉPOCA LLUVIA		ÉPOCA SECA	
	ÁREA	%	ÁREA	%
BOFEDAL DIMU	7.27	20.62	8.93	25.31
BOFEDAL MULTIFLORA	8.45	23.96	9.20	26.07
INCLUSIONES FEDO	4.31	12.23	5.20	14.74
SUELO	3.63	10.30	9.24	26.20
AGUA	11.60	32.89	2.71	7.68
<b>TOTAL</b>	<b>35.27</b>	<b>100.00</b>	<b>35.27</b>	<b>100.00</b>

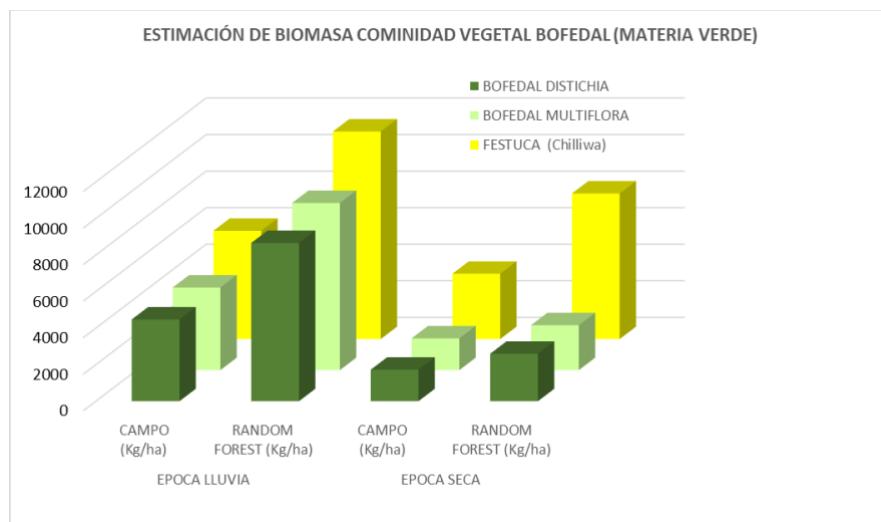
Las diferencias más importantes se observaron en la estimación de la cobertura de suelo y agua. Para la cobertura de suelo se halló 15.90% (5.61) más para la época seca. Para la cobertura de agua 25,21% (8.89) más para la época de lluvia. (Tabla 14) Las diferencias encontradas en la estimación de áreas de las coberturas de agua y suelo, muestran la importancia de los bofedales como reguladores de agua. Las coberturas muestran que en la época de lluvia el bofedal está inundado y contiene mayor volumen de agua. Ello explica que en la época seca el área de la cobertura suelo se incrementa (Figura 39).



**Figura 39: Coberturas de la comunidad vegetal bofedal**

El modelo *Random Forest*, para el final de la época de lluvia, estimó la producción de biomasa para bofedal DIMU en 8,658.98 Kg/ha (MV), para bofedal multiflora 9,145.85 Kg/ha (MV) y 11,357.47 Kg/ha para inclusiones de FEDO. Para el final de la época seca, el modelo estimó 2,596.03 Kg/ha de bofedal DIMU, 2,457.60 Kg/ha para bofedal multiflora y 7,963.47 Kg/ha de biomasa para inclusiones de FEDO (Tabla 16).

La estimación de producción de biomasa realizada por *Random Forest*, muestra diferencias importantes en la producción de biomasa entre las dos épocas de muestreo. Para el bofedal DIMU la diferencia de producción de biomasa es del 70% (6,062.95 Kg/ha), para el bofedal multiflora es del 73% (6,688.25 Kg/ha) y para las inclusiones FEDO del 29.88% (3,394.00 kg/ha). Las diferencias encontradas muestran acercamiento a la realidad, toda vez que los bofedales en la época de lluvia están más verdes, más exuberantes y el muestreo por unidad de área pesa más que en la época seca (Anexo 16 y Anexo 17).



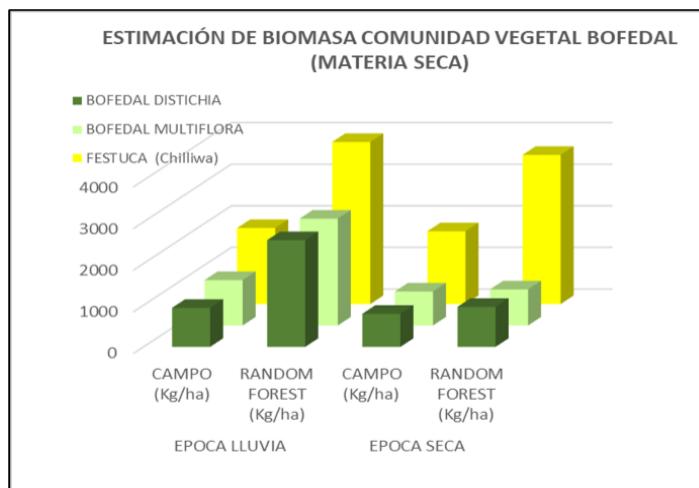
**Figura 40: Estimación de producción biomasa (MV) del bofedal en campo, con el modelo Random Forest**

**Tabla 16: Estimación de biomasa modelo Random Forest datos de campo de la comunidad vegetal bofedal**

CLASE	ÉPOCA DE LLUVIA				ÉPOCA SECA				
	ESTIMACIÓN BIOMASA		DIFERENCIA (Random Forest _ CAMPO)		ESTIMACIÓN BIOMASA		DIFERENCIA Random Forest _ CAMPO)		
	CAMPO (Kg/ha)	RANDOM FOREST (Kg/ha)	(Kg/ha)	%	CAMPO (Kg/ha)	RANDOM FOREST (Kg/ha)	Kg/ha	%	
MATERIA VERDE	<b>BOFEDAL DISTICHLIA</b>	4473.49	8658.98	4185.49	93.56	1723.16	2596.03	872.87	33.62
	<b>BOFEDAL MULTIFLORA</b>	4516.93	9145.85	4628.93	102.48	1735.59	2457.60	722.01	29.38
	<b>FESTUCA (Chilliwa)</b>	5922.74	11357.47	5434.74	91.76	3571.31	7963.47	4392.16	55.15
MATERIA SECA	<b>BOFEDAL DISTICHLIA</b>	937.84	2564.27	1626.43	173.42	795.05	961.23	166.18	17.29
	<b>BOFEDAL MULTIFLORA</b>	1090.25	2566.80	1476.55	135.43	815.49	867.13	51.64	5.96
	<b>FESTUCA (Chilliwa)</b>	1826.05	3894.27	2068.22	113.26	1749.00	3583.56	1834.56	51.19

La comparación de estimaciones de producción de biomasa entre el modelo RF y los valores calculados en base a muestras de materia verde tomadas en campo al final de la época de lluvia, muestran diferencias del 93.56% para el bofedal DIMU, 102.48% para el bofedal multiflora y 91.76% para las inclusiones FEDO. El mismo análisis realizado para la época seca, muestra menores diferencias entre métodos de estimación, siendo 33.62% para bofedal DIMU, 29.38 % para bofedal multiflora y 55.15% para inclusiones FEDO (Tabla 16 y Figura 40 y Anexo 18).

La estimación de biomasa en base a materia seca para la época de lluvias, muestran diferencias del 173.42% para bofedal DIMU, 135.43% para bofedal multiflora y 113.26 % para inclusiones FEDO, para la época seca presentan diferencias de 17.29% para DIMU, 5,96% para bofedal multiflora y 51.19% para FEDO (Figura 41 y Anexo 18).



**Figura 41: Estimación de producción biomasa bofedal (MS) en campo y con el modelo Random Forest**

La vegetación de los bofedales es postrada y forma almohadillas que reducen la compactación causada por el pastoreo. Ruiz y Tapia (1987) y Flórez (1993) muestran que, a pesar de la importancia de los bofedales en el ciclo hidrológico y la producción de biomasa, no existe una cuantificación que permita realizar el seguimiento y analizar la dinámica de este ecosistema en riesgo de desaparición.

Para la existencia de un respaldo científico y cuantitativo en el altiplano peruano - boliviano, Zorogastúa *et al.* (2012), utilizando el NDVI en imágenes LANSAT 2 y 5 y SPOT 4 y 5, discriminó y cuantificó áreas de cuerpos de agua, bofedales, tolares, pajonales, entre otros ecosistemas.

El presente estudio de identificación y estimación de biomasa en comunidades vegetales de puna seca, utilizando imágenes adquiridas con cámaras multiespectrales en una plataforma UAS, a 100 m de altura, además de identificar los ecosistemas tolar, bofedal y césped, discriminó el bofedal en sus componentes DIMU, bofedal multiflora y en las inclusiones de FEDO. Ello refleja que con imágenes que tienen resoluciones mayores, se consigue mejor separabilidad de parches y una mejor caracterización del bofedal.

Los resultados del análisis de las escalas espaciales del NDVI, obtenidas de las imágenes LANSAT 5 y la estimación de biomasa, muestran una variación del 90% en la estimación de la biomasa entre las épocas de lluvia y la época seca, determinando que los bofedales deben ser estudiados con resoluciones menores a 30 m (Zorogastúa *et al.* 2012).

El estudio realizado en el bofedal de Chalhuanca, con resoluciones espaciales de 6 a 13 cm/pixel y el modelo *Random Forest*, encontró una variación del 55% de producción de biomasa entre la época de lluvia y la seca para el bofedal compuesto por DIMU, multiflora e inclusiones de FEDO. Este resultado apoya las recomendaciones realizadas por Zorogastúa *et al.* (2012), De Cola (1997) y Paredes (2018), donde las imágenes de resolución menores a 30 m permiten definir los límites de un ecosistema o comunidad vegetal.

Los valores NDVI encontrados en el estudio presentan rangos de -0.40 a 0.90 para la época de lluvia y alcanzan un valor de -0.50 a 0.50 para la época seca en ortofotografías procesadas con R. En el mismo estudio, los valores encontrados con el software *Pix 4D* para la época de lluvia reportan un rango de 0.40 a 0.95, y para la época seca un rango de 0.1 a 0.95. Los valores NDVI encontrados en el estudio son cercanos a los valores NDVI estimados por Ramos (2018) en el período 1986 a 2016 con imágenes LANDSAT, ya que éste consigna valores de 0.22 a 0.99 en los extremos inferior y superior respectivamente, y para la época

seca se presentan valores que están entre 0.1 y 0.7. En ambos estudios la tendencia general de NDVI muestra variaciones para cada época. Mientras que Buitrón y Calisaya (2012), en su estudio de los bofedales de Sajama, en época seca encontraron valores de NDVI con umbrales que van de 0.2 a 1, que son diferentes a los valores encontrados en el bofedal de Chalhuanca, aun cuando se encuentran en una misma zona de producción de puna seca. El umbral superior estimado para los bofedales de Sajama sería ligeramente superior al encontrado entre los estudios realizados para bofedales en la región andina.

A partir del rango de NDVI, que varía entre -1 a +1, no solo se pueden realizar clasificaciones detalladas de los bofedales respecto a grupos de vegetación, sino también identificar con mayor precisión especies o ecotopos. Pero ello requiere de un conocimiento profundo de la diversidad florística del bofedal. La clasificación mediante valores de NDVI varía según las distintas clases de vegetación, dado que valores iguales en este índice pueden tener un significado muy distinto. Buitrón y Calisaya (2012), para el bofedal de Sajama en función al NDVI, identificaron de tres tipos de bofedales:

- ❖ Tipo 1: (Primario) Están representados por los cojines de *Distichia mucoides* o de *Oxychloe andina*.
- ❖ Tipo 2: (Secundario) Está compuesto por *Plantago rigida* o *Plantago tubulosa*, acompañado con *Juncus stipulatus*. Estos forman un césped plano y de color verde oscuro. En los alrededores de este césped se encuentran *Festuca orthophylla*.
- ❖ Tipo 3: (Terciario) Está compuesto por *Plantago rigida* o *Plantago tubulosa* con *Juncus stipulatus*, pero en forma dispersa no forman un césped discontinuo. Se encuentra entremezclado por formas circulares de *Deyeuxia curvula*.

En el estudio de identificación de comunidades vegetales en Chalhuanca, utilizando la clasificación supervisada y el algoritmo *Random Forest*, se identificaron tres clases de bofedal:

- ❖ **Clase I:** Bofedal de DIMU, compuesto por *Distichia muscoides* y *Oxicloe andicola*.
- ❖ **Clase II:** Bofedal Multiflora, compuesto por *Plantago sp.*, *Hypochoeris sp.*, *Lachhemilla sp.*; *Acciane sp.*, *Calamagrotis sp.* y *carex sp.*
- ❖ **Clase III:** Bofedal compuesto por inclusiones de *chilliwar* o *Festuca Dollicopilla*.

El análisis indica que existen coincidencias entre los tipos I y II y las clases I y II. Por ello, esta modalidad de clasificación podría considerarse adecuada para la estimación de la biomasa a partir de signos espectrales e índices de vegetación en los bofedales.

#### 4.2.2 Estimación de biomasa en la comunidad vegetal tolar de puna seca

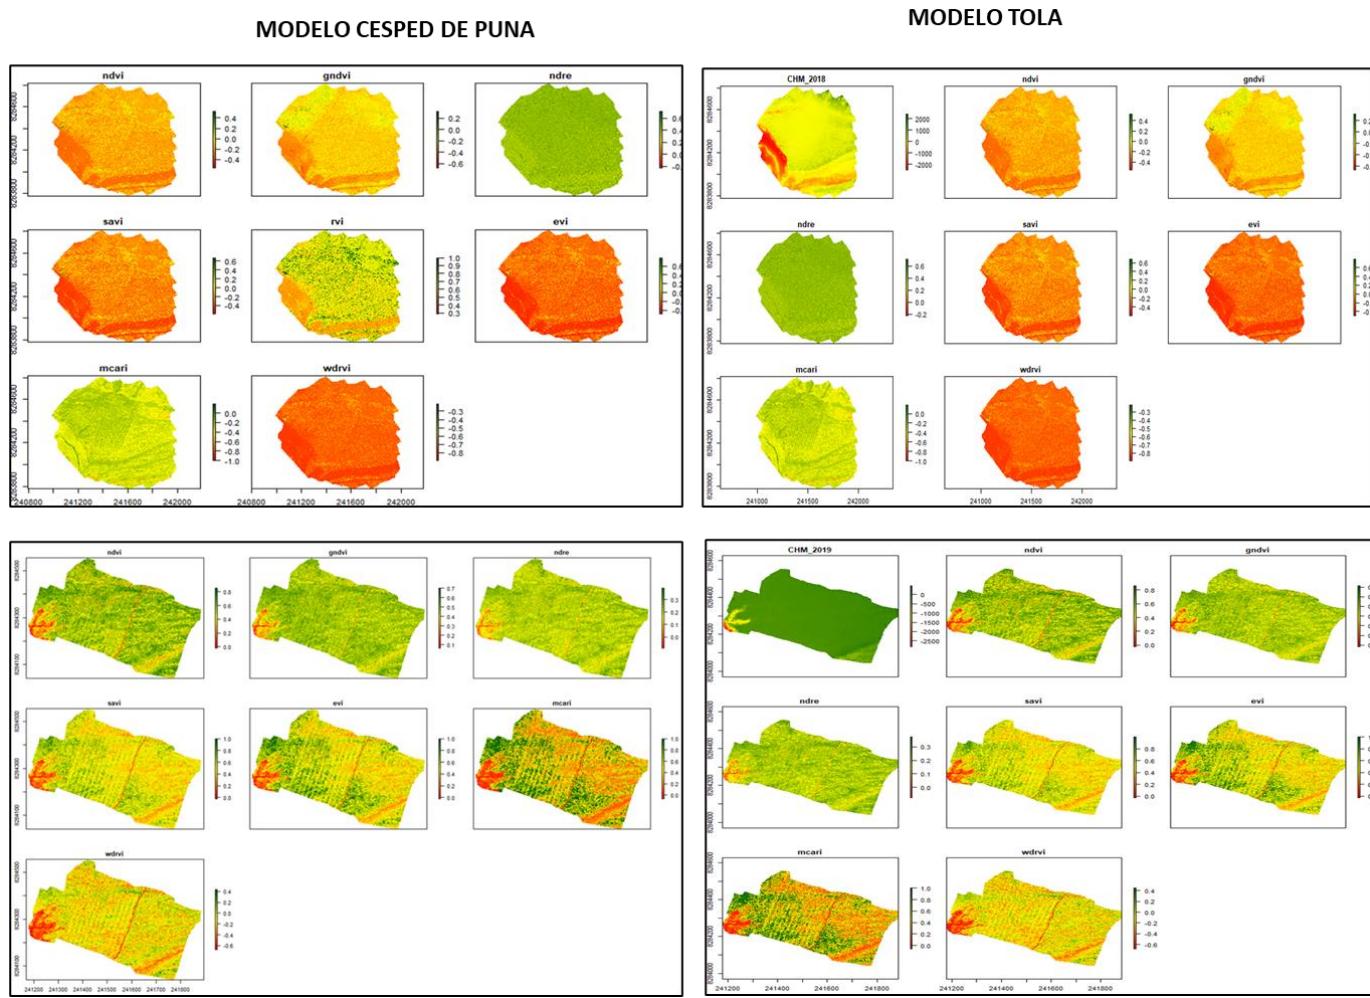
##### 4.2.2.1 Índices de vegetación estimados para la comunidad vegetal tolar de puna seca

Los valores del NDVI para la comunidad vegetal tolar en la época de lluvia, estuvieron en el rango de 0.0 a 0.8, mientras que los índices GNDVI, SAVI, EVI y MCARI mostraron valores positivos que van de 0.0 a 1.00.

En la época seca los valores del NDVI de esta comunidad vegetal presentaron un rango que va de -0.4 a 0.4. Los índices GNDVI, NDRE, SAVI y EVI muestran rangos de valor más amplios que van de -0.6 a 0.6. Los índices MCARI y WDRVI muestran rangos negativos desde -1.0 a 00 (Tabla 17 y Figura 42), los valores negativos encontrados corresponden a las coberturas de agua y suelo desnudo.

**Tabla 17: Índices de vegetación**

ÍNDICES	ÉPOCA LLUVIA		ÉPOCA SECA	
	MÍNIMO	MÁXIMO	MÍNIMO	MÁXIMO
NDVI	0.0	0.8	-0.4	0.45
GNDVI	0.1	0.7	-0.6	0.2
NDRE	0.0	0.3	-0.4	0.6
SAVI	0.0	1.0	-0.4	0.6
EVI	0.0	1.0	-0.6	0.6
MCARI	0.0	1.0	-1.0	0.0
WDRVI	-0.6	0.4	-0.8	-0.3



**Figura 42: Índices de vegetación en época seca y época de lluvia**

Índices de vegetación analizados desde el modelo césped y el moldeo tola. Parte superior época seca y parte inferior época de lluvia

Los valores observados muestran que en efecto existe influencia de la época de muestreo. La humedad o presencia de agua en el suelo y el estado fenológico (verdor o senescencia) de la comunidad vegetal tolar marca una diferencia.

#### **4.2.2.2 Predicción de biomasa aérea de la comunidad vegetal tolar de puna seca en base a índices de vegetación (evaluación de modelos, asociación de variables y predicción)**

La evaluación de modelos para estimación de biomasa reporta que el modelo *Random Forest*, utilizando información adquirida al finalizar la época de lluvia, presenta una precisión de entrenamiento de 0.9450, de verificación o prueba de 0.9409 y el coeficiente de Kappa asciende a 0.9071.

Los valores de precisión de *Random Forest* como estimador de biomasa, aun siendo cercanos a los valores de precisión del moldeo *Machine Learning* (SVM) y del moldeo *Elastic net*, permiten una clasificación de coberturas y estimación de biomasa más cercana a la realidad (Tabla 18).

**Tabla 18: Evaluación de modelos para predicción de biomasa**

MODELO	ÉPOCA DE LLUVIA			ÉPOCA DE SECA		
	PRECISIÓN		KAPPA TEST	PRECISIÓN		KAPPA TEST
	ENTRENA MIENTO	PRUEBA		ENTRENA MIENTO	PRUEBA	
Elastic Net	0.9111	0.9196	0.8946	0.7942	0.8067	0.7680
Machine Learning para clasificación (SVM)	0.9001	0.9093	0.8809	0.7797	0.7888	0.7465
Random Forest.	0.9450	0.9409	0.9071	0.8413	0.8333	0.791

Para el final de la época seca, *Random Forest* presenta 0.8413 como valor de precisión de entrenamiento, 0.8333 como valor de precisión de prueba y un índice de Kappa de 0.791, observándose la misma tendencia en los modelos *Elastic net* y *SVM*. Considerando los resultados obtenidos sobre la precisión de los tres modelos, en el presente estudio se tomó en

cuenta el modelo *Random Forest* para estimar la producción de biomasa en la comunidad vegetal tolar.

La media decreciente en *Gini* ( $MDG = Mean\ Decrease\ Gini$ ) muestra que los índices de vegetación tienen mayor importancia que los espectros o bandas como variables de estimación de biomasa para la comunidad vegetal tolar de puna seca. La priorización de variables realizadas a través de la MDG, muestra que, para la estimación de biomasa, según la época del año, existen diferentes índices de vegetación priorizados. De esta forma, queda establecido que para estimar biomasa sobre imágenes adquiridas al final de la época de lluvia será mejor usar los índices de vegetación WDRVI, NDVI y GNDVI, y con restricciones los índices de vegetación SAVI, EVI, mientras que para la época seca los índices priorizados para estimación de biomasa son EVI, RVI y WRDVI (Figura 43, Anexo 19, Anexo 20).

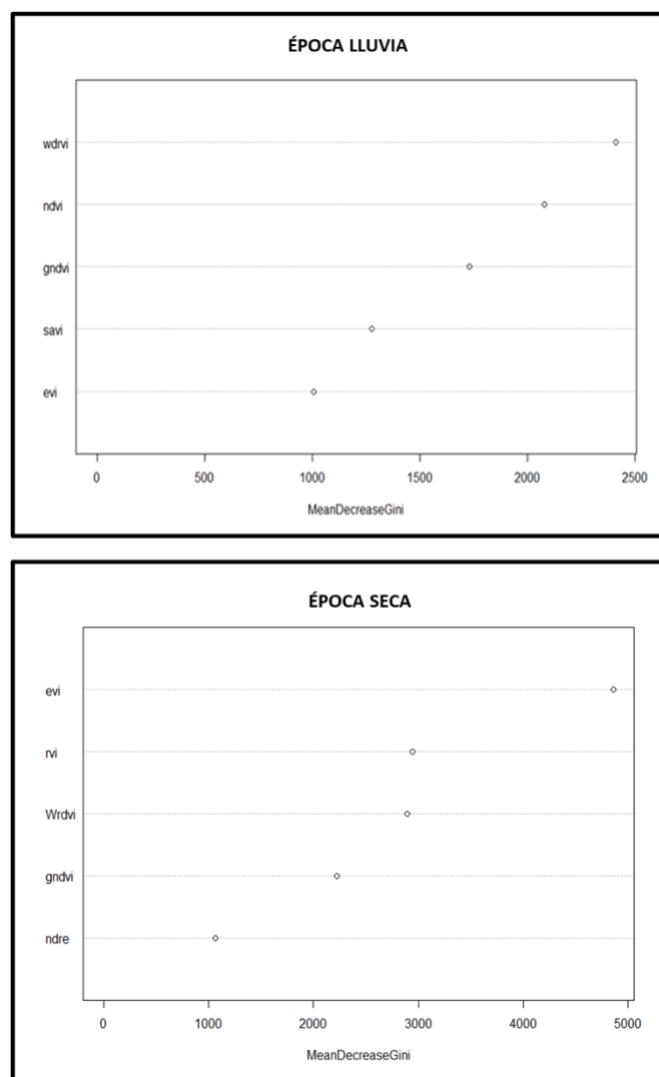
Las variables priorizadas en el párrafo anterior se sustentan en los resultados del análisis realizado a través de la MDG en muestras adquiridas al final de la época de lluvia. Ello permite establecer que los índices de vegetación WDRVI, NDVI y GNDVI son de alta importancia en la estimación de biomasa, por encontrarse en más de 2000 nodos de árboles de decisión aleatoria.

Los índices corregidos por suelo (SAVI) y saturación de vegetación (EVI) son calificados como índices de menor importancia para la estimación de biomasa, ya que se encuentran entre 1000 a 1500 nodos. Entre ambos índices, el análisis de muestras adquiridas al final de la época de lluvia a través de la MDG, evidenció que la variable de mayor prioridad es el índice de vegetación EVI, el que se encuentra en más de 4500 nodos, seguido por RVI y WRDVI, que se hace presente entre los 3000 a 4000 nodos de árboles de decisión aleatoria.

El coeficiente de correlación de Pearson, aplicado a muestras de materia verde adquiridas en la época de lluvia, define una asociación del 3% ( $p=0.03$ ) entre la biomasa estimada con los datos de campo y la biomasa estimada a partir de los índices de vegetación NDVI, NDRE, GNDI, SAVI, EVI y MCARI. En cambio, el índice WDRVI muestra una asociación negativa muy débil ( $p=0.00$ ). Para la misma época y tomando en cuenta la materia seca, se encuentra

una asociación positiva muy débil del 3 al 6%, con valores de ( $p= 0.03$ ) a ( $p=0.05$ ) (Figura 44).

El mismo coeficiente aplicado a muestras de materia verde adquiridas al final de la época seca, estima una asociación negativa débil para los índices de vegetación NDVI ( $p=-0.22$ ), GNDVI ( $p=-0.23$ ) y NDRE, RVI, EVI, WRDVI, con valores de ( $p=-22$  a  $p=-12$ ), siendo el único caso de correlación positiva muy débil el índice MCARI ( $p=0.07$ ). El análisis realizado con datos de materia seca, muestra la misma tendencia en la mayoría de los casos, una asociación negativa que va de débil a muy débil.



**Figura 43: Priorización de variables por importancia - índice decreciente de Gini**

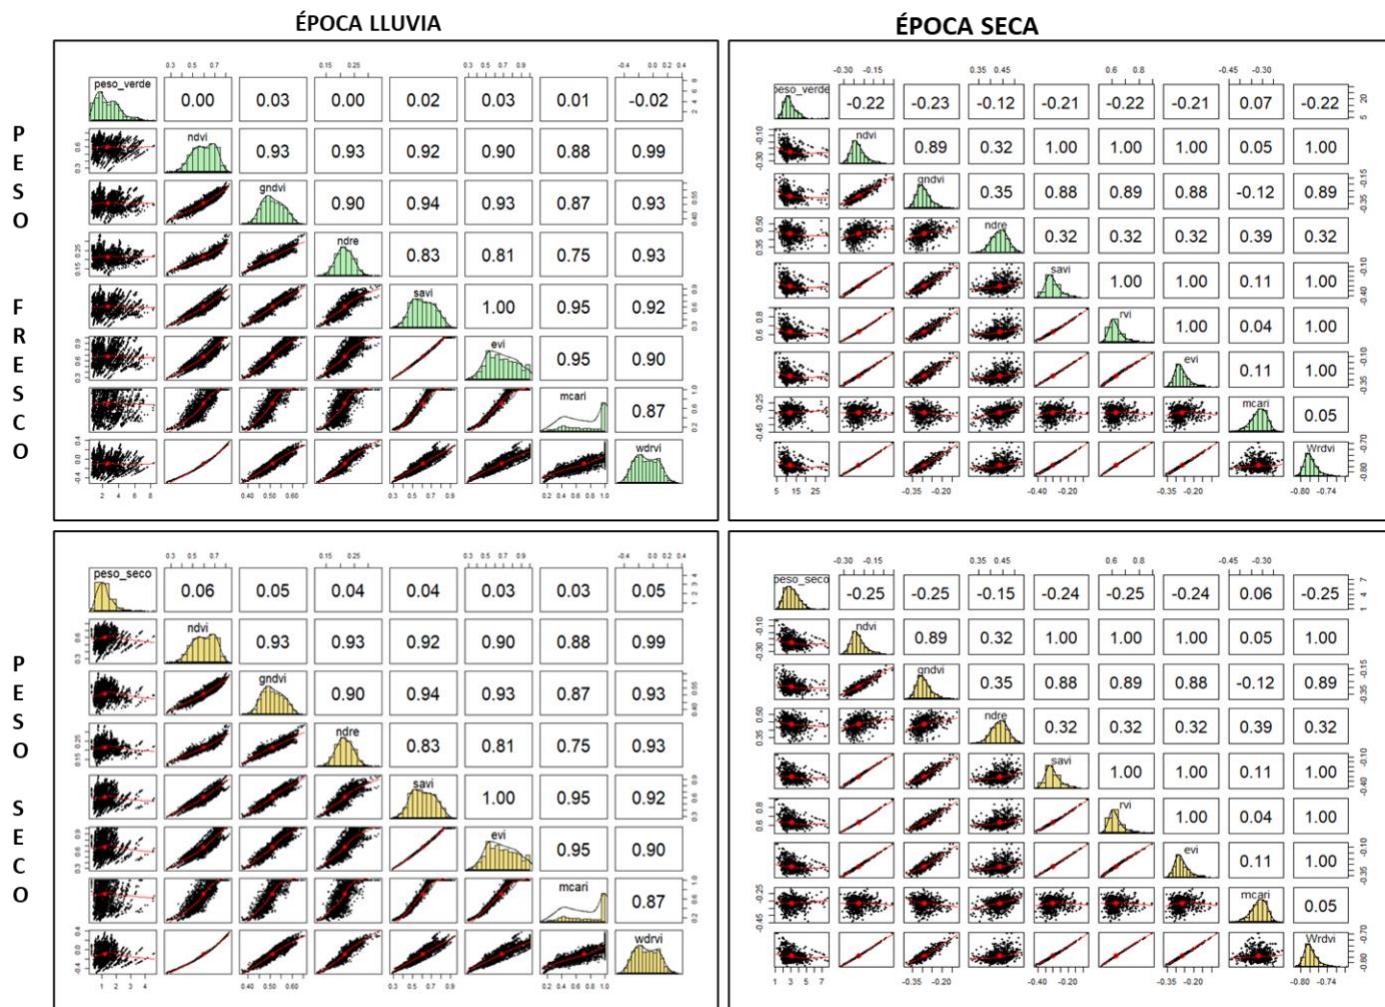


Figura 44: Asociación de variables para predicción de biomasa

El modelo *Random Forest* para la cobertura de césped de puna de la comunidad vegetal “tolar”, con información adquirida en la época de lluvia, predijo una producción de biomasa en un rango de 1 a 8 g/pixel de materia verde, siendo los más frecuentes los píxeles que predicen la producción de 1 y 2 g de biomasa. Los valores de predicción de biomasa en base a materia seca fueron de 0.1 a 4 g/pixel, presentándose con mayor frecuencia píxeles que producen 0.5 a 1.5 g de biomasa (Figura 45).

Este modelo, aplicado a las muestras recopiladas al final de la época seca, estimó una producción que va de 5 a 30 g/pixel de materia verde, encontrándose mayor frecuencia de píxeles que producen 10 y 11 g de biomasa. Los resultados en base a materia seca en la misma época, predicen un rango de producción de 1 a 8 g/pixel de biomasa, encontrándose con mayor frecuencia píxeles que producen 2 a 4 g de biomasa. Los resultados encontrados durante el proceso de estimación de biomasa, para el césped del Fundo Quena, muestran poca variación entre época de lluvia y época seca.

El modelo *Random Forest* aplicado a la cobertura tolar de la comunidad vegetal, en muestras adquiridas al final de la época de lluvia, predijo una producción de biomasa en un rango de 1 a 40 g/pixel, teniendo mayor frecuencia los píxeles que estiman 2 a 3 g de biomasa. Para las muestras adquiridas al final de la época de lluvia, el modelo predijo producciones de biomasa de 1 a 60 g/pixel, mostrando mayor frecuencia de píxeles que producen 5 g de biomasa en materia verde. La predicción de biomasa en base a materia seca para ambas épocas presentó mayor frecuencia de píxeles que predicen 4 a 5 g/pixel de biomasa (Figura 46).

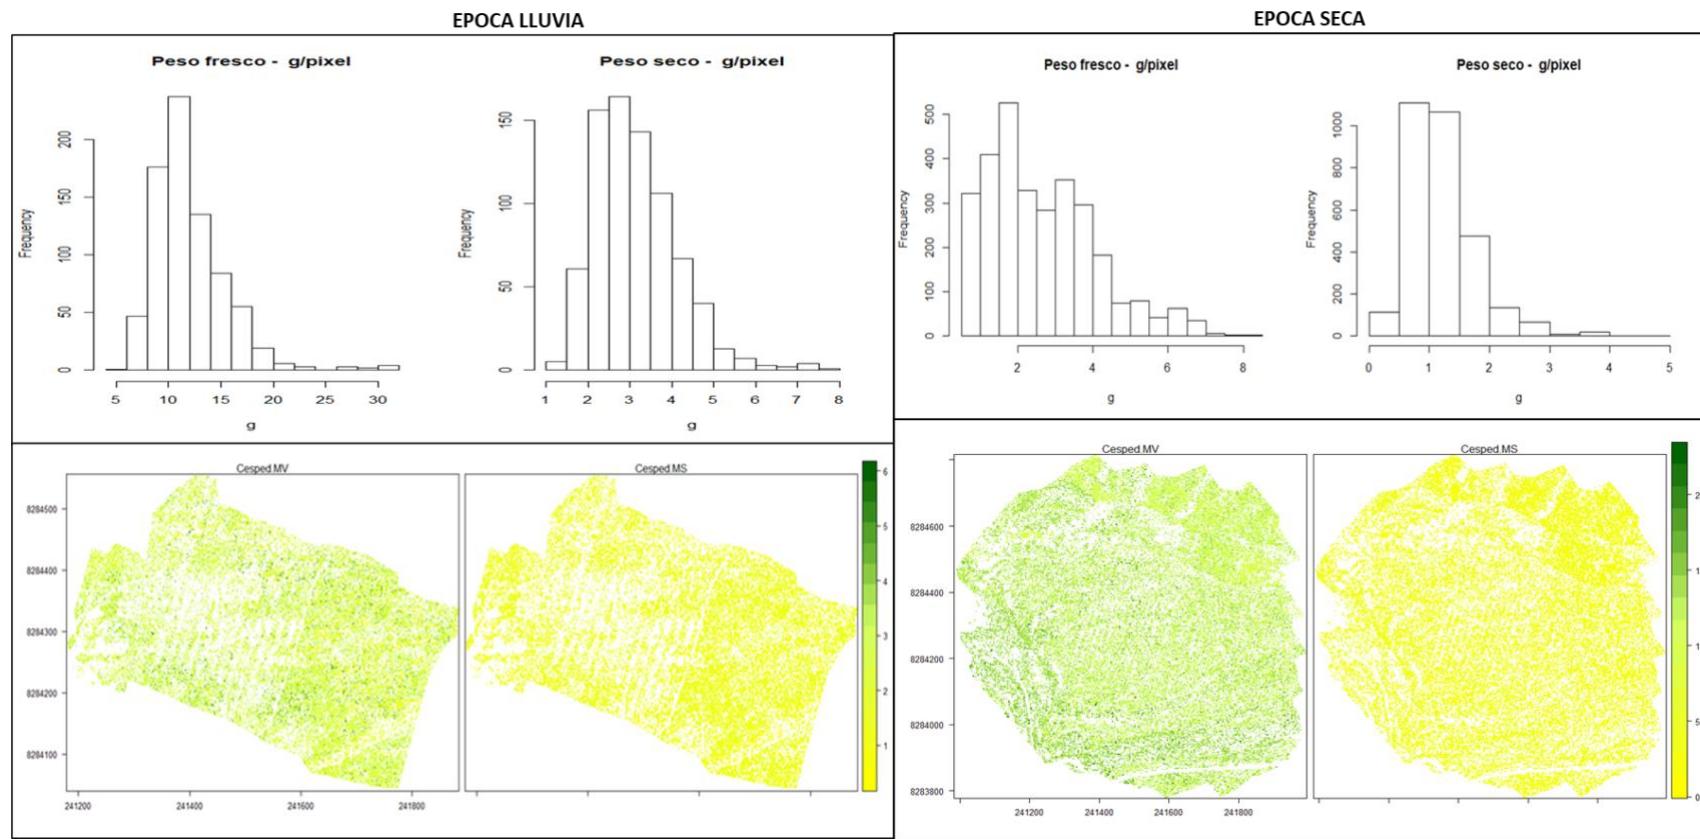
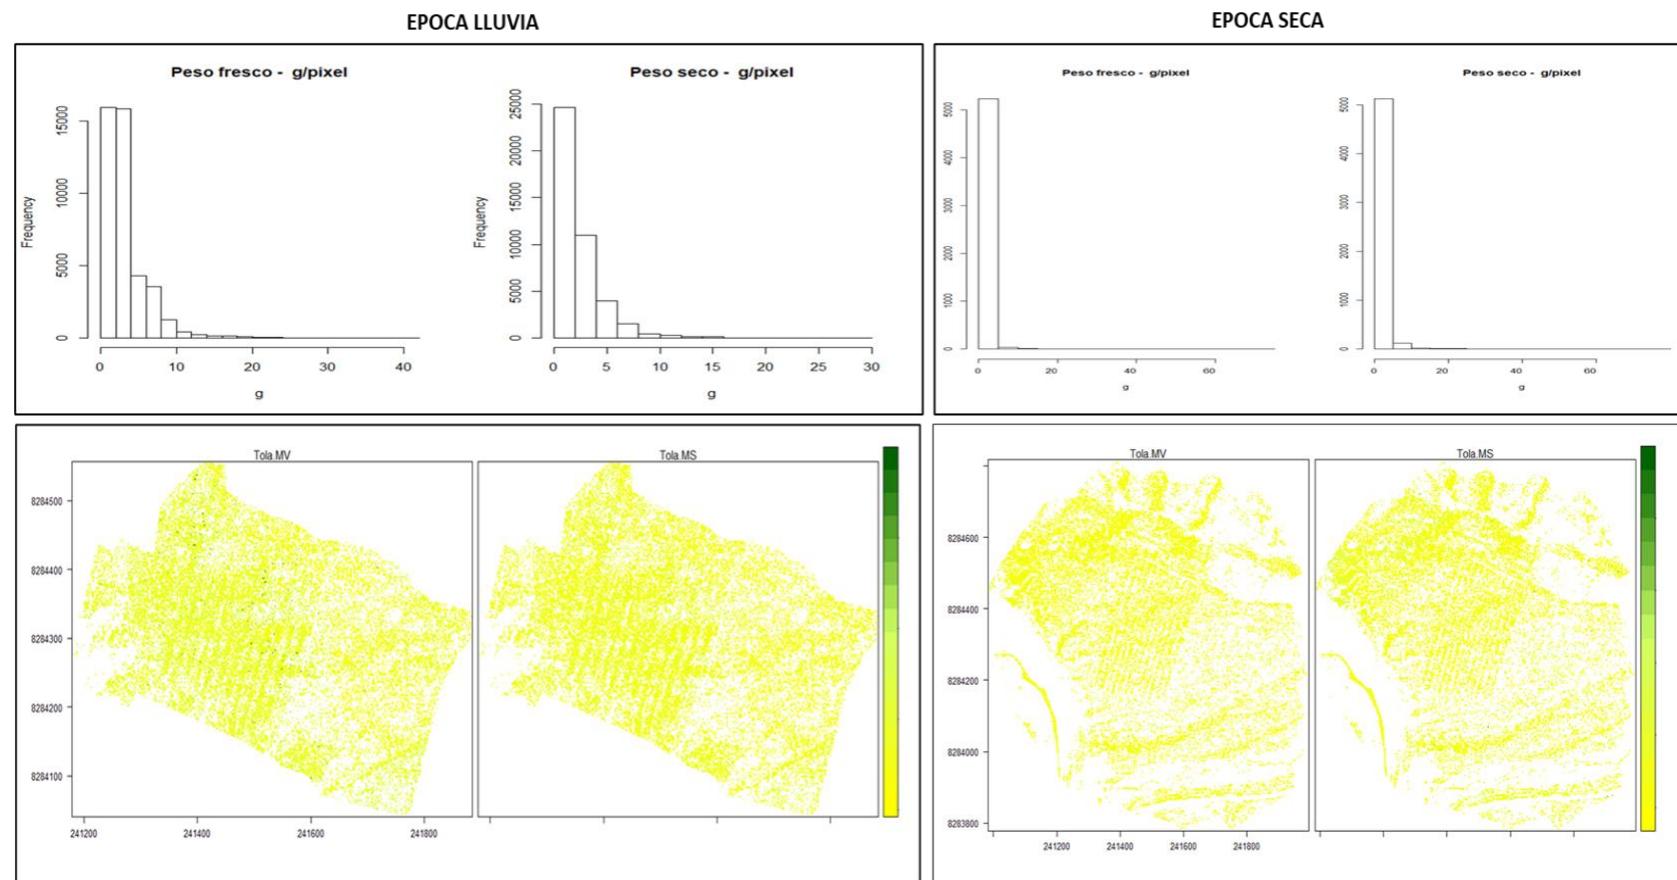


Figura 45: Estimación de biomasa con modelo RF para cobertura césped de puna



**Figura 46:** Estimación de biomasa con modelo RF para cobertura tolar

La evaluación de predicción de biomasa a partir de índices de vegetación para la época de lluvia y época seca, muestran que el modelo de Regresión Lineal ( $R^2= 0.0427$  y  $R^2= 0.146$ ) y el modelo SVM ( $R^2= 0.0016$  y  $R^2= 0.174$ ) presentan los más bajos coeficientes de determinación, siendo su posibilidad de estimación de biomasa muy imprecisa. Ante la evidencia, se concluye que dichos modelos no estarían en condiciones de estimar la producción de biomasa en ninguna época del año.

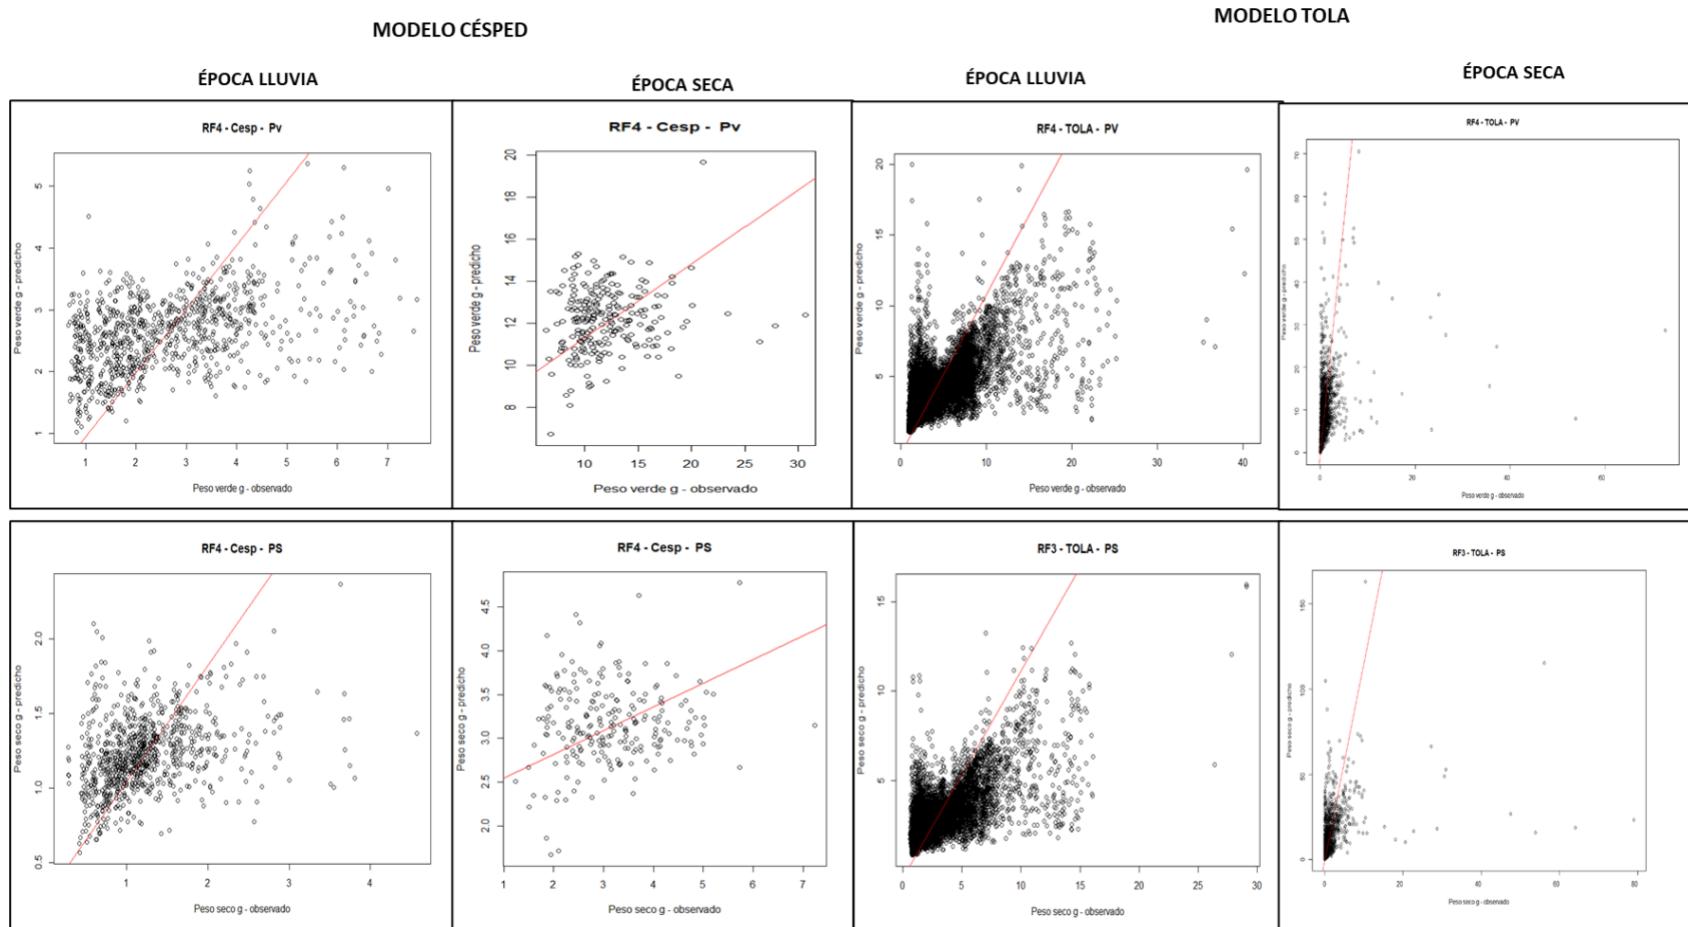
El modelo *Random Forest* realiza la predicción de biomasa de la comunidad vegetal tolar de puna seca con un coeficiente de determinación ( $R^2= 0.4842$ ) para el final de la época de lluvia, y ( $R^2= 0.418$ ) para el final de la época de seca (Tabla 19).

**Tabla 19: Evaluación de los modelos para predicción de biomasa**

MODELO	ÉPOCA LLUVIA			ÉPOCA SECA		
	RMSE	RSq	MAE	RMSE	RSq.	MAE
Linear Regression	2.768	0.043	1.859	3.490	0.146	2.470
Support Vector Machine (SVM)	1.432	0.002	1.131	3.325	0.174	2.904
Random Forest	1.994	0.484	1.148	3.623	0.418	2.817

Los coeficientes de determinación en su conjunto son bajos, por lo que su posibilidad para predecir biomasa de la comunidad vegetal tolar no será el más óptimo. Considerando que el estudio no puede controlar variables de la naturaleza, se puede explicar que el modelo *Random Forest* ha estimado predicciones de producción de biomasa más cercanas a lo observado en campo para las dos épocas de estudio.

El gráfico de dispersión (Figura 47) muestra una mejor distribución para RF en la predicción de producción de biomasa en base a materia verde (peso fresco) para las coberturas de césped y tolar en ambas épocas de muestreo. RF, en base a materia seca (peso seco) predice mejor la producción de biomasa para la cobertura de césped, mientras que RF para cobertura de tolar.



**Figura 47: Comparación entre predicción RF y observado en campo**

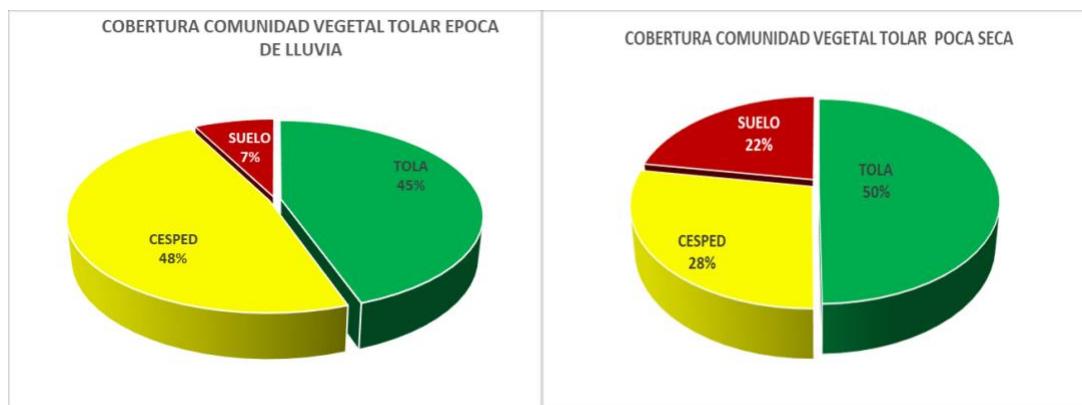
Los gráficos de dispersión muestran que los valores predichos y observados están concentrados entre 1 y 3 g/pixel de biomasa en base a materia verde para el final de la época de lluvia, y de 5 a 15 g/pixel de biomasa para el final de la época seca. Para la cobertura tola, los gráficos muestran valores de 3 a 10 g/pixel de biomasa en base a materia verde.

Sin embargo, el modelo no logró predecir adecuadamente la producción de biomasa de la cobertura tolar en época seca.

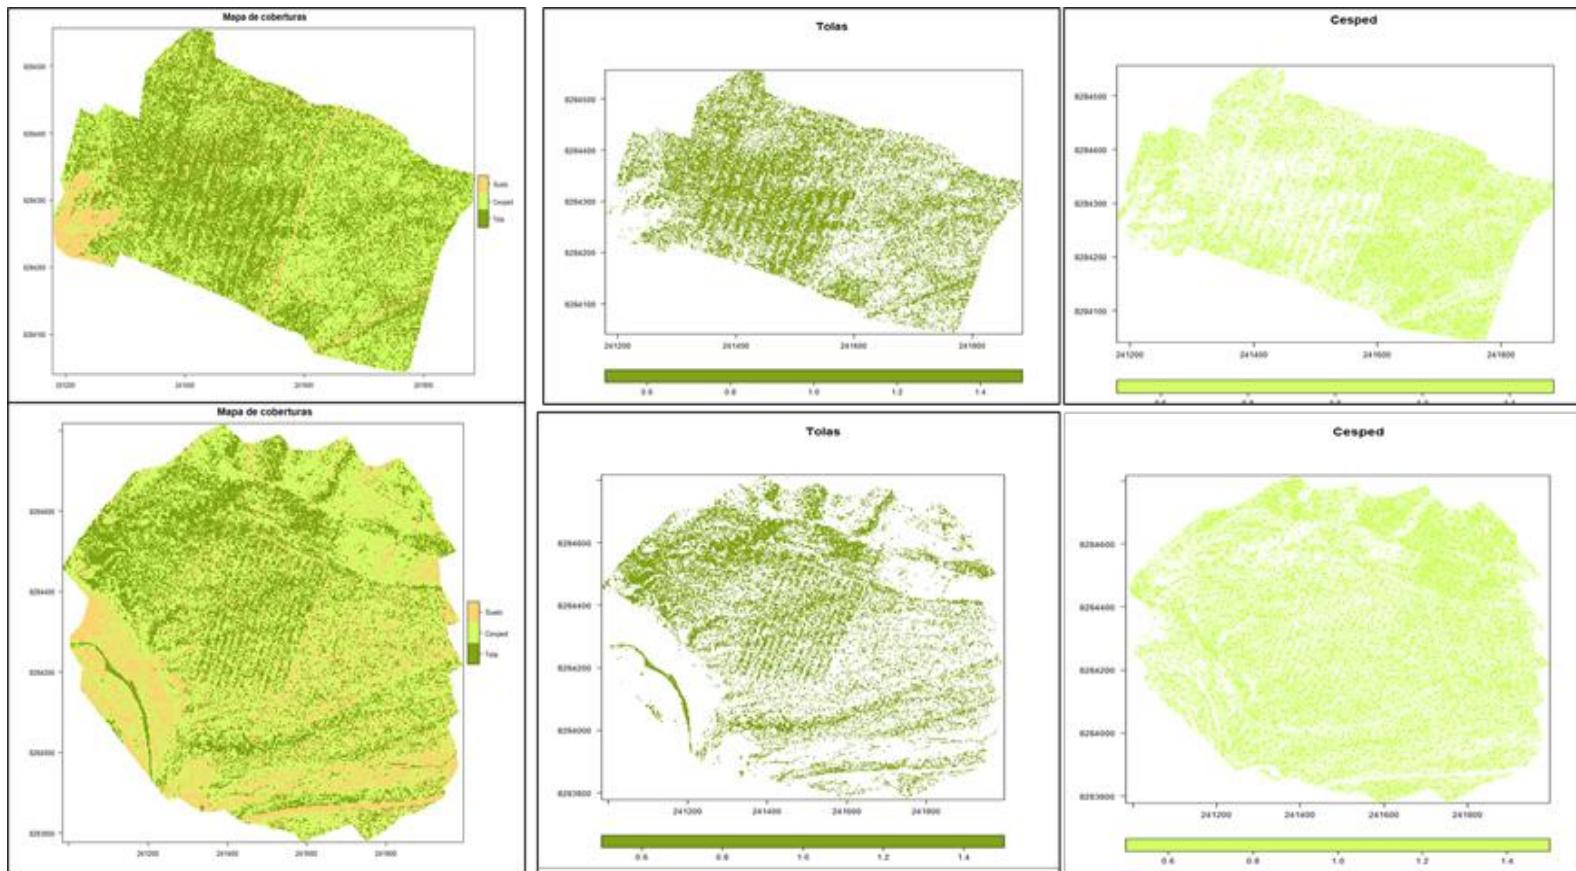
#### **4.2.2.3 Elaboración de mapas de producción de biomasa de la comunidad vegetal tolar del fundo Quena Callalli**

El modelo *Random Forest*, al clasificar la cobertura y la predicción de biomasa, estimó que la comunidad vegetal tolar (20 hectáreas) del fundo Quena, está compuesto por tres clases de cobertura: tola, césped y suelo (Figura 48).

La clase tola ocupa el 44.61 % (9.190 ha.) para la época de lluvia y 49.78% (9.956 ha.) para la época seca, constituyéndose como la especie dominante de la comunidad. La clase césped de puna tiene un comportamiento variable: en la época de lluvia ocupa el 47.82% (9.85 ha.) y en la época de seca ocupa el 27.86% (5.57 ha) de la comunidad, mostrando una diferencia de 19.6 % (4.28 ha.) entre épocas. La clase suelo desnudo también presenta un comportamiento variable entre épocas de muestreo: en la época de lluvia ocupa el 7.57% del área y en la época seca el 22.6% (Figura 48, Anexo 21).



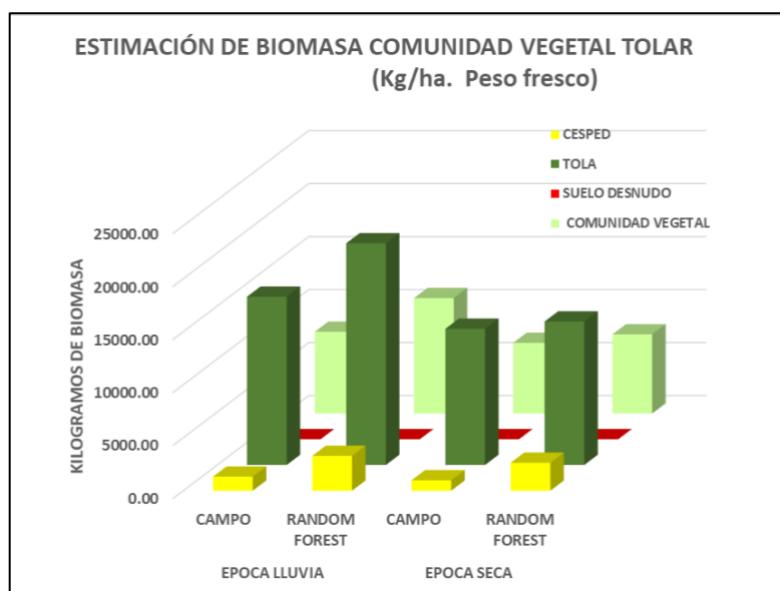
**Figura 48: Estimación de cobertura vegetal**



**Figura 49: Clasificación de coberturas comunidad vegetal tolar de puna seca**

El modelo *Random Forest* aplicado a la clase césped de puna seca, estimó una producción de biomasa en materia verde de 3,282.50 kg/ha para la época de lluvia y de 2,630.11 kg/ha de biomasa para la época seca. La producción de materia seca se estimó en 864.86 kg/ha para la época de lluvia y 1,245.73 kg/ha de biomasa para la época seca (Tabla 20).

La producción estimada de biomasa en materia verde para muestras colectadas en campo fue de 1,326.00 kg/ha para época de lluvia y 975 kg/ha para época seca. Para la materia seca se estimó una producción de biomasa de 450 kg/ha para época de lluvia y 351.00 kg/ha para época seca (Tabla 20). Las diferencias de las estimaciones de producción de biomasa para el componente césped de puna en base a materia verde, ascienden a 147.55% para la época de lluvia y de 169.75% para la época seca. El análisis de resultados en base a materia seca muestra la misma tendencia (Figura 50 y Anexo 22).



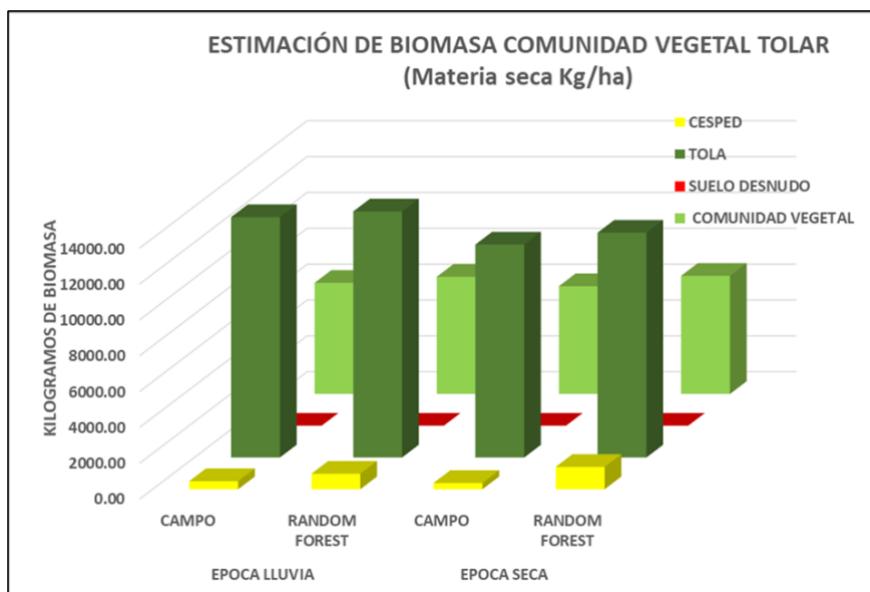
**Figura 50: Estimación de producción de biomasa para la comunidad vegetal tolara materia verde**

La producción de biomasa de la clase tola estimada con *Random Forest* en la época de lluvia, fue de 20,914.42 kg/ha, mientras la producción de biomasa estimado con datos adquiridos en campo es de 15,875.00 kg/ha. Los resultados muestran una diferencia de 31.74% (Tabla 20).

**Tabla 20: Estimación de biomasa con Randon Forest y datos de campo**

CLASE	ÉPOCA DE LLUVIA				ÉPOCA SECA				
	ESTIMACIÓN BIOMASA		DIFERENCIA (RF _ CAMPO)		ESTIMACIÓN BIOMASA		DIFERENCIA (RF _ CAMPO)		
	CAMPO (Kg/ha)	RANDOM FOREST (Kg/ha)	(Kg/ha)	%	CAMPO (Kg/ha)	RANDOM FOREST (Kg/ha)	Kg/ha	%	
MATERIA VERDE	CESPED	1326.00	3282.50	1956.50	147.55	975.00	2630.11	1655.11	169.75
	TOLA	15875.00	20914.42	5039.42	31.74	12850.00	13535.20	685.20	5.33
	COMUNIDAD VEEGETAL	7716.13	10889.82	3173.68	41.13	6668.37	7470.57	802.20	12.03
MATERIA SECA	CESPED	450.84	864.86	414.02	91.83	351.00	1245.73	894.73	254.91
	TOLA	13406.25	13723.63	317.38	2.37	11877.25	12538.68	661.43	5.57
MATERIA SECA	COMUNIDAD VEGETAL	6196.32	6535.88	339.55	5.48	6010.28	6588.81	578.53	9.63

Para la época seca, *Random Forest* estimó la producción de biomasa en base a materia verde en 13,535 kg/ha, mientras que la estimación con datos de campo fue de 12,850 kg/ha, mostrando una diferencia del 5.33%. Las diferencias de estimación en base a materia seca fueron menores para muestras de ambas épocas. Estos resultados determinan que el modelo *Random Forest* permite resultados más cercanos a las estimaciones realizadas con datos de campo (Anexo 23).



**Figura 51: Estimación de producción de biomasa para la comunidad vegetal tolar con materia seca**

Para la comunidad vegetal tolar de puna seca (coberturas de césped, tola y suelo desnudo) el moldeo *Random Forest* estimó para la época de lluvia una producción de biomasa de 10,889.82 kg/ha tomado en cuenta la materia verde, mientras que la producción de biomasa estimada con datos de campo fue de 7,716.3 kg/ha, encontrando una diferencia entre los dos métodos de estimación del 41.13% en materia verde y 5.48 % en materia seca para la misma época.

La estimación realizada con *Random Forest* para el final de la época seca, fue de 7,470.57 kg/ha de biomasa en materia verde, y 6,668.37 kg/ha de biomasa en materia seca para las muestras de campo, hallándose una diferencia de 12.03% entre métodos de estimación de biomasa en base a materia verde. El análisis realizado para la estimación de biomasa en base a materia seca encontró una diferencia de 9.63% (Figura 51) entre métodos de evaluación (Anexo 24 y 25).

La comunidad vegetal tolar está constituida principalmente por las especies arbustivas de los géneros *Parastrepia* y *Baccharis*, y tienen un rol fundamental para el mantenimiento de la vida en las zonas áridas y semiáridas, creando microclimas favorables para la vegetación herbácea que se desarrolla en la sombra (Zorogastua 2012).

Esta comunidad vegetal es de alta importancia en la sierra sur del Perú, en la denominada zona homogénea de producción de puna seca (Tapia y Flores 1984, Berrio y Estrada 1994). El estudio de identificación de comunidades vegetales y estimación de biomasa a partir de signos espectrales, también menciona que la comunidad vegetal tolar es de alta importancia porque facilita el desarrollo del césped como componente de la comunidad y actúa como regulador del ciclo hidrológico, funciones que contribuyen al medio ambiente y a la economía de los pastores.

La percepción remota es una herramienta valiosa de apoyo para las estimaciones de biomasa. Los signos espectrales e índices de vegetación son útiles para estimar de forma indirecta la biomasa, información que debe ser complementada con datos de campo (Chuvieco 2008). Los índices de vegetación obtenidos de plataformas UAS, inicialmente fueron utilizados en agricultura (Berrio *et al.* 2015 y Botello *et al.* 2019) midieron la relación de vigor vegetal con niveles de clorofila para la caña de azúcar. El mapa de NDVI en función a la respuesta espectral obtenida alta, baja o nula. Les permitió la clasificación de parcelas dispersas a lo largo del campo de caña de azúcar y en base a esta información formularon planes de manejo del cultivo de caña.

La correlación entre el estado de los valores de NDVI y el estado de salud de las plantas es alta, de manera que los valores mayores del índice NDVI (superior 0.49) pertenece a las parcelas más saludables. Mientras que los valores bajos, que van de 0.21 a 0.39, están en las parcelas más afectadas por el estrés nutricional o pobre densidad nutricional. Los valores inferiores de 0.21 llamados valores casi nulos de NDVI, se hallan en los sectores de vegetación en mal estado y suelos pobres.

En el Perú, un estudio de pastizales altoandinos a partir de signos espectrales e índices de vegetación con un sensor MODIS TERRA (Paredes 2017), muestra que las relaciones entre las variables NDVI–biomasa y EVI–biomasa, tuvieron coeficientes de determinación de  $R^2$  0.31 y  $R^2=0.22$  respectivamente. En Córdoba, Argentina, un estudio que utilizó imágenes LANSAT 5 TM con datos de biomasa en campo y NDVI obtenidos por sensores remotos, reportó el coeficiente de determinación más alto para estudios de biomasa de pastizal, que es de ( $R^2=0.50$ ) (Santa *et al.* 2013). Estos estudios recomendaron el uso de imágenes satelitales de sensores con una mayor resolución espacial.

El estudio realizado en la comunidad vegetal tolar de puna seca en Caylloma, Arequipa, utilizando una plataforma UAS, signos espectrales, índices de vegetación diversos y el modelo *Random Forest*, encontró coeficientes de determinación bajos ( $R^2=0.4842$  y  $R^2=0.418$ ) para la época de lluvia y seca respectivamente. Estos valores son muy cercanos a los coeficientes de determinación ( $R^2$  0.31 y  $R^2=0.22$ ) reportados por Paredes (2018) en el caso de los pajonales de la sierra central y los reportes de Kharuf *et al.* (2018) que obtuvo coeficientes de determinación de ( $R^2= 0.21$  a  $R^2=0.39$ ).

Los bajos coeficientes de determinación y correlación encontrados en los estudios de Bessone *et al.* (2016), Paredes (2017), Bethany *et al.* (2019), Botello *et al.* (2019) y Grüner *et al.* (2018) atribuyen a: las diferencias propias de los cultivos y las comunidades vegetales para cada una de las zonas de estudio, a la característica heterogénea de la vegetación contenida en un pixel, al número de observaciones por pixel para el método de estimación de biomasa utilizado y, al ruido de la imagen según la época adquirida.

El estudio de Bessone *et al.* (2016) para estimar el rendimiento de trigo con imágenes adquiridas con UAS y el uso del índice NDVI y NDRE, concluye que es posible usar mapas de los índices NDVI y NDRE como referencia para identificar y/o diferenciar zonas de mayor potencial de rendimientos, considerando que el mejor performance del NDVI se presenta en zonas con menor cobertura vegetal. En zonas con mayor índice de área foliar y en zonas bajo riego, la inclusión de la banda del borde rojo utilizando el índice NDRE genera un mapa resultante de mayor precisión, mejorando su asociación con el rendimiento. El estudio de comunidades vegetales establece que, la estimación de biomasa en pastizales de puna seca, en la época de lluvia, muestran buena performance de estimación los índices de vegetación de GNDVI, NDVI, WRDVI, seguidos por los índices corregidos por suelo (SAVI) y saturación de vegetación (EVI). Para la época seca se identificó que las bandas RED y GREEN y los índices MCARI, EVI y SAVI son variables de alta importancia en la predicción de biomasa, aunque el modelo *Random Forest* es el que predice la producción de biomasa más cercana a la realidad.

Las predicciones de biomasa en pastizales tienen relación directa con la época de muestreo. Santa *et al.* (2013), a partir del NDVI, estimaron 189,6 g/m<sup>2</sup> para el mes de diciembre del 2011 y para el mes de marzo 105,74 y 115,22 g/m<sup>2</sup>. Paredes (2018), en la sierra central del Perú, obtuvo valores de biomasa disponible entre 1,558 y 3,559 kg de MS/ha. Para la comunidad vegetal tolar, utilizando el algoritmo *Random Forest*, con índices de vegetación priorizados como variables, el estudio estimó una producción de biomasa de 10,889.82 kg/ha, que resulta mayor a la estimación realizada con datos de campo, que fue de 7,716.3 kg/ha de materia verde para la época de lluvia. Los resultados encontrados son diferentes a los de Santa *et al.* (2013) y superiores a los de Paredes (2018), situación que se explica por la diferencia de la composición florística de cada comunidad estudiada.

Para la comunidad vegetal tolar en su conjunto (césped, tola y suelo desnudo), utilizando el algoritmo *Random Forest* en términos de materia verde y en la época de lluvia, se estimó una producción de biomasa de 10,889.82 kg/ha, encontrando una diferencia entre los dos métodos de estimación del 41.3% en materia verde y 5.48 % de diferencia para misma época en materias seca.

Las estimaciones realizadas con *Random Forest* para la época seca fue de 7,470.57 kg/ha de materia verde, y se estimó 6,668.37 kg/ha de biomasa con información de las muestras de campo. Se halló una diferencia de 12.03% en la materia verde, mientras que para la materia seca la diferencia es de 9.63%.

Utilizando el modelo *Random Forest*, con imágenes UAS de alta resolución espacial y espectral, se puede elaborar, a una escala espacial fina, clasificaciones de coberturas detalladas de la comunidad vegetal. Además, el modelo muestra gran potencial para el mapeo de comunidades a nivel de especies. Este resultado coincide con los reportes de Bethany *et al.* (2019), quienes realizaron estudios de pastizales con sensores hiperespectrales de alta resolución en plataformas UAS, concluyendo que el uso de sensores de alta resolución y el modelo de predicción RF es muy útil para la identificación y clasificación de pastizales, así como para la estimación de la biomasa.

La clasificación comunidades vegetales y la estimación de biomasa utilizando sensores de alta resolución en plataformas UAS, puede realizarse con ortofotografías NDVI obtenidas en el rango espectral del sensor utilizado, siempre y cuando cubran la banda roja e infrarrojo cercano del espectro de 600 a 875 nm. Sin embargo, la tarea de clasificación de coberturas resulta potenciada con el uso de imágenes adquiridas en el espectro visible (Bethany *et al.* 2019). Esta afirmación muestra concordancia con los resultados del presente estudio, donde las imágenes adquiridas con sensores multiespectrales de alta resolución y procesadas en el modelo RF, permitieron clasificar coberturas y estimar biomasa con valores más cercanos a los estimados en el trabajo de campo.

## **4.3. ESCALAMIENTO DE ORTOMOSAICOS OBTENIDOS CON PLATAFORMA UAS, HACIA UNA IMAGEN SATELITAL RAPIDEYE**

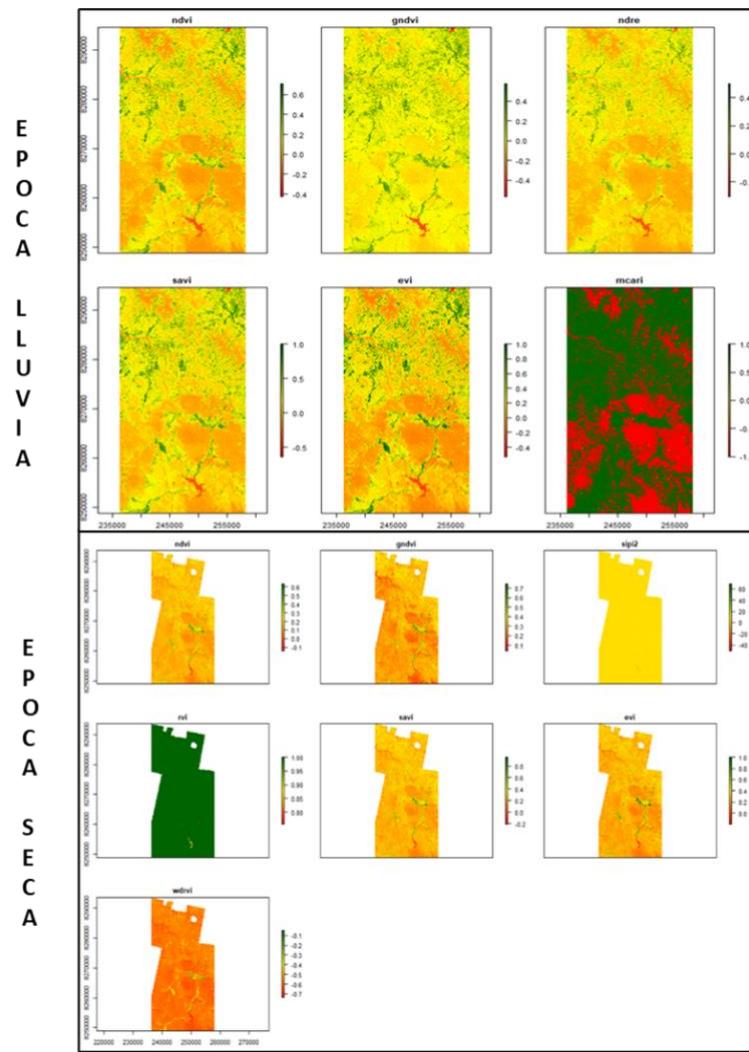
### **4.3.1 Índices de vegetación de las comunidades vegetales de puna seca en imágenes *Rapideye***

El valor de NDVI, GNDVI y NDRE alcanzados en las imágenes *Rapideye* fue de (-0.4 a 0.6) y (-0.1 a 0.7) para la época de lluvia y seca respectivamente. El índice de vegetación que muestra el mayor rango es MCARI, con valores de (-1.0 a 1.0) seguido de los índices SAVI, EVI, GNDVI y WDRVI que muestran valores de (-0.5 a 1.0) (Figura 52, Anexo 3).

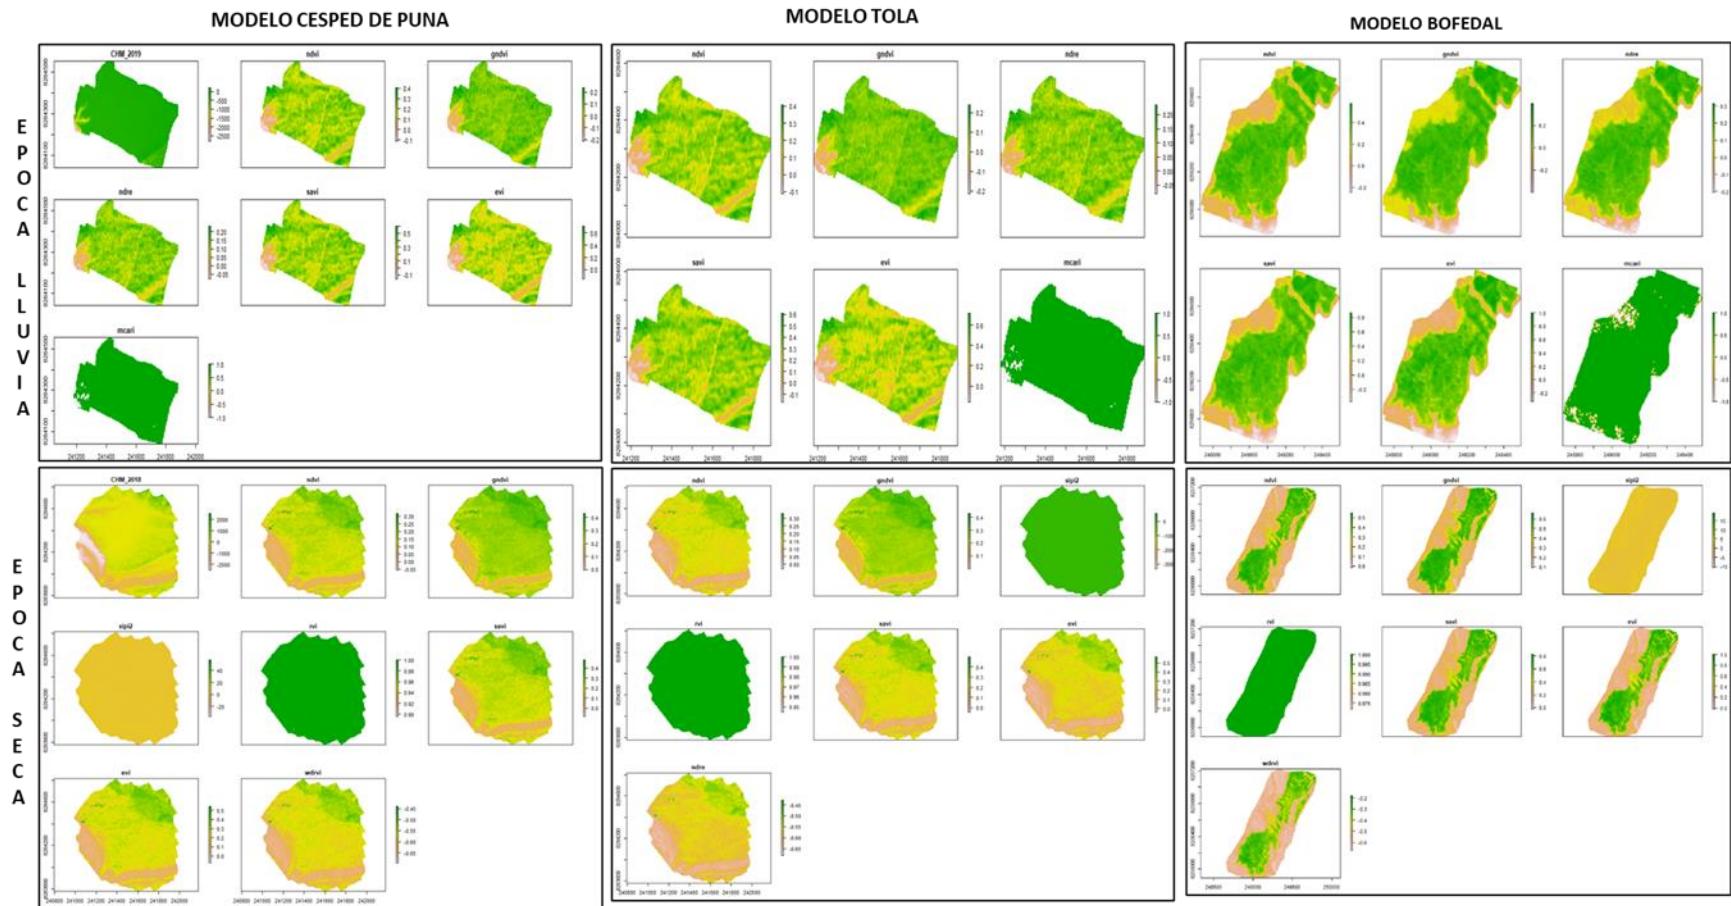
Con las imágenes *Rapideye* + UAV escaladas, se estimaron los índices de vegetación para las comunidades vegetales tolar (tolá y césped) y bofedal. Los resultados para el NDVI muestran rangos pequeños con valores de (-0.2 – 0.5), registrándose los valores más altos (0.00 – 0.5) para bofedales y (-0.1 – 0.4) para césped y tolá. En el mismo ámbito, y utilizando las ortofotografías multiespectrales, se estimó valores de NDVI de (-0.5 a 0.95). Los valores de los demás índices de vegetación estimados tienen la misma tendencia (Figura 53).

Los resultados para la comunidad vegetal tolar con sus componentes césped y tolá (Anexo 26), muestran valores bajos en la estimación de índices de vegetación que van de (-0.1 a 0.3) para el componente tolá, y de (-0.2 a 0.5) para el componente césped. Estos valores son menores a los obtenidos con las ortofotografías adquiridas con UAV, que en el caso del NDVI presenta un rango amplio que va desde (-0.4 a 0.8) y permite discriminar mejor los componentes de la comunidad vegetal. Estas diferencias tienen la misma tendencia en los índices GNDVI, NDRE, SAVI y EVI (Figura 53 y Anexo 26).

Este resultado constituye un primer elemento de diferencia que tienen las imágenes de la plataforma UAV con pixeles de (0.10 x 0.10 cm) con imágenes *Rapideye* de 3 x 3 m.



**Figura 52:** Índices de vegetación de imagen *Rapideye* (2018) final de la época de estiaje, mes de octubre



**Figura 53: Índices de vegetación (UAV + *Rapideye*)**

### 4.3.2 Variables para la predicción de biomasa aérea de las comunidades de puna seca en base índices de vegetación

Para las muestras tomadas al final de la época de lluvia, los valores de precisión de entrenamiento de 0.812, de precisión de prueba de 0.822 y el índice de Kappa de 0.8006, indican que hay buena concordancia entre las variables.

Para la época seca, el valor de precisión para entrenamiento fue de 0.8253, el valor de precisión prueba de 0.8306 y el índice de Kappa de 0.8091. Los resultados encontrados establecen que el modelo *Random Forest* realiza la clasificación y estimación de la biomasa con los valores más cercanos a la realidad (Tabla 21).

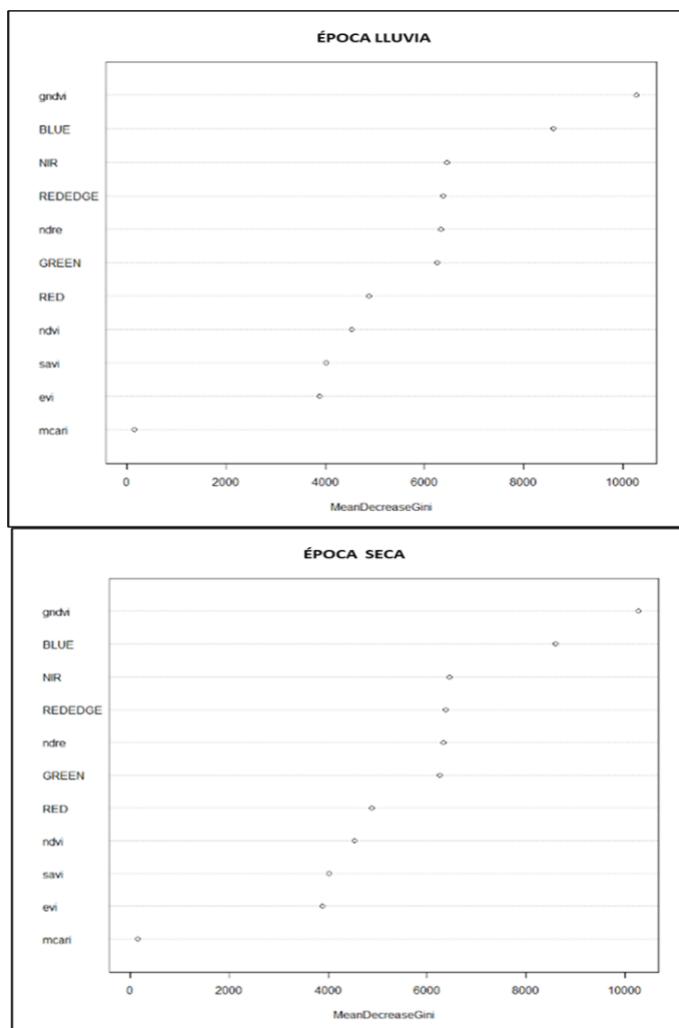
**Tabla 21: Precisión y concordancia de los modelos validados con imágenes escaladas UAS + Rapideye**

MODELO	ÉPOCA DE LLUVIA			ÉPOCA SECA		
	PRECISIÓN		KAPPA TEST	PRECISIÓN		KAPPA TEST
	ENTRENAMIENTO	PRUEBA		ENTRENAMIENTO	PRUEBA	
Elastic Net	0.6278	0.6090	0.5601	0.5609	0.4967	0.4329
Machine Learning para clasificación (SVM)	0.7427	0.7381	0.7054	0.7664	0.7620	0.7319
Random Forest.	0.8122	0.8228	0.8006	0.8253	0.8306	0.8091

Para la época de lluvias, en imágenes *Rapideye* escaladas, *Media decreciente de Gini* (MDG) identifica y prioriza como variable importante para la estimación de la biomasa el índice de vegetación GNDVI, que está presente en más de 9000 nodos de árboles de decisión aleatoria (Figura 54), seguido de las bandas azul, NIR, Red Edge.

El índice NDRE se encuentra en 6000 nodos de árboles. Los índices de vegetación NDVI, SAVI, EVI y MCARI son clasificados de menor importancia para la estimación de la biomasa, ya que se encuentran por debajo de 5000 nodos de árboles de decisión.

Para la época seca, MDG identifica como variables importantes GNVI y NDRE, seguidos por NDVI, EL SAVI, EVI y MCARI.



**Figura 54: Priorización de variables por importancia - índice decreciente de Gini**

Los resultados obtenidos a través del coeficiente de correlación de Pearson para la comunidad vegetal tolerar en época de lluvia, muestran que la asociación entre los índices de vegetación estimados a partir de imágenes adquiridas con UAV y los índices obtenidos con la imagen escalada de *Rapideye*, tienen niveles de asociación positiva y moderada para todos los índices analizados con valores ( $p=0.62$ ,  $p=0.59$ ,  $p=0.61$ ,  $p=0.62$  y  $p=0.61$ ) para NDVI, GNDVI, NDRE, SAVI y EVI respectivamente.

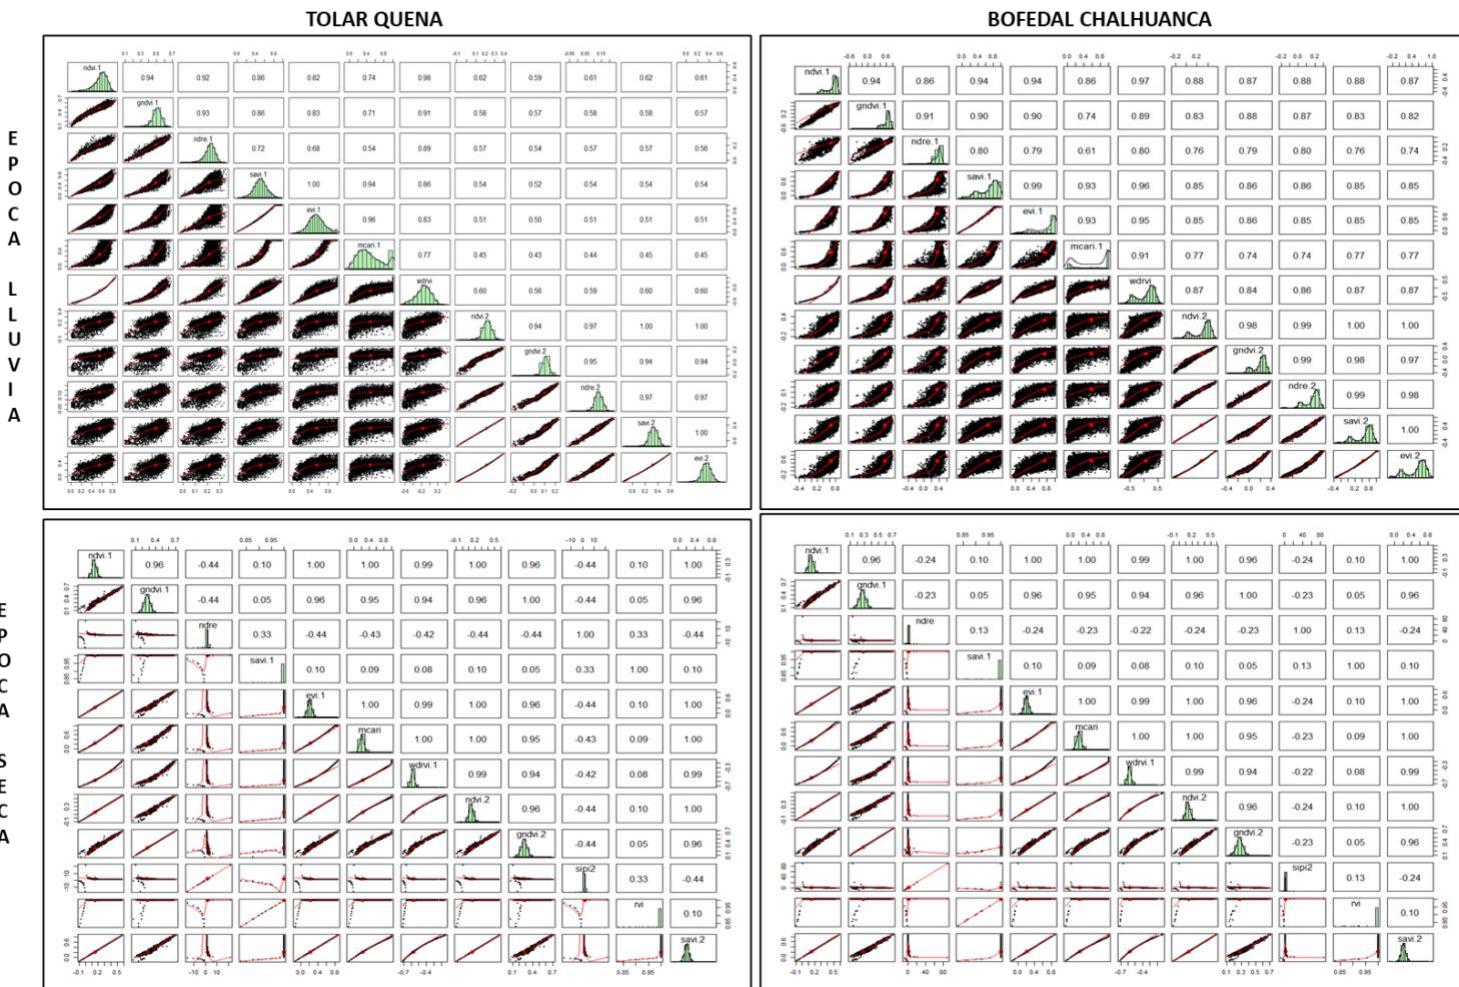


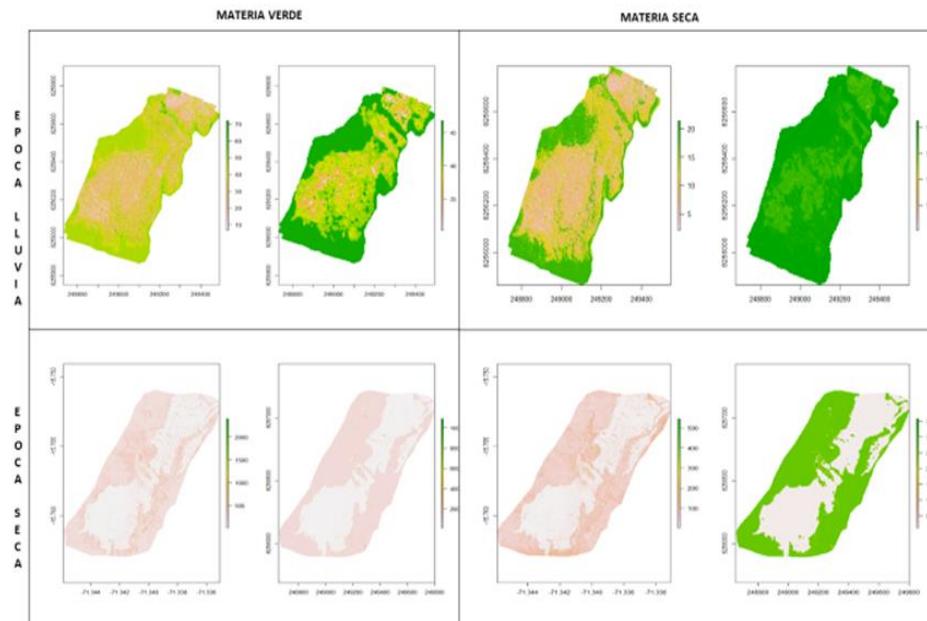
Figura 55: Asociación de variables entre ortofotografías (UAS) e imágenes *Rapideye*

Coeficiente de correlación de Pearson

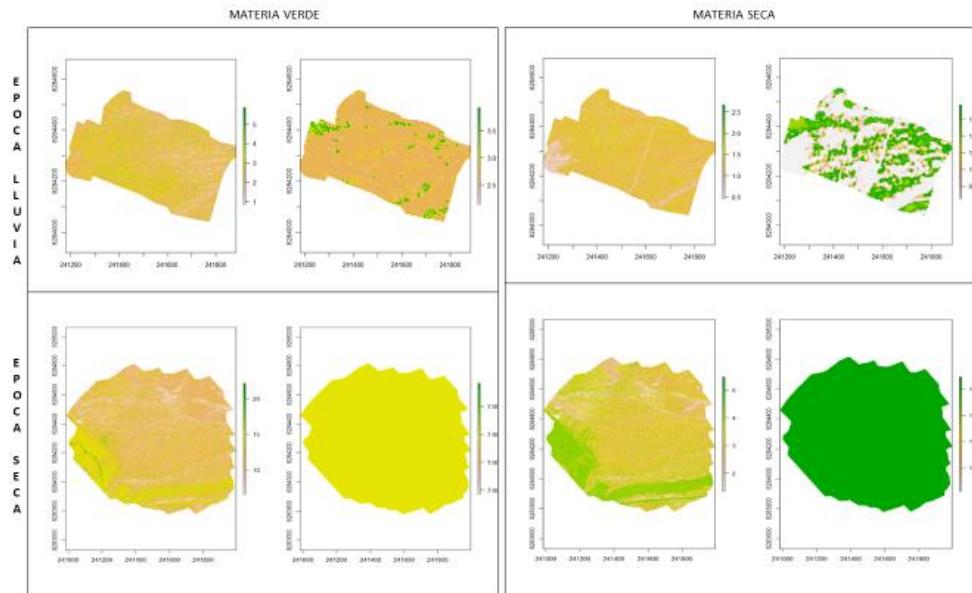
Para la época seca se presenta una asociación directa de los índices NDVI, GNDVI y SAVI, con valores de ( $p=1$ ,  $p=0.96$  y  $p=1$ ). Para los demás índices la asociación es nula (Figura 55). Para la comunidad vegetal bofedal, en época de lluvia, Pearson muestra una asociación positiva fuerte para todos los índices analizados, siendo estos ( $p=0.88$ ,  $p=0.87$ ,  $p=0.88$ ,  $p=0.88$  y  $p=0.87$ ) para NDVI, GNDVI, NDRE, SAVI y EVI respectivamente. Para la época seca se presenta una asociación directa de los índices NDVI, GNDVI y SAVI con valores de ( $p=1$ ,  $p=0.96$  y  $p=1$ ). Para los demás índices la asociación es nula (Figura 55).

#### 4.3.3 Predicción de biomasa de las comunidades vegetales bofedal y tolara con imágenes Rapideye + ortofotografías UAS

El modelo *Random Forest*, que utilizó la imagen *Rapideye* escalada de la época de lluvia, predijo la producción de biomasa para el bofedal de Chalhuanca en un rango de 35 a 45 g/pixel de materia verde y de 12 a 18 g/pixel de materia seca. Los valores predichos para la época seca fueron de 200 a 1000 g/pixel materia verde y de 50 a 350 g/pixel para la época seca (Figura 56).

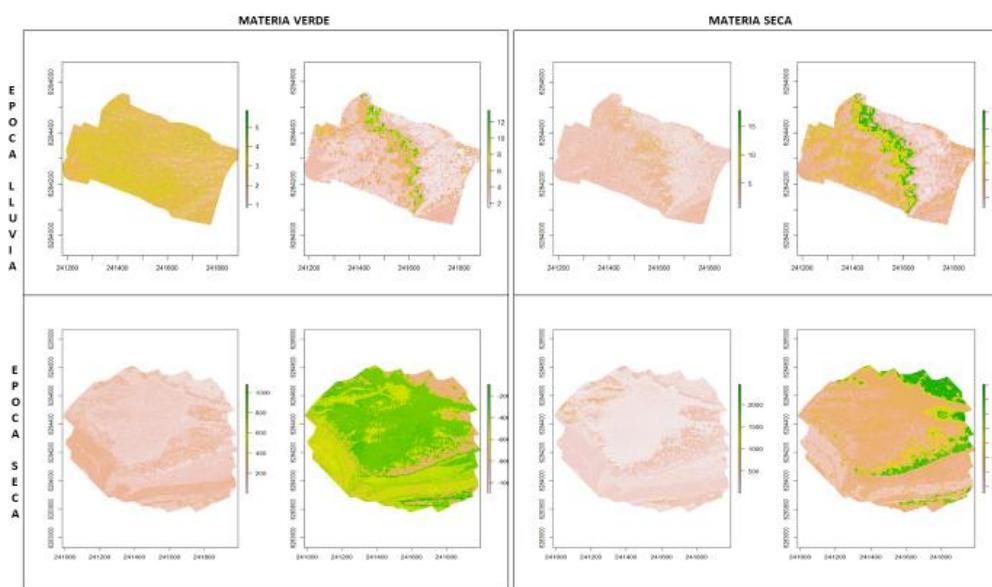


**Figura 56: Predicción de biomasa comunidad vegetal bofedal \_ imagen Rapideye + ortofotografia UAS**



Estimación Biomasa modelo Césped de Puna en imagen Rapideye escalada

**Figura 57: Predicción de biomasa componente césped \_ imagen Rapideye + ortofotografía UAS**



**Figura 58: Predicción de biomasa componente tola - imagen Rapideye + ortofotografías UAS**

En la comunidad vegetal tolar de puna seca (Figura 57), la biomasa predicha para el componente césped en época de lluvia fue de 35 a 45 g/pixel en materia verde, y de 08 a 16 g/pixel en materia seca. Así también, el valor para la época seca fue de 7 g/pixel en materia verde y 1.38 g/pixel en materia seca.

Para el componente arbusto de tola, el modelo predijo de 02 a 12 g/pixel de materia verde y de 2 a 7 g/pixel de materia seca para la época de lluvia. Para la época seca predijo valores de 10 a 200 g/pixel en materia verde y 20 a 600 g/pixel de materia seca (Figura 58).

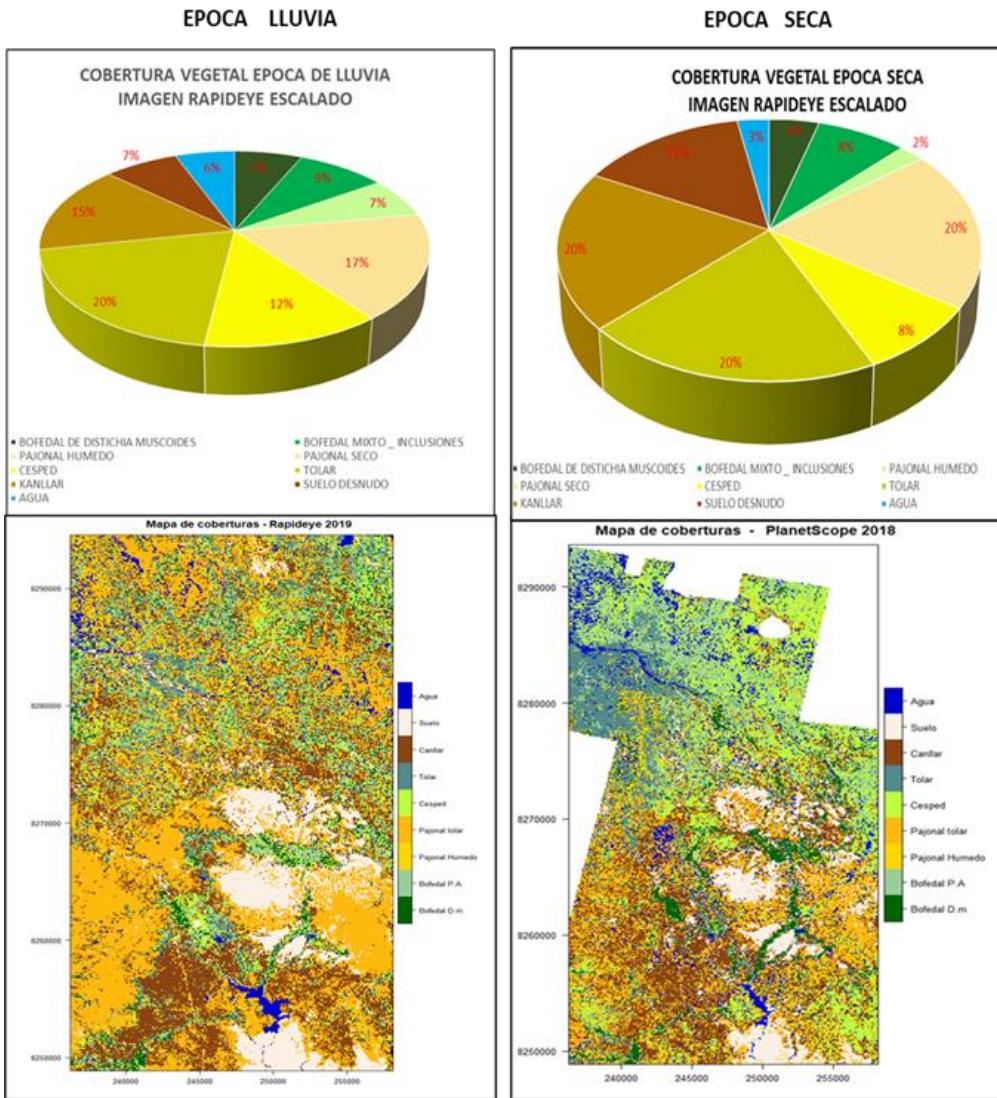
#### **4.3.4 Elaboración de mapas de producción de biomasa de las comunidades vegetales tolar y bofedal de puna seca**

El mapa de coberturas incluye a las comunidades de Hanansaya I y Callalli, del distrito de Callalli, y las comunidades de Chalhuanca, Tocarra y Pulpera, del distrito de Yanque (Figura 59).

En la clasificación supervisada se identificaron nueve coberturas, siete clases de pastizales (bofedal DIMU, bofedal mixto, pajonal húmedo FEDO, pajonal tolar, césped, tola y kanlle), agua y suelo desnudo (Anexo 27).

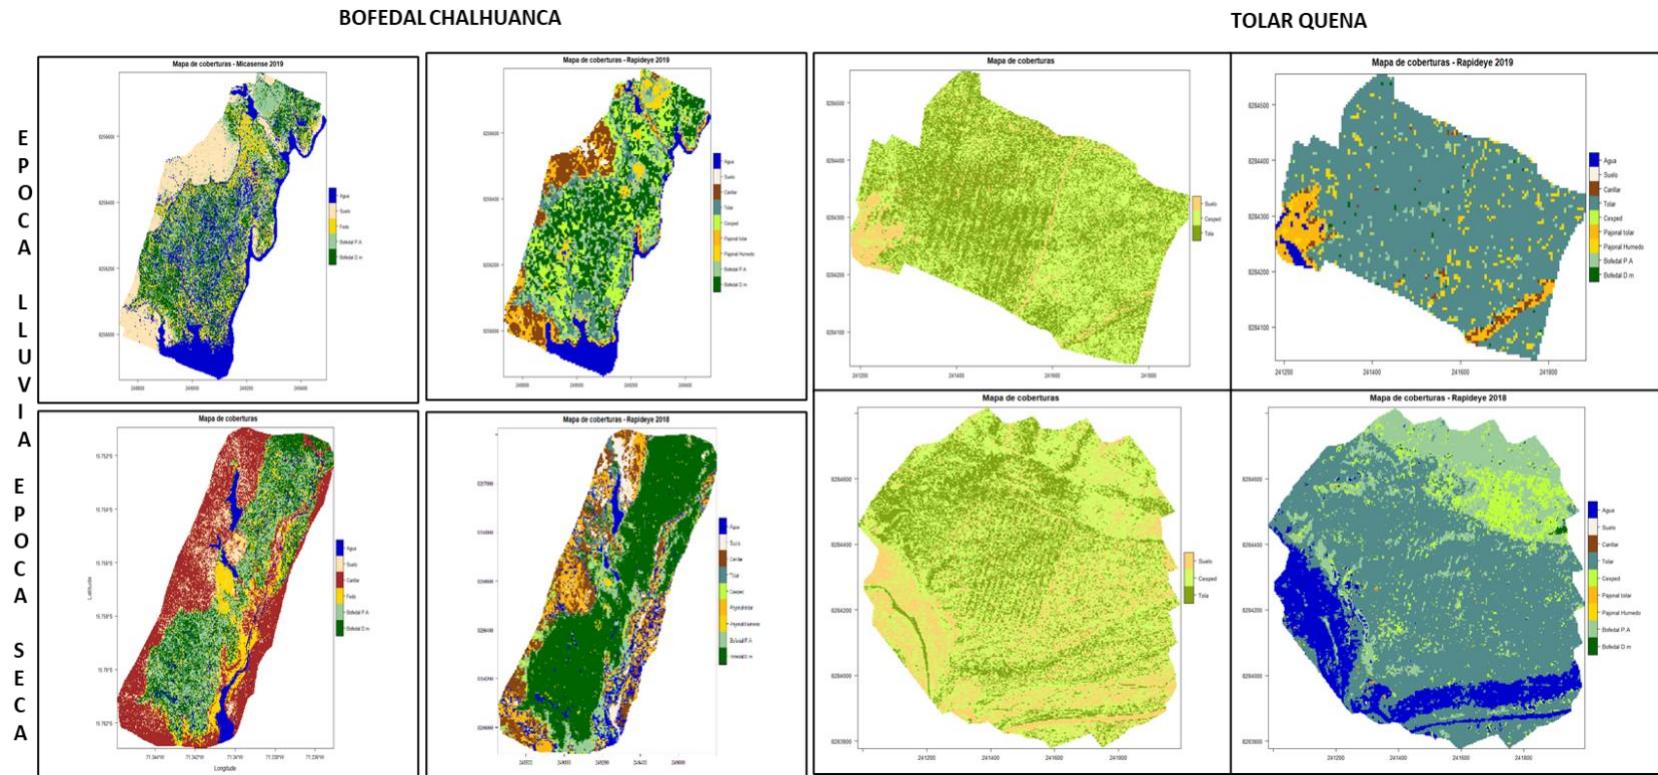
Los resultados de clasificación supervisada muestran 1.99% de diferencia en la estimación del área total de territorio seleccionado para el escalamiento. La variación del área de la cobertura “suelo desnudo” entre épocas fue de 96%. Esto significa que, en la época de lluvia, 681 ha se cubren con especies temporales de césped y plantas de agua.

La cobertura de agua muestra una variación de 52.98%, cifra que se sustenta en la presencia de espejos de agua temporales que, en la época seca, son identificados como suelos desnudos.



**Figura 59: Mapa de coberturas, imágenes *Rapideye* + ortofotografías UAS**

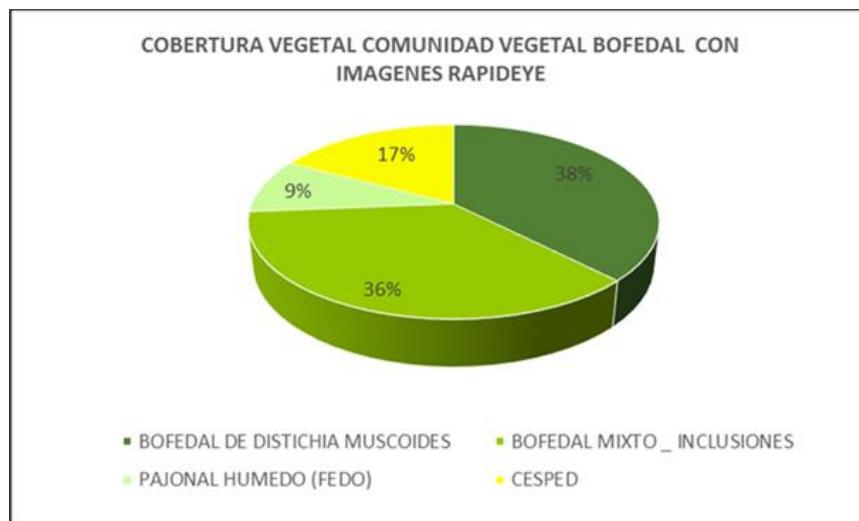
Un aspecto observado en los pajonales es el alto porcentaje de variación entre épocas. La estimación del área total muestra una diferencia de 1.78% entre las dos épocas de estudio. Es posible que estas variaciones estén influenciadas por la época de muestreo, el estado fenológico de las plantas y las características del sensor utilizado (Figura 60).



**Figura 60: Mapa de coberturas imágenes Rapideye + UAS escaladas**

La estimación de biomasa se realizó utilizando imágenes *Rapideye* escaladas y recortadas en las mismas dimensiones que las ortofotografías multiespectrales de las comunidades vegetales tolar y bofedal. El modelo seleccionado fue *Random Forest*, con algoritmos y ecuaciones utilizadas en el proceso de predicción de la biomasa, así como signos espectrales e índices de vegetación de imágenes adquiridas con UAV. En las nuevas imágenes combinadas *Rapideye* con UAV, previamente recortadas, se volvieron a generar los mapas de cobertura y las imágenes de índices de vegetación (Figura 60).

La clasificación y estimación de la producción de la biomasa realizada con *Random Forest*, escalada y recortada al área de la ortofotografía adquirida con el UAV, muestra los siguientes datos: el 38% del área estudiada, cubierta por la clase bofedal de DIMU en materia verde, tiene un rendimiento de 7,562.75 kg/ha para la época de lluvia, y de 2736.11 Kg/ha de biomasa para la época seca. El 36% está cubierto por la clase bofedal mixto, con *Plantagos sp* y una producción de biomasa de 8,034.79 kg/ha y 4,097.26 kg/ha para las épocas de lluvia y seca respectivamente. El 9% del área presenta cobertura de inclusiones de FEDO, con producción de biomasa de 11,357 Kg/ha para la época de lluvias y de 7,963.47 kg/ha para la época seca. Las inclusiones de césped ocupan el 17 % del territorio con una producción de 7,770.24 Kg/ha de biomasa para la época de lluvia y 4,209.86 para la época seca (Figura 61).



**Figura 61: Cobertura vegetal de la comunidad vegetal bofedal con imágenes *Rapideye* + UAS**

**Tabla 22: Comparación de estimación de biomasa UAS - Rapideye de la comunidad vegetal bofedal de puna seca**

COBERTURA	ESTIMACIÓN PRODUCCIÓN BIOMASA								
	ÉPOCA LLUVIA				ÉPOCA SECA				
	UAS (Kg/ha)	RADIPDEYE (Kg/ha)	DIFERENCIA (Kg/ha)	% DIFERENCIA	UAS (Kg/ha)	RADIPDEYE (Kg/ha)	DIFERENCIA (Kg/ha)	% DIFERENCIA	
MATERIA VERDE	BOFEDAL DE DISTICHIA MUSCOIDES	8658.98	7562.33	1096.65	12.66	2596.03	2736.11	-140.08	-5.12
	BOFEDAL MIXTO – INCLUSIONES	9145.85	8034.79	1111.06	12.15	2457.60	4097.26	-1639.66	-40.02
	PAJONAL HÚMEDO (FEDO)	11357.47	7925.01	3432.46	30.22	7963.47	4017.59	3945.88	98.22
	CÉSPED		7770.24	-7770.24			4209.86	-4209.86	
MATERIA SECA	BOFEDAL DE DISTICHIA MUSCOIDES	2564.27	3420.14	-855.87	-33.38	961.23	1482.84	-521.61	-35.18
	BOFEDAL MIXTO – INCLUSIONES	2566.80	3485.96	-919.16	-35.81	867.13	2788.77	-1921.64	-68.91
	PAJONAL HÚMEDO (FEDO)	3894.27	3469.59	424.68	10.91	3583.56	2775.68	807.89	29.11
	CÉSPED		3449.85	-3449.85			2759.88	-2759.88	

Los valores estimados con la imagen *Rapideye* escalada, comparado con los valores estimados con las ortofotografías de la plataforma (UAS) en producción de biomasa, muestran 12% de diferencia a favor de la plataforma UAS para la clase bofedal DIMU, mientras que la diferencia es del 5% a favor de *Rapideye* escalada para la época seca.

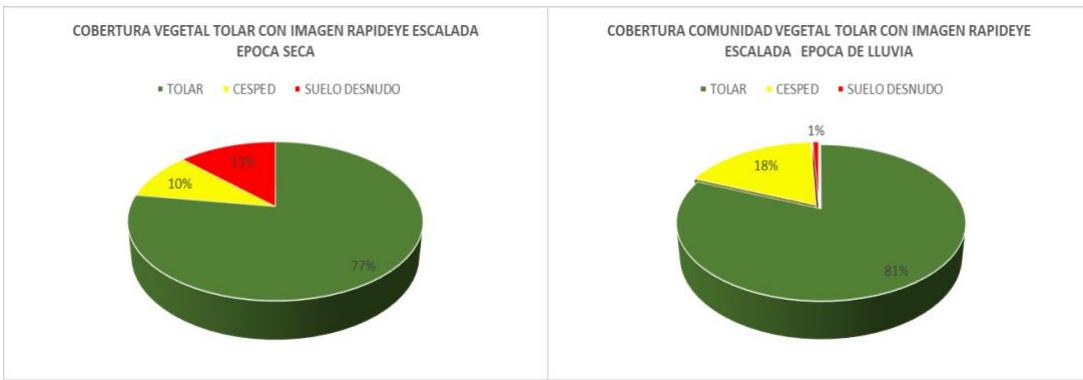
Para el bofedal multiflora se observa una diferencia de 12.15% de rendimiento a favor de la plataforma UAS para la época de lluvia, y de 40.02% a favor de *Rapideye* escalada para la época seca. Para la clase FEDO, la diferencia es de 30.22% y 98.22% a favor de plataforma UAS (Tabla 21).

El procedimiento de estimación de biomasa con las imágenes *Rapideye* identificó la clase césped dentro del bofedal estudiado, el que no estuvo presente en el procesamiento de las ortofotografías ni en el procesamiento de los datos de campo. La explicación es que los algoritmos empleados con escalada de *Rapideye* confunden los bofedales multiflora con el césped.

La clasificación de cobertura realizada con *Random Forest* para la imagen *Rapideye* recortada al área de vuelo de la UAV, estima la clase tola en 81% para la época de lluvia y 77% para la época seca, con una variación de 4%.

Los valores de cobertura estimados para la clase césped fueron de 18 y 10% para las épocas de lluvia y seca respectivamente, con una variación de 8%.

La estimación de suelo desnudo muestra una diferencia de 12% entre época. Las variaciones por época se explican por la presencia de especies temporales en la época de lluvia que alcanzan valores altos de NDVI y otros índices superiores a 0.3 (Figura 62).



**Figura 62: Coberturas comunidad vegetal tolar -imágenes *Rapideye* escalada**

El modelo *Random Forest*, para el componente césped, estimó una producción de biomasa de 6,535.64 kg/ha para la época de lluvia y de 604.52 kg/ha de biomasa para la época seca en términos de materia verde, así también estimó un rendimiento de 5,661.60 kg/ha y 511.83 kg/ha de materia seca para cada una de las épocas.

La estimación de biomasa para el componente tola fue de 7,076.24 kg/ha y de 6128.25 kg/ha de materia verde para la época de lluvia, y de 643.83 kg/ha de materia seca. La estimación para la comunidad vegetal tolar de puna seca, alcanzó los valores de 4,537.29 kg/ha de materia verde y 3,929.95 kg/ha de materia seca para la época de lluvia, y de 644.17 kg/ha y de 385,20 kg/ha para la época seca. Un aspecto resaltante de los resultados es la baja estimación de producción de biomasa por hectárea de la época seca comparada con la época de lluvia. Esto puede constituir una dificultad del proceso de escalamiento que genera confusión en el reconocimiento de las coberturas (Tabla 23).

**Tabla 23: Comparación de estimación de biomasa plataforma UAS e imágenes Rapideye, comunidad vegetal tolar de puna seca**

COBERTURA	ESTIMACIÓN PRODUCCIÓN BIOMASA								
	ÉPOCA LLUVIA				ÉPOCA SECA				
	UAS (Kg/ha)	RADIPDEYE (Kg/ha)	DIFERENCIA Kg/ha	% DIFERENCIA	UAS (Kg/ha)	RADIPDEYE (Kg/ha)	DIFERENCIA Kg/ha	% DIFERENCIA	
MATERIA VERDE	COBERTURA TOLAR	3282.50	7076.24	-3793.74	-115.57	2630.11	1328.00	1302.11	49.51
	COBERTURA CÉSPED	20914.42	6535.64	14378.79	68.75	13535.20	604.52	12930.68	95.53
	COBERTURA SUELO DESNUDO	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
	COMUNIDAD VEGETAL	<b>10889.82</b>	<b>4537.29</b>	<b>6352.52</b>	<b>58.33</b>	<b>7470.57</b>	<b>385.02</b>	<b>7085.55</b>	<b>94.85</b>
MATERIA SECA	COBERTURA TOLAR	864.86	6128.25	-5263.39	-608.58	1245.73	643.23	602.50	48.37
	COBERTURA CÉSPED	13723.63	5661.60	8062.03	58.75	12538.68	511.83	12026.85	95.92
MATERIA SECA	COMUNIDAD VEGETAL	<b>6535.88</b>	<b>3929.95</b>	<b>2605.93</b>	<b>39.87</b>	<b>6588.81</b>	<b>494.46</b>	<b>6094.35</b>	<b>92.50</b>

Los valores estimados con la imagen *Rapideye* escalada, comparados con los valores estimados con las ortofotografías de la plataforma (UAS) para producción de biomasa, muestran altos porcentajes de diferencia. Para muestras de césped de puna recopiladas al final de la época de lluvia, la estimación de producción de biomasa en base a la materia verde fue del 115.57% mayor a favor de las imágenes *Rapideye* escaladas, mientras que para la época seca se encontró 49.51% de diferencia a favor de la estimación realizada con ortofotografías adquiridas con la plataforma UAS. La estimación de biomasa en el componente tola muestra una diferencia de 220% a favor de las ortofotografías para la época de lluvia, incrementando la diferencia para la época.

Los altos porcentajes de diferencia encontradas en el estudio, se explica por la diferencia de resolución espacial entre las imágenes *Rapideye* y las ortofotografías, siendo las primeras las que muestran menos detalles en comparación con las imágenes de alta resolución de las ortofotografías adquiridas con la plataforma UAS, que son más detalladas.

Los resultados encontrados en el estudio resaltan la existencia de una diferencia en la estimación de biomasa a partir de imágenes adquiridas con la plataforma UAS y la plataforma *PlanetScope*. Esta variación se explica por la diferencia de la escala espacial en términos de tamaño del pixel, que para el caso de los UAV son granos muy finos (10 cm. x 10 cm.) con información muy detallada, comparada con las imágenes *Rapideye*, que tienen pixeles de grano mediano (3 m. x 3 m.). Tian *et al.* (2017) señalan que una resolución muy fina, como las UAV, presentarán mayor variación y rango en los valores de los índices de vegetación de las ortofotografías.

Los índices de vegetación obtenidas para tres comunidades vegetales (césped, tolar y bofedal), presentan valores bajos y rangos pequeños. Los ejemplos más visibles son los valores de NDVI más altos (0.00 – 0.5) para bofedales (-0.1 – 0.4).

La tendencia de valoración para la comunidad vegetal tolar es similar, ya que el NDVI presenta valores y rangos pequeños (-0.1 a 0.3) para el componente tola, y de (-0.2 a 0.5) para el componente césped. Estos valores son menores a los obtenidos con las ortofotografías

adquiridas con UAV, que en el caso del NDVI, presenta un rango amplio que va desde (-0.4 a -0.8) y permite discriminar mejor los componentes de la comunidad vegetal. Estas diferencias tienen la misma tendencia en los índices GNDVI, NDRE, SAVI y EVI. El resultado encontrado indica que las imágenes con resoluciones espaciales más pequeñas tienen menor detalle y no discriminan adecuadamente los componentes de una comunidad vegetal; sin embargo, ello no limita su posibilidad de clasificar comunidades vegetales.

El proceso de clasificación y estimación de producción para los tolares y bofedales de puna seca, se elaboró con un modelo cuya precisión de entrenamiento fue de 0.816, con una precisión de prueba de 0.8023 y un índice de Kappa de 0.8006. Los valores de concordancia con los que se clasificaron las comunidades vegetales estudiadas son ligeramente mayores a los encontrados por Bradshaw (2019), quien trabajó con 40% a 50% de precisión y coeficientes de Kappa de 0.2 a 0.5. En general son valores que permiten la clasificación de tierras y comunidades vegetales.

Las comparaciones de valores estimados con las ortofotografías de la plataforma (UAS) en términos de producción de biomasa, muestran diferencias para césped de puna en época de lluvia de 115.57% a favor de *Rapideye*, y de 49.51% en época seca a favor de la plataforma UAS.

El componente tola muestra una diferencia de 220% a favor de la estimación realizada con las ortofotografías en la época de lluvia, pero en la época seca se incrementa esta diferencia. Los altos porcentajes de diferencia que muestran que las imágenes escaladas de *Rapideye* se explica por la diferencia de resolución espacial, las que tienen menos detalle comparadas con las imágenes de alta resolución de las ortofotografías de la plataforma UAS, que tienen mejor separabilidad e identifican mejor las coberturas.

## V. CONCLUSIONES

- La mejor altura de vuelo con drones (UAS) para separar con precisión coberturas de agua, suelo, césped, arbustos de comunidades vegetales de tolار y bofedal durante las épocas de lluvia y estiaje en ortofotografías RGB y NDVI, respectivamente, fue de 25 m, seguido de 50 m.
- La estimación de biomasa utilizando índices de vegetación en ortofotografías multiespectrales tomadas con UAS a 100 m de altura, fue diferente de la biomasa colectada en campo en 41.3% y 12.03% en tolares para época de lluvia y seca respectivamente; y diferente en 93% y 56% para bofedal DIMU en época de lluvia y seca, respectivamente.
- El escalamiento de imágenes UAS de 10 x 10 cm a *Rapideye* de 5 m fue diferente para la clasificación y estimación de biomasa, debido a que *Rapideye* (5 m resolución) no identifica las clases que componen la comunidad vegetal en detalle. Sin embargo, el escalamiento fue mejor en bofedales que en tolares.

## **VI. RECOMENDACIONES**

- Validar el algoritmo desarrollado en *Python* para identificación de elementos segmentados a 25 y 50 m de altura, en asociaciones vegetales de la puna húmeda, bosques relictos y otras comunidades con especies arbustivas.
- Desarrollar algoritmos que pueden ayudar a combinar detalles de información que contienen cada una de las plataformas, ya que el proceso de escalamiento actual es confuso por las imposibilidades de combinar con alta precisión resoluciones espaciales y espectrales de imágenes adquiridas con la plataforma UAS y las plataformas satelitales.
- Determinar la mejor época de colección de imágenes con la plataforma UAS para identificar comunidades vegetales.

## VII. REFERENCIAS BIBLIOGRÁFICAS

- Acebedo, R. 2011. Sistemas de teledetección activos y pasivos embarcados en sistemas aéreos no tripulados para la monitorización de la tierra Barcelona España, 15pp.
- Addati, G., Pérez, G. 2014. Introducción a los UAVs, Drones O Vants De Uso Civil. Universidad Del Cema Buenos Aires Argentina.
- Amat, J. 2016. Introducción a la Regresión Múltiple. [https://www.cienciadedatos.net/documentos/25\\_regresion\\_lineal\\_multiple](https://www.cienciadedatos.net/documentos/25_regresion_lineal_multiple) Revisado 23 de marzo del 2020.
- Andújar, J. 2017. Sistemas Aéreos Pilotados de forma Remota (RPAS): Historia, Sistemas y Operaciones. Publisher: Universidad de la Coruña, España pp. 29-53.
- Azcoiti, J. 2016. Evaluación de aplicaciones para el tratamiento de imágenes mediante correlación Automática. Tesis de Maestría Universidad Pública de Navarra.
- Banco Mundial. 2017. Unmanned aircraft systems Technology. Managing the risks of unmanned aircraft operations in development projects. Ingresado 14 de junio 2020 <http://documents.worldbank.org/curated/en/895861507912703096/pdf/Guidance-note-managing-the-risks-of-unmanned-aircraft-operations-in-development-projects.pdf>
- Baret, F. 2015. Canopy Biophysical Variables Retrieval from the Inversion of Reflectance Models. INRA. UMR. EMMAH. UMT. CAPE USA.
- Berrio, R. y Estrada, A. 1994. Estudio Agrostológico en la Provincia de Caylloma, Proyecto COPASA gtz, Arequipa Perú.
- Berrio, M., Mosquera, T. Alzate, D. 2015. Uso de drones para el análisis de imágenes multiespectrales en agricultura de pre utilización de imágenes multiespectrales obtenidas por vehículos aéreos no tripulados para la determinación de zonas intra lote con mayor rendimiento y calidad en el trigo (*Triticum aestivum*); Universidad Nacional de Villamaría Argentina.
- Bethany, M.; Lucier, A.; y Aryal, J. 2019. Classification of Lowland Native Grassland Communities Using Hyperspectral Unmanned Aircraft System (UAS) Imagery in the Tasmanian Midlands, Revista Drones DOI: 10.3390/drones3010005.

- Boreli, P. 2001. Evaluación de pastizales cap. 6 pp 161-182 En ganadería Sustentable de la Patagonia Austral INTA. Argentina.
- Boix, L. 2015. Integración de sensores y uso de índices de vegetación para evaluar la producción de cítricos en Málaga, Tesis doctoral, Escuela politécnica Superior Málaga España. <http://orcid.org/0000-0001-7285-1400> EDITA.
- Botello, A., Reyes, F., Chavez, L., Galvis, A., Hidalgo, R. 2019. Colegio de Postgraduados, Campus Montecillo. Posgrado en Hidro ciencias México- Estado de México, México, C.P. 56230 \*Autor para correspondencia: <https://doi.org/10.32854/agrop.v0i0.354>
- Bradshaw, A. y Pricope, N. 2019. Examining the relationship between vegetation indices derived from Unmanned Aerial Vehicle (UAV) and planetscope high resolution satellite imagery in a southern African Drylands Ecosystem, University of North Carolina Wilmington. USA.
- Buitrón, C. y Callisaya, J. 2012. Estudio espacial multitemporal de variaciones en superficie observada a través de imágenes satelitales LANDSAT en una región del Parque Nacional Sajama Bolivia, DIACONIA. La Paz Bolivia.
- Buzzi, M.; Ruter, B.; Germandi, L. 2017. Múltiples índices espectrales para predecir la variabilidad de los atributos estructurales y funcionales en zonas áridas. Asociación Argentina de Ecología; Ecología Austral pp. 27:055-062.
- Byrne, M. 2010. Impact of climate change stressors on marine invertebrate life histories with a focus on the Mollusca and Echinodermata. In Climate Alert: Climate Change Monitoring and Strategy, Y. Yu & A. Henderson-Sellers (eds). Sydney: University of Sydney Press, 142–185.
- Byrne, M.; Lauenroth, W.; Adler and Byrne, C. 2011. Estimating aboveground net primary production in grasslands, a comparison of no destructive methods. Rangeland Ecology and Management 64 498 505.
- Campbell, J. B. 1987. Introduction to Remote Sensing. The Guilford Press, New York, USA, 551.
- Chávez, E.; Paz, F.; Bolaños, M. 2017. Estimación de biomasa y cobertura aérea usando radiometría e imágenes digitales a nivel de campo en pastizales y matorrales, revista Terra Latinoamericana v 35. M, México.

- Chen, Z. y Wang, J. 2005. Establishing a ecosystem health model in arid and semiarid area by using remote sensing data. In proceeding of 2005 IEEE International Geoscience and Remote Sensing Symposium, Seoul, Korea.
- Chen, Z. *et al.* 2010. Ecosystem health assessment by using remote sensing derived data. 2005 IEEE International Geoscience and Remote Sensing Symposium, Seoul, Korea.
- Chuvieco, E. 2008. Teledetección ambiental la observación de la tierra desde el espacio, Editorial Ariel 3ra edición España.
- Ceroni, M.; Baeza, S.; Ayala, W.; Paruelo, J. 2015. Eficiencia del uso de la radiación y productividad primaria neta en recursos forrajeros del este de Uruguay.
- Comisión Colombiana del Espacio. 2007. Clasificación de sensores remotos y tecnologías para observación de la Tierra. Campos de aplicación de las tecnologías espaciales y aéreas de acción de la política espacial. Revista Análisis Geográficos 35, p. 51-60.
- Corrales, L. Y Ochoa, V. 2016. Cálculo de reflectancia en imágenes LANSAT OLI 8 sobre la región central de Honduras, Revista Ciencias Especiales; V 9 N 1.
- Cuerno, C., García, H., Sánchez, A., Carrio, J, Sánchez, J., Pascual, C. 2016. Evolución histórica de los vehículos aéreos no tripulados hasta la actualidad Universidad Politécnica de Madrid (España) Centro de Automática y Robótica, UPM-CSIC Vol. 91 N°3 (España).
- Delgado, J.; Alonso, L.; Cendredo, P.; Former, A. Moreno, J. 2009. Aplicación de la Teledetección hiperespectrales a la estimación de contenido de clorofila de las plantas, Departamento de Física de la Tierra y Termodinámica, Universidad de Valencia España.
- Daughtry, C.; Walthall, C.; Kim, M.; Brown, C. y Mc Murtrey, J. 2000. Estimating corn leaf chlorophyll concentration from leaf and canopy reflectance. USDA. Remote sensing and modeling laboratory.
- De Cola, L. 1997. Multiresolution covariation among LANDSAT and AVHRR vegetation indices pp 73-91 In: D.A. Quattrochi and M.A Goodchild (eds). Scale in Remote Sensing and GIS Lewia Publishers, Washintong D.C.

- D'oleira, S.; Marzolff, I.; Klaus, D. And Ries, J. 2012. Unmanned aerial Veicle (UAV) for Monitoring soil erosion in Morocco. *Remote sens* 4- 3390- 3416.
- DGAC. MTC. 2015. Dirección general de aeronáutica Requisitos para las Operaciones de Sistemas de Aeronaves Pilotadas a Distancia. Norma técnica. Lima Perú.
- De La Roza, A., Martínez, A y Gutiérrez, A. 2002. Determinación de Materia Seca en Pastos y Forrajes Área de Nutrición, Pastos y Forrajes. Servicio Regional de Investigación y Desarrollo Agroalimentario (SERIDA). Cita, de Oviedo s/n. 33300 Villaviciosa. Asturias España.
- Dunford, R., Michel, K., Gagnage, M., Piegay, H., Tremelo, M. 2009. Potential and constraints of Unmanned Aerial Vehicle technology for the characterization of Mediterranean riparian Forest. *Int. J. Remote Sens*, 30, 4915-4935
- EASA. 2015. New Regulatory Approach for Remotely Piloted Aircrafty (RSPAS), Unión Europea.
- Easdale, M., Umaña, F., Rafo, F., Fariña, C., Bruzzone, O. 2019. Evaluación de pastizales patagónicos con imágenes de satélites y de vehículos aéreos no tripulados. Instituto de Investigaciones Forestales y Agropecuarias Bariloche (IFAB), INTA - CONICET. 2 Instituto Nacional de Tecnología Agropecuaria (INTA), E.E.A. Bariloche. 306 Ecología Austral 29:306-314 Diciembre 2019. Asociación Argentina de Ecología. <https://doi.org/10.25260/EA.19.29.3.0.791>
- Elisalde, N. 2002. Inventario y evaluación de pastizales naturales de la zona árida y semiárida de la Patagonia. Instituto nacional de tecnología agropecuaria centro regional Patagonia sur, Patagonia Argentina 16 pp.
- Escobar, O. 2015. Respuestas espectrales a la fertilización con nitrógeno y potasio en el cultivo de banano, caso municipio zona bananera Universidad Nacional de Colombia; Bogotá Colombia.
- Escuer, J. 2007. Análisis multitemporal mediante el uso de imágenes del satélite Landsat. Innovación y formación Número 2. Otoño, 2007. Disponible en: [www.doredin.mec.es/documentos/01420093004785.pdf](http://www.doredin.mec.es/documentos/01420093004785.pdf)

- Espinosa, H.; Anderson, D.; Naranjo, J. 2016. Aplicación de los sistemas de información geográficos (SIG) para la implementación de ganadería de precisión, Livestock Research for Rural Developmet. Sitio Argentino de producción animal.
- ESRI. 2016. Función del NDVI. Recuperado el 15 de enero del 2020 de Arcgis Desktop: <http://desktop.arcgis.com/es/ap/> 10.3/ manage-data/raster-and-images/ndvifunction.htm.
- Esser, A y Ortega, R. 2010. Uso de percepción remota o teledetección para el manejo sitio específico de viñedos. Centro de Agricultura de Precisión Departamento de ciencias Vegetales UC Chile; presentado en el VII Congreso de Ecosistemas Agrarios \_ Chile.
- Falk, D. y Campos, A. 2014. Algoritmo semiautomático para contero de áboles en plantaciones Forestales mediante uso de imágenes aéreas, Instituto de clima y agua, Centro de investigación de recursos naturales Argentina.
- Farel, M. y Rivas, R. 2011. Utilización del EVI e Índice de Área Foliar en el análisis de rendimiento en girasol, Instituto Nacional de Tecnología Agropecuaria INTA Argentina ISBN 978-987-543-443-1 pp 103-115.
- Flórez, A. 1993. Producción y Utilización de los pastizales altoandinos del Perú. Red de Pastizales Andinos (REPAAN), CIID Canadá Lima Perú.
- Flórez, A. y Malpartida, I. 1987. Manejo de praderas nativas y pasturas en la región altoandina del Perú. Lima: Banco Agrario del Perú. (pp. 94-187).
- Flores, E.R.; Ñaupari, J.A.; y Tacuna, R.E. 2014. La economía del cambio climático en el Perú: Ganadería altoandina en la economía del cambio climático en el Perú: Desarrollo, CEPAL.
- Flores, E.; Aguirre, L.; Ñaupari, J. 2005. Rotación de canchas, pastizales y Bofedales. Lima: Laboratorio de Utilización de pastizales UNALM, pp. 1-12.
- García, D. y Cervijon, J. 2015. Estudio de índices de vegetación a partir de imágenes aéreas tomadas desde UAS/RPAS y aplicaciones de estos en la agricultura de precisión; Universidad Complutense de Madrid España.
- García, P. y Quintano, C. 2017. Estudio sobre vehículos aéreos no tripulados y sus aplicaciones, Universidad de Valladolid España.

- Gil, C. 2018. Árboles de decisión, métodos de ensamble R studio [https://rpubs.com/Cristina\\_Gil/arboles\\_ensemble](https://rpubs.com/Cristina_Gil/arboles_ensemble); <https://github.com/CristinaGil/Ciencia-de-Datos-R>. Visitado 20 de marzo del 2020.
- Gitelson, A.; Kauman, J. y Merzllyak, M. 1996. Use of Green channel in remote sensing of global vegetation from EOS- MODIS. *Remote Sens Environ* 58(3) 289 - 298 doi: 10.1006/RSEN.1996.0072-7.
- Gómez, M. 2005. Índice de vegetación en áreas de bosque seco del norte del Perú a partir de imágenes satelitales. Universidad de Piura Perú. Pp 29-45.
- Gregory, D. y Mira, J. 2016. Estudios de simulación estocástica con Random Forest frente a árboles individuales, Universidad Politécnica de Madrid España.
- Gross, D. 2005. Monitoring Agricultural Biomass Using NDVI Time Series. Food and Agriculture Organization of the United Nations (FAO).
- Gruñer, E., Astor, T. y Wachendorf, M. 2019. Biomass Prediction of Heterogeneous Temperate Grasslands Using an SfM Approach Based on UAV Imaging. *Grassland Science and Renewable Plant Resources*, Faculty of Organic Agricultural Science, Universität Kassel, Steinstraße 19, 37213 Witzenhausen, Germany; [thastor@uni-kassel.de](mailto:thastor@uni-kassel.de) (T.A.); [mwach@uni-kassel.de](mailto:mwach@uni-kassel.de) (M.W.)
- Gutiérrez, C., Iroumé, P. 2017. Detección y cuantificación de material leñoso de gran tamaño (LW) utilizando imágenes de vuelos UAV, en el cauce del estero Vuelta de Zorra, Chaihuin Chile, Escuela de Geografía de la Universidad Austral de Chile.
- Hemav. 2018. Agricultura de precisión: teledetección satelital Vs Teledetección con Drones. Barcelona España.
- Herrera, E.; Chuvieco, E. 2014. Estimación del contenido de agua a partir de mediciones hiperespectrales para cartografía del riesgo de incendio; cuadernos de investigación geográfica Alcalá de Henares España 14 N° 40 (2) pp. 295-309 ISSN 0211-6820.
- Hernández, J. 2011. Procesamiento de imágenes, Facultad de Ciencias Forestales y de conservación de la Naturaleza Universidad de Chile. Publicado en capítulo “Percepción remota”, libro Manejo y Conservación Forestal ISBN 978-956-353-324-8.

- Holdridge, L.R. 1987. Ecología basada en zonas de vida, servicio editorial IICA, tercera edición, San José de Costa Rica. ISBN 92 9039 1316 pp. 2-26.
- Horning, N.; Robinson, J.; Sterling, E.; Turner, W.; Spector, S. 2010. Remote Sensing for Ecology and Conservation, Golden Cup Printings ISBN 978-0- 19- 921994 -0 pp 59-78.
- Huete, A.; Justice, C. y Liu, H. 1994. Development of vegetation and soil indices for MODIS – EOS, Remote Sensing of Environment, 49, 224-234 doi.org/10.1016/0034-4257(94)90018-3.
- Huete, A. 1988. A soil adjusted vegetation index (SAVI). Remote sensing Environ doi.org/10.1016/0034-4257(94)90018-3.
- Iglesias, A. 2003. Técnicas de teledetección mediante la utilización de vehículos aéreos teledirigidos X Congreso de Teledetección Cáceres España pp 381 – 384.
- Ishida, T.; Kurihara, J.; Viray, F.; Takashi, J. 2017. Un enfoque novedoso para la clasificación de la vegetación con base en UAV imágenes hiper espectrales. Revist Computers and electronic in agriculture 144(80-85) DOI .ORG/100 1016/j. compag. 2017.027.
- Ishida, T; Kurijara, J.; Viray, F.; Baes, S.; Paringit, E.; Pérez, G.; Takahashi, Y.; Marciano, J. 2018. A novel approach vegetation classification using UAV-based hyperspectral imaging. Computer and electronics in agriculture 144 (2018) p. 80-85.
- Isla, R.; López-Lozano, R. 2005. Comparación de índices de vegetación para detectar deficiencias de nitrógeno en maíz; XI Congreso Nacional de Teledetección, Puerto de la Cruz Tenerife España.
- Jaramillo, J. 2013. Drones y aeronaves del futuro, Revista CIENCIA UANL Año 16 N° 64 Universidad Autónoma de Nuevo León México.
- Jones, H. y Vaughan, R. 2010. Remote sensing of vegetation, Oxford University ISBN 978-0-19-920779-4.
- Jordan, C.F. 1969. Derivation of leaf area index from quality of light on the floor. Ecology, (50) 4 663-666 doi10.2307/19366256.
- Justice, C.O.; Townshend, J.R.G.; Holben, B.N.; Tucker C.J. 1985. Analysis of the phenology of global vegetation using meteorological satellite data. International Journal of Remote sensing v.6, p 1271- 1381, 1985.

- Kharuf, S; Hernández, L; Orosco, R; Delgado, I. 2018. Análisis de imágenes multiespectrales adquiridas con vehículos aéreos no tripulados, Revista de ingeniería electrónica automática y comunicación RIELAC ISSN 1815 5928 Vol. XXXIX 2/2018 pp 79-91 Cuba.
- Kumar, L.; Sinha, P.; Brown, J.; Ramsey, D.; Rigge, M.; Stam, C.; Hernandez y Hunt, Jr. 2015. Characterization, Mapping, and Monitoring of Rangelands: Methods and Approaches University of New England.
- López, I.; Fonteno, J.; Peniche, T. 2011. Comparaciones entre cuatro métodos de estimación de biomasa en parcelas de festuca alta; revista Mexicana Ciencia Pecuaria V2(2) p.2009 -220.
- Maini, A. y Agrawal, V. 2007. Satellite Technology. Principles and Applications. Wiley. España.
- Mango, B. 2017. Valoración económica de los servicios ecosistémicos de la regulación, de los bofedales del centro poblado de Chalhuanca, Distrito de Yanque, Provincia de Caylloma, Región Arequipa. Universidad Nacional San Agustín de Arequipa.
- Manrique, E.G. 1999. Índices de vegetación aplicación del NDVI. VIII Congreso Nacional de teledetección, Albacete España pp 217-219.
- Massa, E. y Durante, M. 2016. Estimación de la productividad forrajera mediante el uso de sensores remotos en comunidades vegetales de las islas delta fluvial diamantino entre ríos. Sitio de producción animal, INTA EEA PARANA, ISSN 0325 – 8874.
- Mc Feeters, S. 1998. The use of normalized difference water index (NDWI) in the delineation of open water features, International Journal of Remote Sensing PP 1425. 1432.
- Martínez, R.; Aguirre, O.; Vargas, B; Jiménez, J; Y. Yarena, J. 2016. Modelación de biomasa y carbono arbóreo en bosques del estado de Durango. Revista Mexicana de Ciencias Forestales Vol. 7 núm. 35, 2016.
- Marabel, M. 2016. Estimación de la biomasa aérea de herbáceas con sensores aerotransportados de alta resolución. Escuela superior de ingeniería agraria España.

- Matteucci, S.; Morello, J.; Rodríguez, A. y Silva, M. 2015. Ecorregiones y complejos ecosistémicos argentinos. Proyecto Land use change consequences on the socio-ecological system in the Chaco region, Argentina.
- Ministerio de Defensa España – MDE. 2009. UAS “Unmanned Aircraft System” Sobre su integración en el espacio aéreo no segregado. Depósito Legal: M-34017-2009 Imprime: Imprenta del Ministerio de Defensa. España.
- Mongomery, D.; Peck, E.; Geoffrey, G. 2012. Introduction to linear regression analysis. Fifty edition ISBN 978-0-470-54281, New Jersey USA.
- Muñoz, P. 2013. Índices de teledetección; Centro de Información de Recursos Naturales CIREN Ministerio de Agricultura España.
- Nicholson S.E.; Davenport, L. M.; Malo, A.R. 1990. Comparation of vegetation response to rainfall in the Sahel and East Africa, Using Difference Vegetation Index from NOAA AVHRR Climate Change v. 17 p. 209 -241, 1990.
- Nina, J. 2015. Cambios de la cobertura del suelo en la reserva nacional Salinas y Aguada Blanca – Arequipa, Moquegua, en la relación a la temperatura y precipitación, durante el período 1986 – 2010. Facultad de Biología Universidad Nacional de San Agustín de Arequipa- Arequipa Perú.
- Olave, C. 2011. Uso de la teledetección satelital como herramienta de apoyo al manejo sustentable del predio de producción ovina en la tierra del fuego Universidad Magallanes punta arenas chile.
- Organización de Aviación Civil Internacional – OACI. 2011. Sistemas de aeronaves no tripuladas (UAS). Circular 328, Sistemas de aeronaves no tripuladas (UAS) Núm. de pedido: CIR328 ISBN 978-92-9231-809-3
- Paredes, M. 2018. Uso de índices de vegetación del sensor MODIS TERRA en la estimación de biomasa aérea en pajonales altoandinos, Universidad Nacional Agraria la Molina Lima Perú.
- Perea, M. 2018. Estimación de Biomasa Aérea y Carbono con Teledetección en Bosques Alto-Andinos de Boyacá, Colombia. Estudio de caso: Santuario de Fauna y Flora “Iguaque” Interfaculty Department of Geoinformatics- Z\_GIS Departamento de Geomática – Z\_GIS University of Salzburg | Universidad de Salzburg.

- Perrin, G.; Descombes, X.; Zerubia, J. 2014. 2D and 3D Vegetation resource parameters assessment using marked point processes. INRIA, 2004 FRANCIA <http://www.inria.fr/ariana>
- Pizarro, S. 2017. Degradación y vulnerabilidad al cambio climático en pastizales altoandinos Universidad Nacional Agraria la Molina Lima Perú.
- Plataforma Aeroespacial Española PAE. 2015. Sistemas de Vehículos Aéreos no Tripulados (UAS) Madrid ESPAÑA Visitado 14 junio del 2020- [www.plataforma-aeroespacial.org](http://www.plataforma-aeroespacial.org).
- Priocpe, N., Mapes, K., Woodward, K. y Baxley, J. 2019. Multi- Sensor Assessment of the Effects of Varying Processing Parameters on UAS Product Accuracy and Qualyti. Drones.
- Prieto, M., Santamarina. 2016. Análisis de las aplicaciones y necesidades del uso de los RPAS en las diferentes categorías del patrimonio cultural, Universidad Politécnica De Valencia España
- Pulgar, J. 1996. Geografía del Perú, las ocho regiones naturales; Promoción editorial Inca S.A. décima edición, Lima Perú, ISBN 9972 40 027 3pp 15 al 23.
- Quispe, O. 2015. Análisis de GSD para la generación de cartografía utilizando tecnología DRONE, huaca de la Universidad Nacional Mayor de San marcos. Revista del Instituto de Investigación (RIIGEO), FIGMMG- UNMSAM Vol. 18, Nº 36, pp. 21 – 26.
- Quispe, O. 2016. Propuesta metodológica para la generación de ortofotomapas desde imágenes aéreas obtenidas con micro DRONE multirrotor: Área de estudio playas de Barranco Lima, Universidad Nacional Mayor de San marcos Lima Perú.
- Ramos, C. 2018. Variación espacio temporal de los ecosistemas de Humedales altoandinos en el anexo de Chalhuanca del Distrito de Yanque (Caylloma Arequipa) entre los años 1986 – 2016) Facultad de Biología Universidad Nacional de San Agustín Arequipa Perú.
- Rango, A., Laliberte, A., Herrick, J., Winters, C., Havstad, K., Steele, C., Browning, D. 2009. Unmanned aerial vehicle-based remote sensing for rangeland assessment, monitoring, and management. *J. Appl. Remote Sens.*, 3, 033542:1-033541:15

- Raymond, E. y Hunt, Jr. 2015. Remote Sensing of Rangeland Biodiversity, USDA ARS Beltsville Agricultural Research Center.
- Reeves, M.; Washington, R.; Angerer, J.; Raymond. 2015. Global View of Remote Sensing of Rangelands: Evolution, Applications, Future Pathways Cap. 10 EE.UU.
- Rouse, J. L.; Haas, R.; Schell, J.; Deering, D. 1974. Monitoring Vegetation systems in the great plains with earths., Texas University, College Station NASA Special Publication <https://ntrs.nasa.gov/archive/nasa/casi.ntrs.nasa.gov/19740022614.pdf>.
- Rueda, F.; Peñaranda, L.; Leazquez, W.; Diaz, S. 2015. Application of a method of analysis of remote sensing data obtained by targeting the estimated productivity in cane quantifying NDVI (Normalized difference vegetation index) Corpoica agropecuaria v 16(1) p. 25-40.
- Ruiz, C.; Tapia, M. 1987. Producción y manejo de forrajes en los Andes del Perú, Universidad San Cristóbal de Huamanga Ayacucho y proyecto de investigación de Sistemas Agropecuarios (PISA), Convenio INIPA – CIIDCDI. Lima.
- Sánchez, J. 2008. Lídar fundamentos, usos. Revista sensores remotos y Teledetección España.
- Santa, V.; Rosa, M.; Mónaco, N. y Heguiabehere, A. (2013). Determination of relationship between data obtained from biomass derived from field and remote sensing NDVI along the Arroyo Chucul (PACIA Córdoba). Revista de la Facultad de Agronomía UNLP Vol. 22 ISSN 0326-6184 Argentina.
- Santamarina, V., Molina, B., Segarra, M., Molina, M. 2017. Transfering technology from the remotely piloted aircraft systems (RPAS). industry for the creative industry: Why and what for? En: 4th International Multidisciplinary Scientific Conference. SOCIAL SCIENCES & ARTS SGEM 2017. Bulgaria
- Salgado, L. 2015. Comportamiento espacio-temporal (1986-2003) de plantaciones, frutales en laderas de la provincia de Quillota mediante Ingeniería Satelital y SIG. Consultada el 1 O de enero de 2014, de [http://ucv.altavoz.net/prontus/unidacad/site/artic/20061206/pags/200612061\\_04207](http://ucv.altavoz.net/prontus/unidacad/site/artic/20061206/pags/200612061_04207)
- Segura, A., Baldi, G., Durante, P y Gabulsky, M. 2008. Análisis de la dinámica temporal del NDVI en áreas protegidas: tres casos de estudio a distintas escalas espaciales, temporales y de gestión. Red de Revistas científicas de América Latina,

el Caribe, España y Portugal, (03): 106-117. Consultada el 05 de enero de 2014, de [http://www.redalyc.org/pdf/540/540171\\_0601\\_O.pdf](http://www.redalyc.org/pdf/540/540171_0601_O.pdf).

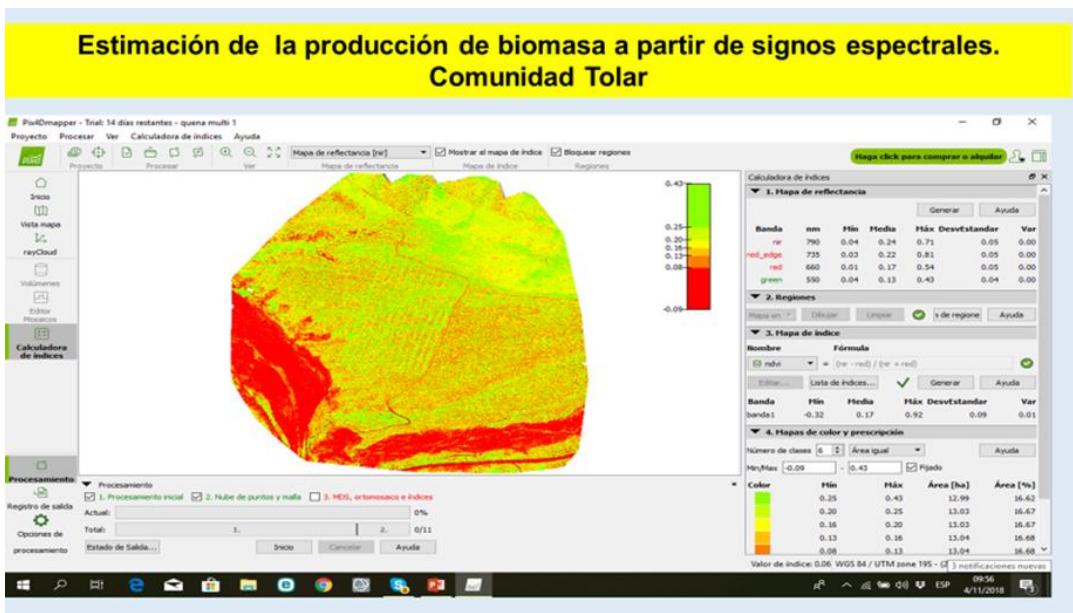
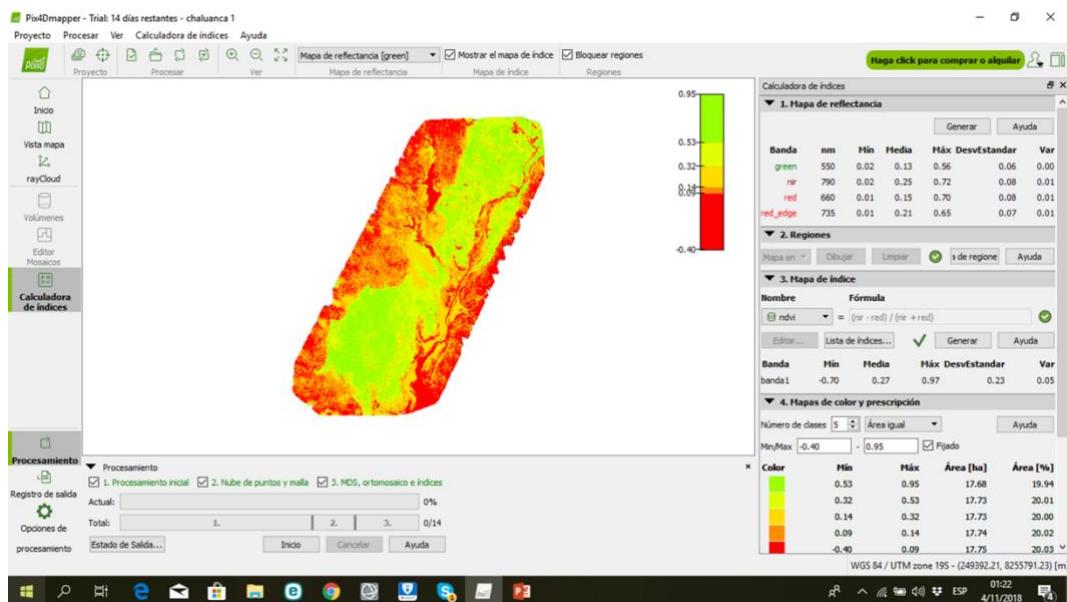
- Shoko, C., Mutanga, O., Dube, T. 2016. Progress in the remote sensing of C3 and C4 grass species aboveground biomass over time and space. ISPRS Journal of Photogrammetry and Remote Sensing p. 13- 24.
- Siguayro, R. 2008. Evaluación Agrostológico y capacidad receptiva estacional en bofedales de puna seca y húmeda del altiplano de Puno. Universidad Nacional del Altiplano Puno, Perú.
- Soria, M. y Matar, M. 2016. Nociones sobre teledetección, Instituto de Investigaciones Mineras, Universidad Nacional San Juan Argentina.
- Sotomayor, M. 1990. Tecnología campesina en el pastoreo Altoandino, Proyecto Alpacas (INIA: CORPUNO0 – COTESU /IC). Puno Perú.
- Sotomayor, M. 1991. Principales pastos alpaqueros del sur del Perú. Proyecto Alpacas Editorial ART. Lautrec. Lima Perú.
- Suo, A., Xiong, C., Wang, T., Yeu, D. 2008. Ecosystem health assessment of the jinghe rivier watershed on the huangtu plateau. Ecoheali.
- Tapia, M. y Flores, J. 1984. Ecosistema de los andes del sur del Perú y su relación con los pastizales, Capítulo del libro Pastoreo y pastizales en los andes del sur del Perú, programa colaborativo de apoyo a la investigación en rumiantes menores Cusco Perú. p51-76.
- Tian, J.; Wang, L.; Li, X.; Gong, H.; Sshi, C.; Zhong, R. y Liu, X. 2017. Comparison of UAV and WorldView-2 imagery for mapping leaf area index of mangrove Forest. International Journal of Applied Earth Observation and Geoinformation, 61. doi:10.1016/j.jag.2017.05.002
- Troll, C. 1968. Geoecology of the montainous regiomofthe tropical Americas. UNESCO Mexico Symposium Ferd Dümmlers Verlag, Bomm, Alemania.
- Tucker, J. C. 1979. Red and photographic infrared lineal combinations for monitoring vegetation. Remote sensing of enviroment, v8.
- Tucker, J.C.; Townshend, J. R.G.; Gof, T.E. 1985. African land cover classification and temperature in the central Geat plains. International Journal Remote Sensing v1 p. 2345-2364 – 2003.

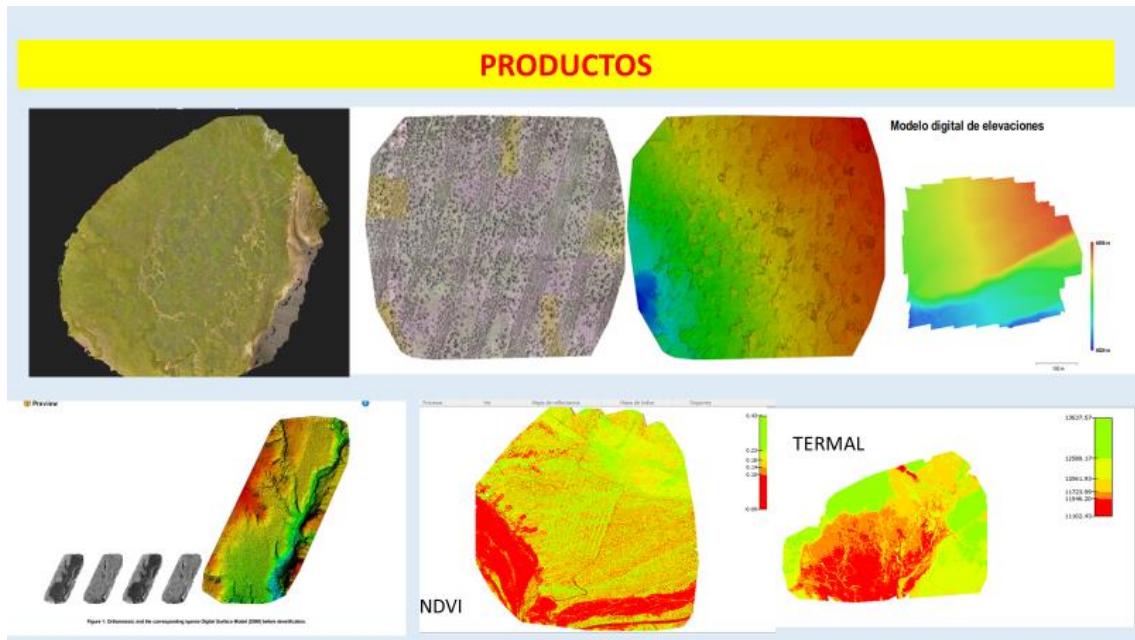
- Ulrike, L., Bolten, A., Menne, J., Leon, M., Schellberg, J. y Bareth, G. 2020. Estimating biomass in temperate grassland with high resolution canopy surface models from UAV-based RGB images and vegetation indices University of Cologne, Institute of Geography. Journal Remote sensing.
- Vila, H.; Pérez, P.; García, M.; Vallone, R. 2007. Estimación de biomasa en viñedos mediante imágenes satelitales y áreas en Mendoza Argentina Ed. Martin ISB 978 987 453 126 – 3 p. 51-58.
- Verstraete, M. y Pinty, B. 1996. Designed optimal spectral index for remote sensing applications. IEEE Transactions on Geoscience and remote sensing, 34(5) 1254-1265.
- Vinícius, B. Calou, C., Adunias, S., Teixeira, L., Moreira, J., Odílio, C., Rocha, N., Da Silva, J. Estimation of maize biomass using unmanned aerial vehicles. Instituto federal de educación, ciencia y tecnología Brasil <https://orcid.org/0000-0002-8396-8054>
- Watanave, J. 2012. Manejo del ENVI 4.5
- Zafra, Y. 2017. Manual para el proceso de imágenes obtenidas a partir de una aeronave tripulada remotamente (DRONE) en los softwares AGISOFT PHOTOSCAN Y PIX 4D, Universidad distrital de San Francisco José de Caldas España.
- Zerda, R. y Tiedemann, R. 2010. The temporal dynamic of NDVI, of Forest and grassland in the Chaco Seco of Santiago Del Estero province, Argentine (PR) v. 6 n. 1 p. 13 - 24 Jan./Abr. 2010 ISSN 1808 – 0251 (971- 39741 \_PB).
- Zorogastua, P.; Quiroz, R.; Garatuza, J. 2012. Dinámica de las Bofedales en el altiplano peruano. Revista Latinoamericana de Recursos Naturales 8 (2) 63-75. Ciudad Obregón, Sonora. México.

## VIII. ANEXOS

### 8.1 ANEXOS DEL PROCESO METODOLÓGICO

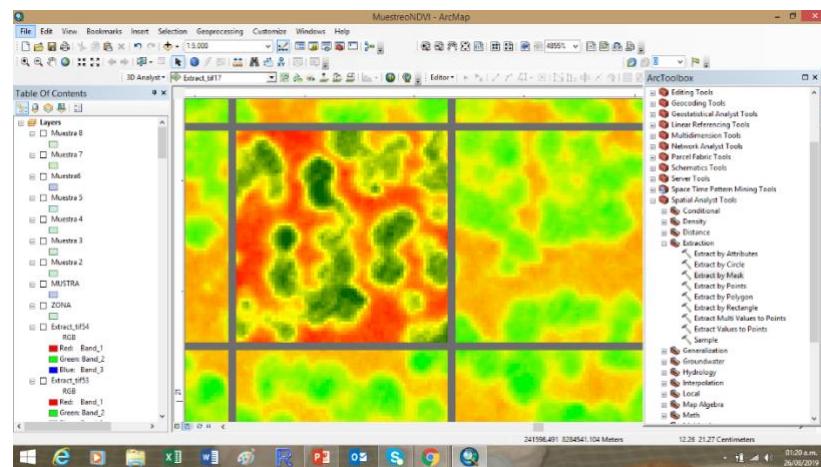
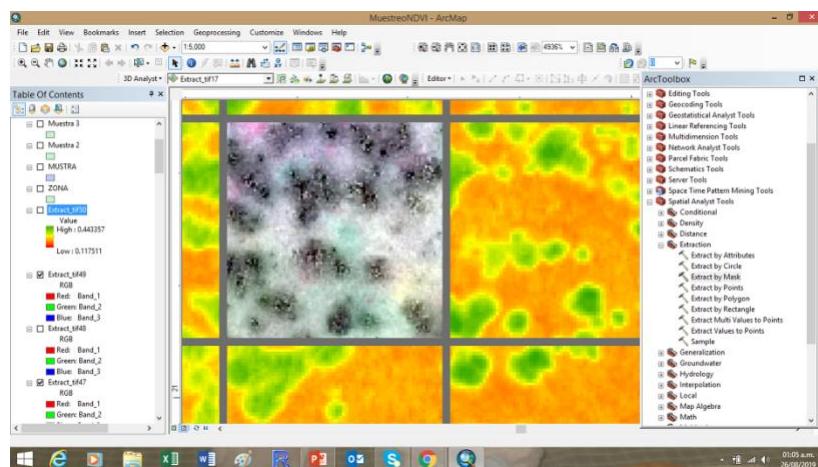
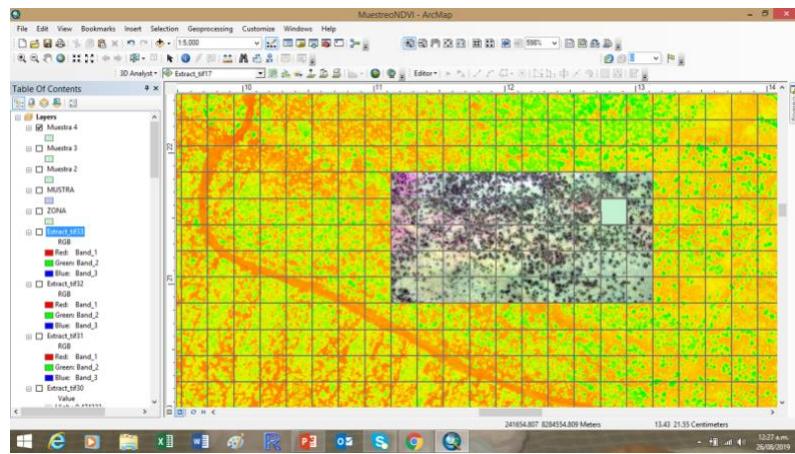
#### Anexo 1: Proceso de generación ortofotografías (PIX 4D y Agisoft)



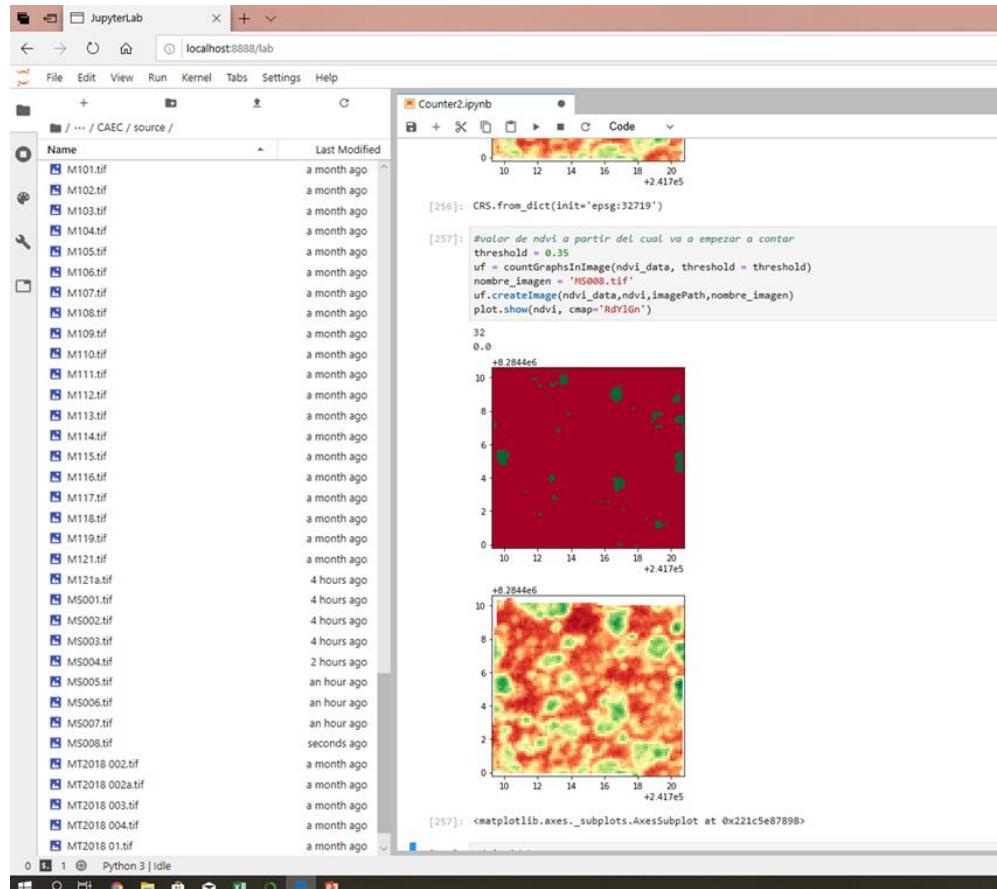


## Anexo 2: Algoritmo para contabilizar especie segmentada

### a) Preparación de las imágenes NDVI y RGB para contabilizar el número de especies segmentadas (tolá y DIMU)



**b) Algoritmo, elaborado en Payton. Identifica especies segmentadas a partir de imágenes NDVI**



```
def countGraphsInImage(ndvi_data, threshold_down = 0.25, threshold_up = 0.45):
```

```
seconds = time.time()
w = ndvi_data.shape[0]
h = ndvi_data.shape[1]

uf = UnionFind([])

}
```

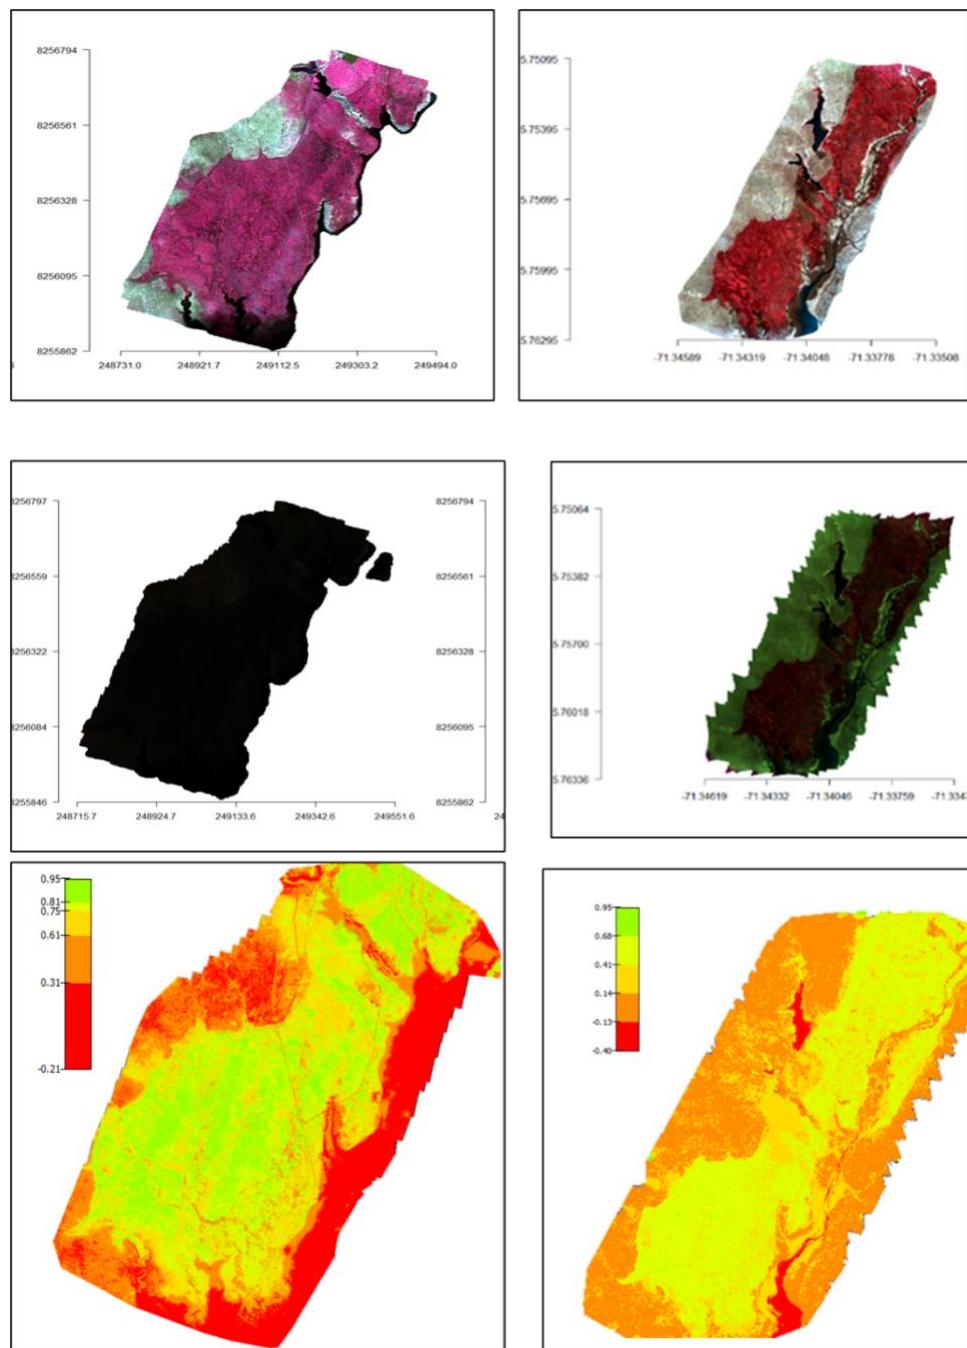
c) Reporte del algoritmo

Nº	threshold_inferior	threshold_superior	Cantidad de arbustos	Tiempo de procesamiento	Nombre de imagen
1	0.25	0.45	17	0.018332	M004B (1).tif
2	0.25	0.45	17	0.0210762	M004a (1).tif
3	0.25	0.45	41	0.0075357	M005 (1).tif
4	0.25	0.45	13	0.00266647	M012 (1).tif
5	0.25	0.45	30	0.01563716	M024 (1).tif
6	0.25	0.45	28	0.0174911	M027 (1).tif
7	0.25	0.45	27	0.00700903	M037 (1).tif
8	0.25	0.45	13	0.00268292	M011 (1).tif
9	0.25	0.45	31	0.00590205	M036 (1).tif
10	0.25	0.45	53	0.00878239	M043 (1).tif
11	0.25	0.45	23	0.00714135	M040 (1).tif
12	0.25	0.45	26	0.00713158	M022 (1).tif
13	0.25	0.45	32	0.00932956	M007 (1).tif
14	0.25	0.45	22	0.0057714	M041 (1).tif
15	0.25	0.45	24	0.01029491	M052 (1).tif
17	0.25	0.45	53	0.00873733	M044 (1).tif
18	0.25	0.45	24	0.01807785	M023 (1).tif
19	0.25	0.45	24	0.01444745	M029 (1).tif
20	0.25	0.45	15	0.00692487	M042 (1).tif
21	0.25	0.45	29	0.00803876	M031 (1).tif
22	0.25	0.45	21	0.00667191	M017 (1).tif
23	0.25	0.45	32	0.00800014	M049 (1).tif
24	0.25	0.45	35	0.01068497	M014 (1).tif
25	0.25	0.45	18	0.00960779	M057 (1).tif
26	0.25	0.45	33	0.00641108	M035 (1).tif
27	0.25	0.45	35	0.00921082	M025 (1).tif
28	0.25	0.45	24	0.01456285	M028 (1).tif
29	0.25	0.45	51	0.00708175	M045 (1).tif

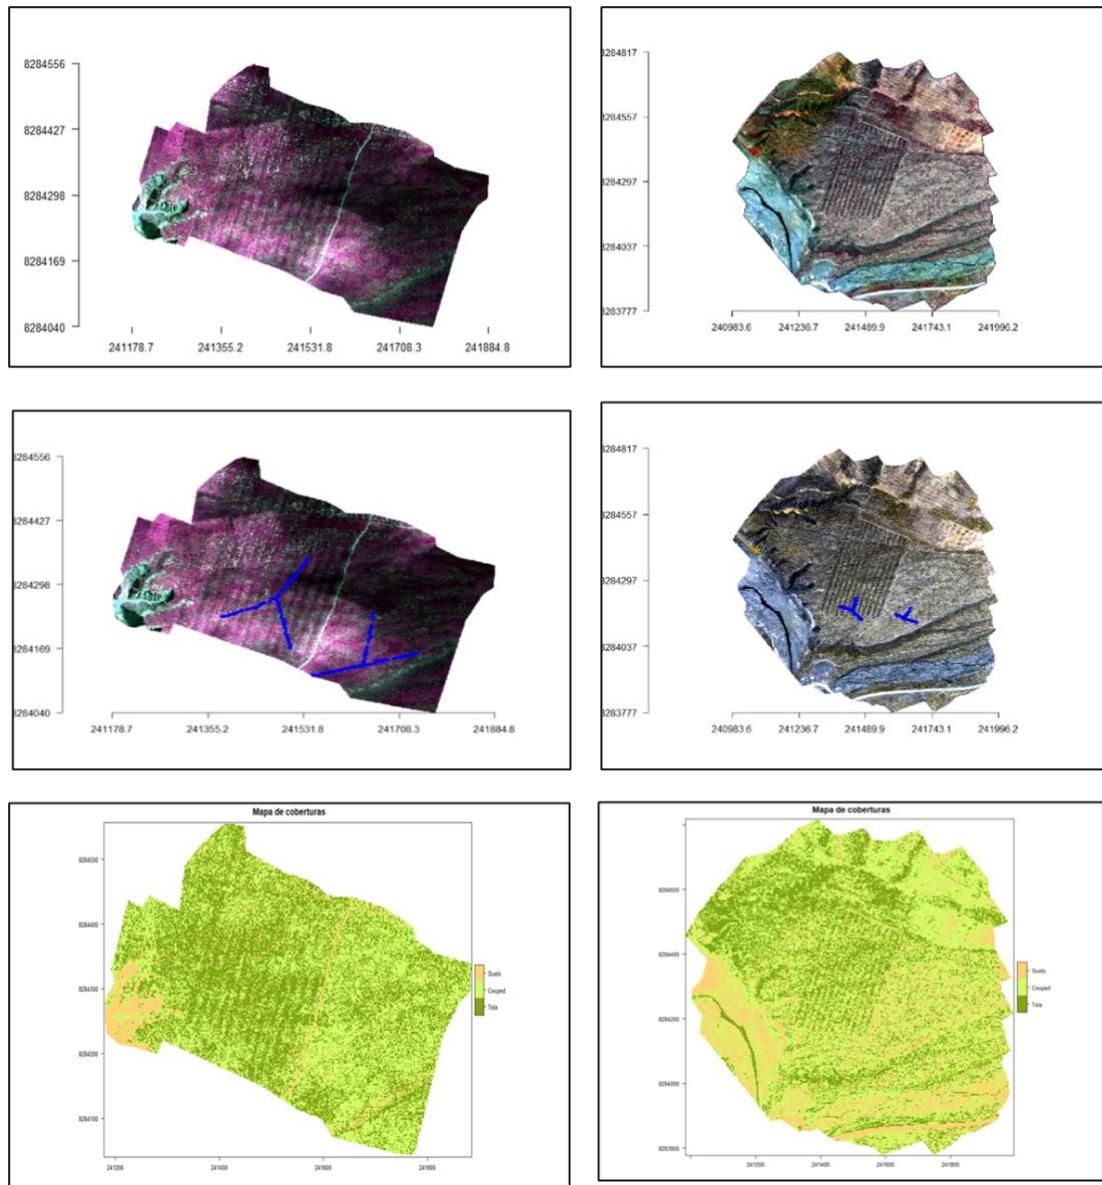
Luego de publicar un artículo con el algoritmo, se pondrá a disposición de los que quieran usar.

**Anexo 3: Algoritmo para estimar biomasa a partir de signos espectrales de ortofotografías multiespectrales**

**a. Preparación de mapas para ser usado con algoritmo y modelos\_ Comunidad vegetal bofedal**



**b. Preparación de mapas para ser usado con algoritmo y modelos\_**  
**Comunidad vegetal Tolar**



### c. Algoritmo para estimación de biomasa a partir de signos espectrales

```
library(caTools)
library(rgdal)
library(raster)
library(Rcpp)
require(ggplot2)
library(caret)
library(snow)
library(spatial)
library(gdalUtils)

# install.packages("snow")

#-----
setwd("D:/ANDRES_TESIS/Tesis Andres_ modelo Samuel/Ortomosaicos
Arcgisoft/QUENA/2017_2018")

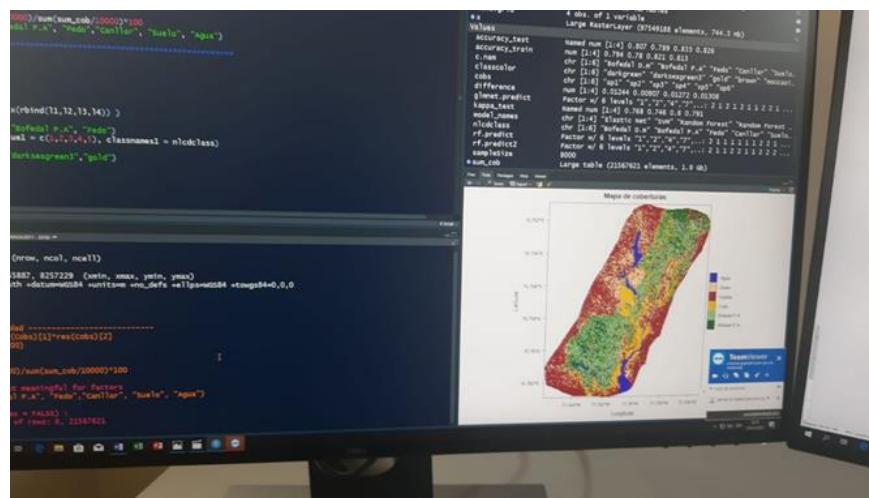
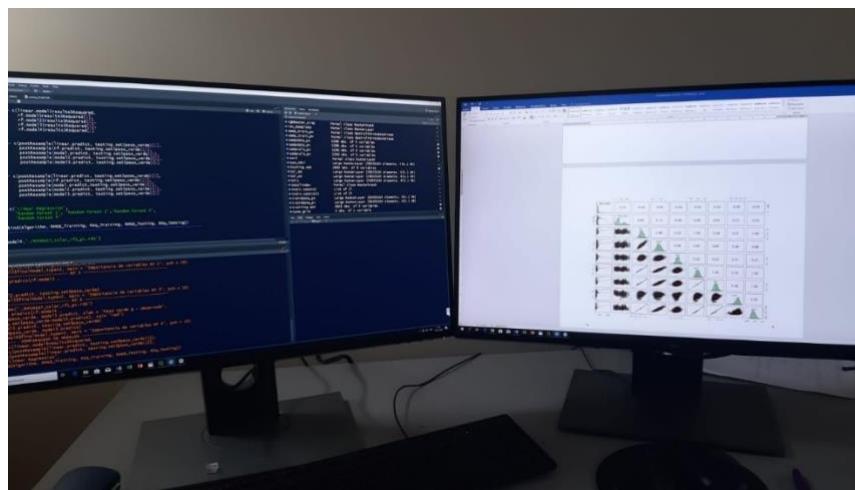
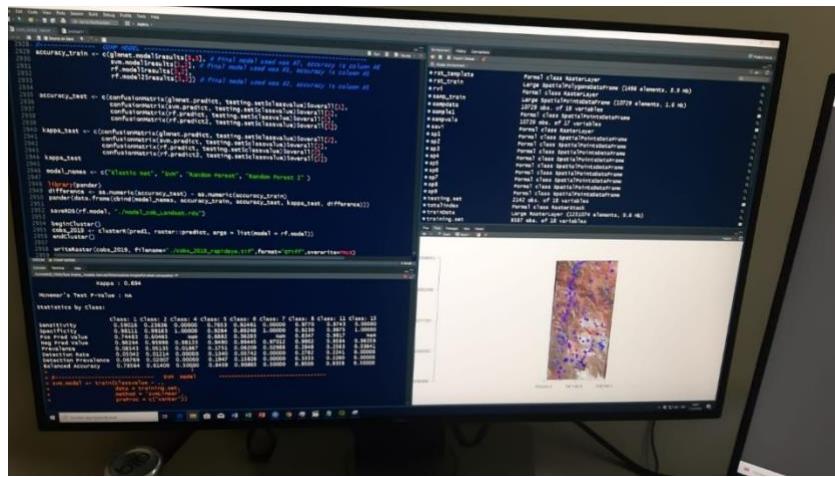
img<- stack("./2018 QUENA ME EBBE.tif")
# img[img > 10000] <- 10000

img<- stack(img[[1]], img[[2]], img[[3]], img[[4]])
names(img) <- c("GREEN", "RED", "REDEDGE", "NIR")
plot(img)

# BANDAS BLUE - 1 ---
#      GREEN - 2 ---
#      RED - 3 ---
#      RED EDGE - 4 ---
#      NIR - 5---
# RGB
plotRGB(img,r=4,g=2,b=1, stretch = "lin", axes=T)

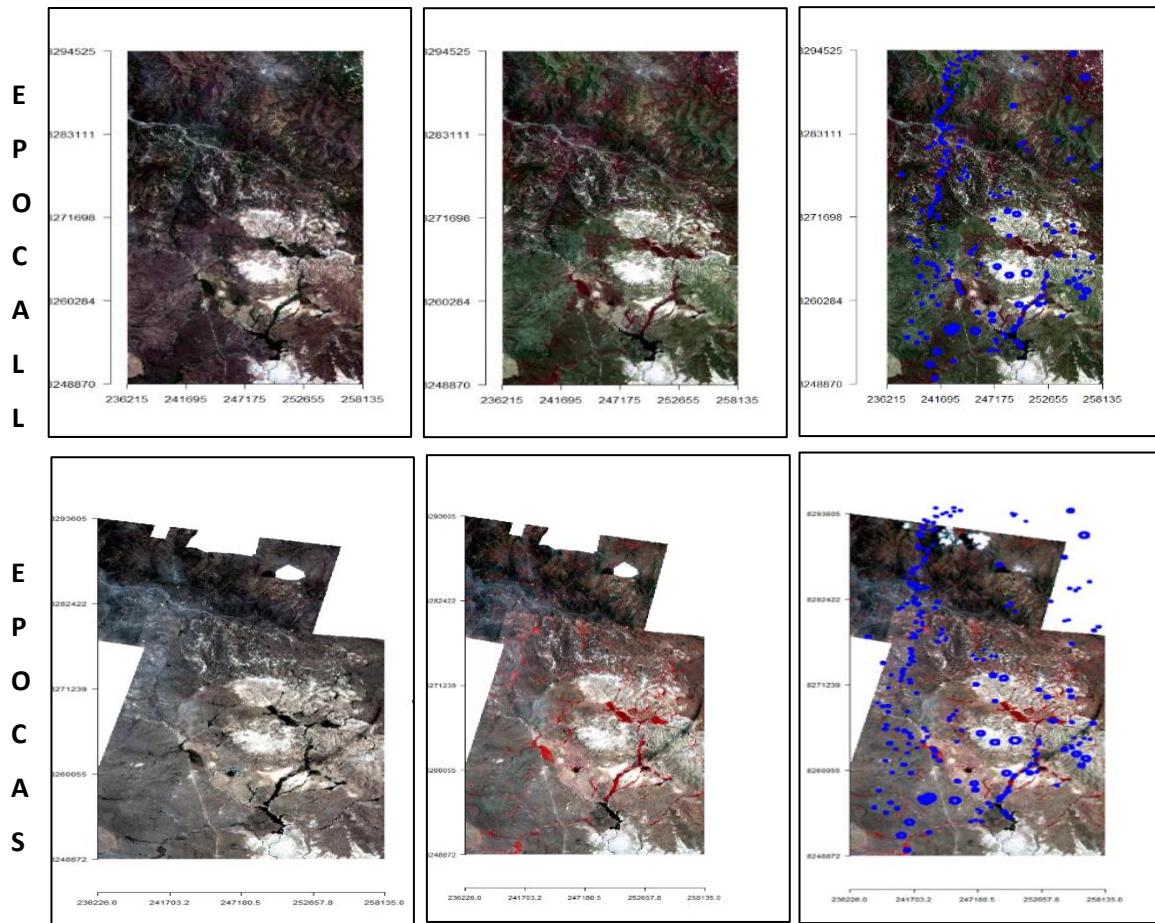
#----- RECORTAR IMAGENES -----
```

### b) Reportes



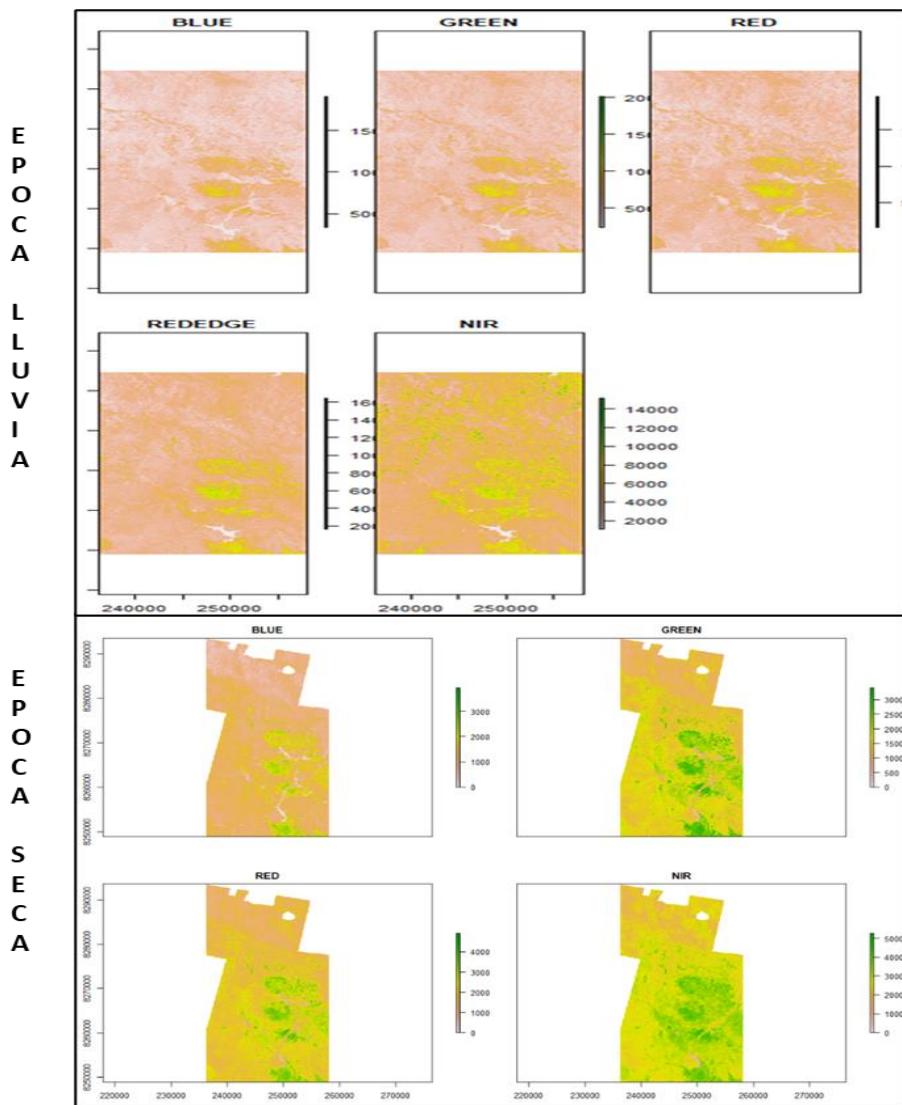
#### Anexo 4: Imágenes para escalamiento

##### a. Preparación imágenes Rapideye adquiridas de plataforma PlanetScope para escalamiento



- Los puntos azules de las imágenes, corresponden a las muestras tomadas en campo. Se utilizó para la clasificación supervisada.

**b. Imágenes Rapideye con espectros**



## 8.2 ANEXOS DEL OBJETIVO ALTURA DE VUELO DE SISTEMAS AÉREOS NO TRIPULADOS (UAS)

### Anexo 5: Comunidad vegetal Bofedal \_ Evaluación de rangos NDVI para identificación de los cojines de DIMU época seca (2017)

Fuente	DF	Suma de cuadrados	Cuadrado de la media	F-Valor	Pr > F	
<b>Modelo</b>	5	9806.35335	1961.27067	707.36	<.0001	
<b>Error</b>	690	1913.1409	2.77267			
<b>Total corregido</b>	695	11719.49425				
R-cuadrado	Coef Var	Raíz MSE	y Media			
0.836756	31.69947	1.665133	5.252874			
<b>Medias de cuadrados mínimos para el efecto BOFEDAL</b>						
t para H0: MediaLS(i)=MediaLS(j) / Pr >  t						
Variable dependiente: y						
i/j	1	2	3	4	5	6
1		5.581228	10.10703	34.43455	38.52969	44.03631
		<.0001	<.0001	<.0001	<.0001	<.0001
2	-5.58123		4.459984	27.75521	32.73653	38.21485
	<.0001		<.0001	<.0001	<.0001	<.0001
3	-10.107	-4.45998		22.85027	28.49434	34.01485
	<.0001	<.0001		<.0001	<.0001	<.0001
4	-34.4346	-27.7552	-22.8503		10.05216	16.4267
	<.0001	<.0001	<.0001		<.0001	<.0001
5	-38.5297	-32.7365	-28.4943	-10.0522		5.520513
	<.0001	<.0001	<.0001	<.0001		<.0001
6	-44.0363	-38.2148	-34.0149	-16.4267	-5.52051	
	<.0001	<.0001	<.0001	<.0001	<.0001	

### Anexo 6: Comunidad vegetal BOFEDAL \_ Evaluación de altura de vuelo con imágenes NDVI para identificación de los cojines de DIMU época seca (2017)

Fuente	DF	Suma de cuadrados	Cuadrado de la media	F-Valor	Pr > F
<b>Modelo</b>	4	7018.092	1754.523	668.82	<.0001
<b>Error</b>	495	1298.54	2.623313		
<b>Total corregido</b>	499	8316.632			
R-cuadrado	Coef Var	Raíz MSE	y Media		
0.843862	25.48245	1.619665	6.356		
<b>Medias de cuadrados mínimos para el efecto BOFEDAL</b>					
t para H0: MediaLS(i)=MediaLS(j) / Pr >  t					
Variable dependiente: y					
i/j	1	2	3	4	5
1		-39.9031	-30.604	-17.5504	-45.4476
		<.0001	<.0001	<.0001	<.0001
2	39.90305		9.29907	22.3527	-5.54452
	<.0001		<.0001	<.0001	<.0001
3	30.60398	-9.29907		13.05362	-14.8436
	<.0001	<.0001		<.0001	<.0001
4	17.55036	-22.3527	-13.0536		-27.8972
	<.0001	<.0001	<.0001		<.0001
5	45.44757	5.544516	14.84359	27.89721	
	<.0001	<.0001	<.0001	<.0001	

**Anexo 7: Comunidad vegetal Bofedal\_ evaluación de rangos NDVI para identificación de los cojines de DIMU época lluvia (2017)**

Fuente	DF	Suma de cuadrados	Cuadrado de la media	F-Valor	Pr > F
<b>Modelo</b>	5	9897.33333	1979.46667	984.76	<.0001
<b>Error</b>	594	1194	2.0101		
<b>Total corregido</b>	599	11091.33333			
<b>R-cuadrado</b>	<b>Coef Var</b>	<b>Raíz MSE</b>	<b>y Media</b>		
0.892348	31.98001	1.41778	4.433333		
<b>Medias de cuadrados mínimos para el efecto BOFEDAL</b>					
<b>t para H0: MediaLS(i)=MediaLS(j) / Pr &gt;  t </b>					
<b>Variable dependiente: y</b>					
i/j	1	2	3	4	5
1	13.66553	21.99453	46.38302	51.22082	52.76692
	<.0001	<.0001	<.0001	<.0001	<.0001
2	-13.6655	8.328994	32.71748	37.55528	39.10138
	<.0001		<.0001	<.0001	<.0001
3	-21.9945	-8.32899	24.38849	29.22629	30.77239
	<.0001	<.0001		<.0001	<.0001
4	-46.383	-32.7175	-24.3885	4.837799	6.383899
	<.0001	<.0001	<.0001		<.0001
5	-51.2208	-37.5553	-29.2263	-4.8378	1.546101
	<.0001	<.0001	<.0001	<.0001	0.1226
6	-52.7669	-39.1014	-30.7724	-6.3839	-1.5461
	<.0001	<.0001	<.0001	<.0001	0.1226

**Anexo 8: Comunidad vegetal Bofedal \_ Evaluación de altura de vuelo con imágenes RGB identificación de los cojines de DIMU época de lluvia**

Fuente	DF	Suma de cuadrados	Cuadrado de la media	F-Valor	Pr > F
<b>Modelo</b>	4	416.754284	104.188571	21.37	<.0001
<b>Error</b>	479	2335.758113	4.876322		
<b>Total corregido</b>	483	2752.512397			
<b>R-cuadrado</b>	<b>Coef Var</b>	<b>Raíz MSE</b>	<b>y Media</b>		
0.151409	24.02851	2.20824	9.190083		
<b>Medias de cuadrados mínimos para el efecto BOFEDAL</b>					
<b>t para H0: MediaLS(i)=MediaLS(j) / Pr &gt;  t </b>					
<b>Variable dependiente: y</b>					
i/j	1	2	3	4	5
1	-2.96376	1.162491	2.193054	-5.73772	
	0.0032	0.2456	0.0288	<.0001	
2	2.96376	4.17615	5.173631	-2.81787	
	0.0032	<.0001	<.0001	0.005	
3	-1.16249	-4.17615	1.059437	-6.97976	
	0.2456	<.0001	0.2899	<.0001	
4	-2.19305	-5.17363	-1.05944	-7.93217	
	0.0288	<.0001	0.2899	<.0001	
5	5.737716	2.817874	6.979756	7.932175	
	<.0001	0.005	<.0001	<.0001	

**Anexo 9: Comunidad vegetal Bofedal \_ Evaluación de altura de vuelo con imágenes RGB identificación de los cojines de DIMU época seca**

ALTURA DE VUELO RGB EPOCA SECA					
Fuente	DF	Suma de cuadrados	Cuadrado de la media	F-Valor	Pr > F
Modelo	4	795.969184	198.992296	42.56	<.0001
Error	429	2005.671369	4.675225		
Total corregido	433	2801.640553			
R-cuadrado	Coef Var	Raíz MSE	y Media		
0.284108	18.34975	2.162227	11.78341		

Medias de cuadrados mínimos para el efecto BOFEDAL					
t para H0: MediaLS(i)=MediaLS(j) / Pr >  t					
Variable dependiente: y					
i/j	1	2	3	4	5
1		10.12421	10.19728	6.533549	11.62812
		<.0001	<.0001	<.0001	<.0001
2	-10.1242		0.104472	-3.7874	1.24913
	<.0001		0.9168	0.0002	0.2123
3	-10.1973	-0.10447		-3.88114	1.137243
	<.0001	0.9168		0.0001	0.2561
4	-6.53355	3.787401	3.881145		5.170558
	<.0001	0.0002	0.0001		<.0001
5	-11.6281	-1.24913	-1.13724	-5.17056	
	<.0001	0.2123	0.2561	<.0001	

**Anexo 10: Comunidad vegetal Tolar \_ Evaluación de altura de vuelo con imágenes RGB para identificación del arbusto Tola época lluvia (2017)**

Fuente	DF	Suma de cuadrados	Cuadrado de la media	F-Valor	Pr > F
Modelo	4	7115.804	1778.951	20.47	<.0001
Error	466	40496.0856	86.90147		
Total corregido	470	47611.8896			
R-cuadrado	Coef Var	Raíz MSE	y Media		
0.149454	29.84034	9.322096	31.23992		

Medias de cuadrados mínimos para el efecto BOFEDAL					
t para H0: MediaLS(i)=MediaLS(j) / Pr >  t					
Variable dependiente: y					
i/j	1	2	3	4	5
1		3.255389	1.207011	-4.30106	2.831557
		0.0012	0.228	<.0001	0.0048
2	-3.25539		-2.10462	-7.9873	-0.42409
	0.0012		0.0359	<.0001	0.6717
3	-1.20701	2.104623		-5.73649	1.672671
	0.228	0.0359		<.0001	0.0951
4	4.301065	7.987297	5.736489		7.502157
	<.0001	<.0001	<.0001		<.0001
5	-2.83156	0.42409	-1.67267	-7.50216	
	0.0048	0.6717	0.0951	<.0001	

**Anexo 11: Comunidad vegetal Tolar – Evaluación de altura de vuelo con imágenes RGB para identificación del arbusto Tola época seca (2017)**

Fuente	DF	Suma de cuadrados	Cuadrado de la media	F-Valor	Pr > F
<b>Modelo</b>	4	12069.60031	3017.40008	25.56	<.0001
<b>Error</b>	477	56308.48475	118.04714		
<b>Total corregido</b>	481	68378.08506			
<b>R-cuadrado</b>	<b>Coef Var</b>	<b>Raíz MSE</b>	<b>y Media</b>		
0.176513	34.99904	10.86495	31.04357		

Medias de cuadrados mínimos para el efecto TOLAR					
t para H0: MediaLS(i)=MediaLS(j) / Pr >  t					
Variable dependiente: y					
i/j	1	2	3	4	5
1		7.148998	7.771721	1.482859	6.420546
		<.0001	<.0001	0.1388	<.0001
2	-7.149		0.77834	-5.71023	-0.69778
	<.0001		0.4368	<.0001	0.4857
3	-7.77172	-0.77834		-6.36707	-1.4576
	<.0001	0.4368		<.0001	0.1456
4	-1.48286	5.710234	6.367066		4.98325
	0.1388	<.0001	<.0001		<.0001
5	-6.42055	0.697776	1.4576	-4.98325	
	<.0001	0.4857	0.1456	<.0001	

**Anexo 12: Comunidad vegetal Tolar – Evaluación de rangos NDVI para identificación del arbusto Tola época lluvia (2017)**

Fuente	DF	Suma de cuadrados	Cuadrado de la media	F-Valor	Pr > F
<b>Modelo</b>	5	61205.2945	12241.0589	206.72	<.0001
<b>Error</b>	569	33693.31419	59.21496		
<b>Total corregido</b>	574	94898.6087			
<b>R-cuadrado</b>	<b>Coef Var</b>	<b>Raíz MSE</b>	<b>y Media</b>		
0.644955	40.9884	7.695126	18.77391		

Medias de cuadrados mínimos para el efecto TOLA						
t para H0: MediaLS(i)=MediaLS(j) / Pr >  t						
Variable dependiente: y						
i/j	1	2	3	4	5	6
1	-1.19146	2.027473	10.45323	17.95762	23.1914	
	0.234	0.0431	<.0001	<.0001	<.0001	
2	1.191459		3.243725	11.73438	19.25729	24.52035
	0.234		0.0012	<.0001	<.0001	<.0001
3	-2.02747	-3.24372		8.490656	16.10008	21.38185
	0.0431	0.0012		<.0001	<.0001	<.0001
4	-10.4532	-11.7344	-8.49066		7.835882	13.16664
	<.0001	<.0001	<.0001		<.0001	<.0001
5	-17.9576	-19.2573	-16.1001	-7.83588		5.242606
	<.0001	<.0001	<.0001	<.0001		<.0001
6	-23.1914	-24.5203	-21.3819	-13.1666	-5.24261	
	<.0001	<.0001	<.0001	<.0001	<.0001	

**Anexo 13: Comunidad vegetal Tolar \_ Evaluación de rangos NDVI para identificación del arbusto Tola época seca (2017)**

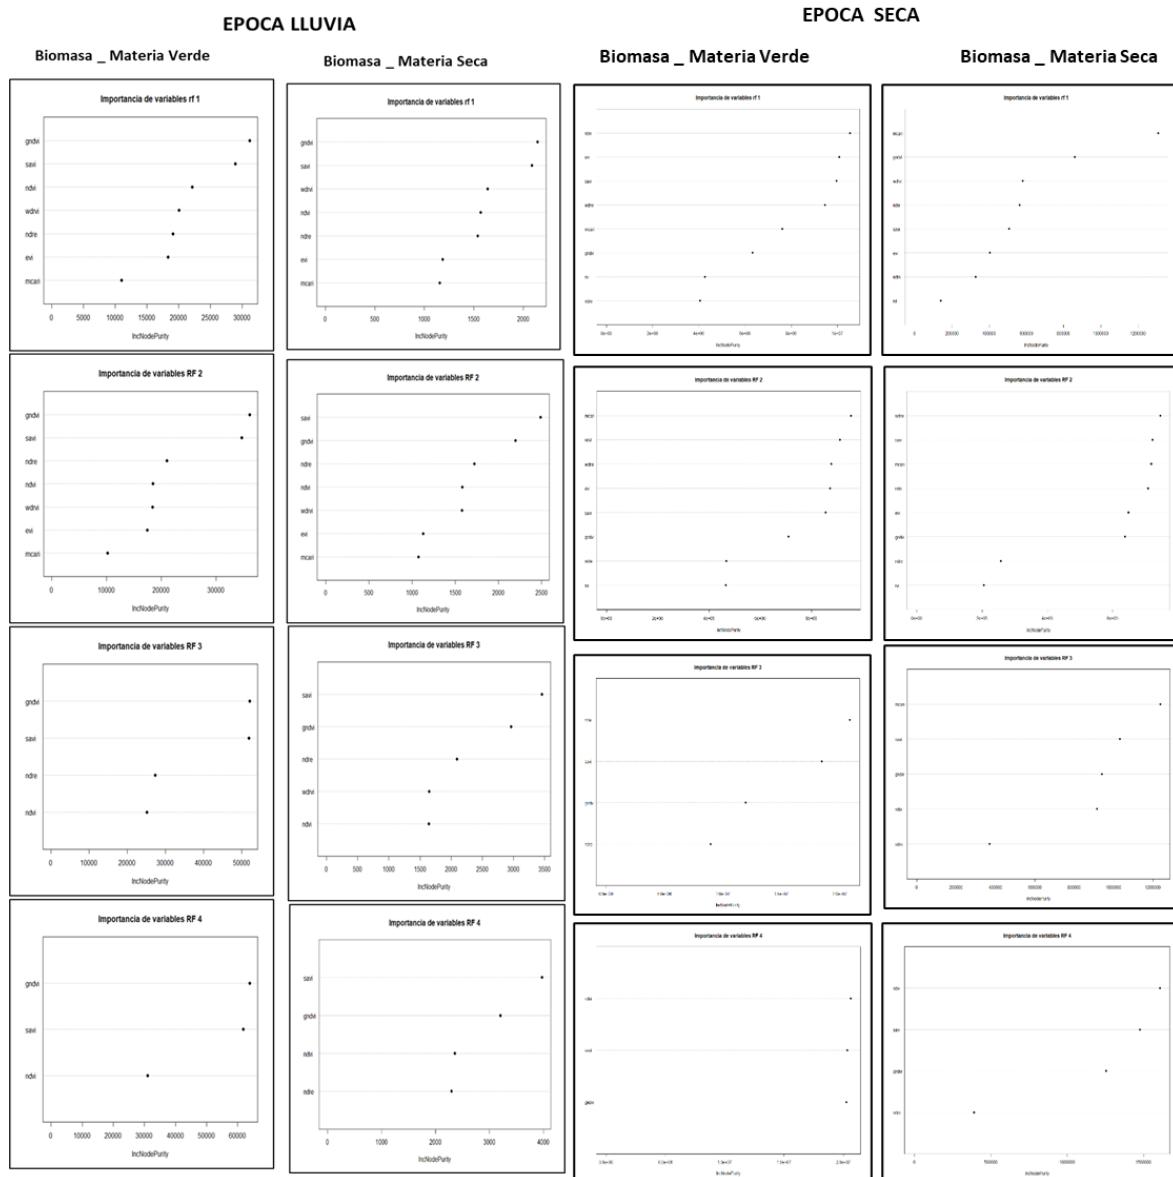
Fuente	DF	Suma de cuadrados	Cuadrado de la media	F-Valor	Pr > F
<b>Modelo</b>	5	55184.19133	11036.83827	187.26	<.0001
<b>Error</b>	575	33889.84998	58.93887		
<b>Total corregido</b>	580	89074.04131			
<b>R-cuadrado</b>	<b>Coef Var</b>	<b>Raíz MSE</b>	<b>y Media</b>		
0.619532	53.11304	7.677165	14.45439		
<b>Medias de cuadrados mínimos para el efecto TOLA</b>					
<b>t para H0: MediaLS(i)=MediaLS(j) / Pr &gt;  t </b>					
<b>Variable dependiente: y</b>					
i/j	1	2	3	4	5
1		6.117849	7.516287	15.04775	22.44958
		<.0001	<.0001	<.0001	<.0001
2	-6.11785		1.409209	8.998677	16.61288
	<.0001		0.1593	<.0001	<.0001
3	-7.51629	-1.40921		7.589468	15.24126
	<.0001	0.1593		<.0001	<.0001
4	-15.0477	-8.99868	-7.58947		7.854214
	<.0001	<.0001	<.0001		<.0001
5	-22.4496	-16.6129	-15.2413	-7.85421	
	<.0001	<.0001	<.0001	<.0001	
6	-24.2004	-18.3122	-16.9249	-9.45376	-1.47101
	<.0001	<.0001	<.0001	<.0001	0.1418

**Anexo 14: Comunidad vegetal Tolar \_ Evaluación de altura de vuelo con imágenes NDVI para identificación del arbusto Tola**

Fuente	DF	Suma de cuadrados	Cuadrado de la media	F-Valor	Pr > F
<b>Modelo</b>	4	48094.9101	12023.72752	273.38	<.0001
<b>Error</b>	468	20583.80449	43.98249		
<b>Total corregido</b>	472	68678.71459			
<b>R-cuadrado</b>	<b>Coef Var</b>	<b>Raíz MSE</b>	<b>Media</b>		
0.700288	35.10017	6.631929	18.89429		
<b>Medias de cuadrados mínimos para el efecto TOLA</b>					
<b>t para H0: MediaLS(i)=MediaLS(j) / Pr &gt;  t </b>					
<b>Variable dependiente: y</b>					
i/j	1	2	3	4	5
1		-25.5712	-23.7091	-10.5374	-27.2742
		<.0001	<.0001	<.0001	<.0001
2	25.57118		2.374796	14.5912	-1.34507
	<.0001		0.018	<.0001	0.1793
3	23.70906	-2.3748		12.53801	-3.7809
	<.0001	0.018		<.0001	0.0002
4	10.53736	-14.5912	-12.538		-16.1083
	<.0001	<.0001	<.0001		<.0001
5	27.2742	1.345072	3.780896	16.10825	
	<.0001	0.1793	0.0002	<.0001	

### 8.3 ANEXOS DEL OBJETIVO ESTIMACIÓN DE BIOMASA A PARTIR DE SIGNOS ESPECTRALES EN ORTOFOTOGRAFÍAS MULTIESPECTRALES

#### Anexo 15: Priorización de variables por importancia \_ índice decreciente de Gini Comunidad vegetal Bofedal



(Disminución de la media de Gini)

**Anexo 16: Estimación de rendimiento de biomasa Kg/ha. datos de campo Comunidad vegetal Bofedal**

	CLASE	AREA BOFEDAL	EPOCA LLUVIA		EPOCA SECA	
			BIOMSA TOTAL	BIOMASA (Kg/ha)	BIOMASA TOTAL	BIOMASA (Kg/ha)
<b>MATERIA VERDE</b>	BOFEDAL DISTICHIA	7.27	32542.40	4473.49	12535.11	1723.16
	BOFEDAL MULTIFLOR	8.45	38170.73	4516.93	14666.77	1735.59
	FESTUCA (Chilliwa)	4.31	25548.31	5922.74	15405.19	3571.31
<b>MATERIA SECA</b>	BOFEDAL DISTICHIA	7.27	6822.33	937.84	5783.61	795.05
	BOFEDAL MULTIFLOR	8.45	9213.24	1090.25	6891.37	815.49
	FESTUCA (Chilliwa)	4.31	7876.84	1826.05	7544.49	1749.00

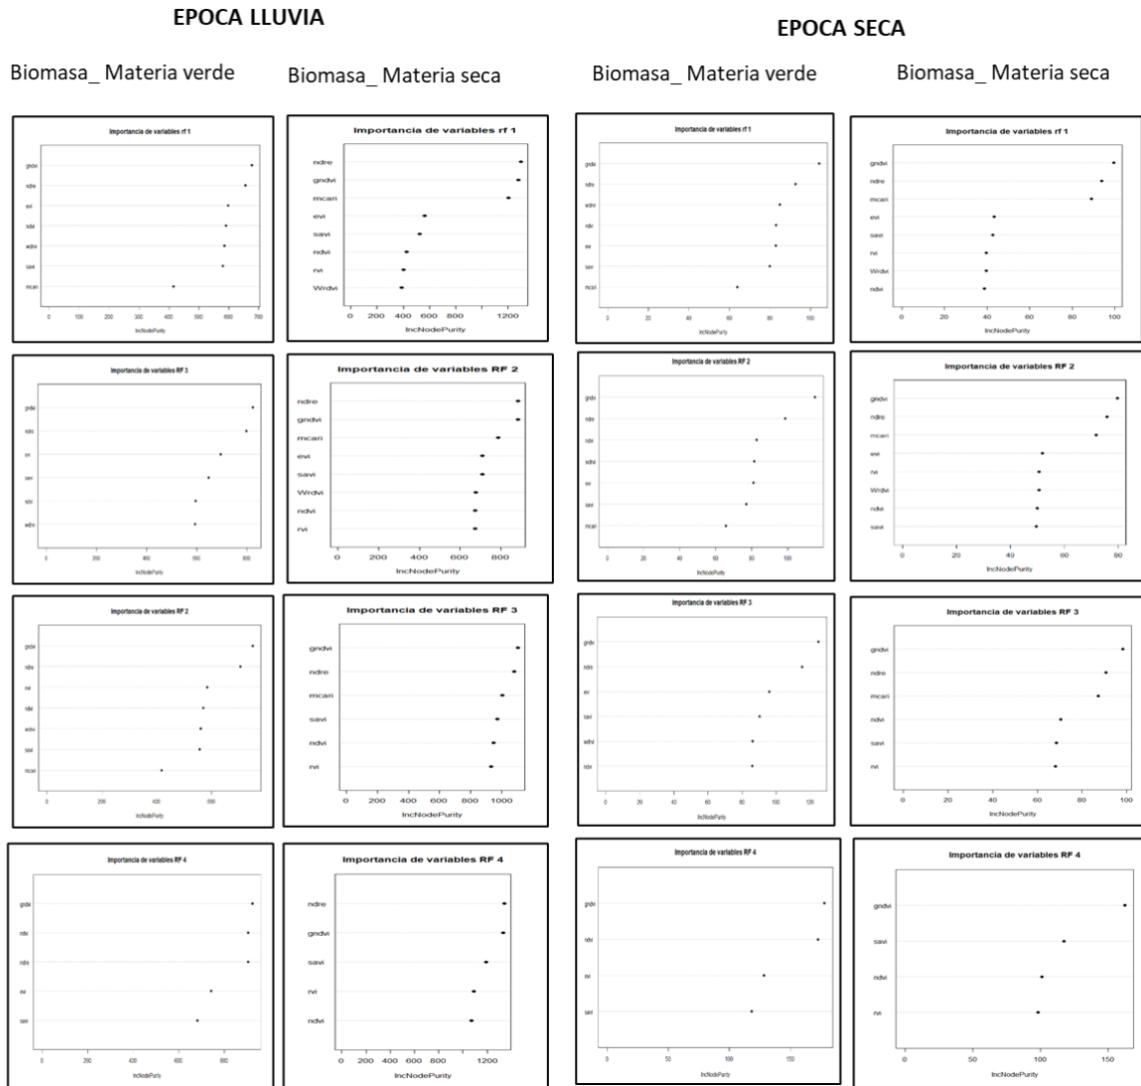
**Anexo 17: Comparación de rendimiento de biomasa Kg/ha. Entre modelo RF y datos de campo comunidad vegetal Bofedal**

	CLASE	AREA BOFEDAL	PRODUCCIÓN DE BIOMASA			
			EPOCA LLUVIA		EPOCA SECA	
			CAMPO (Kg/ha)	RANDOM FOREST (Kg/ha)	CAMPO (Kg/ha)	RANDOM FOREST (Kg/ha)
<b>MATERIA VERDE</b>	BOFEDAL DISTICHIA	7.27	4473.49	8658.98	1723.16	2596.03
	BOFEDAL MULTIFLORA	8.45	4516.93	9145.85	1735.59	2457.60
	FESTUCA (Chilliwa)	4.31	5922.74	11357.47	3571.31	7963.47
<b>MATERIA SECA</b>	BOFEDAL DISTICHIA	7.27	937.84	2564.27	795.05	961.23
	BOFEDAL MULTIFLORA	8.45	1090.25	2566.80	815.49	867.13
	FESTUCA (Chilliwa)	4.31	1826.05	3894.27	1749.00	3583.56

**Anexo 18: Diferencias en la estimación de biomasa entre RF y datos de campo comunidad vegetal Bofedal**

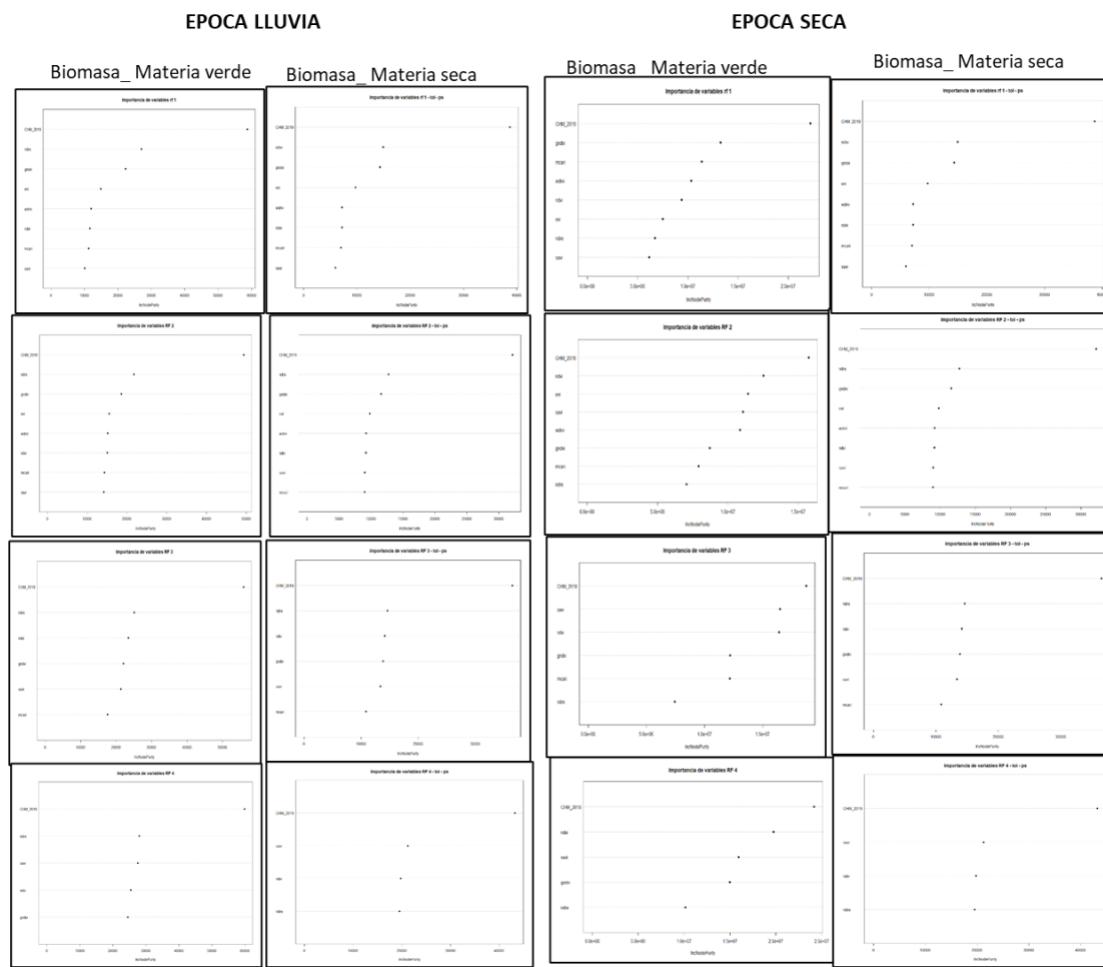
	COBERTURA	AREA BOFEDAL	PRODUCCIÓN DE BIOMASA			
			EPOCA LLUVIA		EPOCA SECA	
			DIFERENCIA (Kg/ha)	%	DIFERENCIA (Kg/ha)	%
<b>MATERIA VERDE</b>	BOFEDAL DISTICHIA	7.27	4185.49	93.56	872.87	50.66
	BOFEDAL MULTIFLORA	8.45	4628.93	102.48	722.01	41.60
	FESTUCA (Chilliwa)	4.31	5434.74	91.76	4392.16	122.98
<b>MATERIA SECA</b>	BOFEDAL DISTICHIA	7.27	1626.43	173.42	166.18	20.90
	BOFEDAL MULTIFLORA	8.45	1476.55	135.43	51.64	6.33
	FESTUCA (Chilliwa)	4.31	2068.22	113.26	1834.56	104.89

## Anexo 19: Priorización de variables por importancia \_ índice decreciente de Gini Césped de puna



(Disminución de la media de Gini)

## Anexo 20: Priorización de variables por importancia \_ índice decreciente de Gini Tola



(Disminución de la media de Gini)

## Anexo 21: Clasificación de coberturas \_ ortofotografías UAS. Comunidad vegetal Tolar

CLASE -COBERTURA	ÉPOCA LLUVIA		ÉPOCA SECA	
	AREA	%	AREA	%
TOLA	9.19	44.61	9.956	49.78
CESPED	9.85	47.82	5.572	27.86
SUELO	1.56	7.57	4.472	22.36
TOTAL	20.6	100	20	100

**Anexo 22: Estimación biomasa comunidad vegetal Tolar\_ modelo Randon Forest  
Comunidad Vegetal Tolar**

	CLASE	EPOCA LLUVIA			EPOCA SECA		
		AREA (ha)	BIOMASA (Kg/ha)	BIOMASA TOTAL	AREA (ha)	BIOMASA (Kg/ha)	BIOMASA TOTAL
<b>MATERIA VERDE</b>	CESPED	9.85	3282.50	32332.65	5.57	2630.11	14654.96
	TOLA	9.19	20914.42	192203.56	9.96	13535.20	134756.43
	SUELO DESNUDO	1.56			4.47		
	COMUNIDAD VEGETAL	20.60	10889.82	224536.21	20.00	7470.57	149411.39
<b>MATERIA SECA</b>	CESPED	9.85	864.86	8518.86	5.57	1245.73	6941.19
	TOLA	9.19	13723.63	126120.18	9.96	12538.68	124835.08
	SUELO DESNUDO	1.56	0.00	0.00	4.47	0.00	0.00
	COMUNIDAD VEGETAL	20.60	6535.88	134639.04	20.00	6588.81	131776.27

**Anexo 23: Estimación de biomasa con datos de campo Comunidad vegetal Tolar**

	CLASE	EPOCA LLUVIA			EPOCA SECA		
		AREA (ha)	BIOMASA (Kg/ha)	BIOMSA TOTAL	AREA (ha)	BIOMASA (Kg/ha)	BIOMASA TOTAL
<b>MATERIA VERDE</b>	CESPED	9.85	1326.00	13061.10	5.57	975.00	5432.70
	TOLA	9.19	15875.00	145891.25	9.96	12850.00	127934.60
	SUELO DESNUDO	1.56			4.47		
	COMUNIDAD VEGETAL	20.60	7716.13	158952.35	20.00	6668.37	133367.30
<b>MATERIA SECA</b>	CESPED	9.85	450.84	4440.77	5.57	351.00	1955.77
	TOLA	9.19	13406.25	123203.44	9.96	11877.25	118249.90
	SUELO DESNUDO	1.56		0.00	4.47		0.00
	COMUNIDAD VEGETAL	20.60	6196.32	127644.21	20.00	6010.28	120205.67

**Anexo 24: Comparación de producción biomasa predicho Randon Forest &  
observación en campo Comunidad vegetal Tolar**

	CLASE	EPOCA LLUVIA			EPOCA SECA		
		AREA (ha)	CAMPO (Kg/ha)	FOREST (Kg/ha)	AREA (ha)	CAMPO (Kg/ha)	FOREST (Kg/ha)
<b>MATERIA VERDE</b>	CESPED	9.85	1326.00	3282.50	5.57	975.00	2630.11
	TOLA	9.19	15875.00	20914.42	9.96	12850.00	13535.20
	SUELO DESNUDO	1.56	0.00	0.00	4.47	0.00	0.00
	COMUNIDAD VEEGETAL	20.60	7716.13	10889.82	20.00	6668.37	7470.57
<b>MATERIA SECA</b>	CESPED	9.85	450.84	864.86	5.57	351.00	1245.73
	TOLA	9.19	13406.25	13723.63	9.96	11877.25	12538.68
	SUELO DESNUDO	1.56	0.00	0.00	4.47	0.00	0.00
	COMUNIDAD VEGETAL	20.60	6196.32	6535.88	20.00	6010.28	6588.81

**Anexo 25: Diferencias de la producción de biomasa Randon Forest & observación en campo comunidad vegetal Tolar**

	CLASE	EPOCA LLUVIA			EPOCA SECA		
		AREA (ha)	DIFERENCI A (Kg/ha)	%	AREA (ha)	DIFERENCI A (Kg/ha)	%
MATERIA VERDE	CESPED	9.85	1956.50	147.55	5.57	1655.11	169.75
	TOLA	9.19	5039.42	31.74	9.96	685.20	5.33
	SUELO DESNUDO	1.56	0.00		4.47	0.00	
	COMUNIDAD VEGETAL	20.60	3173.68	41.13	20.00	802.20	12.03
MATERIA SECA	CESPED	9.85	414.02	91.83	5.57	894.73	254.91
	TOLA	9.19	317.38	2.37	9.96	661.43	5.57
	SUELO DESNUDO	1.56	0.00		4.47	0.00	
	COMUNIDAD VEGETAL	20.60	339.55	5.48	20.00	578.53	9.63

## 8.4 ANEXOS ESCALAMIENTO DE ORTOMOSAICOS OBTENIDOS CON PLATAFORMA UAS HACIA UNA IMAGEN SATELITAL RAPIDEYE

**Anexo 26: Valores NDVI en imagen Rapideye**

ÍNDICES DE VEGETACIÓN	MODELO CÉSPED				MODELO TOLA				MODELO BOFEDAL			
	ÉPOCA LLUVIA		ÉPOCA SECA		ÉPOCA LLUVIA		ÉPOCA SECA		ÉPOCA LLUVIA		ÉPOCA SECA	
	MÍNIMO	MÁXIMO	MÍNIMO	MÁXIMO	MÍNIMO	MÁXIMO	MÍNIMO	MÁXIMO	MÍNIMO	MÁXIMO	MÍNIMO	MÁXIMO
NDVI	-0.1	0.4	0	0.3	-0.1	0.4	-0.1	0.3	-0.2	0.4	0.0	0.5
GNDVI	-0.2	0.2	-0.1	0.4	-0.2	0.2	0.0	0.4	-0.2	0.2	-0.1	0.6
NDRE	-0.1	0.2	-0.7	0.5	-0.1	0.2			-0.2	0.3	0.0	0.8
SAVI	-0.1	0.6	0.0	0.4	-0.1	0.5	0.0	0.4	-2.0	0.8	0.0	1.0
EVI	0.0	0.6	0.0	0.5	0.0	0.6	0.0	0.1	-0.2	1.0		
MCARI	-1.0	1.0			-1.0	1.0			-1.0	1.0		

**Anexo 27: Clasificación de área ocupada por clase \_imagen Rapideye**

CLASE -COBERTURA	ÉPOCA LLUVIA		ÉPOCA SECA	
	ÁREA	%	ÁREA	%
BOFEDAL DE DISTICHIA				
MUSCOIDES	647.78	6.70	419.02	4.42
BOFEDAL MIXTO _ INCLUSIONES	848.49	8.78	754.91	7.97
PAJONAL HÚMEDO	646.65	6.69	209.60	2.21
PAJONAL SECO	1677.36	17.36	1878.85	19.84
CÉSPED	1210.49	12.53	804.93	8.50
TOLAR	1918.71	19.86	1884.60	19.90
KANLLAR	1437.85	14.88	1863.44	19.68
SUELO DESNUDO	706.29	7.31	1387.59	14.65
AGUA	569.08	5.89	267.59	2.83
<b>ÁREA TOTAL</b>	<b>9662.70</b>	<b>100.00</b>	<b>9470.52</b>	<b>100.00</b>